TECH REFERENCE

# Temporal Ensemble Expert Technical Reference

Mamba SSM · Liquid Neural Network · PatchTST · Ensemble Gating

AIOps PLE for Financial Recommendation

v1.0 · 2026-04-01

본 문서는 Temporal Ensemble Expert를 구성하는 세 모델 — Mamba (Selective State Space Model), Liquid Neural Network, PatchTST (Patch Time Series Transformer) — 의 수학적 구조, Ensemble Gating Mechanism, 그리고 Project Implementation Specification을 기술한다.

# Contents


1 Compound Structure of Financial Time Series ... 3
1.1 Static Features vs. Temporal Features ... 3
1.2 Three Components of Time Series ... 3
1.3 금융 거래 데이터의 네 가지 Characteristics ... 4
1.4 Window-Based vs. Event-Based Hybrid ... 4
2 Mamba: Selective State Space Model ... 4
2.1 Theoretical Background ... 4
2.2 Continuous State Space Model ... 5
2.3 ZOH Discretization ... 5
2.4 Discrete Recurrence ... 5
2.5 S6 Selective Mechanism ... 5
2.5.1 Selective Mechanism in Financial Domain ... 5
2.6 Selective Sequential Scan ... 6
2.7 Gated MLP + Causal Conv1d 아키텍처 ... 6
2.8 A Matrix Initialization and Stability ... 6
2.9 Project Implementation Specification ... 6
2.9.1 거래용 Mamba (Transaction) ... 6
2.9.2 세션용 Mamba (Session) ... 7
2.10 복잡도 분석 ... 7
3 Liquid Neural Network (LNN) ... 7
3.1 Theoretical Background ... 7
3.2 핵심 ODE ... 7
3.2.1 각 항의 물리적 의미 ... 8
3.3 Euler 이산화 ... 8
3.4 적응적 시간 상수의 금융 도메인 해석 ... 8
3.5 SingleStep 모드 설계 ... 8
3.5.1 설계 근거 ... 8
3.6 Project Implementation Specification ... 9
4 PatchTST: Patch Time Series Transformer ... 9
4.1 Theoretical Background ... 9
4.2 패치 임베딩 ... 9
4.2.1 패치 크기의 금융 도메인 해석 ... 9
4.3 Multi-Head Self-Attention ... 9
4.4 위치 인코딩 ... 10
4.5 Project Implementation Specification ... 10
4.6 복잡도 비교 ... 10
5 앙상블 게이팅 ... 10
5.1 게이트 아키텍처 ... 10
5.2 입력 분리를 통한 앙상블 다양성 ... 11
5.3 게이트 엔트로피 모니터링 ... 11

5.4 최종 출력 흐름 Summary ..... 12
6 I/O Specification 및 Implementation Notes ..... 12
6.1 전체 I/O Specification ..... 12
6.1.1 입력 ..... 12
6.1.2 중간 표현 ..... 12
6.1.3 출력 ..... 12
6.2 세 모델의 Role 비교 Summary ..... 13
6.3 시계열 분석 세대별 발전과 본 프로젝트의 위치 ..... 13
6.4 구현 시 유의사항 ..... 13
6.4.1 데이터 리키지 방지 ..... 13
6.4.2 수치 안정성 ..... 13
6.4.3 성능 최적화 ..... 13
6.4.4 References ..... 14

# Compound Structure of Financial Time Series

## Static Features vs. Temporal Features

전통적 추천 시스템에서 사용자 표현은 정적*(static)* 벡터이다. 나이, 직업, 선호 카테고리 등 시점에 무관한 Property으로 구성된다. 그러나 실제 사용자 행동은 시간 축을 따라 끊임없이 변화하며, 단일 스냅샷으로 축약하면 주기성, 트렌드, 계절성 같은 핵심 행동 신호가 소멸한다.

| **Perspective** | 정적 피처 | 시간적 피처 |
|---|---|---|
| Representation | 고정 벡터 $\boldsymbol{x} \in \mathbb{R}^d$ | 시퀀스 $\boldsymbol{X} \in \mathbb{R}^{T \times d}$ |
| Information Loss | 시간 축 평균화 → 패턴 소멸 | 순서, 간격, 추세 보존 |
| Model Requirements | MLP, Embedding 테이블 | SSM, ODE, Transformer 등 시퀀스 모델 |

Temporal Expert는 거래와 세션 데이터를 시퀀스로 유지한 채, 시간 차원에 내재된 패턴을 학습하여 64D 표현으로 압축한다.

## Three Components of Time Series

모든 시계열 $y(t)$는 근본적으로 세 가지 성분의 합으로 분해된다:

$$y(t) = T(t) + S(t) + R(t) \tag{1}$$

$T(t)$: 트렌드 (Trend) — 장기적 방향성
$S(t)$: 계절성 (Seasonality) — 반복적 주기 패턴 (요일, 월별, 연별)
$R(t)$: 잔차 (Residual) — 트렌드와 계절성으로 Description되지 않는 불규칙 변동

Temporal Expert의 세 모델은 이 분해에 대응한다:

- **Mamba**: 트렌드 (장기 의존성, 선택적 기억을 통한 방향성 포착)
- **PatchTST**: 계절성 (패치 간 어텐션으로 글로벌 주기 포착)
- **LNN**: 잔차 (적응적 시간 상수로 불규칙 변동 처리)

## 금융 거래 데이터의 네 가지 Characteristics

금융 시계열은 일반 시계열과 구별되는 고유한 Characteristics을 갖는다:

| Characteristics | Description | Processing Model |
|---|---|---|
| 스냅샷 불연속 | 월말 잔액, 분기 평가 등 이산적 관측 | Mamba 선택적 기억 |
| 일별 거래 다발 | 하루 수십 건의 결제, 이체 | PatchTST 패치 집계 |
| 불규칙 간격 | 거래일 vs 휴일, 활Motivation vs 휴면기 | LNN 적응적 $\tau$ |
| 고빈도 이벤트 | 카드 승인 실시간 스트림 | Mamba $O(L)$ 선형 처리 |

## Window-Based vs. Event-Based Hybrid

프로젝트에서는 거래 데이터를 일별 집계하여 윈도우 기반 시퀀스(180 타임스텝)로 구성한다. 이는 Mamba와 PatchTST에 입력된다. 동시에 거래 간 실제 시간 간격 정보가 LNN에 전달되어, 이벤트 기반의 시간 인식 보정을 수행한다.

| Approach | 윈도우 기반 (고정 간격) | 이벤트 기반 (불규칙 간격) |
|---|---|---|
| Time Model | $\Delta t = \text{const}$ | $\Delta t_i \neq \Delta t_j$ |
| Data Shape | $\boldsymbol{X} \in \mathbb{R}^{T \times d}$ | $\{(t_i, \boldsymbol{x}_i)\}$ 이벤트 스트림 |
| Suitable Model | Mamba, PatchTST | LNN (ODE 기반) |

# Mamba: Selective State Space Model

## Theoretical Background

> 참조 논문
>
> Gu & Dao, *"Mamba: Linear-Time Sequence Modeling with Selective State Spaces"* (NeurIPS 2023).
> 계보: HiPPO (Gu et al., NeurIPS 2020) → S4 (ICLR 2022) → Mamba (2023).

SSM(State Space Model)을 입력 의존적 선택 메커니즘(S6)으로 확장하여, RNN의 선형 시간 복잡도와 Transformer의 콘텐츠 인식 능력을 결합한 아키텍처이다.

## Continuous State Space Model

선형 시불변(LTI) 시스템의 기본 형태:

$$\frac{d\boldsymbol{x}}{dt} = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{B}u, \quad y = \boldsymbol{C}\boldsymbol{x} + \boldsymbol{D}u \tag{2}$$

$\boldsymbol{x} \in \mathbb{R}^N$: 은닉 상태, $u \in \mathbb{R}$: 입력 신호, $y \in \mathbb{R}$: 출력 신호
$\boldsymbol{A} \in \mathbb{R}^{N\times N}$: 상태 전이 행렬, $\boldsymbol{B} \in \mathbb{R}^{N\times 1}$: 입력 행렬, $\boldsymbol{C} \in \mathbb{R}^{1\times N}$: 출력 행렬

## ZOH Discretization

연속계를 이산 시간 스텝 $\Delta$로 변환한다:

$$\bar{\boldsymbol{A}} = \exp(\Delta \cdot \boldsymbol{A}), \quad \bar{\boldsymbol{B}} \approx \Delta \cdot \boldsymbol{B} \tag{3}$$

$\bar{\boldsymbol{A}}$는 "연속 시간 $\Delta$만큼 정확히 전진시킨 상태 전이"를 의미한다. 1차 근사 $\exp(\Delta\boldsymbol{A}) \approx \boldsymbol{I} + \Delta\boldsymbol{A}$가 Euler method이며, 정확한 행렬 지수는 무한 차수까지 고려한 것이다. $\boldsymbol{A}$가 대각 행렬이면 $\exp(\boldsymbol{A}t) = \mathrm{diag}(e^{a_1 t}, ..., e^{a_N t})$로 간소화되며, Mamba가 $\boldsymbol{A}$를 대각으로 제한하는 이유이다.

## Discrete Recurrence

$$\boldsymbol{h}_t = \bar{\boldsymbol{A}} \cdot \boldsymbol{h}_{t-1} + \bar{\boldsymbol{B}} \cdot \boldsymbol{x}_t, \quad \boldsymbol{y}_t = \boldsymbol{C}_t \cdot \boldsymbol{h}_t \tag{4}$$

직관적으로 "오늘의 상태 = 어제의 기억 × 감쇠율 + 오늘의 새 정보"이다.

## S6 Selective Mechanism

기존 LTI SSM에서 $\boldsymbol{A}, \boldsymbol{B}, \boldsymbol{C}$는 입력과 무관한 상수이다. Mamba의 S6는 $\Delta, \boldsymbol{B}, \boldsymbol{C}$를 입력 의존적으로 생성하여 콘텐츠 인식 처리를 구현한다.

$$\Delta = \mathrm{softplus}(\boldsymbol{W}_\Delta \cdot \boldsymbol{x} + \boldsymbol{b}_\Delta) \tag{5}$$

$$\boldsymbol{B} = \boldsymbol{W}_B \cdot \boldsymbol{x}, \quad \boldsymbol{C} = \boldsymbol{W}_C \cdot \boldsymbol{x} \tag{6}$$

$\boldsymbol{W}_\Delta \in \mathbb{R}^{D\times r}$: $\Delta$ 프로젝션 ($r = \lceil D/16 \rceil$, dt_rank)
softplus 보장: $\Delta > 0$ (시간 스텝은 양수)

입력에 따라 $\Delta$가 커지면 해당 타임스텝의 정보를 강하게 기억(인코딩)하고, $\Delta$가 작아지면 이전 상태를 유지하며 현재 입력을 무시(망각)한다.

### Selective Mechanism in Financial Domain

- 대형 거래 → 큰 $\Delta$ → 은닉 상태에 강하게 기록 (선택적 기억)
- 소액 일상 거래 → 작은 $\Delta$ → 이전 상태 유지, 배경 처리 (선택적 망각)
- 이 메커니즘은 금융 이벤트의 이질적 중요도를 자연스럽게 모델링한다

## Selective Sequential Scan

각 타임스텝마다 $\Delta_t, \boldsymbol{B}_t, \boldsymbol{C}_t$가 달라지므로:

$$\boldsymbol{h}_t = \underbrace{\exp(\Delta_t \cdot \boldsymbol{A})}_{\bar{\boldsymbol{A}}_t} \cdot \boldsymbol{h}_{t-1} + \underbrace{\Delta_t \cdot \boldsymbol{B}_t}_{\bar{\boldsymbol{B}}_t} \cdot \boldsymbol{x}_t, \quad \boldsymbol{y}_t = \boldsymbol{C}_t^\top \boldsymbol{h}_t \tag{7}$$

전체 시퀀스에 대해 $O(L)$ 선형 시간 복잡도로 처리된다.

## Gated MLP + Causal Conv1d 아키텍처

MambaBlock은 SSM을 Gated MLP와 1D 인과 컨볼루션으로 감싸는 구조이다:

1. **Input Projection**: `d_input` → `d_model`
2. **LayerNorm → in_proj**: `d_model` → `2 * d_inner` (두 경로로 분기)
3. **SSM** 경로: Causal Conv1d (kernel=4) → SiLU → SelectiveSSM (S6)
4. **Gate** 경로: SiLU 활성화
5. **Element-wise multiply** (SSM 출력 ∘ Gate 출력)
6. **out_proj**: `d_inner` → `d_model` + Residual connection

인과 Conv1d (kernel=4)는 시점 $t$에서 $t-3, t-2, t-1, t$만 참조하여 미래 정보 누출 없이 로컬 컨텍스트를 혼합한다.

## A Matrix Initialization and Stability

$\boldsymbol{A}$를 log 공간에 저장하고, forward 시 $-\exp(\mathrm{A}_{\log})$로 복원한다. 이는 모든 고유값이 항상 음수임을 보장하여 시스템의 안정성을 확보한다.

초기값은 HiPPO 스타일의 대각 $[1, 2, ..., N]$이다. 더 큰 인덱스의 상태는 더 높은 주파수의 다항식 성분에 대응하므로, 대각 원소 $-1, -2, ..., -N$이 되어 고주파 성분일수록 빠르게 감쇠한다.

## Project Implementation Specification

### 거래용 Mamba (Transaction)

| 파라미터 | 값 | **Description** |
|---|---|---|
| `d_model` | 128 | 은닉 차원 |
| `d_input` | 16 | card (8D) + deposit (8D) 거래 피처 |
| `d_inner` | 256 | $128 \times 2$ (expand=2) |
| `d_state` | 16 | SSM 상태 벡터 차원 |
| `d_conv` | 4 | 1D 인과 컨볼루션 커널 크기 |
| `dt_rank` | 8 | $\lceil 128/16 \rceil = 8$ |
| `seq_len` | 180 | 180일 거래 시퀀스 |
| 출력 | `[B, 128]` | 마지막 타임스텝 `[:, -1, :]` |

세션용 **Mamba (Session)**

| 파라미터 | 값 | **Description** |
|---|---|---|
| `d_model` | 64 | 거래 대비 절반 차원 |
| `d_input` | 8 | 세션 피처 차원 |
| `d_inner` | 128 | $64 \times 2$ (expand=2) |
| `seq_len` | 90 | 90일 세션 시퀀스 |
| 출력 | `[B, 64]` | 마지막 타임스텝 |

Mamba 총 Output Dimension: $128 + 64 = 192$D (txn + session concat).

## 복잡도 분석

| 연산 | 복잡도 | **Notes** |
|---|---|---|
| 순차 스캔 | $O(L \cdot D \cdot N)$ | $L$: 시퀀스 길이, $D$: 모델 차원, $N$: 상태 차원 |
| Transformer 대비 | $O(L)$ vs $O(L^2)$ | 시퀀스 길이에 선형 |
| 메모리 | $O(D \cdot N)$ | 은닉 상태만 유지 (시퀀스 길이 무관) |

# Liquid Neural Network (LNN)

## Theoretical Background

> 참조 논문
>
> Hasani et al., *"Liquid Time-constant Networks"* (AAAI 2021).
> 계보: Neural ODE (Chen et al., NeurIPS 2018) + 생물학적 뉴런 감쇠 모델 + Liquid State Machine (Maass et al., 2002).

Neural ODE를 기반으로 하되, 시간 상수 $\tau$가 입력에 따라 적응적으로 변하는 연속 시간 신경망이다. 불규칙 시간 간격(금융 거래의 본질적 Characteristics)을 자연스럽게 처리할 수 있다.

## 핵심 ODE

$$\frac{d\boldsymbol{h}}{dt} = \frac{-\boldsymbol{h} + f(\boldsymbol{x}, \boldsymbol{h})}{\tau(\boldsymbol{x}, \boldsymbol{h})} \tag{8}$$

$\boldsymbol{h} \in \mathbb{R}^H$: 은닉 상태, $\boldsymbol{x}$: 외부 입력
$f(\cdot,\cdot)$: 상태 업데이트 함수 (목표 상태), $\tau(\cdot,\cdot) > 0$: 적응적 시간 상수

각 항의 물리적 의미

| 항 | 의미 |
|---|---|
| $-\boldsymbol{h}$ | 감쇠 (leak): 입력 없이 은닉 상태가 0으로 수렴. 오래된 정보를 자연스럽게 잊음 |
| $f(\boldsymbol{x}, \boldsymbol{h})$ | 구동력 (driving force): 새 입력과 현재 상태에 기반한 목표 상태. $f = \tanh(\boldsymbol{W}_f[\boldsymbol{x}; \boldsymbol{h}] + \boldsymbol{b}_f)$ |
| $\tau(\boldsymbol{x}, \boldsymbol{h})$ | 시간 상수: 클수록 변화가 느림 (관성, 상태 보존), 작을수록 빠르게 반응. $\tau = \text{Softplus}(\text{MLP}([\boldsymbol{x}; \boldsymbol{h}])) + 0.1$ |

## Euler 이산화

연속 ODE를 이산 타임스텝으로 변환:

$$\boldsymbol{h}_{t+1} = \boldsymbol{h}_t + \Delta t \cdot \frac{-\boldsymbol{h}_t + f(\boldsymbol{x}_t, \boldsymbol{h}_t)}{\tau(\boldsymbol{x}_t, \boldsymbol{h}_t)} \tag{9}$$

$\Delta t$는 실제 시간 간격(일 단위)으로, 거래 간격이 불규칙하더라도 ODE가 자연스럽게 처리한다.

## 적응적 시간 상수의 금융 도메인 해석

금융 거래 간격은 극도로 불규칙하다:

| 상황 | $\boldsymbol{\Delta t}$ | $\boldsymbol{\tau}$의 **Role** |
|---|---|---|
| 당일 복수 거래 | $\sim 0.01$ 일 | 작은 $\tau$: 빠른 반응, 각 거래를 즉시 반영 |
| 주말 공백 | 2 일 | 중간 $\tau$: 상태 완만하게 유지 |
| 장기 휴면 | $> 30$ 일 | 큰 $\tau$: 상태 보존, 느린 감쇠 |

고정 $\tau$를 사용하는 RNN/LSTM은 모든 간격을 동일하게 처리한다. 적응적 $\tau$는 활발한 거래 시기에는 빠르게 반응하고, 휴면 시기에는 상태를 보존하여 고객 행동 리듬에 자동 적응한다.

## SingleStep 모드 설계

프로젝트에서 LNN은 **SingleStep** 모드로 운용된다. 전체 시퀀스를 ODE로 처리하지 않고, Mamba의 최종 은닉 상태에 대해 단일 *ODE* 스텝만 적용한다.

설계 근거

- Mamba가 이미 $O(L)$로 전체 시퀀스 패턴을 포착
- LNN은 시간 스케일 보정 Role만 수행 (중복 시퀀스 처리 회피)
- 계산 비용: $O(1)$ 단일 스텝 vs $O(L)$ 전체 시퀀스 ODE

> **Mamba → LNN 직렬 구조**
>
> Mamba가 시퀀스 패턴을 학습한 후, LNN이 최종 상태에 시간 인식 보정을 적용하는 직렬 구조이다. 이는 "트렌드 추출 → 잔차 보정"의 분해에 대응한다.

## Project Implementation Specification

| 파라미터 | LNN txn | LNN session | Description |
|---|---|---|---|
| `input_dim` | 128 | 64 | Mamba Output Dimension |
| `hidden_dim` | 64 | 32 | LNN 은닉 차원 |
| 출력 | `[B, 64]` | `[B, 32]` | SingleStep 출력 |

LNN 총 Output Dimension: $64 + 32 = 96$D (txn + session concat).

# PatchTST: Patch Time Series Transformer

## Theoretical Background

> 참조 논문
>
> Nie et al., *"A Time Series is Worth 64 Words: Long-term Forecasting with Transformers"* (ICLR 2023). ViT (Dosovitskiy et al., ICLR 2021)의 패치 개념을 시계열에 적용.

시계열을 고정 크기 패치로 분할한 뒤, 각 패치를 토큰으로 취급하여 Self-Attention을 적용한다. 이는 어텐션 비용을 $O(L^2)$에서 $O((L/P)^2)$로 축소하면서도 다중 스케일 주기 패턴을 효과적으로 포착한다.

### 패치 임베딩

$$\boldsymbol{p}_i = \boldsymbol{W}_{\text{proj}} \cdot \text{flatten}\left(\boldsymbol{x}_{[((i-1)P+1):(iP)]}\right) + \boldsymbol{b}_{\text{proj}} \tag{10}$$

패치 크기 $P = 16$에서 180 타임스텝 거래 시퀀스는 $\lfloor 180/16 \rfloor = 11$개 패치로 변환된다. 어텐션 비용: $O(180^2) = 32400 \rightarrow O(11^2) = 121$.

패치 크기의 금융 도메인 해석

패치 크기 16은 약 2주에 해당하며, 급여 주기 (2주/4주)의 기본 단위와 자연스럽게 정렬된다. 각 패치 내부에서 로컬 패턴 (일별 지출)을 집약하고, 패치 간 어텐션으로 글로벌 주기성 (월간 급여, 분기 보너스)을 포착한다.

## Multi-Head Self-Attention

$$\text{Attention}(\boldsymbol{Q}, \boldsymbol{K}, \boldsymbol{V}) = \text{softmax}\left(\frac{\boldsymbol{Q}\boldsymbol{K}^\top}{\sqrt{d_k}}\right)\boldsymbol{V} \tag{11}$$

$\boldsymbol{QK}^\top$의 $(i, j)$ 원소는 두 패치 벡터의 내적으로, 코사인 유사도에 비례한다. Softmax는 이를 확률 분포로 변환하여, 관련성 높은 패치의 정보를 가중합한다. $\sqrt{d_k}$로 나누는 것은 내적 분산을 정규화하여 softmax gradient의 건전성을 유지하기 위함이다.

## 위치 인코딩

정현파(sinusoidal) 위치 인코딩을 사용한다. 6–12개 패치 수준에서는 학습 가능 위치 인코딩 대비 충분한 성능을 제공하며, 시퀀스 길이 일반화에 유리하다.

## Project Implementation Specification

| 파라미터 | **PatchTST txn** | **PatchTST session** | **Description** |
|---|---|---|---|
| `d_model` | 64 | 32 | Transformer 은닉 차원 |
| `nhead` | 4 | 2 | 멀티헤드 어텐션 수 |
| `num_layers` | 2 | 2 | Transformer 인코더 레이어 수 |
| `patch_size` | 16 | 16 | 패치 크기 (약 2주) |
| 패치 수 | 11 | 5 | $\lfloor L/P \rfloor$ |
| 출력 | `[B, 64]` | `[B, 32]` | AdaptiveAvgPool1d |

PatchTST 총 Output Dimension: $64 + 32 = 96$D (txn + session concat).

## 복잡도 비교

| 모델 | 복잡도 | **L=180** 기준 |
|---|---|---|
| Vanilla Transformer | $O(L^2)$ | $32,400$ |
| PatchTST ($P = 16$) | $O((L/P)^2)$ | 121 |
| Mamba (SSM) | $O(L)$ | 180 |

# 앙상블 게이팅

## 게이트 아키텍처

세 모델의 출력을 연결(concat)한 뒤, 학습 가능한 2-layer 게이트 네트워크가 각 모델의 기여도를 동적으로 결정한다:

$$\boldsymbol{g} = \mathrm{Softmax}(\boldsymbol{W}_2 \cdot \mathrm{ReLU}(\boldsymbol{W}_1 \cdot \boldsymbol{z}_{\mathrm{cat}} + \boldsymbol{b}_1) + \boldsymbol{b}_2) \in \mathbb{R}^3 \tag{12}$$

$$\boldsymbol{y} = \sum_{i=1}^{3} g_i \cdot \mathrm{Proj}_i(\boldsymbol{z}_i) \in \mathbb{R}^{64} \tag{13}$$

$\boldsymbol{z}_{\mathrm{cat}}$: 세 모델 출력의 연결 ($192 + 96 + 96 = 384$D)
$\mathrm{Proj}_i$: 각 모델 출력을 공통 64D 공간으로 프로젝션
$g_i$: 모델 $i$의 가중치 ($\sum g_i = 1$)

## 입력 분리를 통한 앙상블 다양성

| 모델 | 입력 경로 | 다양성 확보 근거 |
|---|---|---|
| Mamba | 원본 시퀀스 직접 입력 | 순차 상태 공간 Perspective |
| LNN | Mamba 최종 상태 (직렬) | 시간 스케일 보정 Perspective |
| PatchTST | 원본 시퀀스 독립 입력 | 글로벌 어텐션 Perspective |

Mamba → LNN 직렬 + PatchTST 독립 구조는 입력 분리를 통해 앙상블 다양성을 확보한다. 동일 입력을 사용하면 게이팅 차별화 효과가 감소하므로, 독립 경로 설계가 필수적이다.

## 게이트 엔트로피 모니터링

게이트 분포의 건전성을 Shannon 엔트로피로 감시한다:

$$H(\boldsymbol{g}) = -\sum_{i=1}^{3} g_i \log_2(g_i) \tag{14}$$

| 상태 | 엔트로피 | 해석 |
|---|---|---|
| 균일 분포 | $\log_2(3) \approx 1.585$ bits | 세 모델이 균등하게 기여 (최대 엔트로피) |
| 건전한 편중 | $0.5 \sim 1.2$ bits | 입력에 따른 적응적 가중치 (정상 작동) |
| Gate Collapse | $< 0.3$ bits | 하나의 모델이 지배, 나머지 학습 중단 (경고) |

**Gate Collapse (Gate Collapse)**

$H < 0.3$ bits이면 하나의 모델이 거의 모든 가중치를 독점한다. 나머지 두 모델은 gradient가 차단되어 학습이 중단되므로 앙상블의 의미가 사라진다. 학습 중 엔트로피를 주기적으로 로깅하고, 붕괴 감지 시 게이트 온도 스케일링 또는 엔트로피 보너스 정규화를 적용한다.

## 최종 출력 흐름 Summary

$$\begin{aligned}
\text{txn_seq } [B, 180, 16] &\rightarrow \text{Mamba}_{\text{txn}} \rightarrow [B, 128] \\
\text{sess_seq } [B, 90, 8] &\rightarrow \text{Mamba}_{\text{sess}} \rightarrow [B, 64] \\
\text{Mamba}_{\text{txn}} &\rightarrow \text{LNN}_{\text{txn}} \rightarrow [B, 64] \\
\text{Mamba}_{\text{sess}} &\rightarrow \text{LNN}_{\text{sess}} \rightarrow [B, 32] \\
\text{txn_seq} &\rightarrow \text{PatchTST}_{\text{txn}} \rightarrow [B, 64] \\
\text{sess_seq} &\rightarrow \text{PatchTST}_{\text{sess}} \rightarrow [B, 32]
\end{aligned} \tag{15}$$

Concat: $[192 + 96 + 96 = 384\text{D}] \rightarrow$ Gate $\rightarrow$ Weighted sum $\rightarrow$ **64D** 최종 출력.

# I/O Specification 및 Implementation Notes

## 전체 I/O Specification

입력

| 입력 | Shape | Description |
|---|---|---|
| `txn_seq` | `[B, 180, 16]` | 180일 거래 시퀀스, card 8D + deposit 8D |
| `session_seq` | `[B, 90, 8]` | 90일 세션 시퀀스, 8D 세션 피처 |

중간 표현

| 모델 | txn 출력 | session 출력 | 합계 |
|---|---|---|---|
| Mamba (SSM) | 128D | 64D | 192D |
| LNN (ODE) | 64D | 32D | 96D |
| PatchTST (Attn) | 64D | 32D | 96D |
| **Concat** | | | **384D** |

출력

| 출력 | Shape | Description |
|---|---|---|
| Temporal Expert 출력 | `[B, 64]` | 게이팅 가중합 후 최종 표현 |
| Gate weights | `[B, 3]` | Mamba, LNN, PatchTST 기여도 (모니터링용) |

출력 64D 벡터는 PLE의 CGC Gate Attention으로 전달되어, 다른 6개 Expert (PersLay, DeepFM, LightGCN, Unified H-GCN, Causal, OT)의 출력과 태스크별로 동적 결합된다.

## 세 모델의 Role 비교 Summary

| 모델 | 포착하는 시간 패턴 | 메커니즘 | 복잡도 |
|---|---|---|---|
| Mamba | 장기 순차 의존성 (트렌드) | Selective State Space (S6) | $O(L)$ 선형 |
| LNN | 불규칙 시간 간격 (잔차) | 적응적 시간 상수 ODE | $O(1)$ 단일 스텝 |
| PatchTST | 글로벌 주기성 (계절성) | 패치 단위 Self-Attention | $O((L/P)^2)$ |

## 시계열 분석 세대별 발전과 본 프로젝트의 위치

| 세대 | **Approach** | **Limitation** | 극복 모델 |
|---|---|---|---|
| 1세대 | ARIMA, Exponential Smoothing | 선형 가정, 수작업 차분 | LSTM, GRU |
| 2세대 | LSTM, GRU (게이트 기반 RNN) | $O(L)$ 순차 병목, vanishing gradient | Transformer |
| 3세대 | Transformer (Self-Attention) | $O(L^2)$ 복잡도, 순서 정보 약함 | SSM, PatchTST |
| 4세대 | SSM + ODE + Patch Transformer | 모델 복잡도, Gate Collapse 위험 | 본 프로젝트 |

## 구현 시 유의사항

데이터 리키지 방지

- 시퀀스 데이터의 마지막 타임스텝이 레이블 산출 기간과 겹치지 않도록 `gap_days` 설정 필수 (최소 7일)
- Mamba의 인과 Conv1d는 미래 정보를 참조하지 않음 (left-padding)
- PatchTST의 어텐션은 causal mask 없이 전체 시퀀스를 참조하나, 입력 시퀀스 자체가 레이블 기간 이전으로 절단되어 있으므로 리키지 위험 없음

수치 안정성

- Mamba $\boldsymbol{A}$ 행렬: $-\exp(\mathrm{A}_{\log})$로 음수 보장 (발산 방지)
- Mamba $\Delta$: softplus로 양수 보장 ($\Delta > 0$)
- LNN $\tau$: $\mathrm{Softplus}(\cdot) + 0.1$ 하한 (영점 방지)
- 게이트 엔트로피 $< 0.3$ bits 시 경고 로깅

성능 최적화

- Mamba sequential scan: 프로토타입은 Python 루프, 프로덕션은 `mamba-ssm` CUDA 커널 권장
- AMP (Mixed Precision) 활성화: g4dn T4 GPU에서 약 2배 속도 향상
- 배치 크기: VRAM과 데이터 규모에 따라 조정 (대규모 데이터 4096 권장)

## References


| 구성 요소 | 논문 | 발표 |
|---|---|---|
| Mamba SSM | Gu & Dao, “Mamba: Linear-Time Sequence Modeling with Selective State Spaces” | NeurIPS 2023 |
| LNN | Hasani et al., “Liquid Time-constant Networks” | AAAI 2021 |
| PatchTST | Nie et al., “A Time Series is Worth 64 Words” | ICLR 2023 |
| Neural ODE | Chen et al., “Neural Ordinary Differential Equations” | NeurIPS 2018 |
| S4 (SSM) | Gu et al., “Efficiently Modeling Long Sequences with Structured State Spaces” | ICLR 2022 |
| HiPPO | Gu et al., “HiPPO: Recurrent Memory with Optimal Polynomial Projections” | NeurIPS 2020 |
| ViT | Dosovitskiy et al., “An Image is Worth 16x16 Words” | ICLR 2021 |
| CfC | Hasani et al., “Closed-form Continuous-depth Models” | Nature MI 2022 |