

금융 AI 규제 준수 프레임워크

금융분야 인공지능 가이드라인(2026.6.22 시행) 7대 원칙 대응
인공지능기본법 · EU AI Act 매핑 · 컴플라이언스 아키텍처 설계

문서 분류

작성일

버전

관련 규정

기술 문서

2026년 6월 (가이드라인 시행 반영 개정)

v2.0

금융분야 인공지능 가이드라인(2026.6.22), 인공지능기본법(법률 제20676호), EU AI Act, GDPR

핵심 요약 — 본 문서는 PLE 기반 금융 AI 추천 **레퍼런스 시스템**(Independent Research)이 금융위 「금융분야 인공지능 가이드라인」(2026.6.22 시행) 7대 원칙 및 인접 규제에 대해 **아키텍처 수준**에서 어떻게 설계, 구현되었는지를 매핑합니다. 대상은 가이드라인 7대 원칙(거버넌스 · 합법성 · 보조수단성 · 신뢰성 · 금융안정성 · 신의성실 · 보안성), 인공지능기본법(2026.1.22 시행), EU AI Act(Art. 13/14/15), GDPR Art. 22이며, 감사 추적 · 공정성 모니터링 · 드리프트 감시 · 설명 탐지 · 킥스위치 · 옵트아웃 · Human-in-the-Loop · 거버넌스 보고서 생성을 포함합니다.

성격 — 운영 중인 금융회사의 준수 증빙이 아닙니다. 본 시스템은 운영 배포, 운영 데이터를 사용하지 않으므로, 각 대응의 구현 상태를 **● 운영 동작** / **● 구현 완료·배선 미완** / **○ 미보유**의 3단계로 정직하게 구분합니다(과대평가 배제).

목차

금융 AI 규제 환경 개요	4
한국 인공지능기본법	4
금융분야 인공지능 가이드라인 7대 원칙 (2026.6.22 시행)	5
위험평가 체계와 AI 위험관리 프레임워크(AI RMF)	5
EU AI Act와의 비교	6
글로벌 규제 흐름 요약	6
7대 원칙 매핑 — 가이드라인 점검사항과 시스템 대응	7
원칙별 대응 매트릭스 (3단계 정직 평가)	7
운영 동작이 입증된 통제 (●)	7
구현 완료·운영 배선 미완 (◐) 및 미보유 (○)	8
EU AI Act 조항별 매핑	9
Article 13: 투명성 및 정보 제공	9
Article 14: 인간 감독 (Human Oversight)	9
Article 15: 정확성, 견고성, 사이버보안	10
GDPR Article 22: 자동화된 의사결정	10
한국 AI 기본법 고영향 AI 분류와 금융 적용	11
고영향 AI 해당 가능성 평가	11
AI 기본법 주요 조항별 대응 현황	11
규제 타임라인	12
컴플라이언스 아키텍처	13
전체 구조	13
보안 통제	14
3계층 풀백 — 규제 보증으로서의 서비스 무중단	14
감사 추적 (Audit Trail)	15
공정성 모니터링 (Fairness)	16
드리프트 감시 (Drift)	16
쓸림 탐지 (Herdning)	16
킬스위치 (Kill Switch)	17
옵트아웃 (Opt-out) 및 동의 관리	17
데이터 보존 정책	18
인시던트 관리	18
Bedrock 데이터 보호 아키텍처	18
온프레미스 환경의 규제 준수	20
데이터 보호	20
모델 구성	20
운영/감사 에이전트	21
규제 충족 비교	21
Human-in-the-Loop 설계	22
설계 원칙	22
채널별 인간 감독 체계	22
5대 인간 개입 포인트	22
모델리스크관리 (MRM) 프레임워크	24

MRM 생애주기	24
모델 인벤토리	25
독립적 검증 (Champion-Challenger)	25
지속적 모니터링과 재학습 트리거	25
비상 대응 (Kill Switch)	26
운영 및 감사 에이전트	27
아키텍처 개요	27
OpsAgent (운영 에이전트)	27
AuditAgent (감사 에이전트)	27
모델 선택	28
설계 원칙	28
Airflow DAG 통합	28
거버넌스 보고서 자동 생성	29
보고서 체계	29
36항목 규제 준수 자동 점검	29
거버넌스 3계층 체계	30
적용 규제 종합 매핑	30
운영/감사 에이전트 통합	31
시간적 팩트 스토어 (2026-04 추가)	31

금융 AI 규제 환경 개요

한국 인공지능기본법

2024년 12월 국회를 통과하고, 2025년 1월 21일 공포된 **「인공지능 발전과 신뢰 기반 조성 등에 관한 기본법」**(법률 제 20676호)은 **2026년 1월 22일** 시행되었습니다. 아시아-태평양 지역 최초의 포괄적 AI 입법으로, 위험 기반 접근법 (Risk-Based Approach)을 채택합니다.

법률 핵심 구조

투명성 의무 (제31조 / 시행령 제22조)
AI 사용 사실 사전 고지, AI 생성물 표시
위반 시 과태료 최대 3,000만 원

안전성 확보 (제32조 / 시행령 제23조)
학습 연산량 10^{26} FLOPs 이상 초거대 모델 대상
(추천 모델은 해당 없음 - **사용 영역** 기반 고영향 AI 분류 적용)

고영향 AI 확인 (제33조 / 시행령 제24조)
사업자의 자체 사전 검토 의무
필요시 과기정통부에 확인 요청 (30일 이내 회신)

고영향 AI 사업자 책무 (제34조 / 시행령 제26조)
위험 관리 방안 수립, 이용자 보호(설명가능성),
관련 사항 홈페이지 등에 공개

고영향 AI와 금융

인공지능기본법은 **“사람의 생명·신체의 안전, 기본권에 중대한 영향을 미치거나 위험을 초래할 수 있는 인공지능”**을 고영향 AI로 정의합니다(제2조 제4호). 시행령에서 11개 분야를 열거하며, **금융(신용·대출)** 분야가 명시적으로 포함됩니다.

분야	적용 예시	금융 관련성
의료	의료기기·디지털 의료기기에 활용되는 AI	간접
금융 (신용·대출)	신용평가·대출심사 등 개인 권리관계 평가 AI	직접
고용	채용·인사 의사결정 AI	없음
공공서비스	자격 확인, 행정 의사결정 AI	간접
원자력·생체정보	원자력 시설, 생체인식 분석 AI	간접

금융분야 시사점

대출심사·신용평가에 사용되는 AI는 법률상 명시적 고영향 AI에 해당합니다. 금융 AI 추천 시스템이 직접적인 여신 업무를 수행하지 않더라도, **상품 추천·적합성 판단·고객 분류** 등의 AI 활용이 향후 시행령 개정이나 금융위 가이드라인에 의해 고영향 AI로 확대 지정될 가능성이 존재합니다. 따라서 **고영향 AI에 준하는 수준**의 거버넌스 체계를 선제적으로 구축하는 것이 합리적 전략입니다.

금융분야 인공지능 가이드라인 7대 원칙 (2026.6.22 시행)

금융위원회는 기존 가이드라인 3종(금융분야 AI 운영 가이드라인 2021, AI 개발·활용 안내서 2022, AI 보안 가이드라인 2023)을 통합, 개정한 「**금융분야 인공지능 가이드라인**」을 **2026년 6월 22일 시행**했습니다. 프런티어, 생성형 AI 등 장과 인공지능기본법 시행을 반영한 것으로, 법적 강제가 아닌 **자율적용**(보유 자원, 업무 특성, 서비스 위험도에 따라 적용 범위와 수준을 자율 결정) 방식이며, 금융권 의견을 수렴해 **연례 업데이트**됩니다. 적용대상 “금융회사등”에는 은행, 보험, 카드, 금융투자 등과 함께 **채신관서(우체국예금·보험)**가 명시적으로 포함되고, 핀테크 등 비금융회사도 AI 활용이 금융거래에 영향을 주면 적용됩니다.

1. 거버넌스

의사결정기구(예: AI 윤리위원회) + **독립적 위험관리 전담 조직**
AI 내규·매뉴얼, 종합 위험평가 체계 구축

2. 합법성

적용 법규 사전 검토, 내규 주기 점검·현행화
외부 위탁 모델·역외 규제까지 준수 확인

3. 보조수단성

최종 의사결정·책임은 임직원(HITL)
고위험 AI는 긴급정지(Kill switch)·Override **필수 적용**

4. 신뢰성

모델 성능·데이터 품질·공정성 점검
설명가능성(전역·국소, 법적 의무 시 **SHAP 수준 이상**)

5. 금융안정성

시장 쏠림(동조화)·제3자 IT리스크 평가
백업모형 + 사후 개입 긴급정지 안전장치

6. 신의성실

이해상충 방지(계열사·고수수료 상품 유인 통제)
소비자 보호, AI 이용 사실 사전 고지

7. 보안성

AI 특화 위협(데이터·모델 오염, 프롬프트 인젝션)
외부 모델·데이터 검증, 망분리 완화 시 대체 통제

출처: 금융위 「금융분야 인공지능 가이드라인」(2026.6.22 시행)

위험평가 체계와 AI 위험관리 프레임워크(AI RMF)

가이드라인 거버넌스 원칙(§1.3)은 인공지능서비스별로 **위험 인식·측정 → 위험 경감 → 잔여위험 평가 → 위험등급 산정**의 종합 위험평가 체계를 요구하며, 그 표준 절차의 상세는 동반 문서 「**금융분야 AI 위험관리 프레임워크(AI RMF)**」로 위임합니다. 위험등급은 **저위험·중위험·고위험** 3단계로 구분하되, 구체적 점수 임계값과 부문 배점은 회사의 위험 선호도에 따라 정하는 **예시**로 제시됩니다.

위험평가 체계 — 거버넌스 §1.3 (점수·배점은 가이드라인 예시)

위험등급 띠 (예시)

위험점수 < 25 → 저위험 (통제 완화)
25 ~ 50 → 중위험 (기본 통제·관리)
50 이상 → 고위험 (추가 통제·관리)
75 이상 → 의사결정기구 심의로 출시 여부 재검토

부문 가중 (예시)

합법성 20% · 신뢰성 30%
신의성실 30% · 보안성 30%
위험경감 미수행 시 잔여위험 100%로 평가
인공지능기본법상 **고영향 AI**는 **고위험 AI**로 자동 분류·통제 강화

구현 정합 — 정직한 단서

본 시스템의 AIRiskClassifier(6차원 가중합 위험등급 산출)와 오프라인 승급 게이트는 이 위험평가 체계에 대응하는 구현입니다. 다만 현재는 서빙 상시 평가가 아닌 **오프라인 승급 시점 전용**이고, 등급 이력 저장소가 휘발성(in-memory) 기본값이라 “위험경감 → 잔여위험” 추적 산출이 미완입니다 (● 구현 완료·운영 배선 미완).

EU AI Act와의 비교

구분	한국 인공지능기본법	EU AI Act
시행일	2026. 1. 22.	고위험 AI: 2027. 12.
분류 체계	일반/고영향 (2단계)	금지/고위험/제한/최소 (4단계)
금융 적용	신용평가·대출심사 명시	신용평가·보험 산정 포함
금지 AI	없음	사회점수 부여, 실시간 원격 생체인식 등
의무 대상	사업자 중심 단일 기준	공급자·배포자·이용자 등 공급망 전체
제재 수준	과태료 최대 3,000만 원	글로벌 매출 최대 7% 또는 3,500만 유로
접근 방식	진흥 중심 + 자율규제	안전 중심 + 강제적 준수
영향평가	노력 의무	사전 적합성 평가 법적 의무

비교의 시사점

한국의 AI 기본법은 EU 대비 제재 수준이 **수천 배 낮고** 자율규제 비중이 크지만, 이는 **시행 초기 연착륙 전략**입니다. 금융분야 인공지능 가이드라인은 AI 기본법보다 적용 대상이 넓어(핀테크 등 비금융회사 포함), 신의성실 원칙에서 **AI를 이용한 금융상품 추천·자문 등 대고객 서비스의 AI 이용 사실 사전 고지**를 요구합니다. 향후 연례 업데이트와 금융위 세부 규율을 통해 적용 수준이 점진적으로 구체화될 것으로 예상되며, **선제적 대비**가 유리합니다.

글로벌 규제 흐름 요약

금융 AI에 대한 글로벌 규제는 세 가지 방향으로 수렴하고 있습니다.

투명성·설명가능성

AI 사용 고지 의무 확대
의사결정 근거 설명 요구
자동화 의사결정 거부권 보장

공정성·비차별

보호 속성별 편향 정량 측정
시장 쏠림·이해상충 방지
정기적 공정성 감사 의무화

안전성·책임성

위험 기반 분류(고위험 AI)
긴급 중단 메커니즘 의무
감사 추적 및 보존 의무

7대 원칙 매핑 — 가이드라인 점검사항과 시스템 대응

금융분야 인공지능 가이드라인 7대 원칙의 핵심 점검사항에 대해, PLE 기반 추천 레퍼런스 시스템의 구현 산물과 그 운영 배선 상태를 매핑합니다. 평가 기준은 “운영 효력”입니다 — 모듈이 존재해도 실제 배포 경로에서 호출되지 않으면 ●로 분류합니다. (자세한 항목별 단서는 outreach/05_fsc_supplementary 자율점검 자료와 일치.)

원칙별 대응 매트릭스 (3단계 정직 평가)

원칙	가이드라인 핵심 점검사항	시스템 구현 산물	상태
① 거버넌스	의사결정기구, 독립 위험관리 전담조직, AI 내규, 종합 위험평가체계(저/중/고)	위험등급 산출기(6차원 가중합), 오프라인 승급 게이트, 거버넌스 리포트 생성기	●○
② 합법성	적용 법규 사전 검토·현행화, 외부 위탁 모델·역외 규제 준수	36항목 법규-기능 매핑 카탈로그(AI기본법, 개보법, 금소법, 신정법 §36의2, EU AI Act, SR 11-7), 규제 자동점검기(증거 부재 시 fail-closed)	●○
③ 보조수단성	최종 책임은 임직원(HITL), 인적 개입 자동화, 고위험은 긴급정지·Override 필수	오프라인 승급 인간 게이트(auto_promote=false + HMAC 감사), 인적 검토 큐(tier별), 인적 폴백 라우터	●●○
④ 신뢰성	모델 성능·데이터 품질·공정성(Parity), 설명가능성(전역·국소, 법적 의무 시 SHAP 수준 이상)	학습 성능지표(AUC/F1/MAE), 종류 데이터 품질 게이트, 공정성 모니터(DI/SPD/EOD), 귀인(CEH·IG)·OOD 탐지	●●
⑤ 금융안정성	시장 쏠림(동조화) 영향평가, 백업모형+사후 긴급정지, 제3자 IT리스크	오프라인 무인 자동승급 차단, Kill Switch(전체/기능별/고객군별), 드리프트(PSI)-집중도 지표, 사고 보고기	●●○
⑥ 신의성실	이해상충 방지 관리·감독 장치, 금융소비자 보호	적합성 필터(금소법 §17, 미평가 시 fail-closed), 연락 보호(야간·DNC 동의)	●○
⑦ 보안성	AI 특화 위협·공격탐지, 자산 보호, 외부 모델·데이터 검증	인입 PII 단방향 해시(SHA256+salt), AI 보안 점검기(프롬프트 인젝션), 외부 산출물 무결성 검증(sha256 사이드카·안전 로드)	●●

● 운영 동작 (코드 경로 확인) ● 구현 완료·운영 배선 미완 ○ 미보유 / 조직 프로세스 영역

* 한 원칙에 여러 상태가 함께 표기된 것은, 점검사항별로 운영 동작·배선 미완·미보유가 섞여 있다는 뜻입니다(예: ③ 보조수단성 — 오프라인 승급 인간 게이트는 ●, HITL 큐는 ●, 임직원 교육은 ○). 본 평가는 2026-06 코드 감사 및 가이드라인 정합 수정(fail-open/배선 갭 10건) 결과를 반영합니다.

운영 동작이 확증된 통제 (●)

코드 경로로 실제 실행이 확인된 통제만 모았습니다.

- 학습 시 성능 지표 산출 (④ 신뢰성) — SageMaker 학습 컨테이너 본체에 인라인 배선되어 학습마다 실행. 태스크 유형별 분리 집계(분류 AUC, 다중분류 F1-macro, 회귀 MAE/RMSE).
- 종류 데이터 차단형 품질 게이트 (④ 신뢰성) — 종류 경로에서 품질 미달 시 파이프라인을 실제로 중단(예외 발생). 단 메인 학습 경로가 아닌 종류 경로 한정.

- **오프라인 무인 자동승급 차단 (③·⑤)** — auto_promote=false 강제로 운영자의 명시적 승인(서명) 없이는 승격되지 않음. 모든 승급 결정은 사유·트리거와 함께 HMAC 감사로그에 기록. 정직한 단서 — 자동 배포 오케스트레이션(Step Functions) 경로는 현재 자동 승급으로 우회되어 있어, 두 경로의 정합이 필요한 알려진 갭.
- **인입 PII 단방향 해시 (⑦ 보안성)** — 데이터 인입 경로에서 SHA256(salt+값) 단방향 해시가 실패출됨. 단서 — salt 미주입 시 빈 salt로 진행되는 fail-open 지점이 있어, 배포 시 시크릿 존재 확인 게이트 필요.
- **예측 로그 무결성·자동화 결정 거부권 (⑤·⑥)** — 예측 로그 HMAC 해시체인 + 자동화된 결정 거부(opt-out, 개보법 §37의2 / GDPR Art.22 준용) 혹은 서빙에 배선됨.

구현 완료·운영 배선 미완 (●) 및 미보유 (○)

모듈과 로직은 완성됐으나 서빙, 데이터 파이프라인 또는 스케줄 배선이 미완인 항목(●), 코드로 입증되지 않거나 조직 프로세스 영역인 항목(○)입니다.

- **종합 위험평가체계·규제 자동점검기·거버넌스 리포트 (①·②, ●)** — 위험등급 산출(6차원 가중합), 규제 점검기(증거 부재 시 fail-closed로 강화됨), 리포트 생성기 구현. 단 서빙 진입점 미배선, 등급 이력 저장소가 휘발성(in-memory) 기본값.
- **공정성·설명가능성 (④, ●)** — DI/SPD/EOD(가이드라인의 Parity 지표에 대응), 교차 보호속성 분석기, 예측별 귀인(CEH)·통합 그래디언트(IG)·z-공간 Mahalanobis OOD 구현. IG 산출물의 서빙 표면화는 소비자(consumer) 배선까지 완료, 생산자(producer)·로더는 잔여. 단 예측 로그가 보호속성·결과 라벨을 적재하지 않아 평가 데이터가 비어 있음.
- **Kill Switch·드리프트/집중도·인적 검토 큐·적합성/연락 보호 (③·⑤·⑥, ●)** — Kill Switch 3단계, PSI 드리프트, 집중도 지표, HITL 큐·폴백 라우터 완비. 단 배포 서빙 경로(핸들러 마이그레이션) 및 무인 스케줄(기본 DISABLED) 배선이 미완. 금소법 §17 적합성은 미평가 고객을 차단하도록 fail-closed로 역전됨(실패 차단은 서빙 컨텍스트 주입에 종속).
- **외부 모델·데이터 무결성 검증 (⑦, ●)** — sha256 사이드카·검증 로드·안전 tar 추출(traversal 차단) 신설. checkpoint 저장과 register 램다에 배선, blanket weights_only=True 전환은 단계적 잔여. (가이드라인 보안성 §7.4 외부 모델·데이터 검증에 직결.)
- **거버넌스 기구·내규·임직원 교육 (①·③, ○)** — AI 윤리위원회, 독립 위험관리 전담조직, 운영 내규·업무 매뉴얼, 임직원 AI 위험 교육은 조직 프로세스 영역으로 코드로 입증 불가.
- **이해상충 방지 관리·감독 장치 (⑥, ○)** — 수수료/인센티브 정렬 점검, 계열사·하우스상품 편향 가드 등 이해상충 통제 는 코드에 부재(집중도 지표는 이해상충 통제가 아님).
- **제3자 IT리스크 거버넌스 (⑥, ○)** — 벤더 SLA, 클라우드 단일의존 대체경로, 모델 공급자 집중리스크 평가 전용 절차 미보유.

EU AI Act 조항별 매핑

EU AI Act는 금융 AI 추천 시스템을 **고위험 AI**(Annex III, 5(b): 신용평가·보험 산정)로 분류할 가능성이 높습니다. 주요 조항별 시스템 대응을 매핑합니다.

Article 13: 투명성 및 정보 제공

Art. 13 요구사항과 시스템 대응

Art. 13 요구사항	시스템 대응
고위험 AI 사용 사실 고지	AI 사용 고지 중앙 관리 + 세그먼트별 안내 분리 모든 추천 출력에 AI 사용 표기 자동 포함
시스템 작동 방식 설명	2-Layer 추천 사유 생성 (L1 Template + L2 LLM) 3-Agent 파이프라인 (Feature Selector → Reason Generator → Safety Gate)
입력 데이터 사양 공개	피처 스키마 자동 문서화 (349D 입력 / 403D Phase 0 후 현재 구현 / 734D 풀뱅크 설계) 학습 데이터 출처·범위·가명처리 여부 기록
성능 수준 공개	모델 카드 자동 생성 (아키텍처·성능·피처 중요도) 태스크별 독립 AUC 추적 (13개 태스크)
로그 생성 의무	HMAC + 해시 체인 감사 로그 (S3 Object Lock WORM) 추천 이력 전수 Parquet 아카이빙

Article 14: 인간 감독 (Human Oversight)

Art. 14 요구사항과 시스템 대응

Art. 14 요구사항	시스템 대응
인간이 AI 시스템을 감독할 수 있는 인터페이스 제공	오프라인: 직원 화면에 추천 리스트 + 사유 제공, 최종 권유는 직원 판단 온라인: AI 운영팀이 추천 방향·대상·제외 목록 직접 제어
시스템 작동을 개입·중단할 수 있는 능력 보장	Kill Switch 3단계 (GLOBAL/PER_TASK/PER_CLUSTER) 드리프트 감지 시 보수적 모드 자동 전환
자동화 결정에 대한 거부·대안 경로	옵트아웃 등록·철회·확인 + 인적 재처리 3단계 라우팅 (P1 긴급 1h / P2 4h / P3 24h SLA)

Article 15: 정확성, 견고성, 사이버보안

Art. 15 요구사항과 시스템 대응

Art. 15 요구사항	시스템 대응
적절한 정확성 수준 달성 및 유지	Champion-Challenger 자동 모델 경쟁 PSI 기반 드리프트 감지 + 3일 연속 임계 초과 시 자동 재학습
오류·결함에 대한 견고성	Ablation 기반 컴포넌트별 기여도 정량 검증 중류 LGBM 폴백 (teacher 성능 이상 시 자동 전환)
사이버보안 위협 대응	프롬프트 인젝션 방어 8패턴 (심각도 5단계) 모델 무결성 SHA-256 검증 입력 검증 (포맷 + 크기 제한)
편향 방지 조치	DI-SPD-EOD 3대 공정성 지표 자동 측정 보호 속성 5종 상시 감시 임계값 위반 시 자동 인시던트 생성

GDPR Article 22: 자동화된 의사결정

GDPR Art. 22 및 관련 조항 대응

GDPR Art. 22는 정보주체에게 “프로파일링을 포함한 자동화된 의사결정에만 기반한 결정”에 대한 거부권을 부여합니다. 한국 개인정보보호법 §37조의2도 동일한 권리를 보장합니다.

GDPR 요구사항	시스템 대응
자동화 의사결정 거부권 (Art. 22(1))	옵트아웃 등록·철회·확인 전 생애주기 관리 거부 시 즉시 인적 대체 경로 전환
인적 개입 요청권 (Art. 22(3))	인적 재처리 라우팅 (7개 사유별 자동 상담원 전환) P1/P2/P3 SLA 관리
프로파일링 관련 정보 제공 (Art. 13(2)(f))	의사결정 기준 자동 문서화 (30개+ 필터 사유 한국어 설명) 피처 역매핑 + 태스크별 해석
삭제권 (Art. 17)	30일 PII 보존 정책 + 암호화 삭제 S3 Lifecycle 자동 적용
정보주체 권리 행사 감사 (Art. 30)	7개 감사 테이블 중 profiling_audit, opt_out_audit, consent_audit DynamoDB 서버리스 관리 + TTL 자동 정리

한국 AI 기본법 고영향 AI 분류와 금융 적용

고영향 AI 해당 가능성 평가

현행법상 금융상품 추천 시스템은 **대출심사에 해당하지 않으므로** 명시적 고영향 AI 분류 대상은 아닙니다. 그러나 다음 시나리오에서 확대 지정 가능성이 존재합니다.

시나리오	가능성	근거
시행령 개정으로 금융상품 추천 전반 포함	중간	EU AI Act가 이미 이 범위 포함
고객 분류·세그먼트가 권리관계 평가로 해석	낮음 중간	투자 적합성 판단과 유사 구조
보험 상품 추천으로 업무 확대 시	높음	보험 산정은 EU 고위험·국내 고영향 모두 해당
이탈 예측 기반 차별적 혜택 제공	중간	공정성 이슈와 직결
가이드라인 연례 업데이트에서 추천 AI 별도 규율	중간	시행본은 대출심사를 고영향 예시로 들 뿐 추천 AI 별도 규율은 미명시 — 연례 업데이트 추이 관찰

대응 전략

현시점에서 직접적 고영향 AI 해당은 아니나, **규제 환경의 방향성**을 고려하면 사실상 **고영향 AI에 준하는 수준**의 거버넌스 체계를 미리 구축하는 것이 합리적 전략입니다. 이는 규제 리스크 최소화뿐 아니라, 향후 업무 확대(보험·펀드 추천 등) 시 즉시 대응 가능한 기반이 됩니다.

AI 기본법 주요 조항별 대응 현황

요구사항	근거	구현 산물 / 배선 상태	상태
AI 사용 사실의 사전 고지	제31조	AI 사용 고지 모듈, 세그먼트별 안내 분리 (서빙 배선은 핸들러 마이그레이션 중속)	●
AI 생성물의 표시	제31조	추천 사유 텍스트에 AI 생성 표기 로직	●
위험 관리 조치 이행	제32조	Kill Switch(3단계) + 적격성·적정성 검증 1. 드리프트 감지 (모듈 완비, 배포 배선 미완)	●
고영향 AI 해당 여부 확인	제33조	시나리오별 해당 가능성 자체 분석 (문서)	●
위험 관리 방안·이용자 보호	제34조	안전신뢰문서 + 모델카드 생성 추천 사유 3단계 파이프라인	●
영향평가 실시	제35조	KoreanFRIAAssessor(7차원) 구현, 정기 실시 프로세스 조직 수립 필요	●
자동화 의사결정 거부권	개보법 §37조의2	옵트아웃 혹은 서빙 배선 + 인적 재처리 라우팅	●

거버넌스 체계 구축	7대 원칙	3계층 프레임워크 설계, 위원회 공식 설치는 조직 결정	○
------------	-------	--------------------------------	---

● 운영 동작 ● 구현 완료·운영 배선 미완 ○ 미보유 / 조직 결정

규제 타임라인

주요 규제 일정

일자	이벤트
2025. 1. 21	AI 기본법 공포
2025. 08	AI 기본법 시행령 입법예고
2025. 12. 22	금융위 AI협의회 — 가이드라인 초안 공개·의견수렴
2026. 01. 22	AI 기본법 시행
2026. 06. 22	금융분야 인공지능 가이드라인 시행 (AI RMF·보안 안내서 동반)
연례	가이드라인 업데이트 (금융권 의견 수렴)
2027. 01 (예상)	AI 기본법 과태료 실제 부과 시작
2027. 12	EU AI Act 고위험 AI 규정 완전 적용

컴플라이언스 아키텍처

전체 구조

규제 준수 인프라를 3개 레이어로 구성합니다.




그림 1: 3계층 컴플라이언스 아키텍처.

Layer 1: AWS 네이티브 (자동, 추가 비용 없음)

- **CloudTrail** → 모든 AWS API 호출 자동 기록
- **S3 Versioning** → 데이터/모델 변경 이력 보존
- **S3 Object Lock** → 감사 로그 불변성 (WORM)
- **KMS** → 암호화 키 관리 + 키 사용 감사
- **IAM Access Log** → 리소스 접근 감사

Layer 2: 플랫폼 레벨 (반자동)

- **ComplianceAuditStore** → 7개 감사 테이블 (DynamoDB)
- **AuditLogger** → HMAC + 해시 체인 (S3 + DynamoDB)
- **DataLineageTracker** → 피처→원천 추적 (S3 메타데이터)
- **ExperimentTracker** → 실험 메트릭 (SageMaker Experiments)
- **DriftDetector** → PSI 모니터링 (SageMaker Model Monitor)

Layer 3: 비즈니스/규제 레벨 (명시적)

- **RegulatoryComplianceChecker** → 36항목 자동 점검
- **FairnessMonitor** → DI/SPD/EOD 보호 속성 감시 (주기별 배치 평가)

- **HerdingDetector** → 시스템 리스크 쏠림 탐지
- **IncidentReporter** → 심각도별 자동 보고
- **GovernanceReportGenerator** → 월/분기 거버넌스 보고서 (주기별 자동 생성)
- **KillSwitch** → 긴급 모델 비활성화
- **ComplianceAuditStore** → 모든 예측 건에 전체 컴플라이언스 컨텍스트 로그
- **ConsentManager** → 마케팅 동의 생애주기 (부여/철회/갱신/확인)
- **AIOptOut** → AI 결정 거부 등록·철회·확인
- **ProfilingRights** → 정보주체 권리 행사 (열람/정정/삭제/이동)

보안 통제

PII 보호 및 LLM 보안

서빙 시 PII 마스킹: 고객 개인정보(성명, 계좌번호, 주민등록번호)는 추천 사유 생성 파이프라인 진입 전에 마스킹 처리됩니다. LLM 레이어에는 익명화 토큰만 전달되어, 외부 모델 제공사로의 PII 유출을 구조적으로 차단합니다.

LLM 호출의 PromptSanitizer: Bedrock(Claude Haiku)에 전달되는 모든 프롬프트는 PromptSanitizer를 통해 전처리됩니다. 8가지 인젝션 패턴(한국어 4 + 영어 4)을 제거하고 프롬프트 구조를 검증한 후 API를 호출합니다. 금융위 7대 원칙 7번(보안성)과 AI 기본법 제34조(위험관리)를 충족합니다.

구조적 분리: 컴플라이언스 모듈(ConsentManager, AIOptOut, RegulatoryChecker, ProfilingRights)은 스코어링 및 사유 생성 경로와 독립적으로 동작합니다. 컴플라이언스 검사는 사전 게이트로 강제되며, 모든 조건이 충족될 때만 예측 결과가 서빙됩니다.

3계층 폴백 — 규제 보증으로서의 서비스 무중단

3계층 폴백 아키텍처는 서비스가 완전히 멈추지 않도록 보장합니다. 이는 가이드라인 금융안정성 원칙 §5.2(백업모형 활용 + 사후 개입 가능한 긴급정지)의 핵심 요구사항에 대응합니다.

계층	메커니즘	활성 조건
1계층 (Primary)	Lambda + FallbackRouter를 통한 증류 LGBM Student	정상 운영
2계층 (Failover)	PLE Teacher 직접 추론 (SageMaker Endpoint)	Student 성능 저하 또는 이용 불가
3계층 (Safety Net)	규칙 기반 엔진: 13개 태스크 규칙 + Financial DNA 라우팅	두 모델 계층 모두 이용 불가

규제적 의미: CRITICAL 킬스위치 발동 시에도 3계층이 규칙 기반 상품 안내를 보장하여 서비스 완전 차단을 방지합니다. 세 계층 모두 설명 컴플라이언스를 위한 contributing_features를 생성합니다.

CloudFormation DynamoDB 컴플라이언스 테이블

다음 DynamoDB 테이블이 컴플라이언스 상태 관리를 위해 CloudFormation으로 프로비저닝됩니다:

- consent-store: 마케팅 동의 기록 (부여/철회/갱신/채널)
- opt-out-store: 고객별 AI 결정 거부 이력
- profiling-rights-store: 정보주체 권리 행사 기록
- audit-store: 예측 건별 컴플라이언스 감사 로그 (ComplianceAuditStore)

모든 테이블은 7년 보존 정책에 맞춰 TTL 자동 정리를 적용합니다.

감사 추적 (Audit Trail)

불변 로그 — HMAC + 해시 체인

각 감사 로그 엔트리에 HMAC-SHA256 서명을 부여하고, 연속 엔트리 간 SHA256 해시 체인(prev_hash)으로 연결하여 위변조를 방지합니다.

On-Prem	AWS
로컬 JSONL + HMAC + 해시 체인	S3 Object Lock (WORM) + HMAC + 해시 체인

AWS 강화 요소:

- S3 Object Lock: AWS 레벨에서 물리적 삭제 차단 (관리자도 삭제 불가)
- KMS 암호화: 감사 로그 자체를 암호화
- CloudTrail: 감사 로그에 대한 접근도 감사 (메타 감사)

7개 규제 감사 테이블

DynamoDB 기반 서버리스 관리 (자동 스케일링, 항목별 TTL):

테이블	용도	보존 기간
ks_audit	킬스위치 활성화/비활성화 이력	7년
consent_audit	마케팅 동의 변경 이력 (부여/철회/갱신)	7년
profiling_audit	정보주체 권리 행사 (열람/정정/삭제/제한/이동)	7년
opt_out_audit	AI 결정 거부 이력	7년
incident_audit	규제 인시던트 (심각도별)	7년
distillation_audit	교사-학생 모델 성능 갭	3년
embedding_audit	임베딩 품질 메트릭	3년

공정성 모니터링 (Fairness)

보호 속성 5개에 대해 3대 공정성 지표를 상시 감시합니다.

소득 관련 주의사항: **소득(income)**은 입력 피처이자 공정성 편향 모니터링 대상 보호 속성이다. 모델 태스크가 아니다. 결정론적 버킷 변환인 `income_tier`는 리키지 이유로 태스크에서 제거되었다(v14 태스크 세트) — 모델이 피처에서 레이블을 완벽히 복원할 수 있기 때문이다. 소득 피처 자체는 유지되며 공정성 모니터링 대상이다.

보호 속성

- **연령대:** youth / middle / pre_senior / senior
- **성별:** M / F / unspecified
- **지역 유형:** metropolitan / urban / rural
- **소득 분위:** low / middle / high (피처, 태스크 아님)
- **생애주기:** 6개 클래스

임계값 및 조치

- **DI (Disparate Impact):** 0.8 1.25
- **SPD (Statistical Parity Difference):** | SPD | ≤ 0.1
- **EOD (Equal Opportunity Difference):** | EOD | ≤ 0.1

DI < 0.6 → CRITICAL 인시던트

DI < 0.8 → MAJOR 인시던트

|SPD| > 0.1 → MINOR 인시던트

드리프트 감시 (Drift)

SageMaker Model Monitor (기본) + 커스텀 PSI (확장)를 결합합니다.

지표	임계값	자동 조치
PSI (warning)	0.1	경고 로깅
PSI (critical)	0.25	담당자 알림
연속 3일 critical	–	자동 재학습 트리거 (Step Functions)

피처별 개별 PSI를 추적하여, 전체 분포가 안정적이라도 특정 피처의 급변을 조기에 감지합니다.

쓸림 탐지 (Herding)

동일 상품에 추천이 과도하게 집중되는 **시스템 리스크**를 방지합니다.

지표	설명	심각도 분류
HHI	허핀달-허쉬만 지수 – 시장 집중도	none → low → medium
Gini 계수	추천 불평등 측정	→ high → critical
Entropy	추천 다양성 측정	
쓸림률	최다 추천 상품의 비율	critical 시 킬스위치 검토

킬스위치 (Kill Switch)

3단계 긴급 모델 비활성화 체계입니다.




그림 2: 킬스위치 에스컬레이션: 3단계 캐스케이드. 서비스가 완전히 중단되지 않음.

킬스위치 구조

GLOBAL

전체 모델 비활성화
DynamoDB 상태 저장
매 요청마다 확인

PER_TASK

특정 태스크만 비활성화
(예: click, purchase)
해당 태스크만 폴백

PER_CLUSTER

특정 고객군만 비활성화
(예: cluster_5)
해당 클러스터만 폴백

폴백 전략: 규칙 기반 추천 / 이전 모델 롤백 / 추천 비활성화 중 선택

옵트아웃 (Opt-out) 및 동의 관리

기능	설명
AI 결정 거부 등록	옵트아웃 등록 → 즉시 인적 대체 경로 전환
거부 철회	이전 옵트아웃 철회 → AI 추천 재활성화
마케팅 동의 관리	부여/철회/갱신 이력 추적, 채널별·목적별 옵트인 확인
야간 SMS 차단	마케팅 동의 여부 + 시간대 자동 필터링
감사 추적	모든 동의 변경·거부 이력을 consent_audit, opt_out_audit에 기록

데이터 보존 정책

S3 Lifecycle Rule으로 자동 적용합니다.

카테고리	보존 기간	조치	규제 근거
Raw Data	30일	삭제	GDPR 최소화 원칙
Processed Features	90일	Glacier 아카이브	재학습 지원
Training Data	365일	Glacier 아카이브	재현성 보장
Model Checkpoints	365일	보관	롤백 지원
Inference Results	90일	삭제	분쟁 대응
Audit Logs	2,555일 (7년)	불변 보관 (WORM)	금융 규제 7년 보존
PII Data	30일	암호화 삭제	GDPR §17 삭제권

인시던트 관리

심각도별 자동 분류 및 대응 체계입니다.




그림 3: 인시던트 심각도 분류 및 에스컬레이션.

심각도	대응 시간	트리거	보고 대상
CRITICAL	1시간	킬스위치 발동, DI<0.6, 보안 침해	과기부/금감원/CISO
MAJOR	4시간	DI<0.8, 쏟림 critical, 모델 롤백	금감원/AI 위원회
MINOR	24시간	드리프트 경고, 품질 저하, 쏟림 high	ML팀

※ 위 보고 대상, 대응 시간은 **시스템 내부 에스컬레이션 정책** 예시입니다. 가이드라인은 사고 발생을 트리거로 한 감독당국 자동 보고를 강제하지 않으며(금융안정성 원칙은 “감독당국 정보공유·보고”를 점검사항으로 두고, 제3자 위탁현황 등은 감독당국 요청 시 제출), 실제 보고 채널, 기준은 기관 내규로 정합니다.

Bedrock 데이터 보호 아키텍처

금융 AI 시스템에서 LLM을 활용할 때 가장 중요한 규제 이슈는 고객 데이터의 외부 유출이다. Amazon Bedrock은 다음 5가지 구조적 보호 장치를 통해 이 문제를 해결한다:

보호 장치	상세
데이터 미학습	입출력 데이터가 모델 제공사(Anthropic, Meta 등)에 전달되지 않으며, 모델 재학습(fine-tuning 포함)에 사용되지 않는다. AWS가 이를 서비스 약관으로 보장한다.

전송 암호화	TLS 1.2+ 암호화로 전송 중 데이터를 보호한다.
VPC PrivateLink	인터넷을 경유하지 않고 VPC 내부 엔드포인트를 통해 Bedrock API를 호출한다. 고객 데이터가 공개 네트워크에 노출되지 않는다.
리전 내 처리	모든 추론이 ap-northeast-2(서울) 리전에서 처리된다. 고객 데이터가 한국 밖으로 전송되지 않는다.
CloudTrail 감사	모든 Bedrock API 호출(InvokeModel, Converse 등)이 CloudTrail에 자동 기록된다. 누가 언제 어떤 모델을 호출했는지 완전한 감사 추적이 가능하다.

규제 매핑

규제	요구사항	Bedrock 충족 방식
개인정보보호법	제3자 제공 vs 위탁 처리 구분	Bedrock은 AWS 인프라 내 위탁 처리에 해당. 데이터가 모델 제공사에 전달되지 않으므로 제3자 제공이 아님.
개인정보보호법	국외 이전 제한	ap-northeast-2 리전 내 처리. 국외 이전 불발생.
금융분야 AI 가이드라인	데이터 거버넌스	CloudTrail 감사 로그 + VPC 격리 + 전송 암호화로 데이터 흐름 완전 추적.
EU AI Act Art.10	데이터 거버넌스	학습 데이터 미사용 보장. 추론 데이터 처리 위치 문서화.
AI 기본법	고영향 AI 데이터 관리	HMAC 감사 로그와 CloudTrail 이중 기록으로 데이터 처리 이력 증명.

데이터 흐름도

추천사유 생성 및 에이전트 진단 시 데이터 흐름:




그림 4: AWS Bedrock 데이터 흐름: VPC PrivateLink로 리전 외부 전송 없이 처리.

온프레미스 환경의 규제 준수

폐쇄망(air-gapped) 온프레미스 환경은 외부 네트워크 접근이 원천적으로 차단되어, 데이터 보호 관점에서 AWS보다 구조적으로 더 강력하다.




그림 5: 온프레미스 vs AWS: 동일한 DuckDB 파이프라인과 규제 준수 프레임워크, 인프라 계층만 다름.

데이터 보호

항목	온프레미스	AWS (Bedrock)
외부 데이터 전송	원천 불가 — 폐쇄망	VPC PrivateLink로 리전 내 처리
모델 제공사 데이터 접근	해당 없음 — 로컬 오픈소스 모델	Bedrock 약관으로 미전달 보장
감사 추적	로컬 HMAC 해시체인 (JSONL)	S3 Object Lock + CloudTrail
국외 이전	발생 불가	ap-northeast-2 내 처리

모델 구성

온프레미스에서 사용하는 모델은 모두 오픈소스이다:

용도	모델	라이선스 및 비고
추천사유 생성/critique	Exaone 3.5 7.8B	Apache 2.0 (LG AI Research). 한국어 특화.
에이전트 합의	Qwen 2.5 14B Q4	Apache 2.0 (Alibaba). 논리적 추론 특화.
임베딩	all-MiniLM-L6-v2	Apache 2.0 (sentence-transformers).

RTX 4070 (12GB VRAM)에서 순차 로딩으로 운용한다. 벤더 종속성이 없으며, 모델 교체가 config 변경만으로 가능하다.

운영/감사 에이전트

온프레미스 에이전트는 AWS와 **동일한 롤 엔진 + 체크리스트 + 도구 카탈로그**를 사용한다. 차이점:

기능	온프레미스	AWS
체크리스트 자동 판정	동일 (48항목)	동일
합의 메커니즘	2-Round 하이브리드 (Qwen 14B × 5+2)	독립 투표 (Bedrock Claude Sonnet 4.6 × 3 병렬). 만장일치 PASS 요구; 하나라도 이견이면 WARN + minority_report 보존
마이너리티 리포트	동일 — Round 1에서 확정, 삭제 불가	동일 — 모든 dissent 보존
담당자 대화	미제공 — 정형 리포트만	Sonnet Tool Use 대화
케이스 스토어	동일 (LanceDB)	동일
알림	이메일/Slack	SNS + Slack

규제 충족 비교

규제 요구사항	온프레미스 충족	AWS 충족
개인정보보호법 국외이전	원천 불가 (폐쇄망)	ap-northeast-2 내 처리
금감원 데이터 거버넌스	로컬 HMAC 감사 로그	CloudTrail + S3 Object Lock
EU AI Act 인간 감독	에이전트 권고 + 담당자 판단 (동일)	동일 + 대화 인터페이스
AI 기본법 킬스위치	로컬 킬스위치 (동일)	DynamoDB 킬스위치
설명 가능성	LGBM SHAP 기반 사유 + Exaone 리라이트	LGBM SHAP 기반 사유 + Claude Sonnet 리라이트

온프레미스는 대화형 에이전트가 없는 대신, 데이터 보호가 구조적으로 완벽하다. 규제기관 관점에서 “고객 데이터가 절대 외부로 나가지 않는다”는 가장 강력한 보호 근거이다.

Human-in-the-Loop 설계

금융분야 AI 가이드라인(보조수단성 원칙)은 최종 의사결정과 책임을 **임직원**이 수행하도록 요구합니다. EU AI Act Art. 14도 동일한 원칙을 명시합니다. 모든 것이 자동화되어 있더라도, 최종 검수는 사람이 수행합니다.

설계 원칙

AI는 도구이고, 최종 결정권은 사람에게

PLE 기반 추천 시스템은 “사람을 대체”하는 것이 아니라 “사람의 의사결정을 지원”하는 도구입니다. 이 원칙은 시스템 아키텍처 전반에 내장되어 있습니다.

채널별 인간 감독 체계

채널	인간 감독 방식
오프라인 (창구)	AI가 직원 화면에 추천 리스트 + 사유를 제공 최종 권유 여부는 직원이 판단 추천 사유를 확인한 뒤 고객 상황에 맞게 권유
온라인 (앱/웹)	AI가 추천 리스트를 자동 서빙 AI 운영팀이 추천 방향·대상·제외 목록을 직접 제어 긴급 시 킬스위치로 즉시 차단

5대 인간 개입 포인트

1. 추천 사유 샘플링 검수

전수 조사는 불가하더라도, 주기적으로 추천 사유 생성 결과를 샘플링하여 품질·적합성·규제 준수 여부를 검수합니다. 추천 품질 모니터링 시스템(L1 규칙 / L2a 리라이트 / L2b LLM 검증)이 자동 품질 지표를 산출하고, 이상 징후 발견 시 인간 검토를 트리거합니다.

2. 모델 교체 승인

오프라인 Champion-Challenger 게이트(ModelCompetition.evaluate)가 통계적으로 유의한 개선이 있을 때 자동 승격을 결정하며, 부트스트랩 및 긴급 롤백은 --force-promote 운영자 오버라이드로 처리합니다. 모든 판정(bootstrap / promote / reject / force_promote)은 AuditLogger.log_model_promotion을 통해 HMAC 서명 + 해시 체인 연결된 S3 WORM 감사 로그에 기록되며, 교체 사유·성능 비교·공정성 지표를 포함한 리포트와 함께 운영팀이 사후 검토합니다.

3. 인시던트 에스컬레이션

자동 탐지된 이상 징후(공정성 위반, 드리프트, 쏠림)를 사람이 판단하여 조치합니다. CRITICAL 인시던트는 킬스위치 자동 발동 후 사람이 원인 분석 및 복구를 수행합니다.

4. 공정성 리뷰

공정성 모니터링 결과를 주기적으로 사람이 리뷰합니다. DI·SPD·EOD 자동 측정 결과에 대해 도메인 전문가가 맥락을 고려한 해석을 제공하고, 필요시 임계값 조정이나 모델 재학습을 결정합니다.

5. 옴트아웃·이의 제기 처리

고객의 AI 결정 거부 및 이의 제기에 대해 인적 재처리 경로가 자동으로 활성화됩니다. 7개 사유별 자동 상담원 전환이 이루어지며, P1(1h)/P2(4h)/P3(24h) SLA로 관리됩니다.

인적 재처리 사유 분류

P1 (긴급 1시간)

- 컴플라이언스 위반 탐지
- 적합성 미달 고객
- 킬스위치 발동 상황

P2 (4시간) / P3 (24시간)

- AI 결정 거부(옴트아웃)
- 저신뢰 추천 결과
- 설명 보충 요청
- 일반 이의 제기

모델리스크관리 (MRM) 프레임워크

미국 연준/OCC의 **SR 11-7**(모델 리스크 관리 가이드선스), **NIST AI RMF 1.0**, 그리고 **EBA 머신러닝 가이드라인**은 모델의 전 생애주기에 걸친 체계적 리스크 관리를 요구합니다. 본 시스템은 이러한 글로벌 프레임워크를 가이드라인이 위임하는 「금융분야 AI 위험관리 프레임워크(AI RMF)」 및 인공지능기본법 요구사항과 통합하여, 모델 개발부터 폐기까지 일관된 관리 체계를 설계합니다.

MRM 생애주기

모델 리스크 관리는 5단계 생애주기를 따르며, 각 단계가 시스템 컴포넌트에 직접 매핑됩니다.




그림 6: MRM 생애주기: SR 11-7, NIST AI RMF, 금융분야 AI RMF 기반 5단계 순환. 3단계(승인)는 반드시 수동.

단계	활동	시스템 컴포넌트	규제 근거
1. 개발	피쳐 파이프라인 구축, 모델 학습, 하이퍼파라미터 최적화	PipelineRunner + train.py + SageMaker Ablation	SR 11-7 Pillar 1
2. 검증	독립적 성능 평가, 공정성 감사, 편향 테스트	Champion-Challenger 비교 + FairnessMonitor	SR 11-7 Pillar 2
3. 승인	AI 위험관리위원회 심의, 배포 승인	ModelCompetitionManager (auto_promote=False)	NIST GOVERN
4. 모니터링	드리프트 감지, 성능 추적, 공정성 지표 측정	DriftDetector + PSI + DI/SPD/ EOD	NIST MEASURE
5. 재학습/폐기	자동 재학습 트리거, 성능 미달 모델 폐기	ConsecutiveDriftTracker + dag_monthly_retrain	NIST MANAGE

모델 인벤토리

운영 중인 모든 모델을 추적하는 중앙 레지스트리를 유지합니다. SR 11-7은 조직 내 모든 모델의 목록화와 위험 등급 분류를 요구합니다.

모델 레지스트리 관리 항목

식별 정보: 모델 ID, 버전, 학습 일시, 학습 데이터 기간, 피처 스키마 해시
성능 기록: 태스크별 AUC/F1/MAPE, 검증 데이터셋 메트릭, calibration 지표
위험 등급: 고/중/저 3단계 (가이드라인 위험평가 체계 §1.3 기준)
상태 관리: 개발중 → 검증중 → 승인 대기 → 운영중 → 폐기 (5단계 상태 전이)
감사 추적: 모든 상태 변경에 대한 변경자, 사유, 타임스탬프 기록

독립적 검증 (Champion-Challenger)

SR 11-7 Pillar 2가 요구하는 **독립적 모델 검증**을 Champion-Challenger 프레임워크로 구현합니다. 핵심 원칙은 모델 개발자가 아닌 독립적 프로세스가 승인 여부를 결정하는 것입니다.

자동 비교 기준

성능: 태스크별 AUC 동등 또는 우위
보정: Expected Calibration Error < 5%
공정성: DI/SPD/EOD 악화 없음
안정성: 검증 데이터 3-fold 분산 허용 범위 내

승인 프로세스

auto_promote=False: 자동 배포 차단
비교 보고서: 성능/공정성/안정성 종합 리포트 자동 생성
위원회 심의: AI 운영팀 검토 → 위험관리위원회 승인
promote/reject: 수동 의사결정 후 상태 전이

지속적 모니터링과 재학습 트리거

배포 후 모니터링은 세 가지 축으로 운영되며, 임계값 위반 시 자동 재학습 파이프라인이 작동합니다.

드리프트 감지 → 재학습

DriftDetector (PSI): 피처/예측/라벨 분포 변화를 일간 측정
ConsecutiveDriftTracker: PSI 임계값 초과가 **3일 연속** 발생 시 재학습 트리거 발동
재학습 파이프라인: dag_monthly_retrain → 신규 모델 학습 → ModelRegistry 등록 → 오프라인 Champion-Challenger 게이트(ModelCompetition + fidelity floor) → HMAC 서명 감사 로그 기록 → promote/reject 자동 판정 (--force-promote는 운영자 override 전용)

공정성 모니터링

FairnessMonitor: 보호 속성 5종(연령, 성별, 지역, 소득, 생애주기)에 대해 DI/SPD/EOD를 일간 측정
임계값 위반 시: 즉시 알림 발송 + 인시던트 기록 + 거버넌스 보고서에 자동 포함
연속 위반 시: 해당 세그먼트 추천 일시 중단 검토 (AI 운영팀 판단)

비상 대응 (Kill Switch)

모델이 예기치 않은 위험을 발생시킬 경우, 3단계 긴급 차단 메커니즘을 통해 즉시 대응합니다.

단계	조치	트리거 조건
1단계: 모델 비활성화	문제 모델의 서빙 즉시 중단	성능 위험(Red) 또는 공정성 임계값 중대 위반
2단계: 이전 버전 롤백	모델 레지스트리에서 직전 승인 버전으로 자동 복원	비활성화 후 자동 실행
3단계: 규칙 기반 폴백	AI 모델 전체 비활성화, 사전 정의된 규칙 기반 추천으로 전환	롤백 모델도 기준 미달 시

복구 절차: 원인 분석 → 수정 모델 학습 → 오프라인 Champion-Challenger 게이트 자동 판정 → HMAC 서명 감사 로그 기록 → 위원회 사후 검토(긴급 롤백은 --force-promote로 즉시 적용 후 사후 검토) → 재배포. 모든 비상 대응 이력은 감사 로그에 불변 기록되며, 금감원 보고 대상 여부가 자동 판정됩니다.

운영 및 감사 에이전트

아키텍처 개요

서빙 에이전트(L1 Rule/L2a Retrieval/L2b Generation)는 실시간 추천 경로에 위치하며, 여기서 다루는 **OpsAgent**와 **AuditAgent**는 완전히 분리된 **배치 전용** 에이전트입니다. 서빙 경로와 상태를 공유하지 않으며, Airflow DAG의 후속 태스크로만 실행됩니다. 이 분리는 실시간 서빙 SLA에 영향을 주지 않으면서 규제 감시 기능을 수행하기 위한 설계 원칙입니다.

OpsAgent (운영 에이전트)

트리거 및 입력

트리거: dag_drift_monitoring 완료, 학습 Job 완료 이벤트

입력 데이터:

- eval_metrics.json: 태스크별 AUC/F1/MAPE, calibration 지표
- 학습 로그: 태스크별 loss 추이, gradient norm 이력
- Gate entropy: 전문가 라우팅 편중도 (MoE gate softmax 분포)
- PSI 드리프트 보고서: 피쳐/예측/라벨 분포 변화

처리 파이프라인: JSON 파싱 → 이상 탐지 규칙 적용(임계값 기반 사전 필터링) → 이상 감지 시 LLM에 구조화된 프롬프트 전달.

프롬프트 예시

"다음 eval_metrics.json과 gate entropy를 분석하여 (1) 성능 저하 태스크 식별, (2) gate 편중 여부(entropy < 0.3인 전문가), (3) PSI 임계값 초과 피쳐 목록, (4) 권장 조치를 구조화하여 보고하십시오."

출력: 모델 건강 보고서(Markdown) — S3 governance/ops_reports/ 경로에 저장. 이상 감지 시 Slack 채널 및 이메일로 알림 발송.

AuditAgent (감사 에이전트)

트리거 및 입력

트리거: dag_fairness_monitoring 완료, 분기별 거버넌스 사이클(dag_governance_quarterly)

입력 데이터:

- FairnessMonitor 보고서: DI/SPD/EOD (보호 속성 5종 × 태스크별)
- 감사추적 무결성 검증 결과: HMAC 해시 체인 검증 상태
- 옴트아웃 통계: 기간별 요청 건수, 처리율, 평균 처리 시간
- 거버넌스 체크리스트: 36항목 자동 점검 결과

처리 파이프라인: 규제 기준 대비 자동 비교($DI \geq 0.8$, $|SPD| \leq 0.1$, $|EOD| \leq 0.1$) → 위반 항목 추출 → LLM에 위반 사항 요약 및 권장 조치 요청.

프롬프트 예시

“다음 공정성 지표를 사내 공정성 기준($DI \geq 0.8$, $|SPD| \leq 0.1$, $|EOD| \leq 0.1$ — 가이드라인 신뢰성 원칙의 Parity 지표에 대응)과 비교하여 (1) 위반 항목(보호 속성, 태스크, 지표값), (2) 위반 심각도(P1/P2/P3), (3) 권장 조치를 보고하십시오.”

출력: 규제 준수 보고서(Markdown) — S3 governance/audit_reports/ 경로에 저장. 위반 감지 시 우선순위별 알림 발송: P1(즉시 에스컬레이션), P2(24시간 내 검토), P3(분기 보고서 포함).

모델 선택

환경	모델	사유
폐쇄망 (온프레임)	Exaone 3.5 7.8B (사유 생성) + Qwen 2.5 14B Q4 (에이전트 합의)	Apache 2.0 오픈소스. RTX 4070에서 순차 로딩.
클라우드 (AWS)	Claude Haiku 4.5 API	비용 효율적 (\$0.25/1M input), 구조화된 출력 안정적

비용 추정: 배치당 1~2회 호출로 일일 비용 약 \$0.01 이하. 입력은 JSON 메트릭(수 KB) + 프롬프트이므로 토큰 소모가 최소화됩니다.

설계 원칙

자동화 범위

배치 전용: 실시간 서빙 경로에 개입하지 않음
정형적 판단: 임계값 비교, 추세 분석, 위반 분류는 에이전트가 수행
비정형적 판단: 데이터 오염 의심, 비즈니스 맥락 변화, 규제 해석은 인간이 수행

감사 산출물 보장

HMAC 서명: 에이전트 출력 자체가 감사 산출물 — 생성 즉시 HMAC 서명 후 불변 저장
해시 체인: 이전 보고서와 연결된 해시 체인으로 변조 불가 보장
인간 검토: “출근 시 확인” 방식 — 에이전트가 정리하고 인간이 자기 페이스로 검토

Airflow DAG 통합

DAG	에이전트 태스크	실행 주기
dag_drift_monitoring	드리프트 감지 완료 후 → ops_agent_report 태스크 추가	일간
dag_fairness_monitoring	공정성 측정 완료 후 → audit_agent_report 태스크 추가	일간
dag_governance_quarterly	36항목 점검 완료 후 → audit_agent_quarterly 분기 보고서	분기
학습 Job 완료 콜백	ops_agent_training_report — 학습 메트릭 분석	이벤트

거버넌스 보고서 자동 생성

보고서 체계

월/분기 단위로 자동 생성되어 S3에 저장되고, AI 거버넌스 위원회에 배포됩니다.

9개 섹션 구성

섹션	내용	데이터 소스
1	공정성 요약 (DI/SPD/EOD by 보호 속성)	FairnessMonitor
2	드리프트 요약 (기간 내 PSI 통계)	DriftDetector
3	인시던트 요약 (CRITICAL/MAJOR/MINOR 건수 + 상세)	IncidentReporter
4	모델 변경 이력 (학습/배포/롤백)	ExperimentTracker
5	킬스위치 이력 (활성화/비활성화 횟수)	ComplianceAuditStore
6	추천 품질 (L1/L2 사유 품질 지표)	ReasonQualityMonitor
7	리스크 변동 (슬림 추이, 리스크 수준)	HerdingDetector
8	감사 스토어 요약 (7개 테이블 건수)	ComplianceAuditStore
9	경영진 요약 (자동 생성 서술형)	종합

36항목 규제 준수 자동 점검

36항목 규제 준수 레지스트리를 통해 분기별 전체 점검이 자동 실행됩니다.

A그룹 (구현 완료 18항목)

모델 카드 · 학습 데이터 문서화 · 안전신뢰문서
AI 공시 · 설명 가능성 · 옵트아웃 권리
인간 검토 · 킬스위치 · 모델 롤백
헬스 체크 · 공정성 모니터링 · 적합성 제약 등

GAP그룹 (갭 분석 18항목)

드리프트 자동 대응 · 추천 사유 품질 검증
SLA 추적 · EU AI Act 고위험 분류
PIA (개인정보 영향 평가) 등

점검 주기:

- 일간: 킬스위치 상태, 헬스 체크
- 주간: 공정성 지표, 설명 가능성
- 분기: 전체 36항목 종합 점검

거버넌스 3계층 체계

1계층: 의사결정 - AI 위험관리위원회

AI 활용 정책 승인 · 고영향 AI 해당 여부 판단 · 연간 영향평가 승인 · 중대 사고 보고 체계

2계층: 실행 - AI 운영팀

모델 개발·운영 · 성과 모니터링 · 공정성 점검 · 추천 품질 관리 · 인시던트 대응

3계층: 검증 - 내부 감사·컴플라이언스

독립적 감사 · 규제 준수 확인 · 영향평가 검토 · 외부 감사 대응

적용 규제 종합 매핑

규제	관련 조항	설계 반영
AI 기본법	§31 (AI 생성물 표시)	AI 공시 + 추천 사유 L1/L2
	§33 (고영향 AI 거버넌스)	36항목 레지스트리 + 거버넌스 보고서
	§34 (위험 관리 기록)	감사 로그 불변성 + 7개 감사 테이블
금소법	§19 (설명 의무)	피쳐 역매핑 + 태스크별 해석
금융분야 AI 가이드라인 7대 원칙	① 거버넌스	위험평가 체계 + 거버넌스 리포트 (●)
	② 합법성	36항목 법규-기능 매핑 + 규제 자동점검기 (●)
	③ 보조수단성	오프라인 승급 인간 게이트 (●) + HITL 큐 (●)
	④ 신뢰성	학습 성능지표 (●) + 공정성·설명가능성 (●)
	⑤ 금융안정성	킬스위치 + 드리프트(PSI) + 집중도 지표 (●)
	⑦ 보안성	PII 해시 (●) + 외부 모델-데이터 무결성 검증 (●)
	⑧ 투명성	추천 사유 + 모델 카드 + 감사 로그
GDPR	§17 (삭제권)	30일 PII 보존 + 암호화 삭제
	§22 (자동화 거부)	opt_out_audit 테이블
	§35 (DPIA)	PIA 갭 분석 항목
개보법	§28의2 (가명정보)	가명 처리 기록 감사
	§37조의2 (자동화 결정)	옵트아웃 + 인적 재처리
EU AI Act	Art. 13 (투명성)	추천 사유 + 모델 카드 + 감사 로그
	Art. 14 (인간 감독)	킬스위치 + 인적 재처리 + 채널별 인간 감독

운영/감사 에이전트 통합

본 문서의 모든 규제 준수 컴포넌트(FairnessMonitor, HerdingDetector, ComplianceChecker, AuditLogger 등)는 AuditAgent의 도구(tool)로 래핑되어 48개 체크리스트 항목으로 자동 점검된다.

3-에이전트 합의 메커니즘(Sonnet×3 독립 투표)이 할루시네이션을 구조적으로 완화하며, 마이너리티 리포트가 소수 의견을 보존한다. 판정 규칙은 의도된 fail-safe다: FAIL이 1표면 FAIL로 격상되고 PASS는 만장일치를 요구하는데, 이는 운영과 감사에서 놓친 위험 신호를 거짓 경보보다 비싸게 취급하기 때문이고, 모든 이견이 보존되므로 감사인은 소수 의견이 왜 격상되었는지(또는 되지 않았는지)를 항상 추적할 수 있다. 진단 이력은 LanceDB 케이스 스토어에 축적되어 규제기관 감사 시 “지속적 개선 증명” 근거로 활용된다.

핵심 설계 원칙: **“AI가 분석하고, 사람이 판단한다”** — 에이전트는 권고만 하고 최종 의사결정은 담당자가 수행. EU AI Act Art.14(인간 감독), 금융분야 AI 가이드라인 보조수단성 원칙(인적 개입), AI 기본법(킬스위치)에 구조적으로 대응.

상세 설계: Design Document 11 (docs/design/11_ops_audit_agent.typ)

시간적 팩트 스토어 (2026-04 추가)

감사 증적의 핵심 요구사항 중 하나는 **“특정 시점의 시스템 상태 복원”**이다. “2026-03-15에 고객 A에게 추천한 시점의 모델 버전, 피쳐, 판정은 무엇이었는가?” 같은 질문에 답하려면 분산된 여러 컴포넌트(AuditLogger, DiagnosticCaseStore, pipeline_state.json)를 조인해야 하는데 비용이 크다.

이 문제를 Zep/Graphiti 패턴에서 차용한 TemporalFactStore로 해결했다. 스키마는 (entity, attribute, value, valid_from, valid_to)이며, 대부분의 감사 질의가 **단일 엔티티의 시점 복원**이라 LanceDB 네이티브 필터로 해결된다.

특성	구현
삭제 불가	expire_fact()는 valid_to만 설정, 원본 보존
백엔드	DiagnosticCaseStore와 LanceDB 인스턴스 공유 (신규 의존성 0)
Z-suffix 호환	외부 쿼리의 다양한 timestamp 형식 정규화
쿼리 API	snapshot_at(), get_timeline(), expire_fact()

이 설계는 EU AI Act 제12조(기록 보관), 금융분야 AI 가이드라인(감사 추적), AI 기본법의 시계열 증적 요구사항에 부합하도록 설계된 단일 스토어 구조이다.

본 문서는 금융위 「금융분야 인공지능 가이드라인」(2026.6.22 시행)을 기준으로 2026년 6월 개정되었습니다. 가이드라인은 금융권 의견을 수렴하여 연례 업데이트되며, 동반 문서(금융분야 AI 위험관리 프레임워크, AI 보안 안내서)와 인공지능기본법 하위법령 개정에 따라 본 문서 내용도 갱신될 수 있습니다. 본 자료는 운영 준수 증빙이 아닌 Independent Research 레퍼런스의 아키텍처 정합성 자기점검이며, 구현 상태는 ● 운영 동작 / ● 구현 완료·배선 미완 / ○ 미보유의 3단계로 정직하게 구분했습니다.