

TECH REFERENCE

지식 증류 · 추천 사유 생성

기술 참조서: Temperature Scaling, FD-TVS, Grounding, LLM Safety

Author 1¹, Author 2¹

¹Organization Name
contact@org.com

범위(Scope).

- 지식 종류: PLE Teacher → LGBM Student (Temperature Scaling, custom objective, calibration)
- 피쳐 선택: LGBM gain importance 기반 1205D → task별 280D (17 feature groups, 2026-04-28)
- FD-TVS 스코어링: dynamic(segment × behavior) task 가중치 적용
- 추천 사유 생성: L1 Template → L2a LLM rewrite → L2b 3-Agent 검증 + SelfChecker
- Layer 분리: 7 distilled LGBM + 3 direct LGBM + 3 Layer-3 rule-based
- 서빙: Lambda Container Image + LanceDB(recommendation cases) + DynamoDB(cache-audit)

Contents

1 지식 종류 (Knowledge Distillation)	5
1.1 설계 철학 및 동기	5
1.1.1 핵심 문제	5
1.1.2 해결 전략	5
1.1.3 Teacher-Student 비교	5
1.2 Temperature Scaling	6
1.2.1 수학적 정의	6
1.2.2 볼츠만 분포와의 대응	6
1.2.3 Temperature 범위 설정	6
1.3 Dark Knowledge: Soft Label의 정보량	6
1.3.1 Hard Label의 한계	6
1.3.2 Soft Label의 풍부한 구조	6
1.3.3 라벨 스무딩 효과	6
1.4 Unified Distillation Loss	7
1.4.1 통합 손실 함수	7
1.4.2 T^2 보정의 수학적 유도	7
1.4.3 태스크별 손실 함수	7
1.4.4 KL-Divergence	7
1.5 LGBM 피쳐 중요도 기반 피쳐 선택	7
1.5.1 설계 근거	7
1.5.2 2단계 파이프라인	8
1.6 LightGBM Custom Objective	8
1.6.1 구현 구조	8
1.6.2 Soft Label 전달 기법	8
1.6.3 종류 성능 비교	8
1.7 10단계 DAG 오케스트레이션	8
1.8 적응형 종류 임계값	9
1.9 캘리브레이션: Platt Scaling	9
1.10 시간적 드리프트 모니터링	9
2 FD-TVS 스코어링 엔진	11
2.1 설계 철학	11
2.2 Master Formula	11

2.3	Stage 1: Task-Weighted Sum	11
2.4	Stage 2: Financial DNA Modifier	11
2.5	Stage 3: TDA Behavioral Velocity	12
2.6	Stage 4: Risk Penalty	12
2.7	Fatigue Decay	12
2.8	Confidence Formula	12
3	추천 사유 생성	13
3.1	2-Layer 아키텍처 (v3.0.0)	13
3.1.1	3-에이전트 사유 파이프라인 (L1)	13
3.2	L1 Template 생성	13
3.2.1	구조	13
3.2.2	세그먼트 인식	14
3.3	L2a LLM Rewrite	14
3.3.1	프롬프트 4계층 구조	14
3.3.2	디코딩 전략	14
3.4	Self-Critique 판정	14
3.5	L2b 3축 품질 검증	14
4	그라운드링 + 피쳐 역매핑	15
4.1	핵심 문제	15
4.2	Grounding 함수	15
4.3	734D 피쳐 벡터 구조	15
4.4	Integrated Gradients 귀인	15
4.5	Reverse Mapping 아키텍처	16
4.6	모듈 구성	16
4.7	Trust Loop	16
4.8	3중 Grounding	16
5	Safety Gate	17
5.1	다층 방어 아키텍처	17
5.2	관련 규제	17
5.3	감사 아카이빙	17
6	서빙 아키텍처	18
6.1	End-to-End 파이프라인	18
6.2	LGBM → ONNX 변환	18
6.2.1	ZipMap 제거 (필수)	18
6.2.2	변환 사양	18
6.3	Triton Inference Server 구성	18
6.3.1	모델 배치	18
6.3.2	Dynamic Batching	18
6.3.3	배치 + 실시간 하이브리드	19
6.4	Training-Serving Skew 방지	19
6.5	Calibration 고려사항	19
6.6	3계층 풀백 아키텍처	19
6.6.1	규칙 엔진 설계	19
6.7	LLM 종류: Gemini Teacher → Qwen Student (QLoRA)	20
6.7.1	두 가지 종류의 구분	20
6.7.2	QLoRA: LoRA 수학적 기초	20

6.7.3 NF4 양자화	20
6.7.4 QLoRA 메모리 분석	20
6.7.5 Self-Consistency 학습 데이터 필터링	20
7 비용 효율 및 운영 요약	21
7.1 비용 효율 요약	21
7.2 교차 관심사	21
7.2.1 금융 도메인 특화	21
7.2.2 전체 파이프라인 정합성	21
8 운영/감사 에이전트와의 연계	21
8.1 팩트 추출 레이어 (신규, 2026-04)	22
8.1.1 룰 기반, LLM 없음	22
8.1.2 L2a 프롬프트 통합	22

설계 vs 구현 차원 안내

본 문서는 **풀뱅크 설계(734D)**를 기준으로 작성되었습니다. 현재 Santander 벤치마크 구현은 **1205D 입력 (17 feature groups, 2026-04-28)**입니다. 본문의 차원 수치(734D, 200D, 140D 등)는 풀뱅크 설계 기준이며, 실제 Santander 구현에서는 중간 차원이 달라질 수 있습니다. 실제 구현의 차원 명세는 `outputs/phase0/feature_schema.json`을 참조하십시오.

지식 증류 (Knowledge Distillation)

설계 철학 및 동기

핵심 문제

PLE Teacher 모델은 약 2.6M 파라미터(AWS Santander 벤치마크 기준)이며 g4dn.xlarge GPU에서 배치 1,024건 기준 약 50ms의 추론 지연을 보인다. 수백만 고객에 대한 일일 배치 추론에서 GPU 인스턴스를 상시 운용하는 비용을 제거하고, 실시간 추천 SLA(10ms 이내)를 CPU-only Lambda에서 충족하기 위해 LightGBM Student로 증류한다.

해결 전략

Knowledge Distillation (Hinton et al., 2015)을 통해 Teacher의 출력 분포에 담긴 암묵적 지식(dark knowledge)을 LightGBM Student로 전이한다. Student는 8GB RAM CPU에서 약 5ms/1K batch로 추론하여 10배 속도 향상을 달성하면서도 성능 손실을 3%p 이내로 유지한다.

Teacher-Student 비교

속성	PLE Teacher	LGBM Student
모델 구조	PLE-adaTT + Cluster Head	LightGBM (태스크별 독립)
파라미터	~2.6M (AWS Santander)	~500 trees/task
메모리	~8GB VRAM (g4dn.xlarge GPU)	~1GB RAM (Lambda CPU)
추론 속도	~50ms / 1K batch	~5ms / 1K batch
피쳐 차원	734D(설계) / 1205D (Santander 17-group 구현)	200D (IG 선택 후, 설계 기준)
학습 데이터	원본 피쳐 + 라벨	원본 피쳐 + Hard Label + Soft Label

Cross-architecture distillation (DNN → GBDT)이 가능한 이유는 지식 증류가 파라미터가 아닌 출력 분포를 통해 지식을 전달하기 때문이다. “딥러닝으로 학습, GBDT로 서빙”은 추천, 금융, 광고 도메인의 사실상 표준이다 (Borisov et al., NeurIPS 2022).

Temperature Scaling

수학적 정의

표준 softmax에 Temperature 파라미터 T 를 도입한다.

$$p_i^T = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)} \quad (1)$$

- $T = 1$: 표준 softmax. 최대 로짓에 확률이 집중된다.
- $T = 5$ (기본값): 클래스 간 상대적 관계가 드러나는 평할 분포.
- $T \rightarrow \infty$: 균등 분포. 정보가 소실된다.

볼츠만 분포와의 대응

이 수식은 통계역학의 볼츠만 분포 $P(E_i) = \exp(-E_i/(k_B T))/Z$ 와 수학적으로 동치(isomorphic)이다. 로짓 z_i 는 (음의) 에너지, T 는 절대 온도에 대응하며, 두 분야가 동일한 지수 족(exponential family) 분포를 공유한다.

Temperature 범위 설정

$T \in [3, 7]$ 로 제한한다.

- $T = 3$: 이진 태스크 (CTR, CVR, Churn, Retention)
- $T = 5$: 기본값
- $T = 7$: 다중 클래스 태스크 (NBA 12-class, Timing 28-class)
- $T > 10$: 과도한 정보 손실 위험

LGBM Student의 Temperature

LGBM Student에게 soft label을 전달할 때는 $T = 1$ (표준 softmax)를 사용한다. LGBM의 custom objective는 확률 벡터를 직접 수신하므로, GBDT 내부 최적화 위에 $T > 1$ 평활화를 추가 적용하면 오히려 캘리브레이션이 저하될 수 있다. $T = 3-5$ 범위는 신경망 간(neural-to-neural) 증류에 적합하며, DNN→GBDT 증류에는 해당하지 않는다.

Dark Knowledge: Soft Label의 정보량

Hard Label의 한계

Hard Label (one-hot)은 $\log_2(C)$ 비트의 정보만 인코딩한다. NBA 12-class에서 약 3.6비트이며, 차선택 클래스 간 관계 정보를 전혀 포함하지 않는다.

Soft Label의 풍부한 구조

Teacher의 softmax 출력은 $(C - 1)$ 개의 연속 확률값을 담고 있어 $\log_2(C)$ 보다 훨씬 많은 정보를 제공한다.

$$p_{\text{teacher}} = [0.72, 0.14, 0.08, 0.03, 0.01, \dots] \quad (2)$$

이 분포에서 주요 답변(72%), 차선택 구조(B 14% > C 8%), 클래스 간 유사성, 불확실성 수준까지 읽어낼 수 있다. 이것이 Hinton이 명명한 Dark Knowledge 이다.

라벨 스무딩 효과

Soft Label 학습은 Label Smoothing과 유사한 정규화 효과를 가진다. Hard Label이 확률 0 또는 1의 극단으로 모델을 밀어붙이는 반면(과적합 유도), Soft Label은 합리적인 확률 분포를 출력하도록 유도하여 일반화를 촉진한다.

Unified Distillation Loss

통합 손실 함수

$$\mathcal{L}_{\text{distill}} = \alpha \cdot \mathcal{L}_{\text{hard}} + (1 - \alpha) \cdot T^2 \cdot \mathcal{L}_{\text{soft}} \quad (3)$$

- α : Hard/Soft 비율 (기본값 0.3, 즉 30% ground truth + 70% Teacher 의견)
- T^2 : 그래디언트 크기 보정 스케일링

T^2 보정의 수학적 유도

Chain rule로부터 $\partial \hat{y} / \partial z = (1/T) \sigma(z/T) (1 - \sigma(z/T))$ 이다. $1/T$ 인자가 누적되어 전체 그래디언트가 $1/T^2$ 로 축소된다. T^2 를 곱함으로써 원래 스케일을 복원한다. $T = 5$ 일 때 그래디언트는 $1/25$ 로 축소되므로 $T^2 = 25$ 를 곱하여 보정한다.

태스크별 손실 함수

이진 분류 (CTR, CVR, Churn, Retention):

$$\mathcal{L}_{\text{binary}} = \alpha \cdot \text{BCE}(\hat{y}, y) + (1 - \alpha) \cdot T^2 \cdot D_{\text{KL}}(p_t \parallel p_s) \quad (4)$$

여기서 $p_t = \sigma(z_t/T)$, $p_s = \sigma(z_s/T)$ 이다.

다중 클래스 (NBA 12-class, Life-stage 6-class, Timing 28-class):

$$\mathcal{L}_{\text{multi}} = \alpha \cdot \text{CE}(z_s, y) + (1 - \alpha) \cdot T^2 \cdot D_{\text{KL}}(\text{softmax}(z_t/T) \parallel \text{softmax}(z_s/T)) \quad (5)$$

회귀 (LTV, Engagement):

$$\mathcal{L}_{\text{reg}} = \alpha \cdot \text{MSE}(\hat{y}_s, y) + (1 - \alpha) \cdot \text{MSE}(\hat{y}_s, \hat{y}_t) \quad (6)$$

회귀에서는 Temperature Scaling이 무의미하므로 T^2 보정을 적용하지 않는다.

KL-Divergence

$$D_{\text{KL}}(q \parallel p) = \sum_i q_i \log \frac{q_i}{p_i} = \underbrace{-H(q)}_{\text{상수}} + \underbrace{H(q, p)}_{\text{교차 엔트로피}} \quad (7)$$

Forward KL $D_{\text{KL}}(\text{Teacher} \parallel \text{Student})$ 를 사용한다. 이는 mean-seeking 특성으로 Student가 Teacher의 모든 중요 모드를 커버하도록 강제한다. Reverse KL은 mode-seeking 특성으로 일부 모드를 무시할 위험이 있어 증류에 부적합하다.

LGBM 피쳐 중요도 기반 피쳐 선택

피쳐 선택은 학습된 LGBM Student 모델의 **gain importance**를 기반으로 수행된다. 교사 모델 IG(Integrated Gradients) 귀인은 사용하지 않는다 — 교사는 이미 증류 완료된 상태이며, 서빙 모델(LGBM Student)의 관점에서 중요한 피쳐를 선택하는 것이 설계 목적과 일치한다.

설계 근거

서빙 모델 정렬: 배포된 모델은 LGBM Student이다. Gain importance는 LGBM이 실제로 사용하는 피쳐를 반영한다. 교사(PLE) IG 귀인은 심층 신경망과 그래디언트 부스팅 간 아키텍처 차이로 인해 Student 중요도와 크게 다를 수 있다.

운영 안정성: LGBM gain 계산은 학습된 Student에 대한 빠른 사후 처리 단계이다. 교사 IG는 941K 고객 × 1205D 피쳐 스케일에서 전체 PLE 그래프에 대한 역전파를 요구하여 OOM 장애를 유발한다.

해석 가능성 정렬: LGBM Student에서 도출된 SHAP/gain 설명은 추천을 생성한 모델에 직접 근거하여, EU AI Act 제13조(실제 결정 메커니즘 반영 설명) 요건을 충족한다.

2단계 파이프라인

아래 차원 수치는 풀뱅크 설계(734D) 기준입니다. Santander 17-group 구현은 1205D 입력입니다.

풀뱅크 설계 기준: 734D(설계) / 1205D (Santander 17-group 구현) → 140D(Stage 1) → 최종 LGBM 입력

Stage 1 – LGBM Gain Importance 필터: 누적 gain importance 기준 상위 95%를 포착하는 상위- k 피쳐를 태스크별로 유지한다. 결과 피쳐 집합은 일반적으로 태스크당 40~80개 피쳐이다(전체 입력 차원에서 축소).

Stage 2 – 필수 피쳐 보존: LGBM importance와 무관하게 항상 포함하는 7개 피쳐:

- TDA: persistence_entropy, landscape_peak
- Economics: mpc, income_elasticity, permanent_income_ratio
- FinEng: sharpe_ratio, volatility

LightGBM Custom Objective

구현 구조

DistillationLossNumpy가 LightGBM의 fobj에 gradient/hessian을 제공한다.

$$\text{grad} = \alpha \cdot \text{grad}_{\text{hard}} + (1 - \alpha) \cdot T^2 \cdot \text{grad}_{\text{soft}} \quad (8)$$

$$\text{hess} = \alpha \cdot \text{hess}_{\text{hard}} + (1 - \alpha) \cdot T^2 \cdot \text{hess}_{\text{soft}} \quad (9)$$

Soft Label 전달 기법

LightGBM Dataset은 label과 weight만 지원하므로, Hard Label은 get_label(), Soft Label은 get_weight()를 통해 전달한다.

종류 성능 비교

방법	CTR AUC	NBA Accuracy	LTV RMSE
LGBM (Hard Label only)	0.812	0.634	1.247
LGBM (Distilled, $T = 5$)	0.841	0.698	1.089
PLE Teacher (원본)	0.856	0.723	1.021

10단계 DAG 오케스트레이션

전체 종류 파이프라인은 distillation_entrypoint.py에서 10단계 DAG로 실행된다.

단계	내용
----	----

1	Teacher 추론 (전체 데이터에 대한 로짓 생성)
2	Soft Label 생성 (Temperature Scaling 적용)
3	LGBM gain importance 피쳐 선택 (1205D → task별 140D)
4	Student 학습 (태스크별 독립 LGBM)
5	검증 (5개 기준: AUC, RMSE, Accuracy 등; 메트릭 집계는 태스크 타입별 — 이진 태스크: AUC, 회귀 태스크: RMSE, 다중 클래스: top-k Accuracy)
6	MLflow 모델 레지스트리 등록
7	ONNX 변환 (ZipMap 제거 포함)
8	Triton 패키징 (config.pbtxt 생성)
9	통합 검증 (ONNX-PyTorch 수치 동치성)
10	배포 아티팩트 업로드

적응형 종류 임계값

증류된 LGBM은 무조건 수용되지 않습니다. 수용을 위해서는 태스크별로 **랜덤 기준선의 2배** 이상의 적응형 임계값을 충족해야 합니다. 이 하한선 미만이면 Student는 SKIP으로 분류되고, 종류 라운드는 폐기되며 Teacher 직접 추론 경로가 활성화됩니다.

태스크 유형	하한 임계값	SKIP 정책
이진 (CTR/CVR/Churn)	$AUC > 0.5 + \delta_{\min}$ (랜덤 2배)	Student 폐기, 2계층 (Teacher 직접) 활성화
다중 클래스 (NBA)	Top-1 정확도 $> 1/C + \delta_{\min}$	Student 폐기, 인기도 규칙으로 폴백
회귀 (LTV)	RMSE $<$ 기준선 평균 예측기	Student 폐기, 전역 평균 사용

이는 단순 기준선보다 나쁜 종류 모델의 배포를 방지하여, 가이드라인 거버넌스 원칙 §1.4(출시 전 위험경감 조치 검증)에 대응합니다.

캘리브레이션: Platt Scaling

FD-TVS Stage 1은 모든 태스크 확률이 공통 $[0, 1]$ 스케일에 있을 것을 요구합니다. 확률이 중요한 태스크(이탈, product_stability, cross_sell_count)에는 종류 후 **Platt scaling**을 적용합니다.

$$p_{\text{calibrated}} = \sigma(a \cdot f(x) + b) \quad (10)$$

여기서 $f(x)$ 는 LGBM 원시 점수이고, a, b 는 홀드아웃 캘리브레이션 세트(학습 데이터 제외)에서 적합됩니다. 캘리브레이션은 ECE(Expected Calibration Error)를 줄이고, 예측 확률 0.8이 실제 양성률 약 80%에 대응하도록 보장합니다.

시간적 드리프트 모니터링

모집단 수준의 PSI 외에도 세 가지 지표가 종류 LGBM 입력 피쳐와 예측 출력의 분포 이동을 시계열로 감시합니다.

지표	감지 대상	임계값
PSI (모집단 안정성 지수)	전체 입력 분포 이동	> 0.25 critical
JSD (Jensen-Shannon 발산)	대칭적 분포 거리; KL보다 근-영 셀에 안정적	> 0.10 alert
순위 상관 (Spearman)	재학습 주기 간 피쳐 중요도 순위 안정성	< 0.70 alert

세 가지 모두 피쳐별로 일간 계산됩니다. ConsecutiveDriftTracker는 PSI > 0.25가 3일 연속 지속될 때 자동 재학습을 트리거합니다. JSD 및 순위 상관 경고는 OpsAgent에 전달되어 서술적 분석이 이루어집니다.

FD-TVS 스코어링 엔진

설계 철학

FD-TVS (Financial DNA-based Target Value Score)는 4단계 복합 스코어링 엔진으로, 모델 예측과 고객 수준 비즈니스 맥락을 결합한다. 핵심 설계 원칙은 **곱셈적 결합(multiplicative combination)**이다. 어떤 단일 요소라도 0에 접근하면 전체 점수가 거부(veto)되어 "리스크 우선(risk-first)" 원칙을 강제한다.

단순 합산 $\sum p_i$ 는 윈도우 쇼퍼 (CTR=0.9, CVR=0.1)와 실구매자 (CTR=0.5, CVR=0.5)를 구분하지 못한다 — 둘 다 합이 1.0이다. 곱셈 구조는 각 차원에 거부권(veto power)을 부여한다.

Master Formula

$$\text{FD-TVS} = \underbrace{S_{\text{task}}}_{\text{What}} \times \underbrace{W_{\text{DNA}}}_{\text{Who}} \times \underbrace{V_{\text{TDA}}}_{\text{When}} \times \underbrace{(1-R)}_{\text{Safe?}} \times \underbrace{f \cdot e}_{\text{Appropriate?}} \quad (11)$$

구성 요소	설명	범위
S_{task}	Task Weighted Sum	[0, 1]
W_{DNA}	Financial DNA Modifier	{0.8, 1.0, 1.2}
V_{TDA}	Behavioral Velocity	[1.0, 1.15]
R	Risk Penalty	[0, 1]
f	Fatigue Decay	[0, 1]
e	Engagement Boost	[0.85, 1.15]

Stage 1: Task-Weighted Sum

$$S_{\text{task}} = \beta_{\text{CTR}} \cdot p_{\text{CTR}} + \beta_{\text{CVR}} \cdot p_{\text{CVR}} + \beta_{\text{NBA}} \cdot p_{\text{NBA}} + \beta_{\text{LTV}} \cdot p_{\text{LTV}} \quad (12)$$

기본 가중치: CVR=0.4 (최고, 전환이 매출에 직결), CTR=0.3, NBA=0.2, LTV=0.1. $\sum \beta_i = 1$ 이고 모든 $p_i \in [0, 1]$ 이면 $S_{\text{task}} \in [0, 1]$ 이 보장되는 WSM (Weighted Sum Model, Fishburn 1967) 볼록 결합(convex combination)이다.

Stage 2: Financial DNA Modifier

Friedman의 항상소득가설(Permanent Income Hypothesis, 1957)에 기초한다. 소비자는 일시적 소득 변동이 아닌 항상(안정) 소득에 기반하여 소비를 결정한다.

$$W_{\text{DNA}} = \begin{cases} 1.2 & \text{if } CV < 0.2 \quad (\text{Permanent -- 안정 소득}) \\ 1.0 & \text{if } 0.2 \leq CV < 0.5 \quad (\text{Mixed}) \\ 0.8 & \text{if } CV \geq 0.5 \quad (\text{Transitory -- 불안정}) \end{cases} \quad (13)$$

여기서 $CV = \sigma_{\text{income}} / \mu_{\text{income}}$ (변동 계수, 무차원)이다. 안정 소득 고객은 장기 금융 상품(연금, 정기예금)에 적합하므로 추천 점수를 20% 상향한다.

Stage 3: TDA Behavioral Velocity

$$V_{\text{TDA}} = 1.0 + \gamma_{\text{flare}} \cdot \mathbb{1}[\text{flare}_{\text{detected}}] \quad (14)$$

$\gamma_{\text{flare}} = 0.15$ 이다. TDA flare 감지는 행동 변화 가속을 나타내며, 점수를 최대 15% 상향한다.

Stage 4: Risk Penalty

$$R = 0.2 \cdot I_{\text{limit}} + 0.3 \cdot I_{\text{fatigue}} + 0.5 \cdot I_{\text{churn}} \quad (15)$$

비대칭 가중치의 근거 – 비가역성(irreversibility):

- 신용한도 소진 ($\lambda_1 = 0.2$): 가역적 (상환으로 한도 복원)
- 메시지 피로 ($\lambda_2 = 0.3$): 부분 가역 (시간이 지나면 회복)
- 고객 이탈 ($\lambda_3 = 0.5$): 거의 비가역 (재획득 비용이 신규 대비 5-7배)

$(1 - R)$ 은 곱셈적 거부권을 행사한다. $R \rightarrow 1$ 이면 다른 요소와 무관하게 점수가 0으로 수렴한다. 로그 공간에서 $\ln(1 - R) \rightarrow -\infty$ as $R \rightarrow 1$ 이다.

Fatigue Decay

$$f(n) = e^{-\lambda n} \quad (16)$$

지수적 감쇠로 **일정 비율 감소(constant fractional decay)**를 구현한다. $f(n+1)/f(n) = e^{-\lambda}$ (상수 비율).

반감기: $n_{1/2} = \ln 2 / \lambda$. App Push ($\lambda = 0.4$): 반감기 ≈ 1.73 회. Email ($\lambda = 0.15$): 반감기 ≈ 4.62 회.

Confidence Formula

$$\text{confidence} = |p - 0.5| \times 2 \quad (17)$$

결정 경계(0.5)로부터의 거리를 $[0, 1]$ 로 정규화한다. 낮은 confidence 예측은 추천 품질 필터에서 후순위로 처리한다.

추천 사유 생성

2-Layer 아키텍처 (v3.0.0)

설계 철학: “전 고객에게 동등한 사유를, 컨텍스트 풍부 고객에게 LLM 강화 사유를.”

Layer	대상	방식	LLM 호출	처리량
L1	1,200만 전량	3-에이전트 파이프라인 (FactExtractor → InterpretationRegistry → TemplateEngine → Self-Checker)	0	~20분
L2a	~50만/주	LLM rewrite (Bedrock Claude Haiku, 3-layer safety gate)	1	~1.0초/건
L2b	~6.7만 샘플링	품질 검증 (Bedrock Claude Haiku; 사실성, 관련성, 자연스러움)	1	—

3-에이전트 사유 파이프라인 (L1)

L1 사유 생성은 결정론적 4단계 에이전트 파이프라인으로 실행됩니다 — LLM 호출 없음.

- FactExtractor:** YAML 설정 Python 표현식을 통해 피쳐 값에서 고객 수준 서술적 팩트를 추출합니다(예: “예적 금 중심 포트폴리오”, “리스크 회피 성향”). 샌드박스 환경에서 완전 결정론적으로 동작합니다.
- InterpretationRegistry:** 사전 등록된 3-tuple 풍부화(피쳐 → display_name, 방향, 설명)를 통해 IG 귀인 상위 5개 피쳐를 금융 언어로 매핑합니다. 항목이 없으면 ReverseMapper(Level RM)로 폴백합니다.
- TemplateEngine:** $\text{hash}(\text{customer_id} : \text{category}) \bmod 5$ 로 템플릿 변형을 선택하고 FactExtractor 출력 + IG 해석을 주입합니다.
- SelfChecker:** 3-stage 검증 게이트 — (1) compliance: 금지 패턴(비교 광고, 수익 보장 표현 등) 규칙 매칭, (2) injection: 프롬프트 인젝션 패턴 탐지, (3) factuality: LLM 기반 사실성 검증. 세 단계 모두 통과한 사유만 release.

규제 근거: 금융소비자보호법 제19조는 전 고객에 대한 동등한 설명의무를 요구한다. L1이 1,200만 전량에 비용 0의 템플릿을 제공하여 이를 충족한다.

비용 효율: 전량 LLM 처리 시 ~1,000 GPU-hours 소요. 2-Layer 설계는 ~162 GPU-hours로 달성한다.

L1 Template 생성

구조

6 categories × 5 variants = 30개 템플릿.

결정론적 변형 선택:

$$\text{variant}_{\text{index}} = \text{hash}(\text{customer_id} : \text{category}) \bmod 5 \quad (18)$$

동일 고객은 항상 동일 변형을 수신한다 (일관성 + 감사 재현성).

세그먼트 인식

- **WARMSTART**: IG Top-3 역매핑 기반 사유
- **COLDSTART**: 인기도 + 혜택 기반 사유
- **ANONYMOUS**: 일반적 인기도 기반 사유

규칙 기반 컴플라이언스 검사 후 AI 생성 고지 문구를 자동 부착한다.

L2a LLM Rewrite

우선순위 큐: rich 먼저, moderate 다음, sparse 제외. 3-Layer Safety Gate를 통과한 후 rewrite가 적용된다. **AWS 배포**: Bedrock Claude Haiku (\$0.25/1M input tokens; VPC PrivateLink; Anthropic으로 데이터 미전송). **온프레미스**: RTX 4070 (12GB VRAM)에서 vLLM Qwen3-8B-AWQ 구동.

프롬프트 4계층 구조

1. **System 프롬프트**: 역할 정의 (금융 추천 사유 전문가) + 금소법 위반 금지 규칙
2. **Few-shot 예제**: 세그먼트별 톤·형식 가이드
3. **Context 주입**: 고객 피쳐, IG 기여도, 상담 이력 → 자연어 변환
4. **출력 형식**: JSON 스키마 (`{"reasons": [...], "summary": "..."}`)

디코딩 전략

- 사유 생성: $\tau = 0.3$ (사실 보존 + 약간의 다양성)
- Critique: $\tau = 0.1$ (거의 결정론적, 일관된 품질 평가)
- L2a Rewrite: $\tau = 0.3$ (원본 사실 유지, 표현 윤색)

Self-Critique 판정

$$\text{verdict} = \begin{cases} \text{pass} & \text{if } f \geq 0.8 \text{ and } c \geq 1.0 \\ \text{revise} & \text{if } f \geq 0.5 \text{ and } c \geq 1.0 \\ \text{reject} & \text{otherwise} \end{cases} \quad (19)$$

- f : 사실성 점수 (연속값)
- c : 컴플라이언스 점수 (이진: 1.0 = 위반 없음)

컴플라이언스 절대 우선: 규제 위반($c < 1.0$)이 있으면 사실성과 무관하게 즉시 거부. **최대 1회 수정**: 수정 후에도 "revise"이면 안전 템플릿으로 폴백 (무한 루프 방지, LLM 호출 최대 3회).

L2b 3축 품질 검증

$$\text{verdict} = \begin{cases} \text{pass} & \text{if } f \geq 0.7 \text{ and } r \geq 0.7 \text{ and } n \geq 0.7 \\ \text{needs}_{\text{improvement}} & \text{if any score} \in [0.5, 0.7) \\ \text{fail} & \text{if any score} < 0.5 \end{cases} \quad (20)$$

- f : 사실성, r : 관련성, n : 자연스러움
- 임계값 0.7 (Self-Critique의 0.8보다 낮음): L2b는 사후 모니터링이며 실시간 게이트키퍼가 아니므로

그라운드링 + 피쳐 역매핑

핵심 문제

PLE-adaTT는 피쳐 벡터(풀뱅크 설계: 734D; 현재 Santander 17-group 구현: 1205D)를 소비하여 확률 점수를 출력하지만 왜 그 추천을 했는지 설명하지 못한다. AI 기본법 제31조·제34조, 금융소비자보호법 제19조는 유의미한 설명을 요구한다.

Grounding 함수

$$f: \mathbb{R}^{644} \times \mathcal{I} \rightarrow \mathcal{L} \quad (21)$$

여기서 $\mathbb{R}^{644}$ 은 정규화 피쳐 벡터 공간, $\mathcal{I}$ 는 IG 귀인 정보, $\mathcal{L}$ 은 자연어 설명 공간이다.

734D 피쳐 벡터 구조

범위	차원	내용
profile	0-238	Demographics (100D) + RFM (50D) + Financial Summary (88D)
multi_source	238-329	Transaction stats (40D) + Behavioral patterns (51D)
extended_source	329-413	보험, 상담, STT, 캠페인, 해외, 오픈뱅킹
domain	413-572	TDA (70D) + GMM (22D) + Mamba (50D) + Economics (17D)
model_derived	572-599	HMM summary, Bandit/MAB, LNN
multidisciplinary	599-623	전환 역학, 채택 역학, 교차 패턴, 루틴 분석
merchant_hierarchy	623-644	MCC levels, brand embeddings, 통계, radius

총 644D 정규화 + 90D raw power-law = 734D 모델 입력.

Integrated Gradients 귀인

$$\text{IG}_i(\mathbf{x}) = (x_i - x'_i) \times \int_0^1 \frac{\partial F(\mathbf{x}' + \alpha(\mathbf{x} - \mathbf{x}'))}{\partial x_i} d\alpha \quad (22)$$

IG가 SHAP보다 적합한 이유:

- SHAP: 풀뱅크 규모에서 2^{734} 부분집합 평가 필요 (불가능)
- IG: 50-step 사다리꼴 근사로 선형 시간 계산
- **완전성 공리:** $\sum_i \text{IG}_i(\mathbf{x}) = F(\mathbf{x}) - F(\mathbf{x}')$ (벡터 해석학의 그래디언트 정리에 의해 보장)
- **Baseline:** 영벡터 (정규화된 피쳐에서 "평균 고객"에 해당)

Reverse Mapping 아키텍처

$$\text{ReverseMap} : (x \in \mathbb{R}^d, a \in \mathbb{R}^d) \rightarrow \{(r_k, s_k, t_k)\}_{k=1}^K \quad (23)$$

- x : 피쳐 벡터, a : IG 귀인 벡터
- r_k : 피쳐 범위 이름, s_k : 요약 점수, t_k : 금융 언어 텍스트

서브레인지 슬라이싱: $t_k = \mathcal{M}_k(g(x[s_k : e_k]))$ 여기서 g 는 집계 함수 (mean, argmax, threshold 비교), $\mathcal{M}_k$ 는 도메인 전문가가 설계한 매핑 딕셔너리 (수치 $\rightarrow$ 텍스트)이다.

모듈 구성

- **FeatureReverseMapper:** 644D 벡터 $\rightarrow$ 금융 언어 텍스트 (계층적 범위 슬라이싱)
- **MultidisciplinaryInterpreter:** 24D 다학제 피쳐 $\rightarrow$ 비즈니스 해석 (4개 서브도메인)
- **LanceContextVectorStore:** LanceDB 기반 고객 컨텍스트 저장/검색 (768D 임베딩 L2 거리)
- **ContextAssemblyAgent:** IG 기반 도구 선택 + 다중 소스 컨텍스트 조립
- **ConsultationContextExtractor:** STT 상담 이력 추출 + 요약

Trust Loop

모델 예측 $\rightarrow$ LGBM gain 귀인 $\rightarrow$ 역매핑 $\rightarrow$ 컨텍스트 조립 $\rightarrow$ LLM 사유 생성 $\rightarrow$ 상담원 전달 $\rightarrow$ 고객 설득 $\rightarrow$ 전환/피드백 $\rightarrow$ 모델 개선.

역매핑과 컨텍스트 조립 없이는 모델 예측과 상담원 전달 사이에 해석가능성 간극이 발생하여 이 Trust Loop가 단절된다.

3중 Grounding

1. **피쳐 Grounding:** IG Top-5 귀인을 프롬프트에 주입 $\rightarrow$ LLM이 실제 모델 판단 근거에 기반하여 사유 생성
2. **고객 Grounding:** 세그먼트, 거래 패턴, 상담 이력 주입 $\rightarrow$ 환각(hallucination) 억제
3. **규정 Grounding:** 시스템 프롬프트 금지 규칙 + Rule-based Self-Critique $\rightarrow$ 컴플라이언스 강제

Safety Gate

다층 방어 아키텍처

금소법 및 AI 기본법 준수를 위한 6계층 안전 장치이다.

계층	메커니즘	대상 규제
1	System 프롬프트: 불변 규제 금지 규칙	AI 기본법 제31조·제34조
2	Self-Critique: 실시간 게이트키퍼 ($f \geq 0.8, c = 1.0$)	금소법 제19조·제21조
3	3-Layer Safety Gate: 프롬프트 인젝션 탐지 + 사실성 + 규제 준수	금소법 제22조
4	L2b Quality Validation: 사후 모니터링 3축 평가	내부 품질 기준
5	AI Security Checker: 인젝션 탐지 + 컴플라이언스 검증	AI 기본법 제34조
6	Audit Archiver: 불변 Parquet 레코드 (DuckDB 기반 조회)	금융감독원 사후 검사

관련 규제

- **AI 기본법 제31조** (AI 사용 고지): 모든 추천 사유에 AI 생성 고지 문구 자동 부착
- **AI 기본법 제34조** (위험관리): Safety Gate + 감사 추적
- **금융소비자보호법 제19조** (적합성 원칙 + 설명의무): L1이 전량 커버리지 보장
- **금융소비자보호법 제21조** (광고 규제): 금지 패턴 탐지
- **금융소비자보호법 제22조** (불공정행위 금지): 컴플라이언스 점수 검증

감사 아카이빙

RecommendationAuditArchiver가 모든 추천 건을 Parquet으로 영속 저장한다.

- IG 귀인 점수, L1 사유, L2a rewrite 결과, L2b 검증 결과, 처리 시간
- DuckDB 기반 효율적 소급 조회
- 금융감독원 사후 검사 시 개별 추천 건의 전체 의사결정 경로 추적 가능

서빙 아키텍처

End-to-End 파이프라인

PLE-adaTT Teacher (학습)

```
| -> Knowledge Distillation (T=5, alpha=0.3) + 적응형 임계값 (랜덤 2배 하한)
| -> LGBM Student (태스크별, 200D 피쳐) + Platt 캘리브레이션 (확률 중요 태스크)
| -> ONNX Export (ZipMap 제거)
| -> Lambda FallbackRouter
|   | -> 1계층: LGBM ONNX (기본)
|   | -> 2계층: PLE SageMaker Endpoint (폴오버)
|   | -> 3계층: 규칙 엔진 (12개 태스크, Financial DNA 라우팅)
| -> FD-TVS Scoring (4-Stage)
|   | -> Feature Grounding (IG -> Reverse Mapping -> Context Assembly)
|   | -> Recommendation Reason
|     L1: FactExtractor -> InterpretationRegistry -> TemplateEngine -> SelfChecker
|     L2a: Bedrock Claude Haiku (rewrite)
|     L2b: Bedrock Claude Haiku (검증)
| -> Audit Archive (Parquet, ComplianceAuditStore)
```

LGBM → ONNX 변환

ZipMap 제거 (필수)

LightGBM의 ONNX 변환은 ZipMap 연산자를 추가하여 딕셔너리 출력을 생성한다. Triton은 텐서 출력만 지원하므로 ONNX 그래프에서 ZipMap 노드를 우회하여 제거해야 한다.

변환 사양

- Opset 13: LightGBM 연산자 전체 지원
- 2단계 검증: (1) onnx.checker.check_model 스펙 적합성, (2) 더미 추론 수치 동치성 테스트

Triton Inference Server 구성

모델 배치

15개 ONNX 모델 (태스크별) + 1 전처리기 + 1 후처리기 + 15 앙상블 스케줄러 = **32개 모델 설정**.

Dynamic Batching

- Preferred batch sizes: [256, 512, 1024]
- Max queue delay: 100μs
- 전처리기: CPU × 4 인스턴스 (CPU-bound JSON 파싱)
- ONNX 모델: GPU × 2 인스턴스

배치 + 실시간 하이브리드

일일 배치로 전체 고객 기본 점수를 산출하고, 실시간 거래 발생 시 Redis 캐시의 실시간 피처를 반영하여 FD-TVS 점수를 즉시 재계산한다. Triton Dynamic Batching이 개별 실시간 요청을 큐에 모아 마이크로배치로 처리하여 GPU 활용률을 유지한다.

Training-Serving Skew 방지

Feature Serving Spec이 학습과 서빙을 연결한다.

- feature_selector가 학습 시 selected_features_{task}.json을 출력
- FeatureServingSpec이 배포 시점에 이를 로드하여 동일한 피처 순서를 보장
- 7개 필수 피처 (TDA, Economics, FinEng)는 항상 포함

Calibration 고려사항

FD-TVS Stage 1은 모든 태스크 확률이 공통 스케일 $[0, 1]$ 에 있을 것을 요구한다. 확률이 중요한 태스크(이탈, product_stability, cross_sell_count)는 종류 후 Platt scaling을 적용한다(\$1 캘리브레이션 참조). 나머지 태스크에는 Temperature Scaling(Guo et al., ICML 2017)을 경량 대안으로 사용한다.

3계층 풀백 아키텍처

Lambda 서빙 레이어는 가용성과 신뢰도에 따라 세 계층 중 하나를 선택하는 FallbackRouter를 구현한다.

계층	메커니즘	생성 출력
1계층: 증류 LGBM	Lambda를 통한 ONNX 모델; 태스크별 Platt 캘리브레이션	scores, contributing_features (IG top-5)
2계층: PLE 직접 추론	SageMaker Endpoint; LGBM SKIP 또는 Lambda cold-start 실패 시 활성화	scores, contributing_features (IG top-5)
3계층: 규칙 엔진	Python 규칙 셋: 12개 태스크별 규칙 + Financial DNA 피처 라우팅	scores (휴리스틱), contributing_features (규칙 기반)

세 계층 모두 contributing_features를 생성하여 성능 저하 서빙 시에도 AI 기본법 제34조 및 금소법 제19조에 따른 설명 컴플라이언스를 유지한다.

규칙 엔진 설계

규칙 엔진은 Financial DNA 피처 라우팅을 중심으로 구성된 12개 태스크별 규칙을 구현한다.

- **DNA 라우팅:** 향상소득 고객($CV < 0.2$) → 장기 상품 규칙; 일시소득 고객($CV \geq 0.5$) → 단기·저관여 규칙
- **태스크 규칙:** 12개 태스크 각각에 3~5개 해석 가능한 피처 기반 휴리스틱 점수 함수 (예: 이탈 규칙은 최신성 + 빈도 + 고객지원 통화 수 사용)
- **contributing_features:** 규칙이 규칙을 트리거한 상위 3개 피처를 선택하여 사유 생성 파이프라인에 contributing_features로 반환

LLM 종류: Gemini Teacher → Qwen Student (QLoRA)

두 가지 종류의 구분

측면	예측 모델 종류	LLM 종류
목적	예측 정확도	텍스트 생성 품질
Teacher	PLE-Cluster-adaTT	Google Gemini
Student	LightGBM	Qwen3-8B (온프레미스)
전달 대상	Soft labels (logits/probs)	텍스트 출력 (추천 사유)
손실 함수	KL Divergence + CE	Cross-Entropy (SFT)
학습 방법	Soft label learning	QLoRA fine-tuning

AWS 서빙 참고: 프로덕션 AWS Lambda에서 L2a rewrite와 L2b 검증은 **Bedrock Claude Haiku**를 사용합니다(Qwen3-8B 아님). Qwen3-8B QLoRA는 온프레미스 대안입니다. 두 경로 모두 동일한 PromptSanitizer와 3-Layer Safety Gate를 공유합니다.

QLoRA: LoRA 수학적 기초

$$W' = W_0 + \Delta W = W_0 + BA \quad (24)$$

- $W_0 \in \mathbb{R}^{d \times k}$: 원본 사전학습 가중치 (동결)
- $B \in \mathbb{R}^{d \times r}$: Down-projection (학습 가능)
- $A \in \mathbb{R}^{r \times k}$: Up-projection (학습 가능)
- $r \ll \min(d, k)$: Rank ($r = 16$ 에서 원본 대비 0.78%)

압축률: $r \times (d + k) / (d \times k)$. Qwen3-8B ($d = k = 4096, r = 16$): $131,072 / 16,777,216 \approx 0.78\%$.

NF4 양자화

분포 인식(distribution-aware) 양자화로 표준정규분포의 분위수에 양자화 수준을 배치한다.

$$q_i = \Phi^{-1}(i / (2^k + 1)) \quad (25)$$

각 수준이 동일한 확률 질량을 커버하여 Lloyd-Max 최적 조건을 충족한다.

QLoRA 메모리 분석

- Full FT (FP16): 가중치 16GB + 옵티마이저 32GB + 그래디언트 16GB = 64GB+ (RTX 4070 불가)
- QLoRA: 베이스 모델 4GB (NF4) + LoRA 어댑터 ~40MB = **6GB로 학습 가능**

Self-Consistency 학습 데이터 필터링

$$\text{consistency}(s_1, s_2, s_3) = \min_{i \neq j} \text{BERTScore}(s_i, s_j) \quad (26)$$

Gemini Teacher로 동일 입력에 대해 3회 출력을 생성하고, 최소 쌍별 BERTScore를 보수적 일관성 척도로 사용한다. 일관된 출력만 학습 데이터에 포함하여 Teacher 환각을 필터링한다.

비용 효율 및 운영 요약

비용 효율 요약

구성 요소	설계 선택	효과
2-Layer 사유 생성	L1 Template + L2 LLM	162 vs 1,000 GPU-hours
LGBM Student	CPU 추론	GPU Teacher 대비 1/10 비용
QLoRA	NF4 + LoRA	6GB vs 64GB+ 학습
Triton Dynamic Batching	마이크로배치 큐잉	GPU 활용률 극대화

교차 관심사

금융 도메인 특화

- **종류:** TDA, Economics, FinEng 필수 피처를 IG importance와 무관하게 보존
- **스코어링:** Friedman 향상소득가설 기반 DNA modifier, 비가역성 기반 비대칭 리스크 가중
- **그라운드링:** 도메인 전문가 설계 매핑 딕셔너리로 금융 언어 번역
- **사유 생성:** 규정 우선 설계 (규제가 품질을 우선)
- **LLM 종류:** 금융 용어, 컴플라이언스 인식 톤, 상품 특화 지식 전이

전체 파이프라인 정합성

종류 → 서빙 → 스코어링 → 그라운드링 → 사유 생성 → 감사의 각 단계는 Feature Serving Spec, IG 귀인, 역매핑 딕셔너리라는 공유 계약을 통해 End-to-End 정합성을 유지한다. 어떤 단계에서든 이 계약이 깨지면 하류 단계 전체에 오류가 전파되므로, 단계별 검증이 필수적이다.

운영/감사 에이전트와의 연계

추천사유 품질은 AuditAgent의 AV3 관점에서 3-Tier 체계로 모니터링된다:

- **Tier 1** (전수): SelfChecker pass/revise/reject 비율 추이
- **Tier 2** (샘플): 27개 스트라텀 총화추출 → GroundingValidator(사유↔IG 정합성)
- **Tier 3** (전문가): 월 50 100건 수동 리뷰 → 피드백 루프

InterpretationRegistry → 3-tuple enrichment → TemplateEngine 연결이 완료되어 L1 사유에도 한국어 IG 해석이 반영된다. ReverseMapper가 InterpretationRegistry의 Level RM fallback으로 통합되어 피처 해석 커버리지가 확대되었다.

상세 설계: Design Document 11 (docs/design/11_ops_audit_agent.typ)

팩트 추출 레이어 (신규, 2026-04)

FactExtractor가 피쳐 값으로부터 **고객 서술적 팩트**를 추출한다. InterpretationRegistry가 피쳐 레벨 해석을 제공한다면, FactExtractor는 고객 레벨 프로파일("예적금 중심 포트폴리오", "리스크 회피 성향")을 제공한다.

룰 기반, LLM 없음

YAML config (configs/financial/fact_extraction.yaml)에 정의된 Python 표현식을 샌드박스(__builtins__ 차단) 환경에서 평가한다. LLM 호출 0회로 결정론적으로 동작한다. Phase 0 배치 시점에 추출되어 ContextVectorStore에 저장되며, 서빙 타임에는 조회만 하여 L2a 프롬프트에 주입한다.

L2a 프롬프트 통합

```
AsyncReasonOrchestrator.generate_ll()
```

과 get_best_reason() 두 경로에서 context_store.get_context(customer_id).get("customer_facts", [])를 조회하여 context["customer_facts"]로 SQS 메시지에 포함한다. _build_llm_prompt()가 "## 고객 특성 팩트" 섹션으로 최종 프롬프트에 주입한다.