TECH REFERENCE

지식 증류 · 추천 사유 생성

기술 참조서: Temperature Scaling, FD-TVS, Grounding, LLM Safety

Author 1[1], Author 2[1]

[1]Organization Name
contact@org.com

Abstract. 본 문서는 PLE-adaTT Teacher 모델의 지식을 LightGBM Student로 증류하는 파이프라인, FD-TVS 4단계 복합 스코어링 엔진, 734D 피쳐 역매핑을 통한 그라운딩, 2-Layer 추천 사유 생성 아키텍처, Safety Gate 및 서빙 인프라의 이론적 배경과 수학적 구조, 구현 상세를 기술한다. Temperature Scaling ($T = 5$)을 통한 dark knowledge 전달, IG 기반 피쳐 선택 (734D $\rightarrow$ 200D $\rightarrow$ 140D), LGBM custom objective, FD-TVS master formula의 곱셈적 결합 구조, L1 Template + L2 LLM 2계층 사유 생성, 3-Agent Self-Critique, 금소법/AI 기본법 준수를 위한 Safety Gate, ONNX + Triton 서빙까지 End-to-End 흐름을 다룬다.

Keywords: Knowledge Distillation, Temperature Scaling, Dark Knowledge, LightGBM, FD-TVS, Integrated Gradients, Feature Reverse Mapping, Grounding, Recommendation Reason Generation, Self-Critique, Safety Gate, ONNX, Triton Inference Server, Financial Regulation

Contents

1 지식 증류 (Knowledge Distillation) 5
1.1 설계 철학 및 동기 5
1.1.1 핵심 문제 5
1.1.2 해결 전략 5
1.1.3 Teacher–Student 비교 5
1.2 Temperature Scaling 6
1.2.1 수학적 정의 6
1.2.2 볼츠만 분포와의 대응 6
1.2.3 Temperature 범위 설정 6
1.3 Dark Knowledge: Soft Label의 정보량 6
1.3.1 Hard Label의 한계 6
1.3.2 Soft Label의 풍부한 구조 6
1.3.3 라벨 스무딩 효과 6
1.4 Unified Distillation Loss 6
1.4.1 통합 손실 함수 6
1.4.2 T^2 보정의 수학적 유도 7
1.4.3 태스크별 손실 함수 7
1.4.4 KL-Divergence 7
1.5 IG 기반 피쳐 선택 7
1.5.1 3단계 파이프라인 7
1.5.2 IG가 SHAP보다 적합한 이유 8
1.6 LightGBM Custom Objective 8
1.6.1 구현 구조 8
1.6.2 Soft Label 전달 기법 8
1.6.3 증류 성능 비교 8
1.7 10단계 DAG 오케스트레이션 8
2 FD-TVS 스코어링 엔진 10
2.1 설계 철학 10
2.2 Master Formula 10

2.3 Stage 1: Task-Weighted Sum ... 10
2.4 Stage 2: Financial DNA Modifier ... 10
2.5 Stage 3: TDA Behavioral Velocity ... 11
2.6 Stage 4: Risk Penalty ... 11
2.7 Fatigue Decay ... 11
2.8 Confidence Formula ... 11
3 추천 사유 생성 ... 12
3.1 2-Layer 아키텍처 (v3.0.0) ... 12
3.2 L1 Template 생성 ... 12
3.2.1 구조 ... 12
3.2.2 세그먼트 인식 ... 12
3.3 L2a LLM Rewrite ... 12
3.3.1 프롬프트 4계층 구조 ... 12
3.3.2 디코딩 전략 ... 13
3.4 Self-Critique 판정 ... 13
3.5 L2b 3축 품질 검증 ... 13
4 그라운딩 + 피쳐 역매핑 ... 14
4.1 핵심 문제 ... 14
4.2 Grounding 함수 ... 14
4.3 734D 피쳐 벡터 구조 ... 14
4.4 Integrated Gradients 귀인 ... 14
4.5 Reverse Mapping 아키텍처 ... 14
4.6 모듈 구성 ... 15
4.7 Trust Loop ... 15
4.8 3중 Grounding ... 15
5 Safety Gate ... 16
5.1 다층 방어 아키텍처 ... 16
5.2 관련 규제 ... 16
5.3 감사 아카이빙 ... 16
6 서빙 아키텍처 ... 17
6.1 End-to-End 파이프라인 ... 17
6.2 LGBM → ONNX 변환 ... 17
6.2.1 ZipMap 제거 (필수) ... 17
6.2.2 변환 사양 ... 17
6.3 Triton Inference Server 구성 ... 17
6.3.1 모델 배치 ... 17
6.3.2 Dynamic Batching ... 17
6.3.3 배치 + 실시간 하이브리드 ... 17
6.4 Training-Serving Skew 방지 ... 17
6.5 Calibration 고려사항 ... 18
6.6 LLM 증류: Gemini Teacher → Qwen Student (QLoRA) ... 18
6.6.1 두 가지 증류의 구분 ... 18
6.6.2 QLoRA: LoRA 수학적 기초 ... 18
6.6.3 NF4 양자화 ... 18
6.6.4 QLoRA 메모리 분석 ... 18
6.6.5 Self-Consistency 학습 데이터 필터링 ... 18

7 비용 효율 및 운영 요약 20
7.1 비용 효율 요약 20
7.2 교차 관심사 20
7.2.1 금융 도메인 특화 20
7.2.2 전체 파이프라인 정합성 20

> **설계 vs 구현 차원 안내**
> 본 문서는 **풀뱅크 설계(734D)**를 기준으로 작성되었습니다. 현재 Santander 벤치마크 구현은 **316D (12 feature groups)**입니다. 본문의 차원 수치(734D, 200D, 140D 등)는 풀뱅크 설계 기준이며, 실제 Santander 구현에서는 중간 차원이 달라질 수 있습니다. 실제 구현의 차원 명세는 `outputs/phase0/feature_schema.json`을 참조하십시오.

지식 증류 (Knowledge Distillation)

설계 철학 및 동기

핵심 문제

PLE-adaTT Teacher 모델은 약 50M 파라미터, 20GB VRAM을 요구하며 배치 1,024건 기준 약 50ms의 추론 지연을 보인다. 수백만 고객에 대한 일일 배치 추론에서 GPU 비용만으로 월 수천 달러가 소요되며, 실시간 추천 SLA(10ms)를 충족할 수 없다.

해결 전략

Knowledge Distillation (Hinton et al., 2015)을 통해 Teacher의 출력 분포에 담긴 암묵적 지식(dark knowledge)을 LightGBM Student로 전이한다. Student는 8GB RAM CPU에서 약 5ms/1K batch로 추론하여 10배 속도 향상을 달성하면서도 성능 손실을 3%p 이내로 유지한다.

Teacher–Student 비교

속성	PLE Teacher	LGBM Student
모델 구조	PLE-adaTT + Cluster Head	LightGBM (태스크별 독립)
파라미터	~50M	~300–500 trees/task
메모리	20GB VRAM (GPU)	~8GB RAM (CPU)
추론 속도	~50ms / 1K batch	~5ms / 1K batch
피쳐 차원	734D(설계) / 316D(구현)	200D (IG 선택 후, 설계 기준)
학습 데이터	원본 피쳐 + 라벨	원본 피쳐 + Hard Label + Soft Label

Cross-architecture distillation (DNN → GBDT)이 가능한 이유는 지식 증류가 파라미터가 아닌 출력 분포를 통해 지식을 전달하기 때문이다. "딥러닝으로 학습, GBDT로 서빙"은 추천, 금융, 광고 도메인의 사실상 표준이다 (Borisov et al., NeurIPS 2022).

Temperature Scaling

수학적 정의

표준 softmax에 Temperature 파라미터 T를 도입한다.

$$p_i^T = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)} \tag{1}$$

- $T = 1$: 표준 softmax. 최대 로짓에 확률이 집중된다.
- $T = 5$ (기본값): 클래스 간 상대적 관계가 드러나는 평활 분포.
- $T \to \infty$: 균등 분포. 정보가 소실된다.

볼츠만 분포와의 대응

이 수식은 통계역학의 볼츠만 분포 $P(E_i) = \exp(-E_i/(k_B T))/Z$와 수학적으로 동치(isomorphic)이다. 로짓 z_i는 (음의) 에너지, T는 절대 온도에 대응하며, 두 분야가 동일한 지수 족(exponential family) 분포를 공유한다.

Temperature 범위 설정

$T \in [3, 7]$로 제한한다.

- $T = 3$: 이진 태스크 (CTR, CVR, Churn, Retention)
- $T = 5$: 기본값
- $T = 7$: 다중 클래스 태스크 (NBA 12-class, Timing 28-class)
- $T > 10$: 과도한 정보 손실 위험

Dark Knowledge: Soft Label의 정보량

Hard Label의 한계

Hard Label (one-hot)은 $\log_2(C)$ 비트의 정보만 인코딩한다. NBA 12-class에서 약 3.6비트이며, 차선택 클래스 간 관계 정보를 전혀 포함하지 않는다.

Soft Label의 풍부한 구조

Teacher의 softmax 출력은 $(C-1)$개의 연속 확률값을 담고 있어 $\log_2(C)$보다 훨씬 많은 정보를 제공한다.

$$p_{\text{teacher}} = [0.72, 0.14, 0.08, 0.03, 0.01, ...] \tag{2}$$

이 분포에서 주요 답변(72%), 차선택 구조(B 14% > C 8%), 클래스 간 유사성, 불확실성 수준까지 읽어낼 수 있다. 이것이 Hinton이 명명한 Dark Knowledge 이다.

라벨 스무딩 효과

Soft Label 학습은 Label Smoothing과 유사한 정규화 효과를 가진다. Hard Label이 확률 0 또는 1의 극단으로 모델을 밀어붙이는 반면(과적합 유도), Soft Label은 합리적인 확률 분포를 출력하도록 유도하여 일반화를 촉진한다.

Unified Distillation Loss

통합 손실 함수

$$\mathcal{L}_{\text{distill}} = \alpha \cdot \mathcal{L}_{\text{hard}} + (1-\alpha) \cdot T^2 \cdot \mathcal{L}_{\text{soft}} \tag{3}$$

- α: Hard/Soft 비율 (기본값 0.3, 즉 30% ground truth + 70% Teacher 의견)

- T^2: 그래디언트 크기 보정 스케일링

T^2 보정의 수학적 유도

Chain rule로부터 $\partial\hat{y}/\partial z = (1/T)\sigma(z/T)(1-\sigma(z/T))$이다. $1/T$ 인자가 누적되어 전체 그래디언트가 $1/T^2$로 축소된다. T^2를 곱함으로써 원래 스케일을 복원한다. $T=5$일 때 그래디언트는 $1/25$로 축소되므로 $T^2=25$를 곱하여 보정한다.

태스크별 손실 함수

이진 분류 (CTR, CVR, Churn, Retention):

$$\mathcal{L}_{\text{binary}} = \alpha \cdot \text{BCE}(\hat{y}, y) + (1-\alpha) \cdot T^2 \cdot D_{\text{KL}(p_t \parallel p_s)} \tag{4}$$

여기서 $p_t = \sigma(z_t/T)$, $p_s = \sigma(z_s/T)$이다.

다중 클래스 (NBA 12-class, Life-stage 6-class, Timing 28-class):

$$\mathcal{L}_{\text{multi}} = \alpha \cdot \text{CE}(z_s, y) + (1-\alpha) \cdot T^2 \cdot D_{\text{KL}(\text{softmax}(z_t/T) \parallel \text{softmax}(z_s/T))} \tag{5}$$

회귀 (LTV, Engagement):

$$\mathcal{L}_{\text{reg}} = \alpha \cdot \text{MSE}(\hat{y}_s, y) + (1-\alpha) \cdot \text{MSE}(\hat{y}_s, \hat{y}_t) \tag{6}$$

회귀에서는 Temperature Scaling이 무의미하므로 T^2 보정을 적용하지 않는다.

KL-Divergence

$$D_{\text{KL}(q \parallel p)} = \sum_i q_i \log \frac{q_i}{p_i} = \underbrace{-H(q)}_{\text{상수}} + \underbrace{H(q,p)}_{\text{교차 엔트로피}} \tag{7}$$

Forward KL $D_{\text{KL}(\text{Teacher} \parallel \text{Student})}$를 사용한다. 이는 mean-seeking 특성으로 Student가 Teacher의 모든 중요 모드를 커버하도록 강제한다. Reverse KL은 mode-seeking 특성으로 일부 모드를 무시할 위험이 있어 증류에 부적합하다.

IG 기반 피쳐 선택

3단계 파이프라인

아래 차원 수치는 풀뱅크 설계(734D) 기준입니다. Santander 구현(316D)에서는 중간 차원이 달라질 수 있습니다.

풀뱅크 설계 기준: 734D(설계) / 316D(구현) → 200D(Stage 1) → 140D(Stage 2) → 최종 LGBM 입력

Stage 1 – Integrated Gradients (734D → 200D):

$$\text{IG}(\boldsymbol{x})_i = (x_i - x_i') \times \int_0^1 \frac{\partial F(\boldsymbol{x}' + \alpha(\boldsymbol{x} - \boldsymbol{x}'))}{\partial x_i} d\alpha \tag{8}$$

- Baseline: 영벡터 (정규화된 피쳐에서 "평균 고객" 또는 "정보 부재"를 의미)
- Steps: 50 (사다리꼴 적분 근사)
- 완전성 공리: $\sum_i \text{IG}(\boldsymbol{x})_i = F(\boldsymbol{x}) - F(\boldsymbol{x}')$ (귀인 누출 없음)

Stage 2 – LGBM Importance Filter (200D → ∼140D): Gain importance 하위 30%를 제거한다.

Stage 3 – 필수 피쳐 보존: IG/LGBM importance와 무관하게 항상 포함하는 7개 피쳐:

- TDA: `persistence_entropy`, `landscape_peak`

- Economics: `mpc`, `income_elasticity`, `permanent_income_ratio`
- FinEng: `sharpe_ratio`, `volatility`

IG가 SHAP보다 적합한 이유

SHAP는 2^{734}개 부분집합 평가가 필요하여 물리적으로 불가능하다. IG는 경로 적분의 이산 근사로 선형 시간($O(n \cdot s)$, s = steps)에 계산되며, 완전성 공리를 만족하여 귀인 누출이 발생하지 않는다.

LightGBM Custom Objective

구현 구조

`DistillationLossNumpy`가 LightGBM의 `fobj`에 gradient/hessian을 제공한다.

$$\text{grad} = \alpha \cdot \text{grad}_{\text{hard}} + (1-\alpha) \cdot T^2 \cdot \text{grad}_{\text{soft}} \tag{9}$$

$$\text{hess} = \alpha \cdot \text{hess}_{\text{hard}} + (1-\alpha) \cdot T^2 \cdot \text{hess}_{\text{soft}} \tag{10}$$

Soft Label 전달 기법

LightGBM Dataset은 `label`과 `weight`만 지원하므로, Hard Label은 `get_label()`, Soft Label은 `get_weight()`를 통해 전달한다.

증류 성능 비교

방법	CTR AUC	NBA Accuracy	LTV RMSE
LGBM (Hard Label only)	0.812	0.634	1.247
LGBM (Distilled, $T = 5$)	0.841	0.698	1.089
PLE Teacher (원본)	0.856	0.723	1.021

10단계 DAG 오케스트레이션

전체 증류 파이프라인은 `distillation_entrypoint.py`에서 10단계 DAG로 실행된다.

단계	내용
1	Teacher 추론 (전체 데이터에 대한 로짓 생성)
2	Soft Label 생성 (Temperature Scaling 적용)
3	IG 피쳐 선택 (734D → 200D)
4	Student 학습 (태스크별 독립 LGBM)
5	검증 (5개 기준: AUC, RMSE, Accuracy 등)
6	MLflow 모델 레지스트리 등록
7	ONNX 변환 (ZipMap 제거 포함)

8	Triton 패키징 (config.pbtxt 생성)
9	통합 검증 (ONNX-PyTorch 수치 동치성)
10	배포 아티팩트 업로드

FD-TVS 스코어링 엔진

설계 철학

FD-TVS (Financial DNA-based Target Value Score)는 4단계 복합 스코어링 엔진으로, 모델 예측과 고객 수준 비즈니스 맥락을 결합한다. 핵심 설계 원칙은 **곱셈적 결합(multiplicative combination)**이다. 어떤 단일 요소라도 0에 접근하면 전체 점수가 거부(veto)되어 "리스크 우선(risk-first)" 원칙을 강제한다.

단순 합산 $\sum p_i$는 윈도우 쇼퍼 (CTR=0.9, CVR=0.1)와 실구매자 (CTR=0.5, CVR=0.5)를 구분하지 못한다 — 둘 다 합이 1.0이다. 곱셈 구조는 각 차원에 거부권(veto power)을 부여한다.

Master Formula

$$\text{FD-TVS} = \underbrace{S_{\text{task}}}_{\text{What}} \times \underbrace{W_{\text{DNA}}}_{\text{Who}} \times \underbrace{V_{\text{TDA}}}_{\text{When}} \times \underbrace{(1-R)}_{\text{Safe?}} \times \underbrace{f \cdot e}_{\text{Appropriate?}} \tag{11}$$

구성 요소	설명	범위
S_{task}	Task Weighted Sum	$[0, 1]$
W_{DNA}	Financial DNA Modifier	$\{0.8, 1.0, 1.2\}$
V_{TDA}	Behavioral Velocity	$[1.0, 1.15]$
R	Risk Penalty	$[0, 1]$
f	Fatigue Decay	$[0, 1]$
e	Engagement Boost	$[0.85, 1.15]$

Stage 1: Task-Weighted Sum

$$S_{\text{task}} = \beta_{\text{CTR}} \cdot p_{\text{CTR}} + \beta_{\text{CVR}} \cdot p_{\text{CVR}} + \beta_{\text{NBA}} \cdot p_{\text{NBA}} + \beta_{\text{LTV}} \cdot p_{\text{LTV}} \tag{12}$$

기본 가중치: CVR=0.4 (최고, 전환이 매출에 직결), CTR=0.3, NBA=0.2, LTV=0.1. $\sum \beta_i = 1$이고 모든 $p_i \in [0, 1]$이면 $S_{\text{task}} \in [0, 1]$이 보장되는 WSM (Weighted Sum Model, Fishburn 1967) 볼록 결합(convex combination)이다.

Stage 2: Financial DNA Modifier

Friedman의 항상소득가설(Permanent Income Hypothesis, 1957)에 기초한다. 소비자는 일시적 소득 변동이 아닌 항상(안정) 소득에 기반하여 소비를 결정한다.

$$W_{\text{DNA}} = \begin{cases} 1.2 \text{ if CV} < 0.2 \quad (\text{Permanent -- 안정 소득}) \\ 1.0 \text{ if } 0.2 \leq \text{CV} < 0.5 \quad (\text{Mixed}) \\ 0.8 \text{ if CV} \geq 0.5 \quad (\text{Transitory -- 불안정}) \end{cases} \tag{13}$$

여기서 $\mathrm{CV} = \sigma_{\text{income}}/\mu_{\text{income}}$ (변동 계수, 무차원)이다. 안정 소득 고객은 장기 금융 상품(연금, 정기예금)에 적합하므로 추천 점수를 20% 상향한다.

Stage 3: TDA Behavioral Velocity

$$V_{\text{TDA}} = 1.0 + \gamma_{\text{flare}} \cdot \mathbb{1}[\text{flare}_{\text{detected}}] \tag{14}$$

$\gamma_{\text{flare}} = 0.15$이다. TDA flare 감지는 행동 변화 가속을 나타내며, 점수를 최대 15% 상향한다.

Stage 4: Risk Penalty

$$R = 0.2 \cdot I_{\text{limit}} + 0.3 \cdot I_{\text{fatigue}} + 0.5 \cdot I_{\text{churn}} \tag{15}$$

비대칭 가중치의 근거 – 비가역성(irreversibility):

- 신용한도 소진 ($\lambda_1 = 0.2$): 가역적 (상환으로 한도 복원)
- 메시지 피로 ($\lambda_2 = 0.3$): 부분 가역 (시간이 지나면 회복)
- 고객 이탈 ($\lambda_3 = 0.5$): 거의 비가역 (재획득 비용이 신규 대비 5–7배)

$(1 - R)$은 곱셈적 거부권을 행사한다. $R \to 1$이면 다른 요소와 무관하게 점수가 0으로 수렴한다. 로그 공간에서 $\ln(1 - R) \to -\infty$ as $R \to 1$이다.

Fatigue Decay

$$f(n) = e^{-\lambda n} \tag{16}$$

지수적 감쇠로 **일정 비율 감소(constant fractional decay)**를 구현한다. $f(n+1)/f(n) = e^{-\lambda}$ (상수 비율).

반감기: $n_{1/2} = \ln 2/\lambda$. App Push ($\lambda = 0.4$): 반감기 ≈ 1.73회. Email ($\lambda = 0.15$): 반감기 ≈ 4.62회.

Confidence Formula

$$\text{confidence} = |p - 0.5| \times 2 \tag{17}$$

결정 경계(0.5)로부터의 거리를 $[0, 1]$로 정규화한다. 낮은 confidence 예측은 추천 품질 필터에서 후순위로 처리한다.

추천 사유 생성

2-Layer 아키텍처 (v3.0.0)

설계 철학: "전 고객에게 동등한 사유를, 컨텍스트 풍부 고객에게 LLM 강화 사유를."

Layer	대상	방식	LLM 호출	처리량
L1	1,200만 전량	Template (6 categories × 5 variants, hash 선택)	0	∼20분
L2a	∼50만/주	LLM rewrite (vLLM Qwen3-8B-AWQ, 3-layer safety gate)	1	∼1.0초/건
L2b	∼6.7만 샘플링	품질 검증 (factuality, relevance, naturalness)	1	–

규제 근거: 금융소비자보호법 제19조는 전 고객에 대한 동등한 설명의무를 요구한다. L1이 1,200만 전량에 비용 0의 템플릿을 제공하여 이를 충족한다.

비용 효율: 전량 LLM 처리 시 ∼1,000 GPU-hours 소요. 2-Layer 설계는 ∼162 GPU-hours로 달성한다.

L1 Template 생성

구조

6 categories × 5 variants = 30개 템플릿.

결정론적 변형 선택:

$$\text{variant}_{\text{index}} = \text{hash}(\text{customer}_{\text{id}} : \text{category}) \bmod 5 \tag{18}$$

동일 고객은 항상 동일 변형을 수신한다 (일관성 + 감사 재현성).

세그먼트 인식

- **WARMSTART**: IG Top-3 역매핑 기반 사유
- **COLDSTART**: 인기도 + 혜택 기반 사유
- **ANONYMOUS**: 일반적 인기도 기반 사유

규칙 기반 컴플라이언스 검사 후 AI 생성 고지 문구를 자동 부착한다.

L2a LLM Rewrite

우선순위 큐: rich 먼저, moderate 다음, sparse 제외. 3-Layer Safety Gate를 통과한 후 rewrite가 적용된다. vLLM Qwen3-8B-AWQ를 RTX 4070 (12GB VRAM)에서 구동한다.

프롬프트 4계층 구조

1. **System 프롬프트**: 역할 정의 (금융 추천 사유 전문가) + 금소법 위반 금지 규칙
2. **Few-shot 예제**: 세그먼트별 톤·형식 가이드
3. **Context 주입**: 고객 피쳐, IG 기여도, 상담 이력 → 자연어 변환

4. **출력 형식**: JSON 스키마 (`{"reasons": [...], "summary": "..."}`)

디코딩 전략

- 사유 생성: $\tau = 0.3$ (사실 보존 + 약간의 다양성)
- Critique: $\tau = 0.1$ (거의 결정론적, 일관된 품질 평가)
- L2a Rewrite: $\tau = 0.3$ (원본 사실 유지, 표현 윤색)

Self-Critique 판정

$$\text{verdict} = \begin{cases} \text{pass} & \text{if } f \geq 0.8 \text{ and } c \geq 1.0 \\ \text{revise} & \text{if } f \geq 0.5 \text{ and } c \geq 1.0 \\ \text{reject} & \text{otherwise} \end{cases} \tag{19}$$

- f: 사실성 점수 (연속값)
- c: 컴플라이언스 점수 (이진: 1.0 = 위반 없음)

컴플라이언스 절대 우선: 규제 위반($c < 1.0$)이 있으면 사실성과 무관하게 즉시 거부. **최대 1회 수정:** 수정 후에도 "revise"이면 안전 템플릿으로 폴백 (무한 루프 방지, LLM 호출 최대 3회).

L2b 3축 품질 검증

$$\text{verdict} = \begin{cases} \text{pass} & \text{if } f \geq 0.7 \text{ and } r \geq 0.7 \text{ and } n \geq 0.7 \\ \text{needs}_{\text{improvement}} & \text{if any score} \in [0.5, 0.7) \\ \text{fail} & \text{if any score} < 0.5 \end{cases} \tag{20}$$

- f: 사실성, r: 관련성, n: 자연스러움
- 임계값 0.7 (Self-Critique의 0.8보다 낮음): L2b는 사후 모니터링이며 실시간 게이트키퍼가 아니므로

그라운딩 + 피쳐 역매핑

핵심 문제

PLE-adaTT는 734D 피쳐 벡터를 소비하여 확률 점수를 출력하지만 왜 그 추천을 했는지 설명하지 못한다. AI 기본법 제31조·제34조, 금융소비자보호법 제19조는 유의미한 설명을 요구한다.

Grounding 함수

$$f : \mathbb{R}^{644} \times \mathcal{I} \to \mathcal{L} \tag{21}$$

여기서 $\mathbb{R}^{644}$은 정규화 피쳐 벡터 공간, $\mathcal{I}$는 IG 귀인 정보, $\mathcal{L}$은 자연어 설명 공간이다.

734D 피쳐 벡터 구조

범위	차원	내용
profile	0–238	Demographics (100D) + RFM (50D) + Financial Summary (88D)
multi_source	238–329	Transaction stats (40D) + Behavioral patterns (51D)
extended_source	329–413	보험, 상담, STT, 캠페인, 해외, 오픈뱅킹
domain	413–572	TDA (70D) + GMM (22D) + Mamba (50D) + Economics (17D)
model_derived	572–599	HMM summary, Bandit/MAB, LNN
multidisciplinary	599–623	전환 역학, 채택 역학, 교차 패턴, 루틴 분석
merchant_hierarchy	623–644	MCC levels, brand embeddings, 통계, radius

총 644D 정규화 + 90D raw power-law = 734D 모델 입력.

Integrated Gradients 귀인

$$\mathrm{IG}_i(\boldsymbol{x}) = (x_i - x_i') \times \int_0^1 \frac{\partial F(\boldsymbol{x}' + \alpha(\boldsymbol{x} - \boldsymbol{x}'))}{\partial x_i} d\alpha \tag{22}$$

IG가 SHAP보다 적합한 이유:

- SHAP: 2^{734} 부분집합 평가 필요 (불가능)
- IG: 50-step 사다리꼴 근사로 선형 시간 계산
- **완전성 공리:** $\sum_i \mathrm{IG}_i(\boldsymbol{x}) = F(\boldsymbol{x}) - F(\boldsymbol{x}')$ (벡터 해석학의 그래디언트 정리에 의해 보장)
- **Baseline:** 영벡터 (정규화된 피쳐에서 "평균 고객"에 해당)

Reverse Mapping 아키텍처

$$\mathrm{ReverseMap} : \left(\boldsymbol{x} \in \mathbb{R}^d, \boldsymbol{a} \in \mathbb{R}^d\right) \to \{(r_k, s_k, t_k)\}_{k=1}^{K} \tag{23}$$

- $\boldsymbol{x}$: 피쳐 벡터, $\boldsymbol{a}$: IG 귀인 벡터
- r_k: 피쳐 범위 이름, s_k: 요약 점수, t_k: 금융 언어 텍스트

서브레인지 슬라이싱: $t_k = \mathcal{M}_k(g(\boldsymbol{x}[s_k : e_k]))$ 여기서 g는 집계 함수 (mean, argmax, threshold 비교), $\mathcal{M}_k$는 도메인 전문가가 설계한 매핑 딕셔너리 (수치 → 텍스트)이다.

모듈 구성

- **FeatureReverseMapper:** 644D 벡터 → 금융 언어 텍스트 (계층적 범위 슬라이싱)
- **MultidisciplinaryInterpreter:** 24D 다학제 피쳐 → 비즈니스 해석 (4개 서브도메인)
- **LanceContextVectorStore:** LanceDB 기반 고객 컨텍스트 저장/검색 (768D 임베딩 L2 거리)
- **ContextAssemblyAgent:** IG 기반 도구 선택 + 다중 소스 컨텍스트 조립
- **ConsultationContextExtractor:** STT 상담 이력 추출 + 요약

Trust Loop

모델 예측 → IG 귀인 → 역매핑 → 컨텍스트 조립 → LLM 사유 생성 → 상담원 전달 → 고객 설득 → 전환/피드백 → 모델 개선.

역매핑과 컨텍스트 조립 없이는 모델 예측과 상담원 전달 사이에 해석가능성 간극이 발생하여 이 Trust Loop가 단절된다.

3중 Grounding

1. **피쳐 Grounding:** IG Top-5 귀인을 프롬프트에 주입 → LLM이 실제 모델 판단 근거에 기반하여 사유 생성
2. **고객 Grounding:** 세그먼트, 거래 패턴, 상담 이력 주입 → 환각(hallucination) 억제
3. **규정 Grounding:** 시스템 프롬프트 금지 규칙 + Rule-based Self-Critique → 컴플라이언스 강제

Safety Gate

다층 방어 아키텍처

금소법 및 AI 기본법 준수를 위한 6계층 안전 장치이다.

계층	메커니즘	대상 규제
1	System 프롬프트: 불변 규제 금지 규칙	AI 기본법 제31조·제34조
2	Self-Critique: 실시간 게이트키퍼 ($f \geq 0.8$, $c = 1.0$)	금소법 제19조·제21조
3	3-Layer Safety Gate: 프롬프트 인젝션 탐지 + 사실성 + 규제 준수	금소법 제22조
4	L2b Quality Validation: 사후 모니터링 3축 평가	내부 품질 기준
5	AI Security Checker: 인젝션 탐지 + 컴플라이언스 검증	AI 기본법 제34조
6	Audit Archiver: 불변 Parquet 레코드 (DuckDB 기반 조회)	금융감독원 사후 검사

관련 규제

- **AI 기본법 제31조** (AI 사용 고지): 모든 추천 사유에 AI 생성 고지 문구 자동 부착
- **AI 기본법 제34조** (위험관리): Safety Gate + 감사 추적
- **금융소비자보호법 제19조** (적합성 원칙 + 설명의무): L1이 전량 커버리지 보장
- **금융소비자보호법 제21조** (광고 규제): 금지 패턴 탐지
- **금융소비자보호법 제22조** (불공정행위 금지): 컴플라이언스 점수 검증

감사 아카이빙

`RecommendationAuditArchiver`가 모든 추천 건을 Parquet으로 영속 저장한다.

- IG 귀인 점수, L1 사유, L2a rewrite 결과, L2b 검증 결과, 처리 시간
- DuckDB 기반 효율적 소급 조회
- 금융감독원 사후 검사 시 개별 추천 건의 전체 의사결정 경로 추적 가능

서빙 아키텍처

End-to-End 파이프라인

```
PLE-adaTT Teacher (학습)
  |-> Knowledge Distillation (T=5, alpha=0.3)
    |-> LGBM Student (태스크별, 200D 피처)
      |-> ONNX Export (ZipMap 제거)
        |-> Triton Inference Server (15 태스크, Dynamic Batching)
          |-> FD-TVS Scoring (4-Stage)
            |-> Feature Grounding (IG -> Reverse Mapping -> Context Assembly)
              |-> Recommendation Reason (L1 -> L2a -> L2b)
                |-> Audit Archive (Parquet)
```

LGBM → ONNX 변환

ZipMap 제거 (필수)

LightGBM의 ONNX 변환은 ZipMap 연산자를 추가하여 딕셔너리 출력을 생성한다. Triton은 텐서 출력만 지원하므로 ONNX 그래프에서 ZipMap 노드를 우회하여 제거해야 한다.

변환 사양

- Opset 13: LightGBM 연산자 전체 지원
- 2단계 검증: (1) `onnx.checker.check_model` 스펙 적합성, (2) 더미 추론 수치 동치성 테스트

Triton Inference Server 구성

모델 배치

15개 ONNX 모델 (태스크별) + 1 전처리기 + 1 후처리기 + 15 앙상블 스케줄러 = **32개 모델 설정**.

Dynamic Batching

- Preferred batch sizes: [256, 512, 1024]
- Max queue delay: 100μs
- 전처리기: CPU $\times$ 4 인스턴스 (CPU-bound JSON 파싱)
- ONNX 모델: GPU $\times$ 2 인스턴스

배치 + 실시간 하이브리드

일일 배치로 전체 고객 기본 점수를 산출하고, 실시간 거래 발생 시 Redis 캐시의 실시간 피쳐를 반영하여 FD-TVS 점수를 즉시 재계산한다. Triton Dynamic Batching이 개별 실시간 요청을 큐에 모아 마이크로배치로 처리하여 GPU 활용률을 유지한다.

Training-Serving Skew 방지

Feature Serving Spec이 학습과 서빙을 연결한다.

- `feature_selector`가 학습 시 `selected_features_{task}.json`을 출력

- `FeatureServingSpec`이 배포 시점에 이를 로드하여 동일한 피쳐 순서를 보장
- 7개 필수 피쳐 (TDA, Economics, FinEng)는 항상 포함

Calibration 고려사항

FD-TVS Stage 1은 모든 태스크 확률이 공통 스케일 $[0, 1]$에 있을 것을 요구한다. CTR이 과잉 확신(overconfident)이고 CVR이 과소 확신(underconfident)이면 가중 합산에 편향이 발생한다. Temperature Scaling (Guo et al., ICML 2017)을 통한 사후 보정이 향후 개선 과제로 식별되어 있다.

LLM 증류: Gemini Teacher → Qwen Student (QLoRA)

두 가지 증류의 구분

측면	예측 모델 증류	LLM 증류
목적	예측 정확도	텍스트 생성 품질
Teacher	PLE-Cluster-adaTT	Google Gemini
Student	LightGBM	Qwen3-8B
전달 대상	Soft labels (logits/probs)	텍스트 출력 (추천 사유)
손실 함수	KL Divergence + CE	Cross-Entropy (SFT)
학습 방법	Soft label learning	QLoRA fine-tuning

QLoRA: LoRA 수학적 기초

$$W' = W_0 + \Delta W = W_0 + BA \tag{24}$$

- $W_0 \in \mathbb{R}^{d \times k}$: 원본 사전학습 가중치 (동결)
- $B \in \mathbb{R}^{d \times r}$: Down-projection (학습 가능)
- $A \in \mathbb{R}^{r \times k}$: Up-projection (학습 가능)
- $r \ll \min(d, k)$: Rank ($r = 16$에서 원본 대비 0.78%)

압축률: $r \times (d + k)/(d \times k)$. Qwen3-8B ($d = k = 4096$, $r = 16$): $131,072/16,777,216 \approx 0.78\%$.

NF4 양자화

분포 인식(distribution-aware) 양자화로 표준정규분포의 분위수에 양자화 수준을 배치한다.

$$q_i = \Phi^{-1}\big(i/(2^k + 1)\big) \tag{25}$$

각 수준이 동일한 확률 질량을 커버하여 Lloyd-Max 최적 조건을 충족한다.

QLoRA 메모리 분석

- Full FT (FP16): 가중치 16GB + 옵티마이저 32GB + 그래디언트 16GB = 64GB+ (RTX 4070 불가)
- QLoRA: 베이스 모델 4GB (NF4) + LoRA 어댑터 ~40MB = **6GB로 학습 가능**

Self-Consistency 학습 데이터 필터링

$$\text{consistency}(s_1, s_2, s_3) = \min_{i \neq j} \text{BERTScore}\big(s_i, s_j\big) \tag{26}$$

Gemini Teacher로 동일 입력에 대해 3회 출력을 생성하고, 최소 쌍별 BERTScore를 보수적 일관성 척도로 사용한다. 일관된 출력만 학습 데이터에 포함하여 Teacher 환각을 필터링한다.

비용 효율 및 운영 요약

비용 효율 요약

구성 요소	설계 선택	효과
2-Layer 사유 생성	L1 Template + L2 LLM	162 vs 1,000 GPU-hours
LGBM Student	CPU 추론	GPU Teacher 대비 1/10 비용
QLoRA	NF4 + LoRA	6GB vs 64GB+ 학습
Triton Dynamic Batching	마이크로배치 큐잉	GPU 활용률 극대화

교차 관심사

금융 도메인 특화

- **증류:** TDA, Economics, FinEng 필수 피쳐를 IG importance와 무관하게 보존
- **스코어링:** Friedman 항상소득가설 기반 DNA modifier, 비가역성 기반 비대칭 리스크 가중
- **그라운딩:** 도메인 전문가 설계 매핑 딕셔너리로 금융 언어 번역
- **사유 생성:** 규정 우선 설계 (규제가 품질을 우선)
- **LLM 증류:** 금융 용어, 컴플라이언스 인식 톤, 상품 특화 지식 전이

전체 파이프라인 정합성

증류 → 서빙 → 스코어링 → 그라운딩 → 사유 생성 → 감사의 각 단계는 Feature Serving Spec, IG 귀인, 역매핑 딕셔너리라는 공유 계약을 통해 End-to-End 정합성을 유지한다. 어떤 단계에서든 이 계약이 깨지면 하류 단계 전체에 오류가 전파되므로, 단계별 검증이 필수적이다.