

TECH REFERENCE

# 피처 엔지니어링 기술 참조서

11개 학제 · 경제학 · 화학 · 역학 · 범죄학 · 파동 · TDA · HMM · GMM · Mamba · Graph · 3-Stage 정규화

프로젝트

**AWS PLE for Financial**

PLE-adaTT Multi-Task Recommendation

버전

**v1.0**

2026-04-01

이 문서는 AWS PLE for Financial 프로젝트의 피처 엔지니어링 파이프라인 전체를 기술한다. 11개 학제 간 피처 생성기(Economics, Chemical Kinetics, SIR, Crime Pattern, Wave Interference, TDA, HMM, GMM, Mamba, Graph, Base)의 이론적 근거, 수학적 정의, 출력 피처 명세, 그리고 3-Stage 정규화 파이프라인을 포함한다.

# 목차

|                                                     |    |
|-----------------------------------------------------|----|
| 피쳐 설계 철학 .....                                      | 5  |
| 다학제 접근의 근거 .....                                    | 5  |
| 구조적 동형사상 .....                                      | 5  |
| 피쳐의 이중 역할 .....                                     | 5  |
| 전체 피쳐 텐서 구성 .....                                   | 6  |
| 경제학 피쳐 (Economics, 17D) .....                       | 8  |
| 이론적 근거: Friedman 항상소득가설 .....                       | 8  |
| 소득 분해 추정 방법 .....                                   | 8  |
| 소득 분해 출력 (8D) .....                                 | 8  |
| 미시경제 행동 피쳐 (9D) .....                               | 9  |
| 소득 탄력성 .....                                        | 9  |
| 소비 평활화 .....                                        | 9  |
| 시간 할인 .....                                         | 9  |
| 기타 행동 피쳐 .....                                      | 9  |
| 화학 반응속도론 피쳐 (Chemical Kinetics, 6D) .....           | 10 |
| 이론적 근거 .....                                        | 10 |
| Arrhenius 방정식 .....                                 | 10 |
| 반감기 .....                                           | 10 |
| 2차 유한차분 .....                                       | 10 |
| 출력 피쳐 (6D) .....                                    | 10 |
| SIR 역학 피쳐 (Epidemiology, 5D) .....                  | 11 |
| 이론적 근거: Kermack-McKendrick 모델 .....                 | 11 |
| 금융 도메인 매핑 .....                                     | 11 |
| 출력 피쳐 (5D) .....                                    | 11 |
| 고객 프로파일링 .....                                      | 11 |
| 범죄학 피쳐 (Crime Pattern / Routine Activity, 5D) ..... | 13 |
| 이론적 근거 .....                                        | 13 |
| Burstiness (Barabasi, 2005) .....                   | 13 |
| 원형 통계 (Circular Statistics) .....                   | 13 |
| 출력 피쳐 (5D) .....                                    | 13 |
| 파동 간섭 피쳐 (Wave Interference, 8D) .....              | 14 |
| 이론적 근거 .....                                        | 14 |
| KL 발산 .....                                         | 14 |
| Phase Locking Value (PLV) .....                     | 14 |
| Cross-spectral Coherence .....                      | 14 |
| 출력 피쳐 (8D) .....                                    | 14 |
| 정보이론적 정당성 .....                                     | 15 |
| TDA 피쳐 (Topological Data Analysis, 70D) .....       | 16 |
| 핵심 아이디어 .....                                       | 16 |
| Betti 수와 호몰로지 .....                                 | 16 |
| 금융 도메인 해석 .....                                     | 16 |
| Vietoris-Rips 복합체와 지속 호몰로지 .....                    | 16 |

|                                                                         |    |
|-------------------------------------------------------------------------|----|
| 안정성 정리 .....                                                            | 17 |
| 출력 피쳐 (70D) .....                                                       | 17 |
| HMM 피쳐 (Hidden Markov Model, 5D summary + 48D separate) .....           | 18 |
| 핵심 아이디어: 숨겨진 상태 추론 .....                                                | 18 |
| 마르코프 성질 .....                                                           | 18 |
| Triple-Mode 구성 .....                                                    | 18 |
| v14 Phase 0 개선 (2026-05-04): mode_observation_cols 분리 .....             | 18 |
| 세 가지 핵심 알고리즘 .....                                                      | 19 |
| Forward-Backward .....                                                  | 19 |
| HMM Summary (메인 텐서 5D) .....                                            | 19 |
| GMM 피쳐 (Gaussian Mixture Model, 22D) .....                              | 21 |
| 이론적 근거 .....                                                            | 21 |
| EM 알고리즘 .....                                                           | 21 |
| E-Step (사후 책임도) .....                                                   | 21 |
| M-Step .....                                                            | 21 |
| 수렴 보장 .....                                                             | 21 |
| 모델 선택: BIC .....                                                        | 21 |
| 출력 피쳐 (22D) .....                                                       | 21 |
| GMM vs K-Means: 왜 소프트 할당인가 .....                                        | 22 |
| v14 Phase 0 개선 (2026-05-04): K=14 + flat-kwarg fix .....                | 22 |
| Mamba 시계열 피쳐 (Selective State Space, 50D) .....                         | 23 |
| 핵심 아이디어 .....                                                           | 23 |
| Selective State Space Model .....                                       | 23 |
| 기존 방법 대비 강점 .....                                                       | 23 |
| 파이프라인 .....                                                             | 23 |
| 시계열 분석의 4가지 관점 .....                                                    | 23 |
| Graph 피쳐 (LightGCN + Hyperbolic GCN) .....                              | 25 |
| LightGCN: 협업 필터링 .....                                                  | 25 |
| Message Passing .....                                                   | 25 |
| Layer Combination .....                                                 | 25 |
| BPR Loss .....                                                          | 25 |
| Hyperbolic GCN: 계층 구조 .....                                             | 25 |
| Poincare Ball 모델 .....                                                  | 25 |
| 금융 도메인 정당성 .....                                                        | 26 |
| Dual GCN 구성 .....                                                       | 26 |
| 기타 피쳐 (Base Demographics, Product Holdings, Transaction Behavior) ..... | 27 |
| Base 피쳐 (238D) .....                                                    | 27 |
| Multi-Source 피쳐 (91D) .....                                             | 27 |
| Extended-Source 피쳐 (84D) .....                                          | 27 |
| Model-Derived 피쳐 (27D) .....                                            | 28 |
| Merchant Hierarchy 피쳐 (27D) .....                                       | 28 |
| 3-Stage 정규화 파이프라인 .....                                                 | 29 |
| 설계 원칙 .....                                                             | 29 |
| Stage 1: 멍법칙 감지 + log1p 복사본 생성 .....                                    | 29 |
| Stage 2: StandardScaler (TRAIN fit only) .....                          | 29 |
| Stage 3: Raw power-law 보존 .....                                         | 29 |

|                                                    |    |
|----------------------------------------------------|----|
| 최종 텐서 구성 .....                                     | 30 |
| v14 Phase 0 개선 (2026-05-04): 확률 컬럼 scaler 제외 ..... | 30 |
| 정규화 파이프라인 흐름 요약 .....                              | 31 |
| 부록: 설계 vs 구현 차원 매핑 .....                           | 32 |
| 추가 자료 .....                                        | 34 |

### 설계 vs 구현 차원 안내

본 문서는 **폴뱅크 설계(734D)**를 기준으로 작성되었습니다. 현재 Santander 벤치마크 구현은 **1211D 입력 (17 feature groups)**입니다. 실제 구현의 차원 명세는 `outputs/phase0/feature_schema.json` 을 참조하십시오. 부록 "설계 vs 구현 차원 매핑"에서 각 그룹별 차이를 확인할 수 있습니다.

# 피쳐 설계 철학

## 다학제 접근의 근거

전통적 피쳐 엔지니어링은 통계학이라는 단일 렌즈로 데이터를 바라본다. 평균, 분산, 빈도, 상관계수는 강력하지만, 데이터가 가진 구조의 일부만을 드러낸다. 본 시스템은 11개 학문 분야의 수학적 프레임워크를 동시에 적용하여 데이터의 서로 다른 측면을 추출한다.

| 학문 분야            | 포착하는 패턴           | 통계학만으로 보이지 않는 것             |
|------------------|-------------------|-----------------------------|
| 경제학              | 소득 구조, 탄력성, 시간 선호 | 항상소득 vs 일시소득 분해, 인과적 소비 방향성 |
| 화학 반응속도론         | 변환의 속도, 장벽, 촉매    | 상태 전환의 에너지 장벽, 2차 도함수(가속도)  |
| 역학 (SIR)         | 채택 확산, 면역/이탈      | 집단 수준 동역학, 전파 임계값 $R_0$     |
| 범죄학              | 루틴, 이탈, 이상 패턴     | 시간의 원형적 성격, Burstiness      |
| 파동 물리학           | 주기 분해, 위상 동기화     | FFT 주파수 영역, PLV 위상 결합       |
| TDA              | 위상적 형태, 구멍, 연결성   | 좌표 불변 구조, 다중 해상도 관찰         |
| HMM              | 숨겨진 상태 전이         | 관측 불가능한 잠재 단계의 확률적 추론       |
| GMM              | 소프트 클러스터링         | 확률적 유형 할당, 불확실성 정량화         |
| Mamba SSM        | 시계열 장기 의존성        | 선택적 상태 공간의 비선형 시간 표현        |
| Graph (LightGCN) | 협업 필터링 신호         | 다중 홉 간접 선호, 계층 구조           |
| Base 통계          | 인구통계, 보유, 거래      | RFM, 카테고리 분포, 채널 다양성        |

## 구조적 동형사상

다학제 피쳐 엔지니어링에서 “아날로지”는 단순한 비유가 아니다. **구조적 동형사상(structural isomorphism)**에 기반한다. 두 시스템의 표면적 대상(분자 vs 소비자)은 다르지만, 그 대상들 사이의 관계 구조가 수학적으로 동일할 때 구조적 동형사상이 성립한다.

### 핵심 원리

화학에서 “반응물 농도가 절반으로 줄어드는 시간”과 금융에서 “거래 빈도가 절반으로 줄어드는 시간”은 모두 지수 감쇠(exponential decay)라는 동일한 수학적 구조를 공유한다. 수식이 동일하다면, 해당 수식이 포착하는 패턴도 동일하다. 대상이 무엇이냐는 수식의 유효성에 영향을 주지 않는다.

## 피쳐의 이중 역할

본 시스템의 피쳐는 두 가지 역할을 동시에 수행한다.

1. **예측 입력**: PLE-adaTT 모델의 입력 텐서로서 12개 태스크의 예측에 기여한다.

2. **전문가 라우팅 신호:** GMM의 소프트 할당 확률( $\gamma_{nk}$ )은 GroupTaskExpertBasket의 20개 서브헤드를 가중 결합하는 라우팅 신호로 사용되고, HMM 48D는 별도 입력 경로(separate input)를 통해 전용 Projector에 공급된다.

### 전문가 라우팅 단위

전문가 라우팅( `feature_groups.yaml` 의 `target_experts` )은 **피쳐 그룹 단위**로 선언된다 (컬럼 단위 아님). 각 전문가는 `FeatureRouter` 가 할당된 피쳐 그룹의 인덱스를 슬라이싱하여 전달한다. 컬럼 단위 라우팅은 지원하지 않으며, config-driven 설계 원칙에 위배된다.

**FeatureRouter에 의한 서브셋 라우팅 (현재 활성):** 전체 1205D 입력 텐서(1211D, 17 groups)는 `feature_groups.yaml` 의 `target_experts` 선언에 따라 `FeatureRouter` 가 전문가별 지정 인덱스를 슬라이싱하여 전달한다. 각 전문가는 전체 피쳐가 아닌 관련 서브셋만 수신한다: `deepfm=977D`, `temporal_ensemble=116D`, `hgcn=58D`, `perslay=32D`, `causal=129D`, `lightgcn=955D`, `optimal_transport=95D` (mlp=57D 는 PLE CGC 의 task-specific tower). 모델 파라미터는 2.8M (post-FeatureRouter pruning; lag tensor 800D 라우팅으로 그룹 토글에 따라 변동).

## 전체 피쳐 텐서 구성

아래 표는 풀뱅크 설계(734D) 기준이다. 현재 Santander 벤치마크 구현은 1211D 입력 / 17 feature groups이며, `feature_groups.yaml` 설정에 따라 결정된다.

| 피쳐 블록                  | 차원 (설계)                          | 구성 요소                                                                        |
|------------------------|----------------------------------|------------------------------------------------------------------------------|
| Base                   | 238D                             | RFM(34) + Category(64) + Transaction Stats(76) + Product Diversity(12) + ... |
| Multi-Source           | 91D                              | Deposit + Credit + Investment + Digital 등                                    |
| Extended-Source        | 84D                              | Insurance + Refund + Consultation + STT 등                                    |
| Domain                 | 159D                             | TDA(70) + GMM(22) + Mamba(50) + Economics(17)                                |
| Model-Derived          | 27D                              | HMM summary(5) + Bandit/MAB(4) + LNN(18)                                     |
| Multidisciplinary      | 24D                              | Chemical(6) + SIR(5) + Crime(5) + Wave(8)                                    |
| Merchant Hierarchy     | 27D                              | MCC Poincaré 임베딩 (계층 구조) + Brand 임베딩 (v3/v4 이전: 21D 통계치만)                    |
| <b>합계 (normalized)</b> | <b>644D (설계) / 1205D (구현 입력)</b> |                                                                              |
| Raw power-law copy     | 90D                              | 역법칙 컬럼의 log1p 원본 (스케일링 미적용); 설계 기준; 구현에서는 별도 log1p 복사본 미포함                   |
| <b>Main Tensor 총합</b>  | <b>734D (설계) / 1211D 입력 (구현)</b> | 설계: 644D normalized + 90D raw; 구현: 1211D (17 groups)                         |

별도 입력: HMM Triple-Mode 48D + Hyperbolic 20D = 68D (separate input path)

### FeatureRouter 슬라이싱

구현에서 1205D 입력 텐서(1211D, 17 groups)는 FeatureRouter 를 통해 전문가별로 슬라이싱된다. 각 전문가는 feature\_groups.yaml 의 target\_experts 필드에 지정된 피쳐 그룹의 인덱스만 수신한다. 전문가별 입력 차원: deepfm=977D, temporal\_ensemble=116D, hgcn=58D, perslay=32D, causal=129D, lightgcn=955D, optimal\_transport=95D (mlp=57D 는 PLE CGC 의 task-specific tower). 전문가 출력은 모두 64D로 균일하게 정렬되어 CGC Gate에 전달된다.

# 경제학 피쳐 (Economics, 17D)

Domain Features   Friedman PIH   17D / 734D

## 이론적 근거: Friedman 항상소득가설

Friedman(1957)의 항상소득가설(Permanent Income Hypothesis, PIH)은 관측 소득을 항상 성분과 일시 성분으로 분해한다.

$$Y_t = Y_t^P + Y_t^T$$

여기서  $Y_t^P$ 는 항상소득(장기 안정),  $Y_t^T$ 는 일시소득(임시 변동)이다. 소비 함수는 다음을 따른다:

$$C_t = k(r, w, u) \cdot Y_t^P$$

핵심 함의: 소비자는 항상소득에 비례하여 소비하며, 일시소득은 저축/투자로 향한다.

### 소득 분해 추정 방법

| 방법            | 수식                                                                                                                        | 복잡도    |
|---------------|---------------------------------------------------------------------------------------------------------------------------|--------|
| 이동평균          | $\hat{Y}_t^P = \frac{1}{L} \sum_{i=0}^{L-1} Y_{t-i}, L = 12$                                                              | Low    |
| HP Filter     | $\min_{\tau} \left\{ \sum_t (Y_t - \tau_t)^2 + \lambda \sum_t [(\tau_{t+1} - \tau_t) - (\tau_t - \tau_{t-1})]^2 \right\}$ | Medium |
| Kalman Filter | State: $Y_{t+1}^P = Y_t^P + \eta_t$ , Obs: $Y_t = Y_t^P + \varepsilon_t$                                                  | High   |

HP Filter의 1차 조건은  $(I + \lambda D^T D)\tau = Y$ 로, 양정치 띠 행렬 시스템이며 Cholesky 분해로  $O(T)$ 에 풀린다. Ravn-Uhlig(2002) 표준에 따라 월간 데이터에  $\lambda = 14400$ 을 사용한다.

## 소득 분해 출력 (8D)

| 피쳐                           | 수식                                              | 금융 해석                          |
|------------------------------|-------------------------------------------------|--------------------------------|
| permanent_income_avg         | $\text{mean}(\hat{Y}^P)$                        | 장기 안정 소득 수준                    |
| permanent_income_stability   | $\frac{\sigma(\hat{Y}^P)}{\mu(\hat{Y}^P)}$      | 항상소득의 CV; 낮으면 안정 직업            |
| permanent_income_growth      | $\frac{\hat{Y}_T^P - \hat{Y}_1^P}{\hat{Y}_1^P}$ | 소득 궤적 (카드 등급 업그레이드 지표)         |
| permanent_income_trend       | REGR_SLOPE / polyfit                            | 강건한 장기 성장 방향                   |
| transitory_income_avg        | $\text{mean}(\hat{Y}^T)$                        | 보너스 빈도 지표 (이론적으로 $\approx 0$ ) |
| transitory_income_volatility | $\sigma(\hat{Y}^T)$                             | 소득 불확실성 크기                     |
| transitory_income_max        | $\max(\hat{Y}^T)$                               | 최대 보너스 이벤트 프록시                 |



| 피쳐              | 수식                                                  | 금융 해석         |
|-----------------|-----------------------------------------------------|---------------|
| bonus_frequency | $\frac{\text{count}(\hat{Y}^T > 0.5 \hat{Y}^P)}{N}$ | 대규모 보너스 발생 비율 |

## 미시경제 행동 피쳐 (9D)

### 소득 탄력성

$$\varepsilon_Y = \frac{\partial Q}{\partial Y} \cdot \frac{Y}{Q} = \frac{d \ln Q}{d \ln Y}$$

- $\varepsilon_Y > 1$ : 사치재 소비 성향 (소득보다 소비가 빠르게 성장)
- $0 < \varepsilon_Y < 1$ : 필수재 소비 성향
- $\varepsilon_Y < 0$ : 열등재 (소득 증가 시 소비 감소)

이산 호탄력성으로 구현한다:  $\hat{\varepsilon}_Y = \frac{1}{T} \sum_{t=1}^T \frac{\Delta \frac{S_t}{S_{t-1}}}{\Delta \frac{Y_t}{Y_{t-1}}}$

### 소비 평활화

Hall(1978)은 PIH와 합리적 기대를 결합하여 최적 소비가 랜덤 워크를 따름을 보였다.

$$C_t = C_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \text{WN}(0, \sigma^2)$$

consumption\_smoothing =  $\frac{\mu}{\sigma}$  (역CV, 소비의 Sharpe ratio). 높을수록 이론적 최적에 근접.

### 시간 할인

$$V_0 = \sum_{t=0}^T \beta^t u(C_t), \quad 0 < \beta < 1$$

discount\_rate\_proxy = 전반기 소비 / 후반기 소비. 값이 클수록  $\beta$ 가 작으며 현재 편향이 강하다. 즉시 혜택(당일 캐시백)을 선호하는 고객 식별.

### 기타 행동 피쳐

| 피쳐                        | 수식                          | 해석                     |
|---------------------------|-----------------------------|------------------------|
| spending_diversification  | $H = -\sum_i s_i \ln(s_i)$  | Shannon 엔트로피; 카테고리 다양성 |
| category_hhi              | $\text{HHI} = \sum_i s_i^2$ | 허핀달 지수; 소비 집중도         |
| savings_propensity        | $\frac{Y-C}{Y}$             | 저축 성향; 미래 한계효용 기대 반영   |
| price_sensitivity         | 환불 비율 프록시                   | 가격 탄력성의 행동적 대리         |
| cross_category_elasticity | 카테고리 수 시간 변동                | 교차 탄력성 프록시             |

Shannon 엔트로피와 HHI는 Renyi 엔트로피  $H_\alpha = \frac{1}{1-\alpha} \ln(\sum s_i^\alpha)$ 의 특수 사례이다: Shannon은  $\alpha \rightarrow 1$ , HHI는  $\alpha = 2$  ( $H_2 = -\ln(\text{HHI})$ ).

# 화학 반응속도론 피쳐 (Chemical Kinetics, 6D)

Multidisciplinary Arrhenius Equation 6D / 24D

## 이론적 근거

물리화학의 세계관에서 모든 변환(반응)은 에너지 지형(energy landscape) 위에서 일어난다. 시스템이 한 상태에서 다른 상태로 이동하려면 에너지 장벽을 넘어야 하며, 장벽의 높이가 전환의 난이도를, 넘는 빈도가 전환의 속도를 결정한다.

### Arrhenius 방정식

$$k = Ae^{-E_a/RT}$$

카테고리 전환 빈도( $k$ )는 진입 장벽( $E_a$ )이 감소하거나 소비자 활동성( $T$ )이 증가할 때 지수적으로 증가한다.

### 반감기

1차 반응의 반감기  $T_{1/2} = \ln 2/k$ 는 거래 간격의 중앙값에 대응한다. 반감기가 짧은 고객은 빠른 거래 주기를 가진다.

### 2차 유한차분

소비 가속도(spending acceleration)는 이산 2차 도함수이다:

$$f''(t) \approx f(t + \Delta t) - 2f(t) + f(t - \Delta t)$$

Taylor 전개에서  $f'$  항이 상쇄되어 유도되며, 가속(양)과 감속(음)을 구분한다.

## 출력 피쳐 (6D)

| 피쳐                           | 정의                                     | 금융 해석                              |
|------------------------------|----------------------------------------|------------------------------------|
| new_category_activation_rate | 최근 30일 신규 MCC / 활성 MCC                 | 역활성화 에너지 프로ksi                     |
| spending_half_life           | 거래 간격 중앙값 (일)                          | 화학 반감기 $T_{1/2} = \ln \frac{2}{k}$ |
| spending_acceleration        | $f(t+1) - 2f(t) + f(t-1)$              | 2차 유한차분: 가속(+) 또는 감속(-)            |
| dormancy_reactivation_rate   | W1 존재, W2 부재, W3 재출현 MCC               | 촉매적 재활성화율                          |
| catalyst_sensitivity         | 월초 일평균 소비 / 월말 일평균 소비                  | 급여일 촉매 탄력성                         |
| saturation_proximity         | $\frac{\max}{\text{avg} + \text{std}}$ | 소비 천장 근접도                          |

# SIR 역학 피처 (Epidemiology, 5D)

Multidisciplinary

Compartmental Model

5D / 24D

## 이론적 근거: Kermack-McKendrick 모델

$$\frac{dS}{dt} = -\beta SI, \quad \frac{dI}{dt} = \beta SI - \gamma I, \quad \frac{dR}{dt} = \gamma I$$

기본 재생산수:  $R_0 = \frac{\beta}{\gamma}$ .  $R_0 > 1$ 이면 채택이 자기강화적으로 확산,  $R_0 < 1$ 이면 자연 소멸.

## 금융 도메인 매핑

| 구획      | 역학      | 금융 해석                    |
|---------|---------|--------------------------|
| S (감수성) | 미감염     | 인구 Top-15 MCC 중 미사용 카테고리 |
| I (감염)  | 현재 전파 중 | 최근 30일 일평균 빈도 > 이전 기간    |
| R (회복)  | 면역/회복   | 과거 사용했으나 최근 30일 비활성 카테고리 |

감염 분류 기준은 기간 길이 보정 계수  $\frac{30}{L-30}$ 을 적용한다.

## 출력 피처 (5D)

| 피처                              | 설명                                         |
|---------------------------------|--------------------------------------------|
| <code>sir_susceptible</code>    | S 비율. 높으면 추천 기회 공간이 넓음 (exploration-ready) |
| <code>sir_infected</code>       | I 비율. 높으면 활발한 채택 중 (cross-sell 최적 타이밍)     |
| <code>sir_recovered</code>      | R 비율. 높으면 수축 중 (retention 캠페인 대상)          |
| <code>sir_r0</code>             | 기본 재생산수. 채택 확산의 자기강화 정도                    |
| <code>sir_infection_rate</code> | 채택 속도. $\beta S$ 에 대응                      |

## 고객 프로파일링

| 유형    | S    | I    | R   | 해석          |
|-------|------|------|-----|-------------|
| 탐색 준비 | High | Low  | Low | 추천 기회 공간 최대 |
| 활발 채택 | Mid  | High | Low | 교차 판매 최적 시점 |
| 안정 사용 | Low  | Low  | Low | 충성 고객       |

| 유형 | S   | I   | R    | 해석           |
|----|-----|-----|------|--------------|
| 수축 | Low | Low | High | 이탈 방지 캠페인 대상 |

# 범죄학 피쳐 (Crime Pattern / Routine Activity, 5D)

Multidisciplinary Routine Activity Theory 5D / 24D

## 이론적 근거

Cohen & Felson(1979)의 일상활동이론에서 행동은 일상 루틴에 의해 결정되며, 루틴의 이탈이 비정상 사건의 기회를 만든다.

### Burstiness (Barabasi, 2005)

$$B = \frac{\sigma_{\tau} - \mu_{\tau}}{\sigma_{\tau} + \mu_{\tau}} \in [-1, 1]$$

- $B = -1$ : 완벽히 규칙적 간격 (정기 결제)
- $B = 0$ : 포아송 과정 (무작위)
- $B = +1$ : 극단적 군집 (폭발적 쇼핑)

인간 행동은 포아송 과정이 아니라, 짧은 폭발(burst) 후 긴 휴지(rest)가 반복되는 중후꼬리 분포를 따른다.

### 원형 통계 (Circular Statistics)

거래 시각 분석에 필수적이다. 23시와 1시 사이의 거리는 22시간이 아니라 2시간이다.

$$\overline{R} = \left( \frac{1}{n} \sum \cos \theta_i, \frac{1}{n} \sum \sin \theta_i \right), \quad CV = 1 - |\overline{R}|$$

여기서  $\theta = 2\pi h/24$ . 유클리드 거리는 원형 시간을 왜곡하지만, 원형 통계는 올바르게 집중도를 측정한다.

## 출력 피쳐 (5D)

| 피쳐                     | 설명                                |
|------------------------|-----------------------------------|
| txn_burstiness         | 거래 간격의 Burstiness. 소비 리듬의 규칙성/폭발성 |
| time_circular_variance | 거래 시각의 원형 분산. 시간대 집중도             |
| routine_stability      | 루틴 안정성. 요일별 패턴의 일관성               |
| breakpoint_count       | 변조점 수. 소비 루틴이 깨진 횟수               |
| anomaly_score          | 이상 패턴 점수. 루틴 이탈의 강도               |

# 파동 간섭 피쳐 (Wave Interference, 8D)

Multidisciplinary Spectral Analysis 8D / 24D

## 이론적 근거

파동 물리학의 세계관에서 여러 파동이 중첩될 때, 위상 관계에 따라 보강(진폭 증가) 또는 상쇄(진폭 감소)가 일어난다.

### KL 발산

$$D_{\text{KL}}(P\|Q) = \sum P(x) \ln \frac{P(x)}{Q(x)}$$

주중/주말 소비 분포의 KL 발산은 두 맥락에서의 행동이 얼마나 다른지를 비트 단위로 정량화한다. Gibbs 부등식(Jensen 부등식의 결과)에 의해 항상 비음수이다.

### Phase Locking Value (PLV)

신경과학의 기능적 연결성에서 차용한 개념이다.

$$\text{PLV} = \frac{1}{T} \left| \sum_{t=1}^T e^{j(\varphi_x(t) - \varphi_y(t))} \right|$$

Hilbert 변환으로 추출한 두 카테고리 소비 리듬의 위상 차이 일관성을 측정한다.

### Cross-spectral Coherence

$$C_{xy}(f) = \frac{|S_{xy}(f)|^2}{S_{xx}(f) \cdot S_{yy}(f)}$$

주파수 분해능 상관으로, 어떤 주기에서 카테고리가 동기화되는지 식별한다.

## 출력 피쳐 (8D)

| 피쳐                  | 설명                                        |
|---------------------|-------------------------------------------|
| weekday_weekend_kl  | 주중/주말 소비 분포 KL 발산                         |
| spectral_entropy    | 파워 스펙트럼의 정규화 Shannon 엔트로피. 소비 주기성의 예측 가능성 |
| dominant_period     | FFT에서 가장 강한 주파수 성분의 주기 (일)                |
| phase_locking_value | PLV. 카테고리 간 소비 리듬의 위상 동기화                 |
| cross_coherence     | 교차 스펙트럼 코히어런스. 주파수별 카테고리 상관               |
| hhi_shift           | HHI 변화량. 소비 집중화/분산화 추세                    |

| 피쳐                                 | 설명                       |
|------------------------------------|--------------------------|
| <code>category_sync_ratio</code>   | 동기화 비율. 같은 위상의 카테고리 쌍 비율 |
| <code>interference_strength</code> | 간섭 강도. 카테고리 간 보강/상쇄 정도   |

## 정보이론적 정당성

네 다학제 모듈은 거의 직교하는 투영을 포착한다:

- **화학 반응속도론**: 시간의 미분 구조 (1차, 2차 도함수)
- **역학 확산**: 상태 공간 전이 구조 ( $S \rightarrow I \rightarrow R$ )
- **범죄 패턴**: 시계열의 통계적 질감 (주기성, 군집성, 분산)
- **파동 간섭**: 주파수 영역 스펙트럼 구조 (FFT, 코히어런스, 위상)

교차 모듈 조합이 개별 모듈에서 보이지 않는 패턴을 드러낸다: 예를 들어 높은 `catalyst_sensitivity` + 높은 `burstiness` = 급여일 폭발 소비자 (월초 타겟 프로모션 최적).

# TDA 피쳐 (Topological Data Analysis, 70D)

Domain Features Persistent Homology 70D / 159D

## 핵심 아이디어

### TDA의 핵심 원리

데이터 포인트에 점점 커지는 공을 씌우면서, 연결 성분/구멍/빈 공간 같은 위상적 특성이 언제 나타나고 언제 사라지는지를 추적한다. 오래 지속되는 특성은 신호이고, 금방 사라지는 특성은 노이즈이다.

TDA의 강점:

1. **좌표 불변성**: 데이터를 회전하거나 연속 변형해도 위상적 특성 보존. 피쳐 스케일링에 강건.
2. **다중 해상도 관찰**: 단일 임계값이 아닌 모든 스케일을 동시에 고려.
3. **노이즈 내성**: 오래 지속되는 특성만 취하여 허위 구조를 자연스럽게 필터링.

## Betti 수와 호몰로지

$$\beta_k = \text{rank}(H_k(X))$$

$H_k(X)$ 는 공간  $X$ 의  $k$ -차원 호몰로지 그룹이다.

- $\beta_0$ : 연결 성분 수 (점들이 몇 덩어리로 나뉘는가)
- $\beta_1$ : 1차원 구멍 수 (고리/루프가 몇 개인가)
- $\beta_2$ : 2차원 구멍 수 (빈 공동이 몇 개인가)

호몰로지는 “경계가 없는 체인 중에서 다른 것의 경계가 아닌 것”을 찾는 과정이다:

$$H_k = \text{Ker}(\partial_k) / \text{Im}(\partial_{k+1})$$

### 금융 도메인 해석

- $H_0$  **큰 값**: 소비가 여러 분리된 클러스터 (생활비 vs 여행비 vs 교육비)
- $H_1$  **존재**: 주기적 순환 패턴 (월초 카드값 → 월중 식비 → 월말 여가 → 반복)
- $H_2$  **존재**: 3차원 구조에서 “속이 빈” 패턴 (금액-카테고리-시간 축에서 중앙 공백)

## Vietoris-Rips 복합체와 지속 호몰로지

본 시스템은 Vietoris-Rips 복합체를 사용한다:

$$\sigma = \{x_0, \dots, x_k\} \in \text{VR}_\epsilon(X) \quad \text{iff} \quad d(x_i, x_j) \leq \epsilon, \forall i, j$$

Cech 복합체의 “2배 반지름” 근사이지만 계산이 훨씬 효율적이다 (쌍별 거리 비교만 필요).



지속 호몰로지(Persistent Homology)는 모든 스케일을 동시에 관찰하여 단일 임계값 민감성 문제를 해결한다. Persistence Diagram에서 대각선과 먼 점이 강한 신호이다.

### 안정성 정리

$$d_B(\text{Dgm}(f), \text{Dgm}(g)) \leq \|f - g\|_\infty$$

입력 섭동이 filtration 함수의 최대 변화량으로 경계된다. 위상 피쳐의 노이즈 강건성을 수학적으로 보장.

## 출력 피쳐 (70D)

| 서브그룹             | 차원  | 설명                     |
|------------------|-----|------------------------|
| tda_short        | 24D | 90일 앱 로그 기반 단기 위상 패턴   |
| tda_long         | 36D | 12개월 금융 거래 기반 장기 위상 패턴 |
| phase_transition | 10D | 시간 윈도우 간 위상 변화 감지      |

### PersLay Expert와의 관계

본 문서의 TDA 피쳐(오프라인 70D)와 PersLay Expert(온라인 64D)는 모두 Persistent Homology를 활용하지만 역할이 다르다. 70D는 734D 메인 텐서의 일부이며 배치 전처리에서 사전 계산된다. PersLay Expert는 PLE 내부에서 Persistence Diagram을 end-to-end로 학습한다.

# HMM 피쳐 (Hidden Markov Model, 5D summary + 48D separate)

Model-Derived + Separate Input   Triple-Mode HMM   53D total

## 핵심 아이디어: 숨겨진 상태 추론

카드 거래 데이터에서 직접 관측할 수 있는 것은 거래 금액, 횟수, 카테고리 다양성뿐이다. 그러나 같은 월 10만원 소비라도 “새 서비스를 탐색하는 고객”과 “이탈 직전의 마지막 소비”는 전혀 다른 상태이다. HMM은 관측 데이터로부터 관측 불가능한 잠재 상태를 **확률적으로 추론**한다.

### 마르코프 성질

$$P(q_{t+1} \mid q_t, q_{t-1}, \dots, q_1) = P(q_{t+1} \mid q_t)$$

다음 상태는 현재 상태에만 의존한다. 이 단순화 덕분에 파라미터 수가  $O(N^2)$ 로 제한되어 수십만 고객에서도 안정적 학습이 가능하다.

## Triple-Mode 구성

| 모드        | 상태 수 | 출력  | 포착하는 패턴                                                   |
|-----------|------|-----|-----------------------------------------------------------|
| Journey   | 5    | 16D | 일/주 단위 고객 여정 (AWARENESS → CONSIDERATION → PURCHASE → ...) |
| Lifecycle | 5    | 16D | 월/년 단위 생애주기 (NEW → GROWING → MATURE → AT_RISK → ...)      |
| Behavior  | 6    | 16D | 월별 행동 패턴 유형 (절약형, 투자형, 소비형 등)                             |

세 모드의 48D는 별도 입력(separate input)으로 PLE의 HMM Triple-Mode Projector에 공급된다.

### v14 Phase 0 개선 (2026-05-04): mode\_observation\_cols 분리

#### Triple-Mode 결정론적 동치 문제

v13 까지는 세 모드(journey/lifecycle/behavior)가 동일 입력 + 동일 random\_state=42 + 동일 n\_states=5 (journey/lifecycle) 로 학습되어, 결정론적으로 동일한 모델로 수렴하였다. 결과적으로 journey 와 lifecycle 의 상태 할당이 Cramer V = 1.0 으로 완전 일치하여, “Triple-Mode” 라는 설계 의도가 무효화되었다.

**이전:** 모든 모드가 동일 관측 컬럼 + 동일 seed 로 학습 → 동일 모델로 결정론적 수렴.

**수정 1:** mode 별 관측 컬럼을 분리하여 의미적으로 다른 시간 스케일을 포착 ( configs/santander/feature\_groups.yaml:245-274 ).

| 모드        | 전용 관측 컬럼 ( mode_observation_cols )                                                                         |
|-----------|------------------------------------------------------------------------------------------------------------|
| Journey   | synth_unique_mcc , synth_unique_merchants , synth_recency_days , synth_frequency , synth_unique_mcc_ll_idx |
| Lifecycle | synth_monthly_txns , synth_avg_amount , synth_monthly_spend , synth_monetary , synth_stability             |
| Behavior  | synth_morning_ratio , synth_afternoon_ratio , synth_evening_ratio , synth_night_ratio , synth_fraud_ratio  |

**수정 2:** mode 이름 hash 로 per-mode random\_state 자동 생성 ( core/feature/generators/hmm.py ). 동일 입력이라도 seed 가 다르므로 EM 수렴 경로가 분기된다.

**검증:** journey vs lifecycle Cramer V 1.0 → 0.5281. 두 모드가 더 이상 동일 모델이 아니며, 의미적 분리가 달성됨.

## 세 가지 핵심 알고리즘

| 문제  | 질문          | 알고리즘            | 용도                |
|-----|-------------|-----------------|-------------------|
| 평가  | 시퀀스의 우도는?   | Forward         | 모델 품질 검증, 이상치 탐지  |
| 디코딩 | 최적 상태 시퀀스는? | Viterbi         | 상태 시퀀스 추출 → 메타 피쳐 |
| 학습  | 최적 파라미터는?   | Baum-Welch (EM) | 전이/방출 분포 최적화      |

### Forward-Backward

$$\alpha_t(i) = P(o_1, \dots, o_t, q_t = S_i \mid \lambda), \quad \gamma_t(i) = P(q_t = S_i \mid \mathbf{O}, \lambda)$$

$\gamma_{t(i)}$  가 소프트 상태 할당 확률이며, 이것이 피쳐의 핵심이다. “80% 확률로 활성, 15% 확률로 성장, 5% 확률로 위험”이라는 확률 벡터 자체가 풍부한 피쳐가 된다.

## HMM Summary (메인 텐서 5D)

| 피쳐                       | 설명                                                  |
|--------------------------|-----------------------------------------------------|
| hmm_dominant_state       | 3개 모드 통합 시 최고 $\gamma_{t(i)}$ 상태 ID                 |
| hmm_state_duration       | 현재 지배 상태에 머문 연속 기간 (월 수)                            |
| hmm_transition_stability | 최근 N개월 상태 전이 빈도의 역수                                 |
| hmm_transition_entropy   | $H = -\sum_j a_{ij} \log a_{ij}$ . 높으면 다음 상태 예측 어려움 |
| hmm_state_change_rate    | 상태 변화 횟수 / 전체 기간                                    |

### HMM vs GMM

HMM은 시계열 상태 추론이다. “이 고객이 현재 어떤 단계에 있고, 다음에 어디로 이동하는가?” GMM은 횡단면 클러스터링이다. “이 고객이 어떤 유형인가?” 전이 행렬  $A$ 가 시간 역학을 포착하므로, 같은 소비 패턴이라도 “성장 중”인지 “이탈 직전”인지를 구분한다. 두 모듈은 서로 다른 입력 경로로 PLE에 공급되어 상호 보완한다.

# GMM 피쳐 (Gaussian Mixture Model, 22D)

Domain Features   EM Algorithm + BIC   22D / 159D

## 이론적 근거

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

여기서  $\pi_k \geq 0$ ,  $\sum_k \pi_k = 1$ 이고, 각 성분은 다변량 가우시안이다. 구성:  $K = 20$  클러스터,  $D = 40$  입력 차원, `covariance_type = "full"`.

핵심 가정: "관측 데이터는  $K$ 개 하위 집단에서 생성되었으며, 각 데이터 포인트의 소속은 관측되지 않는다(잠재 변수)."

## EM 알고리즘

### E-Step (사후 책임도)

$$\gamma_{nk} = \frac{\pi_k \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_j \pi_j \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}$$

직접적인 베이지 정리 적용: 사전 확률  $\pi_k$ 와 우도  $\mathcal{N}_k$ 를 결합하여 사후 확률  $\gamma_{nk}$ 를 얻는다.

### M-Step

$\gamma_{nk}$ 를 가중치로 사용하여  $\boldsymbol{\mu}_k$ ,  $\boldsymbol{\Sigma}_k$ ,  $\pi_k$ 를 갱신한다.

### 수렴 보장

Jensen 부등식에 의해 EM은 ELBO를 단조 비감소로 구성한다. 전역 최적 보장은 없으므로 `n_init=10`으로 완화.

## 모델 선택: BIC

$$\text{BIC} = -2 \ln \hat{L} + k \ln(n)$$

수십만 데이터에서 AIC( $-2 \ln \hat{L} + 2k$ )보다 BIC의  $k \ln(n)$  패널티가 과적합을 더 효과적으로 방지한다.

## 출력 피쳐 (22D)

| 피쳐                                | 차원  | 설명                                |
|-----------------------------------|-----|-----------------------------------|
| <code>cluster_prob_00 - 19</code> | 20D | 소프트 할당 확률 $\gamma_{nk}$ (합 = 1.0) |
| <code>cluster_id</code>           | 1D  | 하드 할당 $\arg \max_k \gamma_{nk}$   |

| 피쳐              | 차원 | 설명                                                         |
|-----------------|----|------------------------------------------------------------|
| cluster_entropy | 1D | $H_n = -\sum_k \gamma_{nk} \ln(\gamma_{nk} + \varepsilon)$ |

엔트로피 해석:

- $H \approx 0$ : 명확한 행동 원형 (확신 있는 분류)
- $H = \ln(20) \approx 2.996$ : 균등 분포 (골드스타트/분류 불능)

## GMM vs K-Means: 왜 소프트 할당인가

| 관점      | K-Means             | GMM                                |
|---------|---------------------|------------------------------------|
| 할당      | 하드: one-hot (1 bit) | 소프트: 확률 벡터 ( 4.32 bits max)        |
| 경계 고객   | 자의적 할당, 불안정         | 인접 클러스터에 확률 분산                     |
| 클러스터 형태 | 구형 (유클리드)           | 타원형 (Mahalanobis, full covariance) |
| 불확실성    | 없음                  | 엔트로피 기반 신뢰도                        |
| PLE 역할  | 단일 서브헤드 활성          | $\gamma_{nk}$ 가중 앙상블로 20개 서브헤드 결합  |

Mahalanobis 거리  $d_M = \sqrt{(x - \mu)^\top \Sigma^{-1} (x - \mu)}$ 는 피쳐 상관과 스케일 차이를 반영하여 유클리드 거리( $\Sigma = I$ )를 일반화한다.

## v14 Phase 0 개선 (2026-05-04): K=14 + flat-kwarg fix

**이전:**  $K = 20$  로 BIC 기반 선택을 가정하였으나, 실제 학습 결과 7 개 클러스터가 dead (각각 1 row) 상태로 수렴하였다. 출력은 22D (= 20 prob + cluster\_id + entropy) 였으나 유효 클러스터는 13 개에 불과하여 라우팅 신호가 희석되었다.

**수정 1:**  $K = 14$  로 축소 ( configs/santander/feature\_groups.yaml:407 ). 출력 차원은 16D (= 14 prob + cluster\_id + entropy). 14 개 클러스터 모두 활성 (min = 4{, }798 rows, max = 144{, }763 rows).

**수정 2:** GMMClusteringGenerator.\_\_init\_\_ 의 yaml flat-kwarg parsing 버그 수정. 이전에는 yaml 의 n\_clusters: 14 가 평탄화된 kwargs 로 전달되었으나 GMMConfig 로 라우팅되지 않아 내부적으로 default  $K = 20$  이 사용되었다. v14 에서 flat-kwarg 도 GMMConfig 필드로 매핑되도록 수정.

**검증:** 14 클러스터 모두 살아있음. 소프트 할당의 엔트로피 분포가 정상화되어 GroupTaskExpertBasket 의 라우팅 신호가 의미를 회복.

### K 선택의 함의

$K = 14$  는 BIC 의 전역 최적이라기보다, 유효 클러스터 수 와 PLE 서브헤드 수 의 정합을 우선한 운영적 선택이다. dead cluster 가 존재하면 PLE Task Expert 서브헤드 중 일부가 항상 zero gating 을 받아 학습 신호가 끊기므로, BIC 가 약간 더 낮더라도 모두 활성인  $K$  를 선택한다.

# Mamba 시계열 피쳐 (Selective State Space, 50D)

Domain Features    Mamba SSM + PCA    50D / 159D

## 핵심 아이디어

단순 집계 통계(합계, 평균, 표준편차)는 시계열의 **순서 정보(temporal ordering)**를 완전히 파괴한다. 값들을 무작위로 섞어도 합계와 평균은 변하지 않는다. Mamba SSM은 선택적 상태 공간 메커니즘으로 시계열의 비선형 장기 의존성을 포착한다.

## Selective State Space Model

Mamba는 연속 상태 공간 모델(SSM)의 이산화에 기반한다:

$$\text{연속: } h'(t) = Ah(t) + Bx(t), \quad y(t) = Ch(t)$$

$$\text{이산화: } \bar{A} = \exp(\Delta A), \quad \bar{B} = (\Delta A)^{-1}(\exp(\Delta A) - I) \cdot \Delta B$$

핵심:  $\Delta_k$ 가 입력에 따라 **동적으로** 변하므로, 비정상 시계열에서도 적응적으로 상태를 업데이트한다.

## 기존 방법 대비 강점

| 관점     | RNN       | Transformer         | Mamba            |
|--------|-----------|---------------------|------------------|
| 장기 의존성 | 소실 문제     | Self-attention으로 해결 | 선택적 SSM으로 해결     |
| 시퀀스 길이 | $O(T)$ 순차 | $O(T^2)$ 메모리        | $O(T)$ 선형        |
| 비정상성   | 적응 어려움    | 위치 인코딩 의존           | $\Delta_k$ 동적 적응 |

## 파이프라인

1. MCC 15D × 180일 입력 시퀀스
2. Mamba 인코더 ( `d_model=256` )로 숨겨진 표현 추출
3. PCA → 50D 압축
4. 734D 메인 텐서의 Domain 블록에 통합

### 온라인 Mamba Expert와의 구분

본 피쳐(오프라인 50D)는 `d_model=256` , 입력 MCC 15D × 180일이며 PLE 학습 이전에 사전 계산된다. Temporal Expert의 Mamba는 PLE 내부 `d_model=128` , 입력 card 16D × 180 steps로 end-to-end 학습된다. 가중치 공유 없음.

## 시계열 분석의 4가지 관점

Mamba 50D는 아래 네 관점의 정보를 비선형으로 통합한 학습된 표현이다:

| 관점      | 핵심 질문               | 기법              |
|---------|---------------------|-----------------|
| 시간 도메인  | 값이 시간에 따라 어떻게 변하는가? | 자기상관, 변환점, 이동평균 |
| 주파수 도메인 | 어떤 주기로 반복되는가?       | FFT, 스펙트럼 분석    |
| 분포/형상   | 값의 분포는 어떤 모양인가?     | 왜도, 첨도, 꼬리 확률   |
| 정보이론    | 얼마나 복잡하고 예측 가능한가?   | 엔트로피, 순열 엔트로피   |



# Graph 피쳐 (LightGCN + Hyperbolic GCN)

Offline Precomputed   Graph Neural Network   64D + H-GCN aggregation

## LightGCN: 협업 필터링

### Message Passing

$$e_u^{(k+1)} = \sum_{i \in \mathcal{N}_u} \frac{1}{\sqrt{|\mathcal{N}_u|} \cdot \sqrt{|\mathcal{N}_i|}} \cdot e_i^{(k)}$$

대칭 정규화  $\tilde{A} = D^{-1/2} A D^{-1/2}$ 는 인기 아이템(sender)과 수신자 영향을 동시에 억제한다.

### Layer Combination

$$e_u^{\text{final}} = \frac{1}{L+1} \sum_{k=0}^L e_u^{(k)}$$

0-hop 자기 자신 + 1,2,3-hop 이웃의 균등 평균. 학습 가능한 attention 가중치 없이도 실증적으로 우수하며 과적합을 방지한다.

### BPR Loss

$$\mathcal{L}_{\text{BPR}} = - \sum_{(u, i^+, i^-)} \log \sigma(\hat{y}_{ui^+} - \hat{y}_{ui^-}) + \lambda \|\Theta\|^2$$

쌍별 랭킹 손실로 절대 점수가 아닌 상대 순위를 최적화한다.

## Hyperbolic GCN: 계층 구조

### Poincare Ball 모델

$$\mathbb{B}_c^d = \{x \in \mathbb{R}^d : c\|x\|^2 < 1\}$$

**지수 맵:**  $\exp_0(v) = \tanh(\sqrt{c}\|v\|) \cdot \frac{v}{\sqrt{c}\|v\|}$

**Poincare 거리:**  $d_{\mathbb{B}}(x, y) = \frac{1}{\sqrt{c}} \operatorname{arccosh}\left(1 + \frac{2c\|x-y\|^2}{(1-c\|x\|^2)(1-c\|y\|^2)}\right)$

경계 근처에서 분모  $\rightarrow 0$ 이므로 유클리드 거리가 작아도 쌍곡 거리가 폭발한다. 이것이 계층적 깊이를 자연스럽게 인코딩하는 메커니즘이다.

## 금융 도메인 정당성

MCC 분류 체계(Root → L1(8) → L2( 100) → Brand( 50K) → Branch( 500K))는 본질적으로 트리 구조이다. 쌍곡 공간은 지수적 체적 성장으로 트리 분기를 매칭하여 8D Poincare Ball로 550K 노드를 임베딩한다. Nickel & Kiela(2017) 결과: 5D 쌍곡 > 200D 유클리드 (WordNet 계층).

## Dual GCN 구성

| 속성    | LightGCN               | H-GCN                        |
|-------|------------------------|------------------------------|
| 노드    | 고객 + 가맹점 (이분 그래프)      | 가맹점만 (MCC 트리)                |
| 엣지    | 고객-가맹점 거래              | 부모-자식 계층 + 브랜드 co-visitation |
| 공간    | $\mathbb{R}^{64}$ 유클리드 | $\mathbb{B}^8$ Poincare Ball |
| 학습 목적 | “누가 무엇을 좋아하는가”         | “가맹점이 구조적으로 어떻게 관련되는가”       |
| 출력    | 고객 임베딩 64D (직접)        | 가맹점 임베딩 → 고객별 집계 (간접)        |

**2-Stage 파이프라인:** Stage 1(오프라인) 그래프 학습 → 임베딩 Parquet 저장. Stage 2(온라인) lookup + 경량 MLP 적용. 추론 시 그래프 전파 없음 – 단일 GPU에서 VRAM 친화적.

# 기타 피쳐 (Base Demographics, Product Holdings, Transaction Behavior)

Base Features 238D + 91D + 84D 413D / 644D

## Base 피쳐 (238D)

전통적 금융 ML의 기반이 되는 피쳐 블록이다.

| 서브그룹                               | 차원  | 설명                        |
|------------------------------------|-----|---------------------------|
| RFM (Recency, Frequency, Monetary) | 34D | 거래 기간, 빈도, 금액의 다차원 분해     |
| Category                           | 64D | MCC 카테고리별 소비 비율/금액/빈도     |
| Transaction Stats                  | 76D | 거래 통계: 평균/중위/표준편차/왜도/첨도 등 |
| Product Diversity                  | 12D | 보유 상품 다양성, 교차 보유 패턴       |
| Channel Behavior                   | 18D | 온라인/오프라인/모바일 채널 비율        |
| Temporal Pattern                   | 22D | 요일별/시간대별 거래 분포            |
| Demographics                       | 12D | 연령, 성별, 지역 등 인구통계         |

## Multi-Source 피쳐 (91D)

| 서브그룹               | 차원  | 설명                    |
|--------------------|-----|-----------------------|
| Deposit            | 25D | 예금 잔액, 입출금 패턴, 금리 민감도 |
| Credit             | 20D | 신용 등급, 한도 사용률, 연체 이력  |
| Investment         | 15D | 투자 상품 보유, 위험 선호도      |
| Digital Engagement | 31D | 앱 로그, 로그인 빈도, 기능 사용   |

## Extended-Source 피쳐 (84D)

| 서브그룹                | 차원  | 설명              |
|---------------------|-----|-----------------|
| Insurance           | 20D | 보험 상품 보유, 가입 이력 |
| Refund/Cancellation | 15D | 환불 빈도, 취소 패턴    |
| Consultation/STT    | 25D | 상담 이력, 음성 인식 분석 |
| External Signals    | 24D | 외부 데이터 연동 신호    |

## Model-Derived 피처 (27D)

| 서브그룹           | 차원  | 설명                                                                                 |
|----------------|-----|------------------------------------------------------------------------------------|
| HMM Summary    | 5D  | Triple-Mode 48D의 압축 표현 (dominant state, duration, stability, entropy, change rate) |
| Bandit/MAB     | 4D  | Multi-Armed Bandit 기반 탐색-활용 균형 지표                                                  |
| LNN Statistics | 18D | 이동평균, 변동성, 자기상관 등 수작업 통계 피처                                                        |

## Merchant Hierarchy 피처 (27D)

MCC 계층 구조(Root → L1 → L2 → Brand)를 반영한 좌표 및 임베딩. Phase 0 v3/v4에서 MCC Poincaré 임베딩으로 업그레이드됨 (이전 버전: 21D 통계치만). H-GCN에서 추출한 쌍곡 좌표와 co-visitation 기반 브랜드 유사도를 포함한다.

## 3-Stage 정규화 파이프라인

Preprocessing   Power-law → Scaler → Raw Copy   644D + 90D

### 설계 원칙

정규화 파이프라인은 세 단계로 구성되며, **역법칙(power-law) 분포**를 가진 피쳐의 원본 크기 정보를 보존하면서도 모델 학습에 적합한 스케일로 변환하는 것이 핵심 목표이다.

### Stage 1: 역법칙 감지 + log1p 복사본 생성

역법칙 감지 기준:

1. 왜도(skewness) + 첨도(kurtosis) 기반 후보 선별
2. log-log 회귀의  $R^2$ 로 역법칙 여부 판정

**역법칙 확인 시:** 해당 컬럼의 `log1p` 복사본을 생성하여 별도 보존

$$x_{\text{raw}} = \log(1 + x)$$

역법칙 분포(거래 금액, 잔액 등)는 StandardScaler 적용 시 이상치에 의해 대부분의 값이 0 근처에 압축되어 정보가 손실된다. log1p 변환은 이 문제를 완화한다.

### Stage 2: StandardScaler (TRAIN fit only)

$$z = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}}$$

**적용 대상:** continuous 컬럼만 (binary 컬럼 제외) **핵심 규칙:** Scaler는 반드시 TRAIN split에서만 fit. val/test는 train에서 fit된 scaler로 transform만 수행.

#### 데이터 리키지 방지

val/test 데이터로 scaler를 fit하면 미래 정보가 학습에 유입되어 실제 성능보다 과대 추정된다. 이것은 가장 흔한 리키지 패턴이므로 LeakageValidator가 학습 전에 반드시 검증한다.

### Stage 3: Raw power-law 보존

역법칙 컬럼의 `_log` 복사본(Stage 1에서 생성)은 **스케일링하지 않고** 원본 크기(raw magnitude)를 그대로 보존한다.

**왜 raw copy를 보존하는가**

StandardScaler는 정보를 재배치하지만, **절대적 크기 정보**를 파괴한다. 예를 들어 “월 소비 100만원”과 “월 소비 1000만원”의 차이는 z-score로 변환 후 상대적 위치만 남는다. 그러나 일부 태스크(예: LTV 예측, spending\_bucket 분류)에서는 절대 금액 정보가 핵심이다. Raw power-law 90D 복사본은 이 정보를 모델에 직접 제공한다.

## 최종 텐서 구성

| 구간                    | 차원          | 처리                             |
|-----------------------|-------------|--------------------------------|
| Normalized continuous | 554D        | Stage 2 StandardScaler 적용      |
| Binary (pass-through) | 90D         | 스케일링 미적용 (0/1 보존)              |
| Raw power-law copy    | 90D         | Stage 1 log1p만 적용, Stage 2 미적용 |
| 합계                    | <b>734D</b> | 644D normalized + 90D raw      |

## v14 Phase 0 개선 (2026-05-04): 확률 컬럼 scaler 제외

**이전:** GMM의 `gmm_cluster_prob_*` 와 HMM의 `hmm_*_prob_*` 컬럼이 Stage 2의 StandardScaler에 그대로 입력되었다. 원본 분포가  $[0, 1]$  범위인 확률값이 평균 0, 표준편차 1로 변환되어 대략  $\pm 1.7$  범위로 왜곡되었고, 합 = 1.0의 시뮬렉스 제약도 깨졌다. PLE의 라우팅 가중치로 직접 사용되어야 하는 확률 신호가 의미를 잃은 셈이다.

**수정:** `core/pipeline/normalizer.py:112-141` 에서 `_probability_prefixes` 의 default를 확장하고, `_prob_infix` 를 자동 감지하여 StandardScaler에서 제외. 확률 컬럼은 raw  $[0, 1]$  그대로 모델에 공급된다.

**근거:** CLAUDE.md §1.9 의 `exclude_from_scaler: [categorical_id, probability]` 정책의 실 구현. 범주형 ID 파생 정수도 동일하게 제외 대상이다.

### 확률 컬럼 식별 규칙

자동 감지는 두 단계로 작동한다 — (1) `gmm_cluster_prob_`, `hmm_journey_prob_`, `hmm_lifecycle_prob_`, `hmm_behavior_prob_` 등 prefix 매칭, (2) 컬럼명에 `_prob_infix` 가 포함된 모든 컬럼. 추가로 `feature_groups.yaml` 의 `exclude_from_scaler` 필드에 generator 측이 명시적으로 선언할 수도 있다.




그림 1: 3단계 정규화 파이프라인: 멱법칙 감지 → StandardScaler → raw 복사본 보존.

## 정규화 파이프라인 흐름 요약

## 부록: 설계 vs 구현 차원 매핑

### 참고

이 부록은 풀뱅크 설계(734D)와 현재 Santander 벤치마크 구현(1211D 입력, 17 feature groups) 간의 차원 차이를 정리한 것입니다. 구현 차원은 `outputs/phase0/feature_schema.json` 에서 확인할 수 있습니다. **FeatureRouter 활성화**: 1205D 입력은 전문가별로 서브셋 슬라이싱되어 전달됩니다 — 각 전문가의 실제 입력 차원은 아래 per-expert 컬럼을 참조하십시오.

| 피쳐 그룹                 | 설계 (734D)     | 구현 (1205D)   | 주요 수신 전문가              | 비고                                                                                        |
|-----------------------|---------------|--------------|------------------------|-------------------------------------------------------------------------------------------|
| TDA                   | 70D           | 32D          | perslay (32D)          | tda_global 16D + tda_local 16D                                                            |
| HMM                   | 48D + 5D (별도) | 25D          | temporal 일부            | main tensor only                                                                          |
| Base (Profile 등)      | 238D          | 53D          | deepfm, causal, ot 일부  | demographics 11D +<br>product_holdings 24D +<br>derived_temporal 4D +<br>txn_behavior 14D |
| Graph                 | 미명시           | 100D         | lightgcn (955D 포함)     | graph_collaborative 66D +<br>product_hierarchy 34D                                        |
| Merchant Hierarchy /  | 27D           | 27D          | hgcn (58D 포함)          | MCC Poincaré 임베딩 (merchant_hierarchy)                                                     |
| GMM + Model           | 22D           | 49D          | deepfm, causal 일부      | gmm_clustering 22D +<br>model_derived 27D                                                 |
| Lag Tensor (신규)       | —             | 800D         | deepfm, lightgcn       | txn_lag_tensor: K=200×4 (lag_extractor)                                                   |
| Rolling Stats (신규)    | —             | 20D          | deepfm, causal, ot     | txn_rolling_stats: 4 windows×5 (rolling_stats_extractor)                                  |
| Multi-hot (신규)        | —             | 55D          | lightgcn, deepfm, hgcn | nba_label_multihot 24D +<br>mcc_top30_multihot 31D (topn_multihot_extractor)              |
| Mamba                 | —             | 50D          | temporal_ensemble      | GPU 사전 계산, cached parquet DuckDB JOIN                                                     |
| 기타 (Economics, SIR 등) | 335D          | —            | —                      | Santander 벤치마크 미구현                                                                        |
| <b>합계</b>             | <b>734D</b>   | <b>1211D</b> | —                      | 17 feature groups                                                                         |



### per-expert 입력 차원 요약 (FeatureRouter 활성화)

deepfm=977D, temporal\_ensemble=116D, hgcN=58D, perslay=32D, causal=129D, lightgcN=955D, optimal\_transport=95D (mlp=57D 는 PLE CGC 의 task-specific tower). 출력은 모두 64D로 균일. 모델 파라미터: 4.77M → 2.8M (post-FeatureRouter pruning; lag tensor 800D로 deepfm/lightgcN 대폭 증가, 파라미터 추정치는 그룹 토글에 따라 변동). 라우팅 구성: `feature_groups.yaml` 의 `target_experts` 필드.

## 추가 자료

---

- **경제학 계열**: Friedman 1957 (Consumption Function); Hall 1978 (PIH); Hodrick & Prescott 1997; Kalman 1960; Kahneman & Tversky 1979 (Prospect Theory).
- **다학제**: Arrhenius 1889; Kermack & McKendrick 1927 (SIR); Cohen & Felson 1979 (Routine Activity); Barabasi 2005 (burst); Shannon 1948; Kullback & Leibler 1951.
- **TDA / PersLay**: Carlsson 2009; Edelsbrunner et al. 2002; Cohen-Steiner et al. 2007; Carriere et al. AISTATS 2020 (PersLay).
- **HMM**: Baum & Petrie 1966; Rabiner 1989; Dempster et al. 1977 (EM).
- **GMM**: Pearson 1894; Schwarz 1978 (BIC); Bishop 2006 (PRML Ch. 9).
- **시계열 / Mamba**: Gu & Dao 2023 (Mamba); Cooley & Tukey 1965 (FFT).
- **Graph**: He et al. SIGIR 2020 (LightGCN); Chami et al. NeurIPS 2019 (HGCN); Nickel & Kiela NeurIPS 2017 (Poincare); Rendle et al. UAI 2009 (BPR).