

TECH REFERENCE

PLE + adaTT

기술 참조서

Progressive Layered Extraction · Adaptive Task Transfer
CGC Gate · GroupTaskExpertBasket · Logit Transfer · 2-Phase Training

프로젝트

AWS PLE for Financial

PLE-Cluster-adaTT Architecture

버전

v1.0

2026-04-01

이 문서는 PLE-Cluster-adaTT 아키텍처의 핵심 구조를 기술한다. Shared-Bottom에서 PLE까지의 발전, 이중 전문가 Basket 설계, adaTT gradient 기반 태스크 전이, 태스크 그룹 구조, 학습 전략, 구현 시 FP16/GradScaler 주의사항을 포함한다.

목 차

1. PLE 아키텍처	4
1.1 Multi-Task Learning의 동기	4
1.2 Shared-Bottom에서 PLE까지의 발전	4
Shared-Bottom (Caruana, 1997)	4
MMoE (Ma et al., KDD 2018)	4
PLE (Tang et al., RecSys 2020)	4
1.3 CGC (Customized Gate Control)	5
CGCLayer (가중합 방식)	5
CGCAttention (블록 스케일링 방식)	5
초기 Bias 설정 (domain_experts)	6
Entropy 정규화	6
차원 정규화 (v3.3)	6
2. 이중 전문가 Basket	7
2.1 Pool/Basket 패턴	7
2.2 Expert 선정 기준	8
2.3 Expert 라우팅 (FeatureRouter)	8
3. adaTT — Adaptive Task-aware Transfer	10
3.1 Motivation: Negative Transfer	10
3.2 Gradient Cosine Similarity	10
3.3 EMA 안정화	11
3.4 Transfer-Enhanced Loss	11
3.5 Transfer Weight 계산 (4-stage pipeline)	11
3.6 3-Phase Schedule	12
3.7 Group Prior	12
3.8 Negative Transfer 감지 및 차단	13
3.9 Attention 메커니즘과의 유비	13
4. 태스크 그룹	14
4.1 4개 Financial DNA 그룹	14
4.2 Intra/Inter Strength 설계	14
4.3 Logit Transfer 3방식	14
4.4 GroupTaskExpertBasket (v3.2)	15
Soft Routing	15
5. 학습 전략	16
5.1 2-Phase Training	16
Phase 1: Shared Expert Pretrain	16
Phase 2: Cluster Finetune	16
5.2 Uncertainty Weighting	16
5.3 Focal Loss	17
5.4 AMP (Automatic Mixed Precision)	17
6. 구현 참고사항	18
6.1 FP16 주의점	18
Focal Loss float32 캐스팅	18

adaTT Gradient 추출과 autocast	18
6.2 GradScaler Guard	18
Gradient 추출 빈도 최적화	18
torch.compiler.disable	18
6.3 v14 Phase 0 개선 (2026-05-04): train.py 메모리 리팩터	19
이전 (v13 까지)	19
수정 (v14)	19
검증	19
6.4 Phase 2 Frozen Layer	19
CGC-adaTT 동기화	20
6.5 Loss 계산 파이프라인 전체 순서	20
6.6 디버깅 가이드	20
추가 자료	21

설계 vs 구현 참고

본 문서는 풀뱅크 설계(734D)를 기준으로 작성되었습니다. 현재 Santander 벤치마크 구현은 1205D 입력 (17 feature groups, 2026-04-28)입니다. Expert별 라우팅 차원은 feature_schema.json에서 확인하세요. 본문의 734D 수치는 풀뱅크 설계 기준입니다.

1. PLE 아키텍처

1.1 Multi-Task Learning의 동기

AIOps 추천 시스템은 12개 태스크를 동시 예측해야 한다. 태스크 간 공유되는 패턴을 활용하면 데이터 효율이 극적으로 향상된다. 총 손실은 가중합으로 정의된다:

$$\mathcal{L}_{\text{MTL}} = \sum_{k=1}^K w_k \cdot \mathcal{L}_k(f_k(h_{\text{shared}}(x)))$$

h_{shared} 는 어느 한 태스크에만 과적합하기 어렵다. 모든 태스크에 동시에 유용한 표현만이 살아남으며, 이것이 **태스크 간 상호 정규화(inter-task regularization)**이다.

1.2 Shared-Bottom에서 PLE까지의 발전

Shared-Bottom (Caruana, 1997)

모든 태스크가 하나의 trunk을 공유한 뒤 태스크별 head로 분기한다.

$$h = f_{\text{shared}}(x) \rightarrow \hat{y}_k = f_k^{\text{tower}}(h)$$

구현이 단순하고 파라미터 효율적이거나, 태스크 간 관련성이 낮을 때 **Negative Transfer**가 심각하다.

MMoE (Ma et al., KDD 2018)

N 개의 동일 구조 Expert를 두고 태스크별 gate가 가중합을 결정한다.

$$h_k = \sum_{i=1}^N g_{k,i} \cdot f_i^{\text{expert}}(x), \quad g_k = \text{Softmax}(W_k^{\text{gate}} \cdot x)$$

태스크별로 다른 Expert 조합이 가능하나, 모든 gate가 동일 Expert를 선택하는 **Expert Collapse** 문제가 발생한다.

PLE (Tang et al., RecSys 2020)

Expert를 **Shared Expert** $\mathcal{E}^s$ 와 **Task-specific Expert** $\mathcal{E}^k$ 로 명시 분리하고, CGC gate가 두 종류의 Expert를 최적 비율로 결합한다.

$$h_k = \sum_{i=1}^{|\mathcal{E}^s|} g_{k,i}^s \cdot e_i^s + \sum_{j=1}^{|\mathcal{E}^k|} g_{k,j}^k \cdot e_j^k$$

e_i^s : i 번째 Shared Expert 출력, e_j^k : 태스크 k 의 j 번째 Task Expert 출력
 $g_{k,i}^s, g_{k,j}^k$: CGC gate 가중치 (Softmax 정규화)

PLE가 해결하는 문제:

1. **Negative Transfer 완화**: Task-specific Expert가 간섭 없이 특화 패턴 학습

2. **Expert Collapse 방지**: Shared/Task Expert 역할이 자연스럽게 분리
 3. **Progressive Extraction**: 여러 layer를 쌓아 저수준에서 고수준으로 정보 정제

구분	Shared-Bottom	MMoE	PLE
Expert 구조	단일 Shared trunk	N개 Expert 전체 공유	Shared + Task-specific 분리
게이팅	없음	태스크별 Softmax gate	CGC: Shared + Task Expert 결합
Negative Transfer	높음	중간 (Expert Collapse)	낮음 (명시적 분리)
Expert Collapse	N/A	높음	낮음

1.3 CGC (Customized Gate Control)

본 구현에서는 두 가지 CGC 변형이 존재하며, 역할과 출력 형태가 다르다.

CGCLayer (가중합 방식)

원본 PLE 논문의 CGC로, 태스크별 gate가 Shared + Task Expert 출력의 **가중합**을 산출한다. 출력 차원은 `expert_hidden_dim` 으로 고정된다 (Expert 수와 무관).

$$h_k = \sum_{i=1}^N g_{k,i} \cdot e_i, \quad g_k = \text{Softmax}(W_k^{\text{gate}} \cdot x) \in \mathbb{R}^N$$

N : Shared + Task Expert 총 수

$e_i \in \mathbb{R}^{d_{\text{expert}}}$: i 번째 Expert 출력

결과: $h_k \in \mathbb{R}^{d_{\text{expert}}}$ — Expert 수에 무관한 고정 차원

CGCAttention (블록 스케일링 방식)

이중 Expert의 출력을 **연결(concatenation)**한 뒤 태스크별 attention weight로 각 Expert 블록을 스케일링한다. 출력 차원은 모든 Expert 출력 차원의 합이다.

$$w_k = \text{Softmax}(W_k \cdot h_{\text{shared}} + b_k) \in \mathbb{R}^8$$

$$\tilde{h}_{k,i} = w_{k,i} \cdot h_i^{\text{expert}} \quad \text{for } i = 1, \dots, 8$$

$$h_k^{\text{cgc}} = [\tilde{h}_{k,1} \parallel \tilde{h}_{k,2} \parallel \dots \parallel \tilde{h}_{k,8}] \in \mathbb{R}^{576}$$

$W_k \in \mathbb{R}^{8 \times 576}$: 태스크 k 의 gate weight

$w_{k,i}$: 태스크 k 가 Expert i 에 부여하는 attention weight

결과: 동일 576D이지만 태스크마다 Expert별 기여 비중이 다름

본 PLE-Cluster-adaTT 구현에서는 7개 이중 Shared Expert에 대해 **CGCAttention** (블록 스케일링)을 사용한다. Transformer Attention과 유사하게 **Query**(gate weight), **Key**(shared representation), **Value**(Expert output)의 관계로 "관련성에 비례하여 정보를 선택적으로 결합"한다.

초기 Bias 설정 (domain_experts)

태스크별 domain_experts config로 선호 Expert에 bias_high=1.0, 비선호에 bias_low=-1.0을 부여하여 학습 초기 Expert 선택을 유도한다.

Entropy 정규화

Expert Collapse 방지를 위해 gate 분포의 엔트로피를 정규화한다:

$$\mathcal{L}_{\text{entropy}} = \lambda_{\text{ent}} \cdot \left(-\frac{1}{|\mathcal{T}|} \right) \sum_{k \in \mathcal{T}} H(\mathbf{w}_k), \quad H(\mathbf{w}_k) = - \sum_{i=1}^8 w_{k,i} \cdot \log(w_{k,i})$$

$\lambda_{\text{ent}} = 0.01$: 음의 엔트로피를 최소화하면 엔트로피가 증가하여 Expert 활용 분산 유도

차원 정규화 (v3.3)

이중 Expert 차원 비대칭(128D vs 64D)에 의한 기여도 불균형을 보정한다:

$$\text{scale}_i = \sqrt{\frac{\text{mean_dim}}{\text{dim}_i}}, \quad \text{mean_dim} = \frac{128 + 64 \times 7}{8} = 72.0$$

unified_hgcn (128D): scale ≈ 0.750 (감쇠), 나머지 (64D): scale ≈ 1.061 (증폭)

2. 이종 전문가 Basket

2.1 Pool/Basket 패턴

본 시스템은 PLE의 동일 구조 Expert 대신 **7개 이종 도메인 Expert**를 Shared Expert Pool로 결합한다. 각 Expert는 입력 데이터를 전혀 다른 수학적 관점으로 해석하며, CGC Gate가 태스크별 최적 조합을 학습한다.

FeatureRouter 활성화 (현재 구현): `feature_groups.yaml`의 `target_experts` 선언에 따라 FeatureRouter가 각 Expert에게 전체 1205D (17 feature groups) 중 해당 Expert에 지정된 피처 서브셋만을 슬라이싱하여 전달한다. 이로 인해 각 Expert의 입력 차원은 서로 다르며(이종 입력), 출력은 64D로 균일하게 정렬된다.

Expert	라우팅 입력 (1205D 서브셋)	출력	역할 및 대체 불가능성
DeepFM	977D (State + lag_tensor 800D + rolling_stats 20D + multihot 55D)	64D	FM의 $O(nk)$ 2차 교차를 명시적으로 포착
LightGCN	955D (product_hier 34D + graph_collab 66D + lag_tensor 800D + multihot 55D)	64D	이분 그래프 기반 "비슷한 고객" 협업 신호
Unified HGCM	58D (merchant_hier 27D + mcc_top30_mh 31D)	128D	Poincaré 임베딩으로 쌍곡 공간에서 MCC 계층 구조 인코딩
Temporal	116D (txn_behavior 14D + hmm_states 25D + mamba 50D + model_derived 27D)	64D	Mamba+LNN+Transformer 시간 패턴 양상블
PersLay	32D (tda_global 16D + tda_local 16D)	64D	소비 패턴의 위상적 구조(루프, 클러스터)
Causal	129D (demographics 11D + holdings	64D	SCM/NOTEARS 기반 방향성 인과 관계 추출

	24D + txn 14D + derived 4D + prod_hier 34D + gmm 22D + rolling 20D)		
Optimal Transport	95D (demographics 11D + holdings 24D + txn 14D + derived 4D + gmm 22D + rolling 20D)	64D	Sinkhorn Wasserstein 분포 기하학
RawScale	원시 역법칙 서브셋	64D	정규화 전 역법칙 분포 정보 보존

결합 차원은 $7 \times 64 + 1 \times 128 = 576D$ 이다.

$$h_{\text{shared}} = [\text{unified_hgc}_{128D} \parallel \text{perslay}_{64D} \parallel \text{deepfm}_{64D} \parallel \text{temporal}_{64D} \parallel \text{lightgcn}_{64D} \parallel \text{causal}_{64D} \parallel \text{OT}_{64D} \parallel \text{raw_scale}_{64D}]$$

이중 입력 → 균일 출력

FeatureRouter 활성화 이후 각 Expert의 입력 차원이 상이하더라도(이중 입력), 각 Expert 내부의 입력 프로젝션 레이어가 해당 서브셋 차원에 맞게 초기화되어 출력은 64D로 동일하게 유지된다. CGC Gate는 이 균일한 64D 표현을 결합한다.

2.2 Expert 선정 기준

8개 Expert는 동일 고객 데이터의 **근본적으로 다른 수학 구조**를 추출한다:

- **DeepFM (977D)**: 피쳐 상호작용 중심 서브셋 — 대칭 교차(FM) 구조 포착 (lag_tensor 포함)
- **Causal (129D)**: 인과 구조 관련 서브셋 — 비대칭 인과(DAG) 방향성 추출
- **Optimal Transport (95D)**: 분포 비교 서브셋 — Wasserstein 분포 거리 포착
- **Temporal (116D)**: 시계열 서브셋 — 시간적 동역학 (Mamba 50D 포함)
- **PersLay (32D)**: TDA 서브셋 — 위상적 불변량 (Betti number, persistence)
- **Unified HGCN (58D, merchant_hierarchy + mcc_top30_multihot)**: 계층/그래프 서브셋 — 쌍곡 기하학에서의 MCC 계층 관계
- **LightGCN (955D)**: 그래프 서브셋 — 고객-가맹점 그래프의 협업 필터링 신호; lag_tensor 포함
- **RawScale**: 정규화 시 손실되는 원시 스케일/역법칙 분포 패턴

2.3 Expert 라우팅 (FeatureRouter)

각 Expert는 config의 `shared_experts` 섹션에서 활성화되며, `feature_groups.yaml`의 `target_experts` 선언으로부터 FeatureRouter가 빌드된다. FeatureRouter는 전체 1205D 입력 텐서에서 Expert별 지정 인덱스를 슬라이싱하여 전달하며, 입력 데이터가 None인 경우 **zero tensor fallback**을 수행하고 CGC 게이팅이 해당 Expert의 가중치를 자동으로 낮춘다.

라우팅은 전적으로 **config-driven**이다 — `feature_groups.yaml`의 `target_experts` 필드만 수정하면 코드 변경 없이 라우팅이 재구성된다.

HMM Triple-Mode는 별도 입력 경로로 처리된다:

HMM 모드	입력	시간 스케일	대상 태스크
Journey	16D	daily	nba_primary, cross_sell_count, will_acquire_*
Lifecycle	16D	monthly	churn_signal, product_stability
Behavior	16D	monthly	nba_primary, next_mcc, mcc_diversity_trend, top_mcc_shift, ...

각 모드는 10D base 상태 확률 + 6D ODE dynamics로 구성되며, 16D를 32D로 프로젝션하여 CGC 출력과 concat 된다:

$$h_{\text{hmm}}^m = \text{SiLU}(\text{LayerNorm}(\text{Linear}_{16 \rightarrow 32}(x_{\text{hmm}}^m)))$$

3. adaTT — Adaptive Task-aware Transfer

3.1 Motivation: Negative Transfer

12개 태스크가 Shared Expert 파라미터를 공유할 때, gradient 충돌로 인한 Negative Transfer가 발생한다. 고정 타워 MTL의 세 가지 한계:

1. **일방적 공유**: 태스크 간 간섭을 감지/조절할 메커니즘 부재
2. **상호작용 미측정**: 어떤 태스크 쌍이 돕고 해치는지 정량화 불가
3. **시간 변화 미반영**: 학습 단계별 태스크 관계 변화를 추적 불가

adaTT는 이를 각각 **선택적 전이**, **gradient cosine similarity**, **3-Phase schedule**로 해결한다.

스케일 한계 — 13-task에서 adaTT 성능 저하

벤치마크 ablation에서 13개 태스크 규모에서 adaTT가 일관적으로 성능을 하락시키는 것이 관찰되었다 (PLE + adaTT 구조에서 특히 두드러짐). 원인: 표현 수준의 분리(PLE)가 손실 수준의 재혼합(adaTT)에 의해 훼손되는 구조적 충돌. adaTT의 대안으로 GradSurgery(PCGrad 기반 태스크-타입 투영)를 실험하였으나, PLE 단독 baseline 대비 의미 있는 개선이 없었고 retained computation graph로 인한 VRAM 오버헤드가 있어 **프로덕션에는 채택하지 않았다**. 최종 구성은 adaTT와 GradSurgery를 모두 비활성화한다. adaTT는 아키텍처 참조용으로 문서에 유지된다.

3.2 Gradient Cosine Similarity

두 태스크 i, j 의 Shared Expert 파라미터 θ 에 대한 gradient를 $g_i = \nabla_{\theta} \mathcal{L}_i, g_j = \nabla_{\theta} \mathcal{L}_j$ 라 하면:

$$\cos(\theta_{i,j}) = \frac{g_i \cdot g_j}{\|g_i\| \cdot \|g_j\|}$$

$g_i \in \mathbb{R}^d$: 태스크 i 의 flattened gradient 벡터

결과 범위: $[-1, 1]$ — 양수 = positive transfer, 음수 = negative transfer

코사인 유사도를 사용하는 이유:

1. **스케일 불변성**: 태스크별 loss 규모 차이에 영향받지 않고 순수 방향 비교
2. **해석 용이**: $[-1, 1]$ 범위로 정규화되어 직관적 해석 가능
3. **효율적 계산**: gradient 행렬 $G \in \mathbb{R}^{n \times d}$ 를 L2 정규화 후 $\hat{G}\hat{G}^T$ 으로 모든 n^2 유사도를 단일 GEMM으로 계산

```
norms = grad_matrix.norm(dim=1, keepdim=True).clamp(min=1e-8)
normalized = grad_matrix / norms
affinity = torch.mm(normalized, normalized.t()) # [n_tasks, n_tasks]
```

3.3 EMA 안정화

단일 배치의 gradient는 노이즈가 크므로 EMA로 평활화한다:

$$\mathbf{A}_t = \alpha \cdot \mathbf{A}_{t-1} + (1 - \alpha) \cdot \cos(\theta_t)$$

$\alpha = 0.9$: effective window $\approx \frac{1}{1-\alpha} = 10$ 관측
 신호처리 관점: IIR 1차 저역통과 필터 $H(z) = \frac{1-\alpha}{1-\alpha z^{-1}}$

EMA 업데이트 후 반드시 `.clamp(-1.0, 1.0)` 적용 — 부동소수점 오차 누적으로 코사인 유사도가 $[-1, 1]$ 범위를 벗어나면 후속 연산에서 NaN 발생 가능.

3.4 Transfer-Enhanced Loss

각 태스크 i 에 대한 adaTT 강화 손실:

$$\mathcal{L}_i^{\text{adaTT}} = \mathcal{L}_i + \lambda \cdot \sum_{j \neq i} w_{i \rightarrow j} \cdot \mathcal{L}_j$$

$\mathcal{L}_i$: 태스크 i 의 원본 손실
 $\lambda = 0.1$: 다른 태스크 의견의 반영 비율 (10%)
 $w_{i \rightarrow j}$: 태스크 i 에 대한 태스크 j 의 전이 가중치 (softmax 정규화)

본 시스템은 softmax 외에 sigmoid gate도 지원한다 (NeurIPS 2024, Nguyen et al.). Sigmoid gate는 expert 간 독립적 기여를 허용하여 불필요한 경쟁을 줄이는 이점이 있으나, **벤치마크 실험에서 이종 전문가 환경에서는 softmax가 NDCG 메트릭 기준으로 sigmoid를 앞서는 것으로 확인되었다**. 불확실성 가중치(Uncertainty Weighting) 정상화 이후 이 역전이 안정적으로 관찰되었다. 현재 권장 설정: `gate_type: "softmax"` (pipeline.yaml 또는 HP).

Gradient에 대한 영향:

$$\nabla_{\theta} \mathcal{L}_i^{\text{adaTT}} = \nabla_{\theta} \mathcal{L}_i + \lambda \sum_{j \neq i} w_{i \rightarrow j} \nabla_{\theta} \mathcal{L}_j$$

두 번째 항은 공유 파라미터를 여러 태스크에 유리한 방향으로 조향하는 **보정 벡터**이다.

3.5 Transfer Weight 계산 (4-stage pipeline)

$$\begin{aligned} \mathbf{R} &= (\mathbf{W} + \mathbf{A}) \cdot (1 - r) + \mathbf{P} \cdot r \\ R_{i,j} &\leftarrow 0 \quad \text{if } A_{i,j} < \tau_{\text{neg}} \\ R_{i,i} &= 0 \\ w_{i \rightarrow j} &= \text{softmax}\left(\frac{R_{i,j}}{T}\right) \end{aligned}$$

$\mathbf{W}$: 학습 가능한 전이 가중치 (`nn.Parameter`, 초기값 0)
 $\mathbf{A}$: EMA 친화도 행렬

P : Group Prior 행렬 (도메인 지식)
 r : Prior blend ratio (0.5 $\rightarrow$ 0.1로 annealing)
 $\tau_{\text{neg}} = -0.1$: Negative transfer 차단 임계값
 $T = 1.0$: Softmax temperature

각 단계의 의미:

1. 학습 가능 가중치 W 와 관측 친화도 A 를 합산, 도메인 Prior P 와 혼합
2. 친화도가 임계값 이하인 경로를 0으로 차단 (negative transfer blocking)
3. 자기 전이 제외 (대각선 0)
4. Softmax로 확률 분포 생성 — 합이 1이므로 태스크 수에 무관하게 스케일 일정

`max_transfer_ratio = 0.5` : Transfer loss가 원본 loss의 50%를 초과할 수 없다.

3.6 3-Phase Schedule

Phase	기간	동작	목적
1: Warmup	epoch 0 <code>warmup_epochs</code>	친화도 계산만, transfer loss 미적용	안정적 친화도 데이터 축적
2: Dynamic	<code>warmup_epochs</code> <code>freeze_epoch</code>	전이 활성화, Prior blend annealing	태스크 관계 학습 및 적용
3: Frozen	<code>freeze_epoch</code> 종료	전이 가중치 고정 (<code>detach</code>)	Fine-tuning 안정화, gradient overhead 제거

검증: `freeze_epoch > warmup_epochs`

Phase 2가 완전히 스킵되면 학습된 친화도가 전이에 반영되지 않아 adaTT 사용의 의미가 없어진다. 초기화 시 `ValueError` 로 조기 차단.

adaTT Epoch 예산

10-epoch 실행(warmup=3, freeze=8)에서 adaTT의 Dynamic 구간은 5 epoch (Phase 2: epoch 3-8)에 불과하다. 친화도 수렴에 충분하지 않은 경우가 많다. **adaTT 평가에는 20-epoch 실행을 권장한다** — warmup=3, freeze=15로 Dynamic 구간이 12 epoch 확보되어 freeze 전 친화도 행렬이 안정화된다.

3.7 Group Prior

Prior blend ratio는 학습 진행에 따라 선형 감소한다:

$$r(e) = r_{\text{start}} - (r_{\text{start}} - r_{\text{end}}) \cdot \min\left(\frac{e - e_{\text{warmup}}}{e_{\text{freeze}} - e_{\text{warmup}}}, 1.0\right)$$

$r_{\text{start}} = 0.5 \rightarrow r_{\text{end}} = 0.1$: 학습 초기 도메인 지식 의존, 후반 관측 친화도 신뢰

Bayesian 해석: Prior(P)에서 Posterior(관측 기반 A)로의 전환. 데이터가 부족한 초기에는 prior에 의존하고, 데이터가 축적되면 likelihood를 따른다.

3.8 Negative Transfer 감지 및 차단

$$R_{i,j} = \begin{cases} R_{i,j} & \text{if } A_{i,j} > \tau_{\text{neg}} \\ 0 & \text{otherwise} \end{cases}$$

임계값 $\tau_{\text{neg}} = -0.1$ (0이 아닌 이유): 약한 음의 상관은 노이즈일 수 있으므로 허용하고, 명확한 반대 방향 gradient만 차단한다. 0으로 설정하면 과도한 경로 차단으로 adaTT 효과가 약화된다.

진단 API: `detect_negative_transfer()` 가 `{"churn_signal": ["will_acquire_lending", "nba_primary"]}` 형태로 negative transfer 쌍을 반환한다.

3.9 Attention 메커니즘과의 유비

adaTT는 **태스크 공간에서의 Attention**으로 해석할 수 있다:

역할	Transformer Self-Attention	adaTT Task Transfer
Query	현재 토큰의 질의	현재 태스크의 gradient 방향
Key	다른 토큰의 응답 가능성	다른 태스크의 gradient 방향
유사도	$Q \frac{K^T}{\sqrt{d_k}}$	gradient cosine similarity
정규화	softmax	softmax (temperature T)
Value	다른 토큰의 정보	다른 태스크의 loss 값
출력	가중 합산된 context	transfer loss

Hypernetwork(Ha et al., 2017)와 비교하면, adaTT는 학습된 태스크 임베딩 대신 **관측 gradient**를 조건 신호로 사용하여 지연 없이 태스크 관계 변화에 적응한다.

4. 태스크 그룹

4.1 4개 Financial DNA 그룹

도메인 지식에 기반하여 12개 태스크를 4개 그룹으로 분류한다:

그룹	멤버	Intra	Inter	비즈니스 의미
Engagement	cross_sell_count, will_acquire_deposits, will_acquire_investments, will_acquire_accounts, will_acquire_lending, will_acquire_payments	0.8	0.3	고객 참여/전환
Lifecycle	churn_signal, product_stability	0.7	0.3	고객 생애주기
Value	nba_primary	0.6	0.3	고객 가치/행동 패턴
Consumption	next_mcc, mcc_diversity_trend, top_mcc_shift	0.7	0.3	소비 패턴 분석

Intra-group strength: 같은 그룹 내 태스크 간의 전이 강도. Engagement 그룹(0.8)이 가장 높다 — 상품 획득 태스크들은 유사 구조로 강한 positive transfer 기대.

Inter-group strength: 그룹 간 전이 강도. 0.3으로 보수적 — cross-group transfer는 gradient 관측으로 검증된 후에만 활성화.

4.2 Intra/Inter Strength 설계

Group Prior 행렬 P 는 그룹 구조에서 자동 생성된다:

- 같은 그룹 내: intra_strength (0.6 0.8)
- 다른 그룹 간: inter_group_strength (0.3)
- 대각선: 0 (자기 전이 제외)
- 행 정규화로 합을 1로 맞춤

4.3 Logit Transfer 3방식

태스크 간 명시적 정보 전달을 위한 세 가지 전이 방식:

Source	Target	유형	강도	비즈니스 의미
has_nba	nba_primary	Sequential	0.5	NBA 존재 → 주력 상품 결정
churn_signal	product_stability	Inverse	0.5	이탈 신호의 역 $\approx$ 상품 안정성
next_mcc	mcc_diversity_trend	Feature	0.5	다음 소비처 → 다양성 추세

전이 메커니즘 (residual 형태):

$$\mathbf{h}_{\text{tower}}^t = \mathbf{h}_{\text{expert}}^t + \alpha \cdot \text{SiLU}(\text{LayerNorm}(\text{Linear}(\text{pred}^s)))$$

$\alpha = 0.5$: transfer strength. 프로젝션 가중치가 0에 수렴하면 자연스럽게 전이 무시.

실행 순서는 `task_relationships` config의 의존 관계를 **Kahn's algorithm**(위상 정렬)으로 자동 도출한다. 순환이 감지되면 fallback 순서로 전환된다.

4.4 GroupTaskExpertBasket (v3.2)

기존 클러스터×태스크 독립 MLP 대비 **88% 파라미터 감소** ($\sim 3.0\text{M} \rightarrow \sim 362\text{K}$). 같은 태스크 그룹은 GroupEncoder를 공유하고, ClusterEmbedding으로 차별화한다:

$$\mathbf{e}_{\text{cluster}} = \text{Embedding}(\text{cluster_id}) \in \mathbb{R}^{32}$$

$$\mathbf{x}_{\text{input}} = [\text{CGC_output}_{576\text{D}} \parallel \text{HMM_proj}_{32\text{D}} \parallel \mathbf{e}_{\text{cluster}_{32\text{D}}}] \in \mathbb{R}^{640}$$

$$\mathbf{h}_{\text{expert}} = \text{MLP}_{640 \rightarrow 128 \rightarrow 64 \rightarrow 32}(\mathbf{x}_{\text{input}})$$

Soft Routing

클러스터 경계 샘플에 대해 GMM 사후 확률로 임베딩을 혼합한다:

$$\mathbf{e}_{\text{cluster}} = \sum_{c=0}^{19} p_c \cdot \mathbf{E}_c \in \mathbb{R}^{32}$$

p_c : GMM 사후 확률, 구현: `cluster_probs @ embedding.weight` ($[B, 20] \times [20, 32]$)

hard assignment와 달리 경계 고객의 예측이 클러스터 할당 변동에 민감하지 않다.

5. 학습 전략

5.1 2-Phase Training

Phase 1: Shared Expert Pretrain

- **기간:** `shared_expert_epochs` (기본 15)
- **학습 대상:** 전체 모델 — Shared Experts, CGC, Task Experts, Task Towers
- **adaTT:** 활성 — gradient 추출 및 transfer loss 적용

Phase 2: Cluster Finetune

- **기간:** `cluster_finetune_epochs` (기본 8)
- **학습 대상:** 클러스터별 Task Expert 서브헤드만
- **adaTT:** 비활성 — Shared Expert가 frozen이므로 gradient 추출 무의미
- **CGC:** frozen — 입력(Expert 출력)이 변하지 않으므로 gating 학습은 과적합 유발

Phase 전환 시 리셋되는 항목:

리셋 항목	이유
Optimizer	Shared Expert frozen → stale momentum 방지
Scheduler	Phase 2 전용 warmup (2 epoch, Phase 1의 5 epoch보다 짧음)
GradScaler	AMP 스케일러 상태 초기화 (loss 스케일 변화)
Early stopping	<code>best_val_loss</code> , <code>patience_counter</code> 초기화
CGC Attention	Shared Expert frozen → CGC도 함께 freeze

adaTT는 Phase 2 종료 후 반드시 복원된다 (`finally` 블록으로 예외 시에도 보장).

5.2 Uncertainty Weighting

Kendall et al., CVPR 2018 의 homoscedastic uncertainty 기반 자동 태스크 가중치:

$$\mathcal{L}_i^{\text{weighted}} = \frac{1}{2\sigma_i^2} \cdot \mathcal{L}_i + \frac{1}{2} \log \sigma_i^2$$

$\sigma_i^2 = \exp(\log_var_i)$: 태스크 i 의 학습 가능한 불확실성
`log_var` clamp: `[-4.0, 4.0]`, precision clamp: `[0.001, 100.0]`

불확실성이 높은 태스크(σ_i^2 큼)의 가중치($\frac{1}{2\sigma_i^2}$)가 자동으로 낮아지고, $\log \sigma_i^2$ 정규화 항이 불확실성을 무한히 키우는 것을 방지한다. 12개 태스크의 가중치를 수동 튜닝하는 조합 폭발을 **자동 균형**으로 대체한다.

Uncertainty Weighting은 adaTT **이전에** 적용된다. adaTT의 `task_losses` 입력에는 이미 uncertainty weighting이 반영된 값이 들어온다.

5.3 Focal Loss

Lin et al., ICCV 2017 의 class-imbalanced binary classification 손실:

$$FL(p_t) = -\alpha_t \cdot (1 - p_t)^\gamma \cdot \log(p_t)$$

$(1 - p_t)^\gamma$ 항이 핵심 — 쉬운 예제($p_t \approx 1$)의 손실을 급격히 감소시키고, 어려운 예제($p_t \approx 0$)에 학습을 집중한다.

태스크	weight	Focal α/γ	비고
will_acquire_*	1.5	$\gamma=2, \alpha=0.20$	양성 비율 극소 → weight 상향
churn_signal	1.2	$\gamma=2, \alpha=0.60$	FN 비용 높음 → alpha 상향
nba_primary	2.0	CE (multiclass)	비즈니스 핵심
next_mcc	2.0	CE (multiclass)	소비처 예측

5.4 AMP (Automatic Mixed Precision)

Forward pass는 `torch.amp.autocast` 로 fp16 실행. TF32 + cuDNN benchmark로 추가 10 15% 속도 확보:

```
torch.backends.cuda.matmul.allow_tf32 = True
torch.backends.cudnn.allow_tf32 = True
torch.backends.cudnn.benchmark = True
```

LR scheduler: Linear Warmup (5 epoch, start_factor=0.1) → CosineAnnealingWarmRestarts ($T_0=10, T_{mult}=2$). Phase 2에서는 scheduler 리셋 (warmup 2 epoch).

6. 구현 참고사항

6.1 FP16 주의점

Focal Loss float32 캐스팅

fp16에서 `focal_weight * bce` 의 중간 결과가 subnormal 범위에 들어가면 NaN 발생 가능. 전체 focal loss 계산을 float32로 수행한다:

```
p_f = pred.squeeze().float().clamp(1e-7, 1 - 1e-7)
```

adaTT Gradient 추출과 autocast

adaTT의 gradient 추출은 autocast 내에서 이루어지지만, loss 계산 자체는 float32로 캐스팅하여 수치 안정성을 확보한다.

6.2 GradScaler Guard

`retain_graph=True` 는 아키텍처상 제거 불가 — `_extract_task_gradients` 는 loss 계산 후 `backward()` 전에 호출되며, 동일 computation graph를 Trainer의 `loss.backward()` 에서 재사용해야 한다.

메모리 영향:

요소	메모리	비고
Forward pass graph	1x	기준
retain_graph 추가	~1x	graph 미해제로 추가 메모리
12 task gradients	~0.3x	각 gradient는 shared_param_size
합계	~2.3x	RTX 4070 12GB에서 batch 16384 가능

Gradient 추출 빈도 최적화

`adatt_grad_interval=10` : 매 step 대신 10 step마다 gradient 추출. EMA 평활화 덕분에 충분히 안정적이며, 계산 오버헤드가 1/10로 감소.

torch.compiler.disable

`_extract_task_gradients` 에 `@torch.compiler.disable` 데코레이터 적용. `torch.autograd.grad` 는 컴파일된 그래프 내에서 `requires_grad` 추적에 불완전하다. 현재 `torch.compile` 자체가 비활성화(15-태스크 MTL + `retain_graph` + dynamic shape로 커널 컴파일 수백 개, 첫 epoch 30분+)이지만 방어적으로 적용.

6.3 v14 Phase 0 개선 (2026-05-04): train.py 메모리 리팩터

SageMaker g4dn.xlarge (16 GB RAM) 에서 1M 행 × 1{,}210 컬럼 데이터 로딩 중 OOM 이 재현되었다. 원인을 추적한 결과, training-ready parquet 의 풀 materialize 와 fp16 round-trip 두 경로에서 메모리가 중복 점유되고 있었다.

이전 (v13 까지)

`pq.read_table()` 로 parquet 전체를 Arrow Table 로 풀 materialize. 1M 행 × 1{,}210 컬럼 fp64 = 9.68 GB Arrow. 이후 `_arrow_table_to_tensor` 에서 fp32 → fp64 → fp32 round-trip 과 `np.column_stack` copy 가 발생하여 peak 가 16 GB 를 돌파, 컨테이너가 oom-kill 되었다.

수정 (v14)

수정	효과
DuckDB streaming <code>SELECT + FLOAT containers/ cast (training/train.py:162-225)</code>	9.68 GB → 4.99 GB Arrow. CLAUDE.md §3.3 의 “DuckDB 우선” 정책 준수.
<code>table.slice()</code> (zero-copy view) for contiguous splits	<code>take()</code> 의 row-copy 를 회피. train/val/test 분리 시 메모리 추가 점유 없음.
<code>_arrow_table_to_tensor</code> 의 fp32 → fp64 → fp32 round-trip 제거 + <code>column_stack</code> copy 제거	Peak 16 GB → ~5 GB. fp32 그대로 텐서로 zero-copy 변환.

검증

g4dn.xlarge 에서는 여전히 OOM margin 이 좁아 최종적으로 g4dn.2xlarge (32 GB) 로 안착. peak RSS 는 ~ 8 GB 수준에서 안정. `pd.read_parquet` 직접 사용 금지 원칙(CLAUDE.md §3.3)과도 정합.

Arrow → Tensor zero-copy 의 조건

Arrow column 의 `to_numpy(zero_copy_only=True)` 가 성공하려면 (1) 단일 chunk 일 것, (2) null mask 가 없을 것, (3) dtype 이 numpy 와 호환될 것 의 세 조건을 만족해야 한다. v14 에서는 DuckDB SELECT 가 단일 chunk 를 반환하고 NULL 은 사전에 fill 되므로 조건이 자동 충족된다.

6.4 Phase 2 Frozen Layer

Phase 2에서 freeze되는 레이어:

레이어	Frozen	이유
Shared Experts	Yes	Phase 1에서 충분히 학습된 공유 표현 보존
CGC Attention	Yes	Expert 출력 고정 → gating 학습 불필요
adaTT	비활성	Shared Expert frozen → gradient 0, 코사인 유사도 무 의미
GroupEncoder	No	클러스터별 특화 학습 (Phase 2 핵심)

Task Towers	No	최종 예측 layer 미세조정
ClusterEmbedding	No	클러스터 표현 정제

CGC-adaTT 동기화

adaTT freeze_epoch 에서 CGC Attention도 함께 frozen한다. CGC가 계속 학습하면 Expert 가중치가 변경되어 adaTT가 측정한 친화도 관계가 무효화될 수 있다.

```
if freeze_epoch is not None and epoch >= freeze_epoch:
    for param in self.task_expert_attention.parameters():
        param.requires_grad = False
    self._cgc_frozen.fill_(True)
```

_cgc_frozen 은 register_buffer 로 등록되어 체크포인트 저장/복원 시 상태 유지.

6.5 Loss 계산 파이프라인 전체 순서

1. **태스크별 loss 유형 결정** (focal, huber, MSE, NLL, contrastive)
2. **Focal Loss alpha/gamma 적용** (태스크별 양성 클래스 가중치)
3. **Loss weight 적용** (Uncertainty Weighting 또는 고정 가중치)
4. **Evidential loss 가산** (불확실성 추정 보조 손실)
5. **adaTT transfer loss** (gradient 기반 전이 손실 추가)
6. **CGC entropy regularization** (Expert Collapse 방지)

6.6 디버깅 가이드

증상	원인	해결
NaN loss	fp16 focal loss underflow	float32 캐스팅 확인
학습 초기 loss 발산	transfer loss가 원본 지배	max_transfer_ratio 확인 (0.5)
Phase 2 RuntimeError	adaTT 비활성화 누락	model.adatt = None 확인
ValueError 초기화	freeze_epoch <= warmup_epochs	config 검증
학습 hang (무응답)	매 step gradient 추출	adatt_grad_interval 확인 (기본 10)
체크포인트 불일치	fill_() 미사용	buffer 업데이트 시 in-place 연산 확인

건강한 친화도 행렬의 특성:

- 같은 그룹 내: 양의 친화도 (> 0.3)
- 다른 그룹 간: 약한 양 또는 중립 ($-0.1 \sim 0.3$)
- 대각선: 1.0
- 전체가 ± 1 로 포화되지 않을 것 (포화 시 EMA 감쇠율 조정)

추가 자료

- **MTL 기반 연구**: Caruana 1997; Ma et al. KDD 2018 (MMoE); Tang et al. RecSys 2020 (PLE); Jacobs et al. 1991.
- **Loss 가중**: Kendall et al. CVPR 2018 (Uncertainty); Lin et al. ICCV 2017 (Focal); Chen et al. ICML 2018 (GradNorm).
- **Gradient 레벨 MTL**: Yu et al. NeurIPS 2020 (PCGrad); Liu et al. NeurIPS 2021 (CAGrad); Navon et al. ICML 2022 (Nash-MTL).
- **Task 그룹핑/라우팅**: Fifty et al. NeurIPS 2021; Ha et al. ICLR 2017 (HyperNetworks); Fedus et al. JMLR 2022 (Switch Transformer).
- **Attention**: Vaswani et al. NeurIPS 2017.