TECH REFERENCE

Temporal Ensemble Expert 기술 참조서

Mamba SSM · Liquid Neural Network · PatchTST · Ensemble Gating

AIOps PLE for Financial Recommendation

v1.0 · 2026-04-01

> 본 문서는 Temporal Ensemble Expert를 구성하는 세 모델 — Mamba (Selective State Space Model), Liquid Neural Network, PatchTST (Patch Time Series Transformer) — 의 수학적 구조, 앙상블 게이팅 메커니즘, 그리고 프로젝트 구현 사양을 기술한다.

차 례

1 금융 시계열의 복합 구조 . . . 3
1.1 정적 피처 vs 시간적 피처 . . . 3
1.2 시계열의 세 가지 구성 요소 . . . 3
1.3 금융 거래 데이터의 네 가지 특성 . . . 4
1.4 윈도우 기반 vs 이벤트 기반 하이브리드 . . . 4
2 Mamba: Selective State Space Model . . . 4
2.1 이론적 배경 . . . 4
2.2 연속 상태 공간 모델 . . . 4
2.3 ZOH 이산화 . . . 5
2.4 이산 점화식 . . . 5
2.5 S6 선택 메커니즘 . . . 5
2.5.1 금융 도메인에서의 선택 메커니즘 . . . 5
2.6 선택적 순차 스캔 . . . 5
2.7 Gated MLP + Causal Conv1d 아키텍처 . . . 6
2.8 A 행렬 초기화와 안정성 . . . 6
2.9 프로젝트 구현 사양 . . . 6
2.9.1 거래용 Mamba (Transaction) . . . 6
2.9.2 세션용 Mamba (Session) . . . 6
2.10 복잡도 분석 . . . 7
3 Liquid Neural Network (LNN) . . . 7
3.1 이론적 배경 . . . 7
3.2 핵심 ODE . . . 7
3.2.1 각 항의 물리적 의미 . . . 7
3.3 Euler 이산화 . . . 8
3.4 적응적 시간 상수의 금융 도메인 해석 . . . 8
3.5 SingleStep 모드 설계 . . . 8
3.5.1 설계 근거 . . . 8
3.6 프로젝트 구현 사양 . . . 8
4 PatchTST: Patch Time Series Transformer . . . 9
4.1 이론적 배경 . . . 9
4.2 패치 임베딩 . . . 9
4.2.1 패치 크기의 금융 도메인 해석 . . . 9
4.3 Multi-Head Self-Attention . . . 9
4.4 위치 인코딩 . . . 9
4.5 프로젝트 구현 사양 . . . 10
4.6 복잡도 비교 . . . 10
5 앙상블 게이팅 . . . 10
5.1 게이트 아키텍처 . . . 10
5.2 입력 분리를 통한 앙상블 다양성 . . . 10
5.3 게이트 엔트로피 모니터링 . . . 11
5.4 최종 출력 흐름 요약 . . . 11
6 입출력 사양 및 구현 참고사항 . . . 12

6.1 전체 입출력 사양 12
6.1.1 입력 12
6.1.2 중간 표현 12
6.1.3 출력 12
6.2 세 모델의 역할 비교 요약 12
6.3 시계열 분석 세대별 발전과 본 프로젝트의 위치 12
6.4 구현 시 유의사항 13
6.4.1 데이터 리키지 방지 13
6.4.2 수치 안정성 13
6.4.3 성능 최적화 13
6.4.4 추가 자료 13

금융 시계열의 복합 구조

정적 피처 vs 시간적 피처

전통적 추천 시스템에서 사용자 표현은 정적(static) 벡터이다. 나이, 직업, 선호 카테고리 등 시점에 무관한 속성으로 구성된다. 그러나 실제 사용자 행동은 시간 축을 따라 끊임없이 변화하며, 단일 스냅샷으로 축약하면 주기성, 트렌드, 계절성 같은 핵심 행동 신호가 소멸한다.

관점	정적 피처	시간적 피처
표현 형태	고정 벡터 $\boldsymbol{x} \in \mathbb{R}^d$	시퀀스 $\boldsymbol{X} \in \mathbb{R}^{T \times d}$
정보 손실	시간 축 평균화 $\rightarrow$ 패턴 소멸	순서, 간격, 추세 보존
모델 요구사항	MLP, Embedding 테이블	SSM, ODE, Transformer 등 시퀀스 모델

Temporal Expert는 거래와 세션 데이터를 시퀀스로 유지한 채, 시간 차원에 내재된 패턴을 학습하여 64D 표현으로 압축한다.

시계열의 세 가지 구성 요소

모든 시계열 $y(t)$는 근본적으로 세 가지 성분의 합으로 분해된다:

$$y(t) = T(t) + S(t) + R(t) \tag{1}$$

$T(t)$: 트렌드 (Trend) — 장기적 방향성
$S(t)$: 계절성 (Seasonality) — 반복적 주기 패턴 (요일, 월별, 연별)
$R(t)$: 잔차 (Residual) — 트렌드와 계절성으로 설명되지 않는 불규칙 변동

Temporal Expert의 세 모델은 이 분해에 대응한다:

- **Mamba**: 트렌드 (장기 의존성, 선택적 기억을 통한 방향성 포착)
- **PatchTST**: 계절성 (패치 간 어텐션으로 글로벌 주기 포착)
- **LNN**: 잔차 (적응적 시간 상수로 불규칙 변동 처리)

금융 거래 데이터의 네 가지 특성

금융 시계열은 일반 시계열과 구별되는 고유한 특성을 갖는다:

특성	설명	처리 모델
스냅샷 불연속	월말 잔액, 분기 평가 등 이산적 관측	Mamba 선택적 기억
일별 거래 다발	하루 수십 건의 결제, 이체	PatchTST 패치 집계
불규칙 간격	거래일 vs 휴일, 활동기 vs 휴면기	LNN 적응적 τ
고빈도 이벤트	카드 승인 실시간 스트림	Mamba $O(L)$ 선형 처리

윈도우 기반 vs 이벤트 기반 하이브리드

프로젝트에서는 거래 데이터를 일별 집계하여 윈도우 기반 시퀀스(180 타임스텝)로 구성한다. 이는 Mamba와 PatchTST에 입력된다. 동시에 거래 간 실제 시간 간격 정보가 LNN에 전달되어, 이벤트 기반의 시간 인식 보정을 수행한다.

접근법	윈도우 기반 (고정 간격)	이벤트 기반 (불규칙 간격)
시간 모델	$\Delta t = \text{const}$	$\Delta t_i \neq \Delta t_j$
데이터 형태	$\boldsymbol{X} \in \mathbb{R}^{T \times d}$	$\{(t_i, \boldsymbol{x}_i)\}$ 이벤트 스트림
적합 모델	Mamba, PatchTST	LNN (ODE 기반)

Mamba: Selective State Space Model

이론적 배경

> **참조 논문**
>
> Gu & Dao, “Mamba: Linear-Time Sequence Modeling with Selective State Spaces” (NeurIPS 2023).
> 계보: HiPPO (Gu et al., NeurIPS 2020) → S4 (ICLR 2022) → Mamba (2023).

SSM(State Space Model)을 입력 의존적 선택 메커니즘(S6)으로 확장하여, RNN의 선형 시간 복잡도와 Transformer의 콘텐츠 인식 능력을 결합한 아키텍처이다.

연속 상태 공간 모델

선형 시불변(LTI) 시스템의 기본 형태:

$$\frac{d\boldsymbol{x}}{dt} = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{B}u, \quad y = \boldsymbol{C}\boldsymbol{x} + \boldsymbol{D}u \tag{2}$$

> $\boldsymbol{x} \in \mathbb{R}^N$: 은닉 상태, $u \in \mathbb{R}$: 입력 신호, $y \in \mathbb{R}$: 출력 신호
> $\boldsymbol{A} \in \mathbb{R}^{N \times N}$: 상태 전이 행렬, $\boldsymbol{B} \in \mathbb{R}^{N \times 1}$: 입력 행렬, $\boldsymbol{C} \in \mathbb{R}^{1 \times N}$: 출력 행렬

ZOH 이산화

연속계를 이산 시간 스텝 Δ로 변환한다:

$$\bar{\boldsymbol{A}} = \exp(\Delta \cdot \boldsymbol{A}), \quad \bar{\boldsymbol{B}} \approx \Delta \cdot \boldsymbol{B} \tag{3}$$

$\bar{\boldsymbol{A}}$는 "연속 시간 Δ만큼 정확히 전진시킨 상태 전이"를 의미한다. 1차 근사 $\exp(\Delta \boldsymbol{A}) \approx \boldsymbol{I} + \Delta \boldsymbol{A}$가 Euler method이며, 정확한 행렬 지수는 무한 차수까지 고려한 것이다. $\boldsymbol{A}$가 대각 행렬이면 $\exp(\boldsymbol{A}t) = \mathrm{diag}(e^{a_1 t}, \ldots, e^{a_N t})$로 간소화되며, Mamba가 $\boldsymbol{A}$를 대각으로 제한하는 이유이다.

이산 점화식

$$\boldsymbol{h}_t = \bar{\boldsymbol{A}} \cdot \boldsymbol{h}_{t-1} + \bar{\boldsymbol{B}} \cdot \boldsymbol{x}_t, \quad \boldsymbol{y}_t = \boldsymbol{C}_t \cdot \boldsymbol{h}_t \tag{4}$$

직관적으로 "오늘의 상태 = 어제의 기억 $\times$ 감쇠율 + 오늘의 새 정보"이다.

S6 선택 메커니즘

기존 LTI SSM에서 $\boldsymbol{A}, \boldsymbol{B}, \boldsymbol{C}$는 입력과 무관한 상수이다. Mamba의 S6는 $\Delta, \boldsymbol{B}, \boldsymbol{C}$를 입력 의존적으로 생성하여 콘텐츠 인식 처리를 구현한다.

> $$\Delta = \mathrm{softplus}(\boldsymbol{W}_\Delta \cdot \boldsymbol{x} + \boldsymbol{b}_\Delta) \tag{5}$$
>
> $$\boldsymbol{B} = \boldsymbol{W}_B \cdot \boldsymbol{x}, \quad \boldsymbol{C} = \boldsymbol{W}_C \cdot \boldsymbol{x} \tag{6}$$
>
> $\boldsymbol{W}_\Delta \in \mathbb{R}^{D \times r}$: Δ 프로젝션 ($r = \lceil D/16 \rceil$, dt_rank)
> softplus 보장: $\Delta > 0$ (시간 스텝은 양수)

입력에 따라 Δ가 커지면 해당 타임스텝의 정보를 강하게 기억(인코딩)하고, Δ가 작아지면 이전 상태를 유지하며 현재 입력을 무시(망각)한다.

금융 도메인에서의 선택 메커니즘

- 대형 거래 $\rightarrow$ 큰 Δ $\rightarrow$ 은닉 상태에 강하게 기록 (선택적 기억)
- 소액 일상 거래 $\rightarrow$ 작은 Δ $\rightarrow$ 이전 상태 유지, 배경 처리 (선택적 망각)
- 이 메커니즘은 금융 이벤트의 이질적 중요도를 자연스럽게 모델링한다

선택적 순차 스캔

각 타임스텝마다 $\Delta_t, \boldsymbol{B}_t, \boldsymbol{C}_t$가 달라지므로:

$$\boldsymbol{h}_t = \underbrace{\exp(\Delta_t \cdot \boldsymbol{A})}_{\bar{\boldsymbol{A}}_t} \cdot \boldsymbol{h}_{t-1} + \underbrace{\Delta_t \cdot \boldsymbol{B}_t}_{\bar{\boldsymbol{B}}_t} \cdot \boldsymbol{x}_t, \quad \boldsymbol{y}_t = \boldsymbol{C}_t^\top \boldsymbol{h}_t \tag{7}$$

전체 시퀀스에 대해 $O(L)$ 선형 시간 복잡도로 처리된다.

Gated MLP + Causal Conv1d 아키텍처

MambaBlock은 SSM을 Gated MLP와 1D 인과 컨볼루션으로 감싸는 구조이다:

1. **Input Projection**: `d_input` $\rightarrow$ `d_model`
2. **LayerNorm** $\rightarrow$ **in_proj**: `d_model` $\rightarrow$ `2 * d_inner` (두 경로로 분기)
3. **SSM 경로**: Causal Conv1d (kernel=4) $\rightarrow$ SiLU $\rightarrow$ SelectiveSSM (S6)
4. **Gate 경로**: SiLU 활성화
5. **Element-wise multiply** (SSM 출력 $\circ$ Gate 출력)
6. **out_proj**: `d_inner` $\rightarrow$ `d_model` + Residual connection

인과 Conv1d (kernel=4)는 시점 t에서 $t-3, t-2, t-1, t$만 참조하여 미래 정보 누출 없이 로컬 컨텍스트를 혼합한다.

A 행렬 초기화와 안정성

$\boldsymbol{A}$를 $\log$ 공간에 저장하고, forward 시 $-\exp(\mathrm{A}_{\log})$로 복원한다. 이는 모든 고유값이 항상 음수임을 보장하여 시스템의 안정성을 확보한다.

초기값은 HiPPO 스타일의 대각 $[1, 2, \ldots, N]$이다. 더 큰 인덱스의 상태는 더 높은 주파수의 다항식 성분에 대응하므로, 대각 원소 $-1, -2, \ldots, -N$이 되어 고주파 성분일수록 빠르게 감쇠한다.

프로젝트 구현 사양

거래용 Mamba (Transaction)

파라미터	값	설명
`d_model`	128	은닉 차원
`d_input`	16	card (8D) + deposit (8D) 거래 피처
`d_inner`	256	128×2 (expand=2)
`d_state`	16	SSM 상태 벡터 차원
`d_conv`	4	1D 인과 컨볼루션 커널 크기
`dt_rank`	8	$\lceil 128/16 \rceil = 8$
`seq_len`	180	180일 거래 시퀀스
출력	`[B, 128]`	마지막 타임스텝 `[:, -1, :]`

세션용 Mamba (Session)

파라미터	값	설명
`d_model`	64	거래 대비 절반 차원
`d_input`	8	세션 피처 차원
`d_inner`	128	64×2 (expand=2)
`seq_len`	90	90일 세션 시퀀스

파라미터	값	설명
출력	`[B, 64]`	마지막 타임스텝

Mamba 총 출력 차원: $128 + 64 = 192$D (txn + session concat).

복잡도 분석

연산	복잡도	비고
순차 스캔	$O(L \cdot D \cdot N)$	L: 시퀀스 길이, D: 모델 차원, N: 상태 차원
Transformer 대비	$O(L)$ vs $O(L^2)$	시퀀스 길이에 선형
메모리	$O(D \cdot N)$	은닉 상태만 유지 (시퀀스 길이 무관)

Liquid Neural Network (LNN)

이론적 배경

> **참조 논문**
>
> Hasani et al., "Liquid Time-constant Networks" (AAAI 2021).
> 계보: Neural ODE (Chen et al., NeurIPS 2018) + 생물학적 뉴런 감쇠 모델 + Liquid State Machine (Maass et al., 2002).

Neural ODE를 기반으로 하되, 시간 상수 τ가 입력에 따라 적응적으로 변하는 연속 시간 신경망이다. 불규칙 시간 간격 (금융 거래의 본질적 특성)을 자연스럽게 처리할 수 있다.

핵심 ODE

$$\frac{d\boldsymbol{h}}{dt} = \frac{-\boldsymbol{h} + f(\boldsymbol{x}, \boldsymbol{h})}{\tau(\boldsymbol{x}, \boldsymbol{h})} \tag{8}$$

$\boldsymbol{h} \in \mathbb{R}^H$: 은닉 상태, $\boldsymbol{x}$: 외부 입력
$f(\cdot,\cdot)$: 상태 업데이트 함수 (목표 상태), $\tau(\cdot,\cdot) > 0$: 적응적 시간 상수

각 항의 물리적 의미

항	의미
$-\boldsymbol{h}$	감쇠 (leak): 입력 없이 은닉 상태가 0으로 수렴. 오래된 정보를 자연스럽게 잊음
$f(\boldsymbol{x}, \boldsymbol{h})$	구동력 (driving force): 새 입력과 현재 상태에 기반한 목표 상태. $f = \tanh(\boldsymbol{W}_f[\boldsymbol{x}; \boldsymbol{h}] + \boldsymbol{b}_f)$

항	의미
$\tau(\boldsymbol{x}, \boldsymbol{h})$	시간 상수: 클수록 변화가 느림 (관성, 상태 보존), 작을수록 빠르게 반응. $\tau = \mathrm{Softplus}(\mathrm{MLP}([\boldsymbol{x}; \boldsymbol{h}])) + 0.1$

Euler 이산화

연속 ODE를 이산 타임스텝으로 변환:

$$\boldsymbol{h}_{t+1} = \boldsymbol{h}_t + \Delta t \cdot \frac{-\boldsymbol{h}_t + f(\boldsymbol{x}_t, \boldsymbol{h}_t)}{\tau(\boldsymbol{x}_t, \boldsymbol{h}_t)} \tag{9}$$

Δt는 실제 시간 간격(일 단위)으로, 거래 간격이 불규칙하더라도 ODE가 자연스럽게 처리한다.

적응적 시간 상수의 금융 도메인 해석

금융 거래 간격은 극도로 불규칙하다:

상황	Δt	τ의 역할
당일 복수 거래	~ 0.01 일	작은 τ: 빠른 반응, 각 거래를 즉시 반영
주말 공백	2 일	중간 τ: 상태 완만하게 유지
장기 휴면	> 30 일	큰 τ: 상태 보존, 느린 감쇠

고정 τ를 사용하는 RNN/LSTM은 모든 간격을 동일하게 처리한다. 적응적 τ는 활발한 거래 시기에는 빠르게 반응하고, 휴면 시기에는 상태를 보존하여 고객 행동 리듬에 자동 적응한다.

SingleStep 모드 설계

프로젝트에서 LNN은 **SingleStep 모드**로 운용된다. 전체 시퀀스를 ODE로 처리하지 않고, Mamba의 최종 은닉 상태에 대해 단일 ODE 스텝만 적용한다.

설계 근거

- Mamba가 이미 $O(L)$로 전체 시퀀스 패턴을 포착
- LNN은 시간 스케일 보정 역할만 수행 (중복 시퀀스 처리 회피)
- 계산 비용: $O(1)$ 단일 스텝 vs $O(L)$ 전체 시퀀스 ODE

> **Mamba → LNN 직렬 구조**
>
> Mamba가 시퀀스 패턴을 학습한 후, LNN이 최종 상태에 시간 인식 보정을 적용하는 직렬 구조이다. 이는 "트렌드 추출 → 잔차 보정"의 분해에 대응한다.

프로젝트 구현 사양

파라미터	LNN txn	LNN session	설명
`input_dim`	128	64	Mamba 출력 차원
`hidden_dim`	64	32	LNN 은닉 차원

파라미터	LNN txn	LNN session	설명
출력	`[B, 64]`	`[B, 32]`	SingleStep 출력

LNN 총 출력 차원: $64 + 32 = 96$D (txn + session concat).

PatchTST: Patch Time Series Transformer

이론적 배경

> **참조 논문**
>
> Nie et al., "A Time Series is Worth 64 Words: Long-term Forecasting with Transformers" (ICLR 2023). ViT (Dosovitskiy et al., ICLR 2021)의 패치 개념을 시계열에 적용.

시계열을 고정 크기 패치로 분할한 뒤, 각 패치를 토큰으로 취급하여 Self-Attention을 적용한다. 이는 어텐션 비용을 $O(L^2)$에서 $O((L/P)^2)$로 축소하면서도 다중 스케일 주기 패턴을 효과적으로 포착한다.

패치 임베딩

$$\boldsymbol{p}_i = \boldsymbol{W}_{\text{proj}} \cdot \text{flatten}\left(\boldsymbol{x}_{[((i-1)P+1):(iP)]}\right) + \boldsymbol{b}_{\text{proj}} \tag{10}$$

패치 크기 $P = 16$에서 180 타임스텝 거래 시퀀스는 $\lfloor 180/16 \rfloor = 11$개 패치로 변환된다. 어텐션 비용: $O(180^2) = 32400 \to O(11^2) = 121$.

패치 크기의 금융 도메인 해석

패치 크기 16은 약 2주에 해당하며, 급여 주기 (2주/4주)의 기본 단위와 자연스럽게 정렬된다. 각 패치 내부에서 로컬 패턴 (일별 지출)을 집약하고, 패치 간 어텐션으로 글로벌 주기성 (월간 급여, 분기 보너스)을 포착한다.

Multi-Head Self-Attention

$$\text{Attention}(\boldsymbol{Q}, \boldsymbol{K}, \boldsymbol{V}) = \text{softmax}\left(\frac{\boldsymbol{Q}\boldsymbol{K}^\top}{\sqrt{d_k}}\right)\boldsymbol{V} \tag{11}$$

$\boldsymbol{Q}\boldsymbol{K}^\top$의 (i, j) 원소는 두 패치 벡터의 내적으로, 코사인 유사도에 비례한다. Softmax는 이를 확률 분포로 변환하여, 관련성 높은 패치의 정보를 가중합한다. $\sqrt{d_k}$로 나누는 것은 내적 분산을 정규화하여 softmax gradient의 건전성을 유지하기 위함이다.

위치 인코딩

정현파(sinusoidal) 위치 인코딩을 사용한다. 6–12개 패치 수준에서는 학습 가능 위치 인코딩 대비 충분한 성능을 제공하며, 시퀀스 길이 일반화에 유리하다.

프로젝트 구현 사양

파라미터	PatchTST txn	PatchTST session	설명
`d_model`	64	32	Transformer 은닉 차원
`nhead`	4	2	멀티헤드 어텐션 수
`num_layers`	2	2	Transformer 인코더 레이어 수
`patch_size`	16	16	패치 크기 (약 2주)
패치 수	11	5	$\lfloor L/P \rfloor$
출력	`[B, 64]`	`[B, 32]`	AdaptiveAvgPool1d

PatchTST 총 출력 차원: $64 + 32 = 96$D (txn + session concat).

복잡도 비교

모델	복잡도	L=180 기준
Vanilla Transformer	$O(L^2)$	$32,400$
PatchTST ($P = 16$)	$O((L/P)^2)$	121
Mamba (SSM)	$O(L)$	180

앙상블 게이팅

게이트 아키텍처

세 모델의 출력을 연결(concat)한 뒤, 학습 가능한 2-layer 게이트 네트워크가 각 모델의 기여도를 동적으로 결정한다:

$$\boldsymbol{g} = \mathrm{Softmax}(\boldsymbol{W}_2 \cdot \mathrm{ReLU}(\boldsymbol{W}_1 \cdot \boldsymbol{z}_{\mathrm{cat}} + \boldsymbol{b}_1) + \boldsymbol{b}_2) \in \mathbb{R}^3 \tag{12}$$

$$\boldsymbol{y} = \sum_{i=1}^{3} g_i \cdot \mathrm{Proj}_i(\boldsymbol{z}_i) \in \mathbb{R}^{64} \tag{13}$$

z_{cat}: 세 모델 출력의 연결 (192 + 96 + 96 = 384D)
Proj_i: 각 모델 출력을 공통 64D 공간으로 프로젝션
g_i: 모델 i의 가중치 ($\sum g_i = 1$)

입력 분리를 통한 앙상블 다양성

모델	입력 경로	다양성 확보 근거
Mamba	원본 시퀀스 직접 입력	순차 상태 공간 관점

모델	입력 경로	다양성 확보 근거
LNN	Mamba 최종 상태 (직렬)	시간 스케일 보정 관점
PatchTST	원본 시퀀스 독립 입력	글로벌 어텐션 관점

Mamba $\rightarrow$ LNN 직렬 + PatchTST 독립 구조는 입력 분리를 통해 앙상블 다양성을 확보한다. 동일 입력을 사용하면 게이팅 차별화 효과가 감소하므로, 독립 경로 설계가 필수적이다.

게이트 엔트로피 모니터링

게이트 분포의 건전성을 Shannon 엔트로피로 감시한다:

$$H(\boldsymbol{g}) = -\sum_{i=1}^{3} g_i \log_2(g_i) \tag{14}$$

상태	엔트로피	해석
균일 분포	$\log_2(3) \approx 1.585$ bits	세 모델이 균등하게 기여 (최대 엔트로피)
건전한 편중	$0.5 \sim 1.2$ bits	입력에 따른 적응적 가중치 (정상 작동)
게이트 붕괴	< 0.3 bits	하나의 모델이 지배, 나머지 학습 중단 (경고)

> **게이트 붕괴 (Gate Collapse)**
>
> $H < 0.3$ bits이면 하나의 모델이 거의 모든 가중치를 독점한다. 나머지 두 모델은 gradient가 차단되어 학습이 중단되므로 앙상블의 의미가 사라진다. 학습 중 엔트로피를 주기적으로 로깅하고, 붕괴 감지 시 게이트 온도 스케일링 또는 엔트로피 보너스 정규화를 적용한다.

최종 출력 흐름 요약

$$\begin{aligned}
\text{txn_seq } [B, 180, 16] &\rightarrow \text{Mamba}_{\text{txn}} \rightarrow [B, 128] \\
\text{sess_seq } [B, 90, 8] &\rightarrow \text{Mamba}_{\text{sess}} \rightarrow [B, 64] \\
\text{Mamba}_{\text{txn}} &\rightarrow \text{LNN}_{\text{txn}} \rightarrow [B, 64] \\
\text{Mamba}_{\text{sess}} &\rightarrow \text{LNN}_{\text{sess}} \rightarrow [B, 32] \\
\text{txn_seq} &\rightarrow \text{PatchTST}_{\text{txn}} \rightarrow [B, 64] \\
\text{sess_seq} &\rightarrow \text{PatchTST}_{\text{sess}} \rightarrow [B, 32]
\end{aligned} \tag{15}$$

Concat: $[192 + 96 + 96 = 384\text{D}]$ $\rightarrow$ Gate $\rightarrow$ Weighted sum $\rightarrow$ **64D** 최종 출력.

입출력 사양 및 구현 참고사항

전체 입출력 사양

입력

입력	Shape	설명
`txn_seq`	`[B, 180, 16]`	180일 거래 시퀀스, card 8D + deposit 8D
`session_seq`	`[B, 90, 8]`	90일 세션 시퀀스, 8D 세션 피처

중간 표현

모델	txn 출력	session 출력	합계
Mamba (SSM)	128D	64D	192D
LNN (ODE)	64D	32D	96D
PatchTST (Attn)	64D	32D	96D
Concat			**384D**

출력

출력	Shape	설명
Temporal Expert 출력	`[B, 64]`	게이팅 가중합 후 최종 표현
Gate weights	`[B, 3]`	Mamba, LNN, PatchTST 기여도 (모니터링용)

출력 64D 벡터는 PLE의 CGC Gate Attention으로 전달되어, 다른 6개 Expert (PersLay, DeepFM, LightGCN, Unified H-GCN, Causal, OT)의 출력과 태스크별로 동적 결합된다.

세 모델의 역할 비교 요약

모델	포착하는 시간 패턴	메커니즘	복잡도
Mamba	장기 순차 의존성 (트렌드)	Selective State Space (S6)	$O(L)$ 선형
LNN	불규칙 시간 간격 (잔차)	적응적 시간 상수 ODE	$O(1)$ 단일 스텝
PatchTST	글로벌 주기성 (계절성)	패치 단위 Self-Attention	$O((L/P)^2)$

시계열 분석 세대별 발전과 본 프로젝트의 위치

세대	접근법	한계	극복 모델
1세대	ARIMA, Exponential Smoothing	선형 가정, 수작업 차분	LSTM, GRU

세대	접근법	한계	극복 모델
2세대	LSTM, GRU (게이트 기반 RNN)	$O(L)$ 순차 병목, vanishing gradient	Transformer
3세대	Transformer (Self-Attention)	$O(L^2)$ 복잡도, 순서 정보 약함	SSM, PatchTST
4세대	SSM + ODE + Patch Transformer	모델 복잡도, 게이트 붕괴 위험	본 프로젝트

구현 시 유의사항

데이터 리키지 방지

- 시퀀스 데이터의 마지막 타임스텝이 레이블 산출 기간과 겹치지 않도록 `gap_days` 설정 필수 (최소 7일)
- Mamba의 인과 Conv1d는 미래 정보를 참조하지 않음 (left-padding)
- PatchTST의 어텐션은 causal mask 없이 전체 시퀀스를 참조하나, 입력 시퀀스 자체가 레이블 기간 이전으로 절단되어 있으므로 리키지 위험 없음

수치 안정성

- Mamba $\boldsymbol{A}$ 행렬: $-\exp(\mathrm{A}_{\log})$로 음수 보장 (발산 방지)
- Mamba Δ: softplus로 양수 보장 ($\Delta > 0$)
- LNN τ: $\mathrm{Softplus}(\cdot) + 0.1$ 하한 (영점 방지)
- 게이트 엔트로피 < 0.3 bits 시 경고 로깅

성능 최적화

- Mamba sequential scan: 프로토타입은 Python 루프, 프로덕션은 `mamba-ssm` CUDA 커널 권장
- AMP (Mixed Precision) 활성화: g4dn T4 GPU에서 약 2배 속도 향상
- 배치 크기: VRAM과 데이터 규모에 따라 조정 (대규모 데이터 4096 권장)

추가 자료

- **Mamba / S4 / HiPPO**: Gu & Dao NeurIPS 2023; Gu et al. ICLR 2022; Gu et al. NeurIPS 2020.
- **LNN / CfC**: Hasani et al. AAAI 2021; Hasani et al. Nature MI 2022.
- **PatchTST / ViT**: Nie et al. ICLR 2023; Dosovitskiy et al. ICLR 2021.
- **Neural ODE**: Chen et al. NeurIPS 2018.