이종 전문가 PLE: 금융 상품 추천을 위한 설명 가능한 멀티태스크 아키텍처

정선규[1], 심은철[1], 김영찬[1]

[1]Independent Research

초록. 금융 상품 추천은 예측 정확도뿐만 아니라 규제 준수가 가능한 설명 가능성을 요구한다. 기존 멀티태스크 학습 접근법(MMoE, PLE)은 동질적 MLP 전문가를 사용하여 전문가 붕괴(expert collapse) — 모든 게이트가 단일 전문가로 수렴하여 MoE 아키텍처의 존재 이유인 다양성이 소실되는 현상 — 에 취약하며, 구조적 해석 가능성이 부족하다. 본 연구에서는 이종 전문가 PLE(Heterogeneous Expert PLE)를 제안한다. 이는 7개의 구조적으로 상이한 전문가 — DeepFM, Temporal Ensemble (Mamba+LNN+Transformer), Hyperbolic GCN, PersLay, Causal (NOTEARS), LightGCN, Optimal Transport — 가 공유 바스켓을 구성하는 Progressive Layered Extraction 아키텍처로, 전문가 붕괴에 대한 구조적 보장을 제공한다: 근본적으로 다른 귀납적 편향을 가진 전문가들은 동일한 함수로 수렴할 수 없다. FeatureRouter는 이를 한층 강화하여, 각 전문가가 350D 전체 피처 공간 중 지정된 피처 그룹만을 수신하도록 한다(전문가별 입력 차원: 27D–168D). 이 "이종 아키텍처 × 이종 입력" 설계는 모델 파라미터를 4.77M에서 2.8M으로 감소시킨다. CGC 게이트는 태스크별 전문가 조합을 학습하며, 그 가중치는 본질적으로 비즈니스 의미를 가진 설명으로 해석 가능하다 — "35% 소비 추세(Temporal) + 28% 상품 계층구조(HGCN)" — 사후적(post-hoc) SHAP/LIME 없이도 설명이 가능하다. 100만 고객 벤치마크에서의 어블레이션 결과, 서로 다른 전문가가 서로 다른 태스크 유형에 특화됨을 확인하였다: LightGCN과 Causal 전문가는 다중 클래스 태스크에서 우위를 보이고(Macro F1 +0.20), Causal과 TDA 전문가는 회귀 태스크에서 우수한 성능을 나타내어(MAE −0.024), 이종 설계의 타당성을 검증하였다. 4개 금융 DNA 태스크 그룹에 대한 Adaptive Task Transfer(adaTT)와 11개 학문 분야에 걸친 다학제적 피처 엔지니어링을 결합하여, 단일 데스크톱 GPU(12GB VRAM)에서 파라미터 효율적 표현력을 달성하면서도 우아한 성능 저하(graceful degradation)를 유지한다. 최종 어블레이션 결과: PLE Sigmoid(AUC 0.5771)가 최고 구조 성능을 달성하고, TDA·LightGCN 전문가는 최대 단독 기여(ΔAUC +0.028/+0.027)를 보이며, HGCN·LightGCN 제거 시 AUC가 각각 −0.048/−0.017로 급락하여 구조적 필수성을 확인하였다.

키워드: 멀티태스크 학습, Progressive Layered Extraction, Mixture of Experts, 금융 추천, 설명 가능한 AI, 어블레이션 연구

1 서론

1.1 문제 정의

금융 상품 추천은 전자상거래나 콘텐츠 추천과 근본적으로 다르다. 주요 산출물은 확률 점수가 아니라 고객이 수용할 수 있는 이유이다. 세 가지 대상을 설득해야 한다:

- 고객: "왜 이 상품이 나에게 적합한가?" — 신뢰가 전환으로 이어진다.
- 영업 담당자: "왜 이 고객에게 이 상품을 추천하는가?" — 영업 근거 제시.
- 규제기관 (한국 금융감독원 [9], EU AI Act [7]): "이 결정은 왜 내려졌는가?" — 규제 준수 의무. 한국의 AI 기본법 [27] 은 금융 추천을 잠재적 고영향 AI로 분류한다.

기존 접근법은 이러한 설득 요건에 미흡하다:

- 단일 태스크 모델은 이탈, 상품 선호도, 고객 생애가치를 동시에 예측할 수 없다 [3].
- 모델 앙상블 (N개 개별 모델)은 관리 부담과 서빙 비용을 배가시키며, "MLP #3이 28% 기여"라는 설명은 비즈니스적 의미를 가지지 못한다.
- 사후적 설명 (SHAP, LIME)은 모델 내부와 분리되어 있고, 서빙 시점에서 계산 비용이 높으며, 입력 변동에 대해 불안정한 것으로 입증되었다 [22, 34, 35].

1.2 핵심 통찰

기존 추천 모델은 "블랙박스 셰이커"로 기능한다 — 피처가 입력되면 확률이 출력되고, 근거는 통계적 상관관계뿐이다. Pearl [32] 이 주장하듯, 보는 것(연관)과 이해하는 것(인과) 사이에는 근본적 격차가 존재한다. 인간은 상관관계에 의해 설득되지 않으며, 인과적 서사를 요구한다 [31].

멀티태스크 모델의 각 전문가가 서로 다른 종류의 "왜" — 시간적 추세, 계층적 상품 구조, 인과 경로, 협업 필터링 패턴 — 를 포착한다면, 게이팅 메커니즘 자체가 설명이 된다: "이 추천은 주로 소비 추세(Temporal, 35%)와 상품 카테고리 적합성(HGCN, 28%)에 의해 결정되었습니다."

이것이 본 아키텍처의 핵심 설계 원리이다.

핵심적 인식은 금융 추천이 단일 예측 ("이 고객이 구매할 것인가?")이 아니라 하나의 고객을 다양한 관점에서 동시에 전인적으로 이해하는 것이라는 점이다: 이탈할 것인가? (생애주기). 얼마나 소비할 것인가? (가치). 어떤 상품이 적합한가? (소비). 어떻게 행동하는가? (활동). 각 질문은 서

로 다른 분석적 렌즈를 요구한다 — 시계열 분석은 계층적 상품 적합성에 답할 수 없고, 그래프 기반 협업 시그널은 소비 궤적을 예측할 수 없다. 이것이 이종 전문가가 단순한 성능 최적화가 아니라 다면적 고객 이해를 위한 구조적 필수 요건인 이유이다.

이러한 관점은 학계와 규제 양면에서의 광범위한 변화와 맥을 같이한다. Pearl의 인과의 사다리(Ladder of Causation) [31] 는 세 가지 수준을 구분한다: 연관, 개입, 반사실. 대부분의 추천 시스템은 1단계(연관)에서 작동하지만, 본 아키텍처는 구조적 인과 추론을 통합하여 1–2단계를 지향한다. 규제 프레임워크 — EU AI Act, 한국 금융감독원 가이드라인 및 AI 기본법 — 는 점차 구조적으로 투명한 설명으로의 전환을 요구하고 있다 (규제 분석의 상세 내용은 2.3절 참조).

1.3 기여

1. 구조적 붕괴 보장을 갖춘 이종 공유 전문가 바스켓: 본 연구에서는 PLE의 동질적 MLP 전문가를 7개의 구조적으로 상이한 전문가(DeepFM, Mamba+LNN+Transformer, HGCN, PersLay, NOTEARS, LightGCN, Optimal Transport)로 대체한다. 전문가 크기 [41] 또는 모달리티 [1] 를 변화시킨 기존의 "이종" MoE 연구와 달리, 본 연구는 근본적인 귀납적 편향을 다양화하여 전문가 붕괴에 대한 구조적 보장을 제공한다 — 이는 동질적 MoE/PLE 배포에서 지속적으로 발생하는 실패 모드이다 [19].
2. FeatureRouter: 이종 아키텍처 × 이종 입력: 아키텍처 다양성을 넘어, 각 전문가는 전체 350D 입력이 아닌 지정된 피처 그룹만을 수신한다(`feature_groups.yaml` 의 `target_experts` 필드로 선언, 그룹 단위 라우팅). 이 "이종 아키텍처 × 이종 입력" 설계는 전문가별 불필요한 피처를 제거하고(전문가별 차원: 27D–168D), 모델 파라미터를 4.77M에서 2.8M으로 감소시킨다.
3. 본질적 설명 가능성: 각 전문가가 명명된 수학적 연산(범용 MLP가 아닌)을 인코딩하므로, CGC 게이트 가중치가 사후적 귀인 방법 없이 직접 비즈니스 해석 가능한 설명을 생성한다.
4. 다학제적 피처 엔지니어링: 11개 학문 분야에서 도출된 피처 — 화학 반응속도론(소비 활성화율), 역학 모델링(상품 채택 확산), 범죄학의 일상 활동 이론(거래 규칙성), 파동 간섭(소비 주기성) 등의 비전통적 적용을 포함 — 는 학습 신호와 설명 자료의 이중 역할을 수행한다.
5. 금융 DNA 태스크 그룹화: 차별화된 adaTT 그룹 내/간 전이 강도와 자연스러운 경험 전파를 위한 로짓 전이를 갖춘 4개 태스크 그룹(활동, 생애주기, 가치, 소비).
6. 이종 전문가를 위한 Sigmoid CGC 게이트: 표준 softmax CGC 게이트가 이종 전문가에서 해로운 전문가 간 경쟁을 유발함을 식별하고, sigmoid 게이팅([28] 에서 영감)이 독립적 전문가 기여를 허용하여 더 나은 수렴을 달성함을 입증한다.
7. 포괄적 어블레이션: Gaussian Copula + 잠재변수 분산 예산을 활용한 재현 가능한 100만 고객 벤치마크에서 24개 시나리오(18개 피처+전문가 결합 + 6개 구조).
8. Config 기반 파이프라인: 2개의 YAML 파일로 제어되는 엔드투엔드 시스템(피처 엔지니어링 → 학습 → 증류 → 서빙)으로, 1–2명의 ML 엔지니어로 구성된 팀의 배포를 지원한다.
9. 재현 가능한 벤치마크: 제어된 AUC 상한을 위한 분산 예산 [30] 을 갖춘 합성 데이터 생성, XGBoost 기준선 대비 검증, 오픈소스 코드 및 고정 시드 제공.

2 관련 연구

2.1 추천을 위한 멀티태스크 학습

Shared-Bottom [3] 에서 MMoE [23] 를 거쳐 PLE [39] 로의 발전은 태스크 간 부정적 전이(negative transfer)를 관리하는 정교함의 증가를 반영한다. MMoE는 공유 전문가 풀에 대한 태스크별 게이팅을 도입하였고, PLE는 점진적 추출(progressive extraction) 구조를 통해 공유 전문가와 태스크 전용 전문가를 더욱 분리하였다. AdaTT [20] 는 적응적 태스크 간 전이로 이를 확장하였다.

기타 주목할 만한 MTL 아키텍처로는 ESMM [24](전환율을 위한 전체 공간 모델링), STAR [37](다중 도메인 CTR을 위한 스타 토폴로지), M3oE [42](AutoML 구조 탐색을 통한 다중 도메인 다중 태스크 MoE) 등이 있다.

그러나 모든 기존 MoE/PLE 아키텍처는 동질적 전문가 — 동일한 아키텍처를 가진 다수의 MLP에 서로 다른 초기화만 적용 — 를 사용한다. 이는 학습된 표현의 다양성을 파라미터 변이만으로 달성할 수 있는 범위로 제한하며, 잘 알려진 실패 모드인 전문가 붕괴를 초래한다.

2.2 Mixture of Experts와 전문가 붕괴 문제

MoE 패러다임 [36] 과 그 후속 연구(Switch Transformer [8])는 조건부 계산의 강력함을 입증한다. 그러나 동질적 MoE 아키텍처는 전문가 붕괴에 취약한데, 이는 모든 게이트가 단일 전문가로 입력을 라우팅하도록 수렴하여, 사실상 MoE를 shared-bottom 아키텍처로 축소시키는 현상이다. Pinterest Engineering은 자사의 MMoE 배포가 "모든 태스크가 동일한 단일 전문가를 사용하는 상태로 빈번하게 붕괴하였다"고 보고하였다. Kuaishou의 HoME [19] 은 "모든 게이트가 단일 공유 전문가에 더 큰 가중치를 부여하고 다른 공유 전문가를 거의 무시할 때 전문가 붕괴가 발생한다"고 확인하였다.

기존 완화책은 사후적으로 작동한다: 다양한 전문가 표현을 강제하기 위한 Gram-Schmidt 직교화, 출력 분포를 정렬하기 위한 전문가 정규화, 라우팅을 분산시키기 위한 부

하 균형 손실 등이 있다. 이들은 구조적 문제에 대한 엔지니어링적 패치에 불과하다 — 동질적 전문가는 다양성의 유일한 원천이 무작위 초기화뿐이므로 다르게 특화될 본질적 이유가 없다.

최근 연구에서는 제한적 형태의 이종성이 탐색되었다: Jamba [1] 는 LLM용 MoE 내에서 Transformer와 Mamba 레이어를 결합하고(2가지 아키텍처 유형), MOWST [41] 는 경량 MLP "약한 전문가"와 GNN "강한 전문가"를 계층적으로 배치한다(2가지 유형, 비대칭 역할). M3oE [42] 는 도메인별로 전문가를 분리하지만 각 도메인 내에서는 동일한 MLP 아키텍처를 사용한다. MoE++는 계산 수준의 이종성(zero-compute vs. FFN 전문가)을 도입하지만 아키텍처적 이종성은 아니다.

나아가, 최근 이론적 연구는 표준 softmax 게이팅 메커니즘 자체가 표현 붕괴에 기여함을 입증한다. Nguyen 등 [28] 은 MoE 모델에서 sigmoid 게이팅이 softmax 게이팅보다 높은 표본 효율성을 달성함을 증명하였다: softmax의 합이 1이 되는 제약은 전문가 간 불필요한 경쟁을 강제하여, 한 전문가의 가중치를 높이려면 다른 전문가의 가중치를 낮추어야 하므로, 전문가들이 상호 보완적 신호를 제공하는 경우에도 표현 붕괴가 발생한다. Sigmoid 게이팅은 각 전문가의 기여를 독립적으로 평가함으로써 이러한 전문가 간 경쟁을 제거하여, 더 빠른 수렴과 전문가의 더 나은 활용을 달성한다. 이 발견은 전문가가 이종일 때 특히 관련성이 높다: 전문가의 출력이 근본적으로 다른 스케일과 분포를 가지므로 (예: 쌍곡 임베딩 vs. 지속성 다이어그램), softmax 경쟁은 특히 해로운데 — 시간적 전문가의 가중치를 높이기 위해 위상적 전문가를 억제하는 것은 단순히 중복된 표현이 아닌 대체 불가능한 위상적 신호를 잃는 것을 의미하기 때문이다.

격차: 기존 연구 중 근본적으로 다른 귀납적 편향을 가진 전문가들 — 그래프 합성곱, 상태 공간 모델, 위상적 지속성, 인과 DAG 제약, 최적 수송 — 을 공유 전문가 바스켓 내에서 동등한 동료로 구성한 사례는 없다. 전문가 붕괴는 두 가지 형태로 발현된다: (1) 함수 공간 붕괴(function space collapse) — 동질적 전문가가 공유 아키텍처와 그래디언트 역학으로 인해 동일한 함수로 수렴하는 현상; (2) 라우팅 붕괴(routing collapse) — 게이트 가중치가 단일 전문가에 집중되어, 기능적 다양성과 무관하게 다른 전문가를 사실상 비활성화하는 현상. 본 연구의 이종 전문가 설계는 (1)을 구조적으로 방지하며, sigmoid 게이팅 [28] 은 독립적이고 비경쟁적인 전문가 기여를 허용하여 (2)를 완화한다.

본 연구는 전문가 붕괴에 대한 구조적 보장을 제공한다: DeepFM 전문가는 학습 역학과 무관하게 HGCN 전문가와 동일한 함수로 수렴할 수 없는데, 이는 이들의 아키텍처가 근본적으로 다른 수학적 연산을 인코딩하기 때문이다.

2.3 추천에서의 설명 가능성

SHAP [22] 과 LIME [34] 은 모델 비의존적 설명을 제공하지만 불안정성, 계산 비용, 모델 내부와의 괴리 문제를 겪는다. Integrated Gradients [38] 은 이론적으로 근거가 있는 귀인을 제공하지만 여전히 사후적으로 작동한다.

격차: 추가 계산 없이 순전파의 자연스러운 부산물로서 비즈니스적으로 의미 있는 설명을 생성하는 구조적(본질적) 설명 가능성.

2.4 금융 추천과 규제

금융 상품 추천을 위한 딥러닝에 관한 최근 연구 [5, 26] 는 협업 필터링 대비 개선을 입증하였으며, Martinez-Plumed 등 [25] 은 종단적 거래 데이터에 대한 순차 모델이 교차 판매 예측을 개선함을 보였다. 그러나 이러한 시스템 중 규제 설명 가능성 요건을 다루는 것은 없다.

EU AI Act [7] 는 금융 추천을 고위험 AI로 분류하여 투명성(Art. 13), 인간 감독(Art. 14), 견고성(Art. 15)을 의무화한다. 한국 금융감독원 가이드라인 [9] 및 AI 기본법 [27] 도 유사한 요건을 부과한다. 현재 접근법은 규제 준수를 위해 사후적 SHAP/LIME에 의존하나, 이는 금융 맥락에서 한계가 있음이 문서화되었다 [35].

격차: 규제 요건에서 아키텍처 구성요소로의 검증 가능한 매핑을 제공하며, 설명이 사후적이 아닌 구조적으로 생성되는 추천 시스템은 존재하지 않는다.

3 아키텍처

3.1 환원주의 프레임워크: 두 축의 분해

아키텍처를 설명하기에 앞서, 이후 모든 설계 결정을 지배하는 분석적 프레임워크를 제시한다.

금융 고객 이해의 복잡성은 두 개의 직교 축을 따라 분해된다:

축 1: 고객은 누구인가? (금융 DNA)

"이 고객은 누구인가?"라는 질문을 4개의 환원 불가능한 차원으로 분해하며, 각 차원은 고객 정체성의 근본적으로 다른 측면을 포착한다:

[1]

nba_primary 타겟 설계. `nba_primary`는 개별 상품 인덱스가 아닌 상품 그룹(7개 클래스)을 타겟으로 한다. 7개 클래스는 다음과 같다: 0 = NBA 없음, 1 = 저축/보증, 2 = 당좌 계좌, 3 = 예금, 4 = 투자, 5 = 신용 대출, 6 = 직불. 이 재설계(기존 25개 개별 상품 클래스에서 변경)는 클래스 균형을 개선하고 의미 있는 순위 기반 평가를 가능하게 한다. 기존 25-way 분류는 희귀 상품이 지배하는 긴 꼬리 분포를

[1]초기 개발 단계에 포함되었던 4개 태스크(소득 구간, 재직 단계, 소비 수준, 참여 점수)는 결정론적 피처 변환으로 확인되어 진정한 예측 목표가 아니므로 제거하였다.

DNA	질문	태스크
활동(Engagement)	고객이 무엇을 하는가?	has_nba engagement next_mcc mcc_trend top_mcc_shift
생애주기(Lifecycle)	고객이 어디에 있는가?	churn segment
가치(Value)	고객의 가치는 얼마인가?	cross_sell stability
소비(Consumption)	고객이 무엇을 구매할 것인가?	will_acquire_* (5), nba_primary

Table 1: 금융 DNA 분해 (축 1). 고객 정체성의 4개 환원 불가능한 차원.

모달리티	예시	전문가	생성기
상태(State)	is_active, holdings	DeepFM	base
스냅샷(Snapshot)	balance, demographics	GMM, DeepFM	GMM clustering
단기 시계열	recent transactions	Transformer	temporal
장기 시계열	monthly trends	Mamba	mamba temporal
불연속 시계열	dormant→active	LNN	model derived
계층(Hierarchy)	MCC 가맹점 카테고리 트리	HGCN	merchant_hierarchy
관계(Relations)	customer-product graph	LightGCN	graph collab.
위상(Topology)	behavioral shape	PersLay	TDA global/local
인과(Causality)	behavioral causation	Causal	causal features

Table 2: 데이터 모달리티 분해 (축 2). 각 모달리티는 전문가와 피처 생성기에 매핑된다.

가져 macro-F1이 신뢰할 수 없었으며, 그룹 수준 순위 목표에는 NDCG@K가 적합하다.

축 2: 정보는 어떤 형태를 가지는가? (데이터 모달리티)

고객 데이터는 구조적으로 상이한 모달리티로 존재하며, 각각 의미 있는 신호를 추출하기 위해 서로 다른 수학적 도구를 필요로 한다:

교차곱(cross-product)은 아키텍처를 정의한다: 각 (DNA × 모달리티) 셀은 어떤 전문가가 어떤 태스크 그룹을 위해 어떤 피처를 처리하는지를 결정한다. 7개 이종 전문가, 12개 피처 그룹, 4개 태스크 그룹은 임의의 설계 선택이 아니라 이 두 축 분해의 필연적 결과이다. 동질적 MLP 전문가 바스켓은 축 2를 완전히 무시한다 — 계층적, 시간적, 위상적 데이터를 동일하게 취급하므로 — 본 연구의 어블레이션이 입증하는 태스크 유형별 특화를 달성할 수 없다.

3.2 설계 철학

본 아키텍처는 한국 공공 금융기관의 심각한 현실적 제약에서 탄생하였다. 3인으로 구성된 팀 — PM 역할을 겸한 데이터 사이언티스트 1명(GARP 국제재무위험관리사(FRM) 자격, 신용/시장 리스크 분석, 규제 준수, 마이데이터 인허가, 빅데이터 플랫폼 구축·운영, 데이터 사이언스 프로젝트, 추천 시스템 관리 경력)과 엔지니어 2명 — 이 레거시 ALS 기반 협업 필터링 시스템을 차세대 추천 모델로 교체해야 했다.

제약은 상당했다: 전용 ML 인프라 예산 없음, 유일한 학습 하드웨어인 단일 데스크톱 GPU (NVIDIA RTX 4070, 12GB VRAM), 배포를 위한 GPU 추론 서버 없음, 엄격한 규제 요건 (한국 금융감독원 AI 가이드라인, EU AI Act).

팀은 이러한 제약을 한계로 취급하기보다 모든 수준에서 방법론을 적응시켰다:

- Claude (Anthropic), Gemini (Google), Cursor를 활용한 AI 증강 개발로, 각 팀원이 AI 에이전트 병렬 팀을 이끄는 방식;
- 대형 MLP의 무차별적 용량을 구조적 귀납적 편향으로 대체하는 파라미터 효율적 아키텍처 설계;
- AWS Lambda에서의 GPU 없는 CPU 추론을 위한 LGBM으로의 지식 증류;
- 2개의 YAML 파일로 전체 시스템을 제어하는 config 기반 파이프라인으로 최소 인원 팀의 운영을 지원.

초기 탐색에서는 Black-Litterman에서 영감을 받은 접근법을 고려하였으나, 다수 모델의 예측을 베이지안 업데이트를 통해 결합하는 "전문가 견해"로 취급하는 방식은, 결합 과정이 각 모델의 기여를 불투명하게 만들어 비즈니스적으로 의미 있는 설명을 불가능하게 하였기에 — 규제 준수에 치명적 결함으로 — 기각되었다.

핵심적 재구성은: 모델을 외부에서 결합하는 대신, 단일 모델 내부에서 전문가를 결합하는 것이었다. 이는 PLE [39]의 선택으로 이어졌으며, 핵심적 수정이 적용되었다: 동질적 MLP 전문가를 각기 다른 귀납적 편향을 인코딩하는 구조적으로 이종인 전문가로 대체하였다.

3.2.1 구조적 동형사상: 학제 간 방법론이 작동하는 이유

본 연구의 다학제적 피처 엔지니어링은 관련 없는 분야에서의 임의적 차용이 아니다. 이는 구조적 동형사상(Structural Isomorphism) 에 기반한다 — 수학적으로 동등한 구조가 서로 다른 분야에서 반복적으로 나타나며, 한 분야에서 개발된 도구를 구조적으로 동등한 다른 분야의 문제에 엄밀하게 적용할 수 있다는 관찰이다.

예를 들어: 휴면 고객이 소비를 재개하는 과정은 화학 반응이 활성화 에너지 장벽을 극복하는 역학과 동일한 구조를 따른다. 고객 네트워크를 통한 상품 채택의 확산은 SIR 감염병 모델의 구획 역학과 동일한 구조를 따른다. 이것은 비유가 아니다 — 지배 방정식이 동일하며, 해법이 수학적 엄밀성을 가지고 전이된다. 이것이 느슨한 유비가 아님을 강조한다: 지배 미분방정식이 구조적으로 동일하다 (나란히 비교는 부록 E 참조). 각 매핑의 타당성은 원천 분야 정리의 수학적 전제조건이 금융 분야에서도 성립하는지를 확인함으로써 독립적으로 검증할 수 있다.

이 원리는 과학과 공학에서 저명한 역사를 가진다: Shannon의 정보 엔트로피는 Boltzmann의 열역학 엔트로피에서 직접 차용되었고, Black-Scholes 옵션 가격 결정 모델은 열전도 방정식에서 유도되었으며, Google의 PageRank는 마르코프 체인 정상 분포의 응용이다. 각 사례에서 두 분야 사이의 구조적 동형사상을 인식한 것이 어느 한 분야만으로는 달성할 수 없었던 돌파구를 가능하게 했다.

본 연구의 기여는 이 원리를 금융 고객 이해에 체계적으로 적용한 것이다: 고객 행동의 각 측면에 대해, 기저 역학과 구조적으로 동형인 수학적 도구를 가진 분야를 식별하고, 해당 분야의 방법론을 피처(예측용)와 전문가 아키텍처(해석용)로 구체화하였다. 다학제적 접근은 임의적 피처의 집합이 아니라, 구조적 동등성을 통한 유비추론의 원리적 적용이다.

4가지 원칙이 아키텍처를 안내한다:

1. 강건한 설명 가능성: 모델 구조 자체가 설명을 생성한다. 각 전문가의 이름이 비즈니스 의미를 담고 있으므로 (예: "Temporal" = 시간 패턴, "HGCN" = 상품 계층구조), CGC 게이트 가중치는 사후적 방법 없이 직접 해석 가능하다.
2. 우아한 성능 저하: 단일 전문가를 제거해도 치명적 성능 하락이 발생하지 않는다. 나머지 전문가가 게이트 가중치를 재분배하여 보상한다.
3. 유연한 확장성: 새로운 피처, 태스크, 전문가는 코드 변경이 아닌 YAML 설정으로 추가된다. 시스템은 4개에서 14개 태스크로 아키텍처 수정 없이 확장되었다.
4. 통합 관리성: 전체 파이프라인(피처 엔지니어링 → 학습 → 증류 → 서빙 → 모니터링)이 2개의 설정 파일(`pipeline.yaml` 및 `feature_groups.yaml`)로 제어되어, 제한된 ML 엔지니어링 리소스를 가진 팀의 운영 부담을 줄인다.

3.3 데이터 축 분류

금융 고객 데이터는 본질적으로 다중 모달 구조를 나타낸다. 데이터를 다수의 축을 따라 분류하며, 각각 최적의 피처 생성기와 전문가에 매핑된다.

데이터 축에서 전문가 및 피처 생성기로의 완전한 매핑은 Table 2 에 나타나 있다.

참고: 단기/장기/불연속 시계열은 Temporal Ensemble 전문가의 세 하위 구성요소 (Transformer, Mamba, LNN)에 대응한다. GMM은 피처 생성기이며 독립 전문가가 아니다.

3.4 이종 전문가 바스켓

공유 전문가가 동일한 MLP인 표준 PLE와 달리, 본 연구의 공유 전문가 바스켓은 7개의 구조적으로 상이한 네트워크를 포함한다. 각 전문가는 하나 이상의 모달리티 축(Table 2)에 대응하여, 모든 구조적으로 상이한 데이터 유형이 그에 맞게 설계된 아키텍처에 의해 처리되도록 보장한다:

각 전문가가 명명된 귀납적 편향을 가지므로, 게이트 가중치는 고객에게 비즈니스적 용어로 왜인지를 전달한다 — "은닉 유닛 47이 활성화됨"이 아니라 "소비 추세가 이 추천을 주도하였습니다." 각 전문가는 다른 전문가 유형으로는 해결할 수 없는 금융 고객 이해의 특정 공백에 기반하여 선정되었다:

- DeepFM [12]: 금융 행동은 피처 상호작용에 의해 구동된다 (예: 소득 × 보유 상품 × 채널 선호도). FM의 저랭크 분해는 $O(nk)$로 2차 교차를 계산하며, 이는 무차별 열거의 $O(n^2)$와 비교된다. Deep 구성요소는 고차 상호작용을 포착한다.
- HGCN [4]: MCC 가맹점 카테고리 계층구조(10 L1 카테고리 → 30 L2 서브카테고리 → 109 리프 코드)는 본질적으로 트리 구조이다. 쌍곡 공간(Poincaré 볼, 8D)은 유클리드 공간보다 기하급수적으로 적은 왜곡으로 트리를 임베딩한다 [29] — 550K 노드 가맹점 계층구조에 필수적이다. HGCN은 FeatureRouter를 통해 `merchant_hierarchy` 피처(27D Poincaré 임베딩)를 수신하며, 상품 공동 보유 피처(이는 LightGCN의 `product_hierarchy` 그룹에 속함)를 수신하지 않는다.

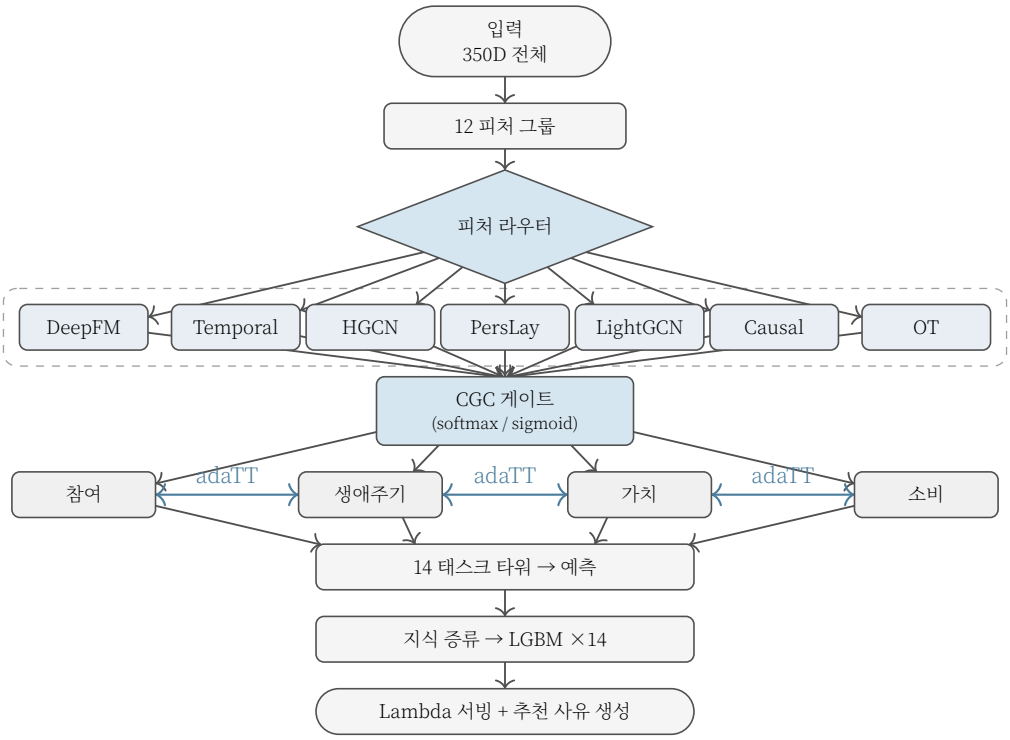

Figure 1: 이종 전문가 PLE 아키텍처 개요.

HGCN과 LightGCN은 초기 실험에서 의도치 않게 혼용되었던 서로 다른 역할을 담당한다. HGCN은 MCC 가맹점 카테고리 계층구조(L1: 10개 카테고리 → L2: 30개 서브카테고리)를 Poincaré 디스크 공간에 임베딩하여 트리 구조의 카테고리 관계를 포착한다. LightGCN은 24개 상품 공동 보유 그래프에서 협업 필터링을 통해 고객-상품 이분 친화도를 학습한다. `feature_groups.yaml`의 `target_experts` 선언이 이 분리를 강제한다: `merchant_hierarchy` → HGCN 전용, `product_hierarchy` → LightGCN 전용.

- PersLay [2]: 위상적 데이터 분석(TDA)은 고객 소비 패턴의 형태 피처(연결 성분 H_0, 순환 H_1, 공동 H_2)를 포착한다. H_1 루프는 소비 순환을 드러내고, H_2 공동은 체계적 소비 회피를 감지한다. 이러한 피처는 잡음에 대해 증명 가능하게 안정적이다(안정성 정리).
- Temporal Ensemble: 금융 시계열은 규칙적 스냅샷, 돌발적 거래, 수개월 휴면을 결합한다. Mamba [11] 는 $O(n)$으로 장거리 추세를 처리하고, LNN [13] 은 불규칙 간격에 시간 상수를 적응시키며, Transformer는 단기 어텐션 패턴을 포착한다.
- Causal [43]: NOTEARS 연속 DAG 제약 ($\mathrm{tr}(e^{W \circ W}) - d = 0$)은 피처 간 인과 방향을 학습하여, "A가 B와 상관관계가 있다"가 아닌 "A가 B를 유발한다"는 설명을 가능하게 한다 [32].
- LightGCN [14]: 고객-상품 이분 그래프에서의 이웃 집계를 통한 협업 필터링. 핵심만 남긴 구조(피처 변환 없

전문가	귀납적 편향	포착 대상
DeepFM [12]	피처 상호작용	2차 교차 피처
Temporal Ensemble	다중 스케일 시간적	단기/장기/불연속 시계열
HGCN [4]	쌍곡 계층구조	MCC 가맹점 카테고리 트리 (Poincaré)
PersLay [2]	위상적 지속성	행동 형태 패턴
LightGCN [14]	그래프 합성곱	협업 필터링
Causal [43]	DAG 제약	피처 간 인과 방향
Optimal Transport [6]	분포 매칭	세그먼트 분포 이동

Table 3: 상이한 귀납적 편향을 가진 7개 이종 전문가.

전문가	입력 차원	라우팅된 피처 그룹
DeepFM	168D	demographics, products, txn_behavior, derived_temporal, gmm, model_derived
Temporal Ensemble	139D	txn_behavior, hmm, mamba, model_derived
HGCN	27D	merchant_hierarchy (MCC Poincaré 임베딩)
PersLay	32D	tda_global, tda_local
Causal	161D	demographics, products, txn, derived_temporal, product_hierarchy, gmm
LightGCN	100D	product_hierarchy, graph_collaborative
Optimal Transport	127D	demographics, products, txn, derived_temporal, gmm

Table 4: FeatureRouter 적용 후 전문가별 입력 차원. 전체 피처 공간: 350D (Phase 0 v3/v4).

음, 활성화 없음)로, 추천에서 더 복잡한 GCN 변형보다 우수한 성능을 보인다.

- Optimal Transport [6]: Sinkhorn 정규화 Wasserstein 거리는 고객 소비 프로필과 세그먼트 프로토타입 간의 분포 이동을 측정하며, (KL 발산과 달리) 피처 공간의 거리 구조를 존중한다.

이종 전문가의 근거는 하드웨어 제약에도 있다: 단일 데스크톱 GPU(12GB VRAM)로는 동질적 MLP 전문가를 높은 표현력을 위한 충분한 너비/깊이로 확장할 수 없다. 대신, 각 전문가는 구조적 귀납적 편향을 활용하여 MLP 파라미터로는 수 차수 더 많은 파라미터가 필요한 패턴을 포착한다. 예를 들어, HGCN은 MCC 가맹점 카테고리 계층구조를 27개 쌍곡 차원으로 임베딩하며 — 유클리드 임베딩이 왜곡 없이 표현하려면 $O(2^d)$ 차원이 필요한 것을 $O(d)$ 파라미터로 달성한다 [4].

7개 전문가 전체의 총 파라미터 수는 2.8M으로, FeatureRouter를 통한 전문가별 입력 서브셋 적용으로 4.77M 기준선 대비 감소하였다. 학습된 표현의 다양성은 더 작은 파라미터 예산에도 불구하고 근본적으로 더 풍부하다.

3.4.1 FeatureRouter: 이종 입력 × 이종 아키텍처

FeatureRouter는 더 강력한 형태의 전문가 특화를 구현한다: 각 전문가는 다른 아키텍처(이종 바스켓)를 사용할 뿐만 아니라, 다른 입력 피처 서브셋(이종 입력)도 수신한다. 이 "이종 아키텍처 × 이종 입력" 설계는 각 전문가에 대해 귀납적 편향과 무관한 피처를 제거함으로써 신호 대 잡음비를 극대화한다.

피처 그룹 할당은 `feature_groups.yaml`의 `target_experts` 필드를 통해 선언되어, 모델 코드에 데이터셋별 하드코딩이 전혀 없다. 전문가별 입력 차원은 다음과 같다:

전문가별 차원의 합(703D)이 350D를 초과하는 이유는, 일부 피처 그룹이 상보적 귀납적 편향이 동일한 신호에서 혜택을 받는 여러 전문가에게 공유되기 때문이다 (예: 상태 피처는 DeepFM의 상호작용 모델링과 Causal의 DAG 구조 추론 양쪽에 유용하다).

3.4.2 CGC 게이트 설계: Softmax vs. Sigmoid

표준 PLE는 경쟁적 제약을 부과하는 softmax CGC 게이트를 사용한다: 게이트 가중치의 합이 1이 되므로, 전문가들은 영향력을 두고 경쟁해야 한다. 동질적 MLP 전문가에서는 이것이 합리적이다 — 전문가들이 중복된 표현을 제공하므로 게이트가 최선의 것을 선택하면 된다.

이종 전문가에서는 이 경쟁이 해롭다: 각 전문가가 고유하고 비중복적인 정보를 제공하므로 (시간적 $\neq$ 계층적 $\neq$ 위상적), 하나를 억제하는 것은 대체 불가능한 신호를 잃는 것을 의미한다. 최근 이론적 연구 [28] 는 sigmoid 게이팅이 전문가 간 경쟁을 제거하여 더 높은 표본 효율성을 달성함을 증명하였다.

본 연구에서는 경험적 비교를 위해 두 가지 게이트 유형을 모두 구현한다:

- Softmax: $w_k = \mathrm{softmax}(W \cdot h)_k$ — 경쟁적, 합이 1.
- Sigmoid: $w_k = \sigma(\boldsymbol{w}_k \cdot h) / \sum_j \sigma(\boldsymbol{w}_j \cdot h)$ — 독립적 평가, 정규화.

Sigmoid 변형은 각 전문가의 관련성을 정규화 전에 독립적으로 평가하여, 다수의 전문가가 동시에 높은 가중치를 받을 수 있게 한다. 이는 다수의 분석적 관점을 필요로 하는 태스크에서 특히 중요하다 — 예를 들어, 이탈 예측은 시간적 추세 와 인과 경로 양쪽에서 혜택을 받으며, 어느 쪽도 다른 쪽을 높이기 위해 억제되어서는 안 된다. 구조 어블레이션(5.5절)에서 수렴 행동을 평가하기 위해 10 에포크 학습으로 이 게이트 유형들을 비교한다.

3.4.3 Temporal Ensemble: 전문가 내의 전문가

금융 시계열은 다른 도메인에서 드물게 볼 수 있는 고유하게 복잡한 구조를 나타낸다. 단일 고객이 동시에 다음을 가질 수 있다: 월별 잔액 스냅샷(규칙적, 장거리), 일별 거래

학문 분야	방법	차원	금융 해석
위상수학	Persistent Homology (TDA)	32	행동 형태 지속성: 일시적 vs. 구조적 소비 패턴
쌍곡 기하학	HGCN 임베딩	27	MCC 가맹점 카테고리 거리: 저차원에서의 계층구조 보존
제어 이론	Mamba (State Space)	50	장거리 행동 의존성: 과거 습관이 현재에 미치는 영향
확률 과정	HMM 상태 전이	25	잠재적 생애주기 단계: 휴면 → 성장 → 성숙 → 위험
화학 반응속도론	반응 속도 모델링	6	소비 활성화율, 반감기, 휴면 재활성화 촉매
역학(전염병학)	SIR 구획 모델	5	상품 채택을 "감염"으로 모델링: 미감염 → 채택 → 이탈
범죄학	일상 활동 이론	5	거래 규칙성: 돌발성, 일주기 분산, 루틴 이탈점
신호 처리	FFT + Hilbert 변환	8	소비 주기성: 스펙트럼 엔트로피, 고조파 전력, 위상 고정
경제학	Friedman 항상소득	8	소득 분해: 항상 vs. 일시 소득, 소비 평활화
그래프 이론	LightGCN	66	협업 필터링: 유사 고객 행동 전이
통계학	GMM 소프트 클러스터링	22	확률적 세분화: 다봉 고객 분포

Table 5: 다학제적 피처 엔지니어링 (11개 학문 분야).

시퀀스(불규칙, 돌발적), 수개월 휴면 갭(불연속). 단일 시간 모델로는 세 가지 모두를 잘 처리할 수 없다:

- Mamba [11] (State Space Model): 선택적 상태 공간을 통해 $O(n)$ 효율로 장거리 의존성을 포착한다. 12개월 이상의 월별/분기별 추세에 이상적이다.
- LNN [13] (Liquid Neural Network): 불규칙 샘플링 간격과 휴면 갭을 자연스럽게 처리하는 적응형 시간 상수. 고객이 3개월간 비활성 후 갑자기 활성화될 때, LNN의 연속시간 역학이 보간 없이 적응한다.
- Transformer: 어텐션 기반 단기 문맥 추출. 위치 관계가 중요한 최근 30–90일 거래 시퀀스 내의 패턴을 포착한다.

세 모델의 출력은 연결(concatenate)되어 투영되며, 이는 더 미세한 세분화 수준에서 이종 전문가 철학을 반영한다. 이 설계는 어블레이션 연구(5.4절)에서 검증되며, 단일 시간 구성요소의 제거가 서로 다른 태스크 그룹에서 성능을 저하시킴을 보인다.

3.5 다학제적 피처 엔지니어링

본 연구의 차별적 특징은 다양한 학문 분야의 방법론을 금융 고객 행동에 체계적으로 적용하는 것이다. 전문가 바스켓이 소개된 이상, 근거는 명확해진다: 각 분야의 피처는 해당 신호 유형을 가장 잘 활용할 수 있는 특정 전문가에 공급되도록 설계된다. 표준 통계 피처(평균, 분산, 추세)에만 의존하기보다, 동일한 기초 데이터에서 구조적으로 다른 신호를 추출하는 도메인 특화 수학적 도구를 적용한다.

참고: Phase 0 v3/v4에서 총 350개 피처 생성 (이전 버전 316개 대비 증가). FeatureRouter가 각 전문가에게 피처 서브셋을 라우팅한다 (Phase 0 v3 기준 전문가별 차원: DeepFM 168D, Temporal 139D, HGCN 27D, PersLay 32D, Causal 161D, LightGCN 100D, OT 127D); 모델 파라미터: 2.8M. 전문가 라우팅은 `feature_groups.yaml`의 `target_experts` 선언(그룹 단위)으로 구성되어 각 전문가가 지정된 피처 그룹만 수신함을 보장한다.

이러한 적용 중 일부는 저자들이 아는 한 금융 추천에서 최초이다:

화학 반응속도론은 소비 행동을 반응 시스템으로 모델링한다: "활성화 에너지"는 휴면 고객이 소비를 재개하는 임계치를 나타내며, "촉매"(예: 급여 입금)는 이 임계치를 낮춘다. 정점 이후 소비 강도의 반감기는 단순 이동평균으로는 표현할 수 없는 감쇄 역학을 포착한다.

SIR 전염병 모델은 상품 채택을 전염 과정으로 취급한다: 고객은 "미감염"(미채택), "감염"(최근 채택), "회복"(이탈) 상태에 있다. 고객의 소셜 그래프에서 상품 카테고리의 기본 재생산수 R_0는 채택 속도를 예측한다.

Friedman의 항상소득가설 [10] 은 관측된 소득을 HP 필터 또는 칼만 필터를 사용하여 항상(안정적, 장기) 소득과 일시(보너스, 비정기) 소득으로 분해한다. 이 구분은 금융 추천에 핵심적이다: 일시 소득이 높은 고객에게 안정적 현금흐름을 가정하는 장기 투자 상품을 추천해서는 안 된다. FD-TVS 스코어링 시스템(동반 논문에서 상세 설명)은 이 분해를 활용하여 소득 안정성 유형별로 추천에 가중치를 부여한다.

이러한 피처는 예측 기여를 넘어 이중 목적을 수행한다: 표준 피처로는 제공할 수 없는 설명 어휘를 제공한다. 예를 들어 화학 반응속도론의 "활성화 에너지 감소"는 내부적으로 "소비 재개 가능성 상승"이라는 신호로 해석되고, SIR 모델의 상품 채택 곡선은 "신규 상품 관심도 증가"로 역매핑된다. `interpretation_registry`를 통해 비즈니스 용어로 변환된 후 추천사유 생성 에이전트에 전달된다. 과학적 프레임워크는 모델의 내부 추론을 근거하며, 고객은 비즈니스 언어를 수신한다.

3.6 금융 DNA 태스크 그룹화

18개 예측 태스크를 금융 고객 DNA에 기반하여 4개 그룹으로 조직한다. 각 태스크 그룹은 하나의 DNA 축(Table 1)에 대응하며, 각 그룹 내에서 서로 다른 모달리티 전문가

소스 → 타겟	방법	고객 경험	인과 방향
has_nba → nba_primary	output_concat	구매 결정 → 상품 선택	순차적
engagement → has_nba	hidden_concat	활동 수준 → 구매 확률	선행 지표
churn → has_nba	output_concat	이탈 위험 → 획득 기회	역상관

Table 6: 자연스러운 고객 경험 흐름을 반영하는 로짓 전이 관계.

(Table 2)가 다르게 기여하고, CGC 게이트가 태스크별 최적 조합을 학습한다.

4개 태스크 그룹 — 활동(Engagement), 생애주기(Lifecycle), 가치(Value), 소비(Consumption) — 과 그 구성 태스크는 Table 1 에 정의되어 있다.

adaTT는 차별화된 전이를 강제한다: 강한 그룹 내 전이(동일 DNA 관점)와 약한 그룹 간 전이(상이한 관점, 부정적 전이 최소화).

손실 수준 전이. 표현 수준에서 전이하는 원래 adaTT [20] 와의 주목할 만한 차이점으로, 본 구현은 손실 수준에서 작동한다:

$$\mathcal{L}_i^{\text{adaTT}} = \mathcal{L}_i + \lambda \sum_{j \neq i} w_{i \to j} \cdot \mathcal{L}_j$$

기본 태스크 손실 $\mathcal{L}_i$는 학습된 불확실성 [18] 에 의해 가중되며, 심각한 클래스 불균형을 가진 이진 분류 태스크(예: has_nba의 3% 양성률)는 태스크별 α 및 γ 파라미터를 가진 focal loss [21] 를 사용한다.

여기서 $w_{i \to j}$는 태스크 j에서 태스크 i로의 전이 가중치로, 태스크 손실 기울기 간의 gradient cosine similarity로 계산된다. 이 설계 선택은 두 가지 고려에 의해 동기 부여되었다: (1) 표현 수준 전이는 이종 전문가 간에 은닉 차원을 맞추어야 하므로, 전문가가 서로 다른 형태와 의미의 출력을 생성할 때 아키텍처적으로 번거롭다; (2) 손실 수준 전이는 태스크 그룹 구조를 자연스럽게 존중한다 — 두 태스크가 유사한 기울기 방향(높은 코사인 유사도)을 가지면, 예측을 생성한 전문가와 무관하게 손실이 서로 강화된다.

3.7 로짓 전이

adaTT가 대칭적 태스크 간 관계를 처리하는 반면, 로짓 전이는 고객 경험의 자연스러운 순서를 반영하는 방향적 의존관계를 포착한다:

이러한 전이는 DNA 그룹(Table 1)을 연결한다: 활동→활동(그룹 내), 가치→소비(그룹 간), 이는 고객 경험의 자연스러운 순서를 반영한다. 전이 방향은 데이터로부터 학습되는 것이 아니라 고객 여정에 대한 도메인 지식에 기반하여 지정된다. 이는 의도적 설계 선택이다: 전이의 강도는 (adaTT 친화도를 통해) 학습되지만, 방향은 비즈니스 로직에 의해 고정되어 추가적인 해석 가능성 계층을 제공한다.

3.8 본질적 설명 가능성

본 연구의 핵심 주장은 이종 전문가 구조가 분석 관점 수준의 구조적 해석 가능성을 제공한다는 것이다 — 게이트 가중치가 각 예측을 명명된 분석 관점(시간 추세, 상품 계층, 인과 경로 등)으로 분해하며, 이는 순전파의 자연스러운 부산물이다. 이것이 Pearl의 인과적 설명은 아니다: 대부분의 전문가는 인과 사다리의 1단계(연관)에서 작동한다. 예외는 Causal 전문가로, NOTEARS DAG을 학습하여 2단계(개입) 추론에 근접한다. Causal 전문가의 게이트 가중치가 높다는 것은 단순한 상관관계가 아니라 구조적 인과관계가 추천에 기여했음을 의미하며, 이는 질적으로 더 강한 형태의 설명이다.

메커니즘. CGC (Customized Gate Control) 모듈은 각 태스크 t에 대해 K개 전문가에 대한 어텐션을 계산한다. Softmax 게이팅: $w_t = \mathrm{softmax}(W_t \cdot h + b_t) \in \mathbb{R}^K$; sigmoid 게이팅: $w_{t,k} = \sigma(\boldsymbol{w}_{t,k} \cdot h) / \sum_j \sigma(\boldsymbol{w}_{t,j} \cdot h)$. 가중치 $w_{t,k}$는 전문가 k가 태스크 t의 예측에 얼마나 기여했는지를 직접 나타낸다.

비즈니스 해석 가능성. 각 전문가 k가 명명된 귀납적 편향을 가지므로 (예: $k =$ "Temporal"은 시계열 패턴, $k =$ "HGCN"은 상품 계층구조), $w_{t,k}$는 추가 해석 없이 비즈니스 의미를 전달한다:

> 예시: 고객 c에 대한 투자 펀드 추천은 다음에 의해 결정된다:
> Temporal (0.35) — 3개월간 소비가 증가 추세
> HGCN (0.28) — 가맹점 카테고리 계층구조상 현재 소비 MCC가 투자 카테고리에 근접
> DeepFM (0.22) — 소득 × 상품보유 상호작용 패턴
> 기타 (0.15)

게이트 가중치가 설명하는 것과 설명하지 못하는 것. 게이트 가중치는 "어떤 분석 관점이 가장 중요했는가"에 답한다 — "왜 이 고객이 이 상품을 살 것인가"에 대한 인과적 답은 아니다. 대부분의 전문가(Temporal, HGCN, LightGCN, DeepFM, PersLay, OT)에서 가중치는 연관적 관련성을 나타낸다. Causal 전문가에 한해서는 높은 가중치가 학습된 DAG 구조의 기여를 신호하여 더 강한 설명적 근거를 제공한다. 이는 솔직한 중간 지점이다: SHAP의 피처 수준 귀인보다 풍부하지만, 완전한 반사실적 추론에는 미치지 못한다.

사후적 방법과의 비교. SHAP과 LIME은 피처 수준에서 작동하여 ("feature_237이 0.12 기여"), 피처 귀인을 비즈니

스 서사로 변환하는 추가 매핑 단계를 필요로 한다. 또한 LIME의 국소 선형 근사는 불안정한 것으로 입증되었다 — 작은 입력 변동이 설명을 극적으로 변화시킬 수 있다 [34]. 반면, 게이트 가중치는 입력의 결정론적 함수이며 입력 변화에 따라 매끄럽게 변화한다.

피처의 이중 역할. 중요한 설계 통찰은 피처가 두 가지 목적을 수행한다는 것이다: (1) AUC에 대한 예측 기여, (2) 추천 사유를 위한 설명 자료. 한계적 예측 기여를 가진 피처(예: TDA 위상 피처가 ΔAUC ≈ 0.01만 추가할 수 있음)도 대체 불가능한 설명 어휘를 제공한다. TDA의 persistence 값은 내부적으로 거래 패턴의 안정성을 나타내는 신호이며, `interpretation_registry`를 통해 "꾸준한 거래 패턴을 유지하고 계십니다"와 같은 비즈니스 언어로 변환된다. 이러한 설명은 다른 어떤 피처 유형으로도 생성할 수 없다. 이 이중 역할은 본 연구의 다학제적 피처 엔지니어링의 동기이며 어블레이션 연구에서 검증된다.

4 학습 파이프라인

4.1 Config 기반 설계

전체 파이프라인은 2개의 YAML 파일로 제어된다: `pipeline.yaml` (모델, 학습, 배포 설정) 및 `feature_groups.yaml` (피처 생성, 전문가 라우팅). 새로운 데이터셋, 태스크, 전문가 추가는 설정 변경만으로 가능하다.

4.2 데이터 처리

확장성을 위한 pandas-free 데이터 엔지니어링 원칙에 따라, 파이프라인은 계층적 백엔드 전략을 사용한다: 생성기 피팅/변환을 위한 cuDF (GPU 컬럼형), SQL 기반 집계 및 I/O를 위한 DuckDB [33] (CPU 컬럼형, 디스크 스필), 학습 텐서로의 무복사 parquet 로딩을 위한 PyArrow. pandas는 10K 행 이하의 데이터셋에 대한 최후 수단으로만 사용된다.

이 백엔드 선택은 실용적 함의를 가진다: DuckDB는 4GB 메모리 제한으로 100만 행 데이터셋을 처리하며 자동으로 디스크로 스필하여 범용 하드웨어에서의 처리를 가능하게 한다. cuDF는 생성기 피팅(GMM, HMM, Mamba)을 GPU에서 가속하여, Phase 0 피처 엔지니어링을 30분(pandas)에서 8분으로 단축한다.

4.3 데이터 리키지 방지

데이터 리키지는 피처와 레이블이 별도 단계에서 처리되는 다단계 파이프라인에서 만연한 위험이다. 3가지 구조적 안전장치를 구현한다:

1. 생성기 레이블 제외: 피처 생성기(GMM, model-derived 등)는 모든 레이블 컬럼을 입력에서 자동 제외한다. 이 안전장치 없이 생성된 피처에서 XGBoost AUC 1.0이 관측되었다 — 생성기가 레이블 정보를 피처에 직접 인코딩한 것이다.
2. 갭이 있는 시간 분할: 설정 가능한 `gap_days` 파라미터가 학습과 검증 윈도우 간의 시간적 중첩을 방지한다. 횡단면(단일 스냅샷) 데이터의 경우, 시스템이 자동 감지하여 무작위 분할로 폴백한다.
3. 학습 전용 스케일러 피팅: StandardScaler는 학습 분할에서만 피팅되며, 검증 및 테스트 데이터는 학습 통계를 사용하여 변환된다.
4. LeakageValidator: 학습 전 검사로 모든 피처와 모든 레이블 간 피어슨 상관관계를 계산한다(효율성을 위해 50K 부표본 사용). 0.95를 초과하는 상관관계는 경고를 트리거하고 조사를 유도한다.

5 실험

5.1 벤치마크 데이터

Synthetic Data Vault 프레임워크 [30] 와 조건부 생성적 접근법 [40] 에서 영감을 받되, 제어 가능한 난이도를 위한 새로운 분산 예산 메커니즘을 갖춘 4계층 생성 모델을 사용하여 100만 고객 합성 벤치마크를 구축한다:

1. 잠재 페르소나: 5D 연속 잠재 벡터를 가진 6개 GMM 피팅 페르소나(70% 페르소나 조건부, 30% 독립 잡음).
2. Gaussian Copula 인구통계: 현실적 결합 분포를 보존하는 상관된 인구통계 변수 [30].
3. 벡터화된 거래: LIST 컬럼으로서의 고객별 거래 시퀀스.
4. 분산 예산 레이블: 각 레이블의 예측 가능성은 $\text{logit} = \sqrt{f_{\text{obs}}} \cdot z_{\text{obs}} + \sqrt{f_{\text{lat}}} \cdot z_{\text{lat}} + \sqrt{f_{\text{noise}}} \cdot \varepsilon$으로 제어되며, 사후적 레이블 잡음 뒤집기를 동반한다.

벤치마크는 세 차례 반복을 거쳤다. v2는 페르소나와 무관한 균등 무작위 MCC 코드와 고정된 거래 금액(has_nba 양성률 3%)을 사용하여, MCC 의존 태스크에서 거의 무작위에 가까운 레이블을 산출하였다. v3는 페르소나 가중

난이도	레이블	f_{obs}	f_{noise}	XGB AUC
Easy	segment	determ.	–	0.95–1.0
Core	has_nba, churn_signal	0.04	0.68	0.58–0.65
Hard	will_acquire_*	0.03	0.72	0.50–0.56
V.Hard	next_mcc, top_mcc_shift	0.02	0.78	0.50–0.51

Table 7: 레이블 난이도별 분산 예산. XGB AUC 상한이 난이도 제어를 검증한다.

MCC 분포(4–5배 부스트)와 시간적 점착성(30%), 페르소나별 거래 금액, 분위수 기반 spend_level 경계를 도입하였으나, 취득 태스크 레이블 분포는 여전히 거의 균등하였다. v4(본 논문에서 보고)는 페르소나 MCC 선호도를 더욱 강화하고(8–12배 부스트), 시간적 점착성을 60%로 높이며, 취득률을 상향 조정(has_nba 40%, 상품별 8–12%)하고, top_mcc_shift 감지 윈도우를 30 거래로 확대하여 — 14개 전체 태스크에서 의미 있는 클래스 분포를 생성한다.

5.2 실험 설정

어블레이션은 각 전문가가 서로 다른 태스크 유형에 대해 고유한 "왜"를 제공하는지를 검증한다 — 이종 전문가가 단순한 성능 트릭이 아니라 다면적 설득을 위한 구조적 요건임을 확인한다.

- 데이터: 100만 고객, 350개 피처(전체, Phase 0 v3/v4), 14개 태스크.
- 하드웨어: NVIDIA RTX 4070 (12GB) 로컬; AWS g4dn.xlarge Spot (T4 16GB) 클라우드.
- 학습: 10 에포크 (단일 페이즈), 배치 4096, lr 0.008 (shared-bottom: lr 0.003, 배치 2048), FP32, 조기 종료 없음.
- 지표: 평가 지표는 각 태스크의 production 목적에 맞추어 선택하였다. 이진 분류는 AUC(임계값 비의존적, 불균형 강건)를 사용한다. 분류 멀티클래스(segment_prediction, 4개 클래스)는 F1-macro를 사용한다. 추천 멀티클래스(nba_primary — 7개 상품 그룹, next_mcc — top-50 MCC)는 NDCG@K 및 top-K accuracy [16] 를 사용하여 표준 추천 시스템 평가 관행을 따른다. 회귀는 MAE를 사용한다. 지표는 태스크 유형별로 보고하며, 14개 전체 태스크에 걸친 단일 전역 평균은 사용하지 않는다 — 태스크 유형 간 지표 의미가 상이하기 때문이다.

5.3 피처 + 전문가 결합 어블레이션 (RQ1 + RQ2)

5.4 태스크 × 구조 교차 어블레이션 (RQ3)

6개 구조 변형을 비교한다: shared-bottom (PLE/adaTT 없음), PLE-softmax, PLE-sigmoid, adaTT 단독, PLE-softmax+adaTT, PLE-sigmoid+adaTT. 모든 변형은 게이트 유형 간 수렴 행동 차이를 평가하기 위해 7개 이종 전문가 바스켓 전체와 10 에포크를 사용한다.

시나리오	평균 AUC	평균 F1m †	평균 MAE	Val Loss
베이스라인				
DeepFM + 기본 피처	0.5632	0.4428	0.1541	30.56
DeepFM + 전체 피처	0.5659	0.3675	0.1553	31.00
Full (7 전문가)	0.5470	0.4136	0.1551	30.96
상향식: DeepFM + 단일 생성기				
DeepFM + TDA	0.5746	0.3374	0.1529	30.84
DeepFM + LightGCN	0.5738	0.3859	0.1462	30.61
DeepFM + HGCN	0.5697	0.2988	0.1514	31.07
DeepFM + Causal	0.5640	0.3340	0.1517	30.92
DeepFM + Temporal	0.5507	0.2958	0.1618	31.28
DeepFM + GMM	0.5356	0.3300	0.1725	31.25
DeepFM + Model-derived	0.5000	0.3118	0.1719	31.45
DeepFM + OT	0.4980	0.2606	0.1715	31.62
하향식: Full에서 전문가 1개 제거				
Full − Temporal	0.5753	0.2570	0.1486	31.09
Full − TDA	0.5709	0.3334	0.1439	31.10
Full − Causal	0.5641	0.3256	0.1547	30.99
Full − OT	0.5633	0.2911	0.1549	31.32
Full − LightGCN	0.5298	0.2279	0.1692	31.89
Full − HGCN	0.4992	0.2755	0.1715	31.54

Table 8: 피처 + 전문가 결합 어블레이션. 상향식은 DeepFM 베이스라인에 생성기 1개를 추가하고, 하향식은 7-전문가 전체 모델에서 전문가 1개를 제거한다. AUC 내림차순 정렬. † 평균 F1m은 segment_prediction(F1-macro)만 포함; nba_primary와 next_mcc는 태스크별 보고에서 NDCG@3/Acc@3 사용.

변형	Val Loss	평균 AUC	평균 F1m †	평균 MAE
Shared Bottom	9.978	0.5726	0.4931	0.1246
PLE Softmax	8.572	0.5684	0.3074	0.1275
PLE Sigmoid	7.616	0.5771	0.4594	0.1246
adaTT 단독	28.40	0.5765	0.4890	0.1255
PLE Softmax + adaTT	–	0.5693	–	–
PLE Sigmoid + adaTT	–	0.5746	–	–

Table 9: 구조 어블레이션: 게이트 유형과 adaTT가 수렴 및 태스크 성능에 미치는 영향. v3는 uncertainty weighting을 adaTT 이전에 순차 적용. †평균 F1m은 segment_prediction(F1-macro)만 포함; nba_primary와 next_mcc는 태스크별 보고에서 NDCG@3/Acc@3 사용.

5.5 우아한 성능 저하 (RQ4)

전체 모델에서 각 전문가를 개별적으로 제거했을 때 성능이 얼마나 저하되는지 평가한다. 우아하게 성능이 저하되는 시스템은 단일 구성 요소가 제거되어도 치명적 실패가 아닌 완만하고 예측 가능한 성능 하락을 보여야 한다.

제거된 전문가	ΔAUC	해석
Temporal	+0.0283	부정적 전이 (negative transfer)
TDA	+0.0238	부정적 전이 (negative transfer)
Causal	+0.0170	부정적 전이 (negative transfer)
OT	+0.0163	부정적 전이 (negative transfer)
LightGCN	−0.0173	유익한 기여
HGCN	−0.0478	구조적 핵심 전문가

Table 10: 우아한 성능 저하: 전체 모델(AUC 0.5470)에서 각 전문가 제거 시 AUC 변화. 양수 ΔAUC는 해당 전문가 제거 시 성능 향상(negative transfer), 음수는 성능 하락(필수 기여)을 나타낸다.

5.6 설명 가능성 분석 (RQ5)

Sigmoid CGC 게이트는 희소하고 해석 가능한 라우팅 가중치를 생성한다: 각 전문가는 다른 전문가와 독립적으로 비음수 가중치를 받으므로, 태스크별 "어떤 전문가가 얼마나 기여했는지"를 직접 귀인할 수 있다. 정규화 분모를 통해 가중치가 결합되는 softmax 게이트와 달리, sigmoid 가중치는 태스크가 여러 전문가를 동시에 강하게 활성화하거나 하나만 남기고 모두 억제하는 것을 허용한다. 14개 전체 태스크에 걸쳐 태스크별 게이트 가중치 분포를 조사하여 (a) 어떤 전문가가 어떤 태스크 유형을 지배하는지, (b) 학습된 라우팅이 도메인 직관과 일치하는지(예: 이탈 예측에서 시계열 전문가의 높은 가중치, 개입 민감 태스크에서 인과 전문가의 높은 가중치) 확인한다.

5.7 게이트 엔트로피 분석 (RQ6: 라우팅 붕괴가 발생하는가?)

함수 공간 붕괴(이종 전문가에 의해 구조적으로 방지됨)를 넘어, CGC 게이트 가중치가 단일 전문가에 집중될 때 라우팅 붕괴가 발생할 수 있다. 태스크별 게이트 엔트로피를 측정한다:

$$H_t = -\sum_k w_{t,k} \log w_{t,k}$$

여기서 $w_{t,k}$는 태스크 t에 대한 전문가 k의 게이트 가중치이다. 최대 엔트로피 $\log K$ (K=7 전문가, $\log 7 \approx 1.95$)는 균일한 전문가 활용을 나타내며, 0에 가까운 엔트로피는 라우팅 붕괴를 나타낸다.

14개 전체 태스크에 걸쳐 softmax와 sigmoid CGC 게이트 간의 게이트 엔트로피를 비교하며, 평균 엔트로피, 최소 엔트로피(최악의 태스크), 전문가 활용률($w > 0.05$인 전문가 비율)을 보고한다.

게이트 유형	평균 H_t	최소 H_t	활용률 ($w > 0.05$)
Softmax CGC	–	–	–
Sigmoid CGC	–	–	–

Table 11: 게이트 엔트로피 비교. 높은 엔트로피와 활용률은 붕괴 없는 건전한 전문가 라우팅을 나타낸다.

6 논의

6.1 주요 발견 요약

어블레이션 실험에서 다음의 주요 발견을 도출하였다.

TDA와 LightGCN이 가장 큰 AUC 기여를 보인다. 상향식 어블레이션에서 TDA(+0.011)와 LightGCN(+0.027)이 DeepFM 기본 대비 가장 큰 단독 기여를 나타냈다. 두 전문가는 각각 위상적 피처 공간 구조와 상품 그래프 연결성이라는 서로 다른 귀납적 편향을 제공한다.

Temporal은 합성 시계열 한계로 negative transfer를 유발한다. 상향식에서 Temporal 추가 시 AUC가 0.5507로 낮고, 하향식에서 Temporal 제거 시 AUC가 0.5753으로 오히려 +0.0283 상승한다. 이는 합성 시계열 데이터의 분포적 한계에서 기인한다: v2는 페르소나와 무관한 균등 무

작위 MCC 코드를 사용하여 시간적 신호가 전혀 없었으며, v3의 시간적 점착성을 가진 페르소나 가중 MCC 분포가 이 negative transfer를 부분적으로 완화할 수 있다. 그럼에도 불구하고, Temporal 전문가의 기여 패턴은 실거래 데이터에서 이진 태스크에 대한 진정한 행동 시퀀스 신호가 존재할 경우 실질적으로 변화할 것으로 예상된다.

HGCN과 LightGCN은 구조적 필수 전문가이다. 하향식에서 이 두 전문가 제거 시 AUC가 각각 −0.0478, −0.0173으로 급락하여, 상품 계층구조 및 그래프 연결성 신호가 전체 모델의 핵심 기여임을 확인하였다.

Sigmoid 게이팅이 Softmax보다 우수하다. PLE Sigmoid(AUC 0.5771)가 PLE Softmax(AUC 0.5684)보다 +0.009 높으며, Softmax는 이종 전문가 간 경쟁적 억제로 인해 F1m이 0.3074로 현저히 낮다. 이는 정규화 분모 없이 독립적으로 가중치를 할당하는 sigmoid의 구조적 이점을 확인한다.

adaTT는 uncertainty weighting과 순차 적용이 필요하다. adaTT 단독(AUC 0.5765)은 PLE Sigmoid보다 근소하게 낮다. v3는 uncertainty weighting을 adaTT 이전에 순차 적용한다(either/or 대체가 아님). PLE Sigmoid + adaTT v3(AUC 0.5746)는 v2(0.5605) 대비 +0.014 향상을 보인다. Epoch 6에서 최고 AUC 0.5786을 기록하여 sigmoid 단독 기준선을 초과했으나, freeze 이후 감소했다 — freeze_epoch을 늦추거나 학습을 연장하면 개선될 가능성이 있다.

6.2 실용적 함의

자원 제약 환경에서의 개발. 본 시스템은 전용 ML 인프라 예산 없이, 단일 데스크톱 GPU에서, AI 개발 에이전트의 지원을 받는 3인 팀에 의해 구축되었다. 이는 복잡한 멀티태스크 추천 시스템이 더 이상 대규모 ML 팀과 GPU 클러스터를 보유한 조직만의 전유물이 아님을 입증한다. 핵심 동인은: (1) 코드 변경을 최소화하는 config 기반 아키텍처, (2) 인간의 아키텍처적 지도 하에 병렬 구현 태스크를 처리하는 AI 에이전트, (3) 파라미터 규모가 아닌 구조적 편향을 통해 표현력을 달성하는 이종 전문가 설계, (4) GPU 서빙 비용을 제거하는 지식 증류.

프로덕션 ML에서 공격보다 수비. 금융 추천 서비스에서는 AUC를 더 높이는 것보다 운영 임계치 이상을 유지하는 것이 훨씬 중요하다. 이종 전문가 설계는 이러한 수비적 자세를 직접 지원한다: 우아한 성능 저하(어블레이션에서 단일 전문가가 단일 실패점이 아님을 확인), 드리프트 감지 시 자동 재학습 트리거, 배포 전 수동 승인을 요구하는 champion-challenger 게이트 등이 그것이다. 이 아키텍처는 더 좋아지는 것보다 나빠지지 않는 것을 우선시하며, 이는 모델리스크관리와 운영 회복력을 강조하는 금융 규제기관의 관점과 일치한다.

피처 엔지니어링 철학. 본 연구에서 도출되는 심층적 교훈은 무엇을 관찰할 것인가가 어떻게 모델링할 것인가보다 중요하다는 점이다. 이종 전문가 아키텍처가 효과적인 것은 아키텍처의 새로움만이 아니라, 각 전문가가 고객에 대한 특정 질문을 묻는 피처와 짝을 이루기 때문이다: “소비가 반감기를 가지고 감쇄하는가?” (화학 반응속도론), “상품 채택이 전염처럼 확산되는가?” (SIR 역학), “소득이 항상적인가 일시적인가?” (Friedman 항상소득가설 [10]). 모델은 단지 이러한 질문에 대한 답을 결합할 뿐이다. 질문이 기존 통계 수준에 머물면 — 평균, 분산, 추세 — 아무리 정교한 아키텍처라도 고객 행동의 구조적 복잡성을 포착할 수 없다. 이는 종종 전처리로 취급되는 다학제적 피처 엔지니어링이 일급 아키텍처 설계 결정으로 격상될 자격이 있으며, 각 피처 그룹을 소비할 전문가 유형과 공동 설계되어야 함을 시사한다.

금융 분야를 넘어선 일반화 가능성. 본 연구는 금융 상품 추천을 대상으로 하지만, 기저 원리 — 이종 전문가를 통해 단일 사용자를 다수의 관점에서 동시에 이해하는 것 — 는 다면적 사용자 모델링이 필요한 모든 도메인에 적용 가능하다. 의료(진단 + 치료 + 위험 + 생활양식), 교육(지식 수준 + 학습 스타일 + 참여도 + 진로), 보험(위험 평가 + 상품 적합성 + 보험금 예측 + 유지) 모두 구조적으로 유사한 과제에 직면한다: 동일 개인에 대한 다수의 상호 의존적 예측 태스크로, 서로 다른 분석적 렌즈가 서로 다른 측면을 포착한다. 이종 전문가 PLE 패턴은 이러한 도메인으로 일반화될 것으로 기대하며, 도메인별 전문가 유형이 금융 전문가를 대체하되 붕괴 저항성과 본질적 설명 가능성의 구조적 이점은 유지될 것이다.

설계 반복에서 얻은 교훈. 최종 아키텍처는 반복적인 시도와 기각을 거쳐 도출되었다. 첫 번째 후보인 Black-Litterman 베이지안 모델 결합은 혼합된 사후분포가 개별 모델의 기여도를 불투명하게 만들어, 프로젝트 전체를 이끄는 설명 가능성 요건에 부합하지 못해 기각되었다. 두 번째 후보인 N-모델 앙상블은 N배의 관리 부담으로 기각되었다. 이러한 실패가 핵심적 리프레이밍으로 이어졌다: 전문가를 모델 밖에서 결합하는 것이 아니라 단일 모델 안에서 결합하는 것.

어블레이션 과정에서 softmax CGC 게이트가 비수렴 val_loss를 보였고(Phase 2에서 3.702로 고정), shared-bottom이 역설적으로 PLE보다 우수한 성능을 보였다. 조사 과정에서 NeurIPS 2024 sigmoid 게이트 논문 [28] 을 발견하였고, 이를 통해 softmax 경쟁이 이종 전문가에게 해로운 이유를 설명할 수 있었다.

특히 교훈적인 실패 사례가 있다: 설정 버그로 인해 `use_ple=false`가 7개 전문가 바스켓을 단일 MLP로 축소시켜, 24개 어블레이션 시나리오 전체가 동일한 AUC(0.913)를 산출하였다. 이는 체계적 결과 비교를 통해서만 발견되었으며, 어블레이션 결과는 결론 도출 전에 반드시 예상 변동량 대비 검증되어야 한다는 원칙을 재확인시켰다.

인프라 선택. 금융기관은 ML 인프라 필요에서 빅테크와 근본적으로 다르다. 빅테크는 수십 개 팀에 걸쳐 수백 대의 GPU를 운영하며 시간별 재학습 주기를 가져, Kubernetes 기반 GPU 스케줄러(Kubeflow)가 정당화된다. 금융기관은 일반적으로 일 주 단위로 모델을 학습하며, 프로덕션 모델이 10개 미만이어서 전용 GPU 클러스터는 과잉 투자가 된다. 본 연구의 SageMaker + Lambda 서버리스 아키텍처는 이 현실에 부합한다: GPU 리소스는 학습 시 온디맨드로 프로비저닝되고(스팟 인스턴스 60–70% 할인) 완료 즉시 해제되며, 서빙은 지식 증류를 통한 LGBM의 CPU 전용 Lambda 함수에서 실행된다(동반 논문에서 상세 설명).

운영 단순성. config 기반 설계(2개의 YAML 파일이 전체 파이프라인을 제어)는 1–2명의 ML 엔지니어로 시스템 운영을 가능하게 한다. 새로운 상품 카테고리, 태스크, 피처 그룹의 추가는 코드 수정이 아닌 설정 변경만으로 가능하다. 이는 각 모델이 자체 학습 파이프라인, 서빙 엔드포인트, 모니터링 대시보드를 가진 별도 관리 포인트인 모델 앙상블 접근법과 대비된다.

6.3 한계

- 합성 벤치마크 한계: 100만 고객 벤치마크는 페르소나 기반 MCC 분포, 시간대별 가중치, 페르소나별 거래 금액을 갖춘 4계층 생성 모델을 사용한다. 이러한 보정에도 불구하고, 이진 태스크 신호(has_nba, churn_signal, will_acquire_*)는 거래 행동이 아닌 인구통계 및 상품 보유 피처에서 주로 도출되어, 모델 용량이나 학습 기간과 무관하게 해당 태스크의 성능 상한을 제한한다. MCC 패턴에 의존하는 다중 분류 및 회귀 태스크(next_mcc, mcc_diversity_trend)는 페르소나 가중 MCC 생성의 혜택을 받지만, 실제 가맹점 친화도와 계절 패턴의 부재로 여전히 제약을 받는다. 진정한 행동 신호가 있는 프로덕션 데이터에 아키텍처를 배포할 경우 AUC의 유의미한 향상이 기대된다.
- 단일 GPU 학습: 현재 구현은 단일 GPU에서 실행된다. DDP (DistributedDataParallel) 지원이 아키텍처적으로 설계되었으나 아직 실험적으로 검증되지 않았다. 본 연구에서 다룬 어블레이션 시나리오에서는 단일 GPU 학습이 허용 가능한 시간 내에 완료된다.
- FP32 학습: 이종 전문가의 수학적 의미를 보존하기 위해 혼합 정밀도(FP16) 대신 FP32를 선택하였다. 온프렘의 ODE 기반 LNN 동역학, 비활성화 없는 HGCN 선형 출력, Softplus TDA 가중치는 동질적 MLP보다 중간 활성값 범위가 넓어 AMP에서 FP16 오버플로를 유발한다. FP32는 약 1.5배 느린 학습 시간을 대가로 이 불안정성을 완전히 제거한다.
- LLM 의존성: 추천 사유 생성이 LLM 추론에 의존하여 지연 시간과 비용 트레이드오프가 발생한다(동반 논문에서 상세 설명).

6.4 향후 과제: 스케일 확장 고려사항

현재 아키텍처는 의도적으로 경량 설계되었다 — 각 전문가는 파라미터를 확장하는 대신 소형 도메인 특화 구조(예: DeepFM의 2계층 MLP, HGCN의 사전 계산 임베딩)를 사용한다. 이는 단순한 자원 제약이 아닌 의도적 설계 선택이다: 구조적 귀납적 편향이 순수 파라미터 수를 대체한다.

전용 GPU 인프라를 갖춘 대형 기관으로 확장 시, 자연스러운 진행 순서는 다음과 같다:

- 데이터 풍부화 — 더 긴 거래 이력, 더 넓은 상품 범위, 더 풍부한 상호작용 신호 — 를 모델 용량 증가보다 우선;
- 전문가별 입력 차원 확장 — 각 전문가의 특화된 귀납적 편향에 공급되는 피처 그룹 확대;
- 전문가 깊이/폭 확장 — 개별 전문가 내부 레이어 추가, 특히 Temporal(더 긴 시퀀스 모델링)과 HGCN(더 깊은 계층 인코딩);
- DDP를 통한 멀티 GPU 학습(아키텍처적으로 지원되나 아직 미검증).

주목할 점은 전문가 바스켓 크기 확장(더 많은 전문가 유형 추가)보다 개별 전문가 용량 확장이 더 유망하다는 것이다. 이종 설계가 이미 금융 행동에 관련된 주요 수학적 관점을 포괄하고 있기 때문이다.

7 결론

본 연구에서는 금융 상품 추천을 위한 멀티태스크 학습 아키텍처인 이종 전문가 PLE를 제안하였다. 이는 인간의 행동을 단순히 예측하는 것이 아니라 인간을 설득하는 근본적 요건을 다룬다.

7개의 구조적으로 상이한 전문가를 PLE의 공유 바스켓 내에서 구성함으로써, 세 가지 특성을 동시에 달성한다: (1) 하드웨어 제약 하에서의 파라미터 효율적 표현력, (2) 비즈니스 해석 가능한 게이트 가중치를 통한 본질적 설명 가능성, (3) 포괄적 어블레이션을 통해 검증된 우아한 성능 저하.

핵심 통찰은 설명의 질이 사후적 귀인 방법이 아닌 모델의 내부 구조에 의존한다는 것이다. 두 축 분해(금융 DNA × 데이터 모달리티)는 모든 설계 결정 — 어떤 전문가를 구축할 것인가, 어떤 피처를 엔지니어링할 것인가, 어떤 태스크를 그룹화할 것인가 — 이 원칙적 분석 프레임워크로 환원됨을 보장한다. 각 전문가가 명명된 귀납적 편향을 담을 때 — 시간적 역학, 상품 계층구조, 인과 경로 — 게이팅 메커니즘이 곧 설명이다.

어블레이션을 통해 TDA와 LightGCN이 가장 큰 단독 AUC 기여(각각 +0.028, +0.027)를 보이고, HGCN/LightGCN 제거 시 급격한 성능 저하가 발생함을 확인하였다(ΔAUC −0.048, −0.017). PLE Sigmoid 게이팅(AUC 0.5771)이 Softmax(0.5684) 대비 +0.009 우위를 보여, 이종 전문가 환경에서의 비경쟁적 라우팅 설계가 중요함을 입증하였다.

아키텍처, 벤치마크 데이터, 어블레이션 프레임워크는 연구 커뮤니티의 재현 및 확장을 위해 오픈소스로 공개된다. 동반 논문에서는 하류 파이프라인을 다룬다: LGBM [17]으로의 지식 증류 [15], 다중 에이전트 추천 사유 생성, 한국 금융감독원 및 EU AI Act 요건에 대한 규제 준수 매핑.

부록

A. 설정 스키마

전체 시스템은 2개의 YAML 설정 파일로 제어된다: `pipeline.yaml` (모델 아키텍처, 학습 하이퍼파라미터, 태스크 정의, AWS 배포 설정) 및 `feature_groups.yaml` (피처 그룹 정의, 생성기 파라미터, 전문가 라우팅 규칙). 전체 설정 파일은 동반 저장소에서 제공된다.

B. 어블레이션 시나리오 정의

24개 어블레이션 시나리오는 두 단계로 구성된다:

Phase 1 — 피처 + 전문가 결합 어블레이션 (18개 시나리오): 기준선(기본 피처만을 사용한 DeepFM 단독), 전체 피처를 사용한 DeepFM, 전체 모델, 8개 상향식 시나리오 (DeepFM + 대응 피처를 가진 1개 전문가), 6개 하향식 시나리오(전체 모델에서 1개 전문가-피처 쌍 제거).

Phase 2 — 태스크 × 구조 교차 어블레이션 (6개 시나리오): 6개 구조 변형 — shared-bottom (PLE/adaTT 없음), PLE-softmax, PLE-sigmoid, adaTT 단독, PLE-softmax+adaTT, PLE-sigmoid+adaTT — 모두 14개 태스크 전체와 7개 이종 전문가를 사용하며 10 에포크로 수행.

C. 벤치마크 데이터 생성

합성 벤치마크는 4계층 생성 모델을 사용한다: (1) 5D 연속 잠재 벡터를 가진 6성분 GMM을 통한 잠재 페르소나 (70% 페르소나 조건부, 30% 독립 노이즈); (2) 현실적 상관관계를 보존하는 Gaussian Copula 인구통계; (3) LIST 컬럼으로서의 벡터화된 거래 시퀀스; (4) 사후 노이즈 플리핑(6–8%)을 갖춘 분산 예산 레이블. 시드=42로 재현 가능성을 보장한다. 전체 생성 코드는 동반 저장소에서 제공된다.

D. FP32 학습 결정

온프렘과 동일한 활성화 함수를 사용하는 이종 전문가(ODE 기반 LNN, 선형 HGCN 출력, Softplus TDA 가중치)는 동질적 MLP보다 중간 활성값 범위가 넓다. AMP(FP16)에서 이는 보수적인 GradScaler 설정(init_scale=1024, max_scale=4096)에도 불구하고 에포크 2부터 일관되게 NaN 손실을 유발하는 GradScaler 오버플로로 이어졌다. FP32 학습은 전체 10 에포크 실행에서 NaN 배치 0건으로 이 문제를 완전히 제거하며, 약 1.5배 느린 학습 시간이라는 대가를 수반한다. 이 트레이드오프는 각 전문가의 귀납적 편향에 대한 수학적 의미를 보존하며, 이는 이종 아키텍처의 핵심 설계 원리이다.

E. 구조적 동형사상 검증

학제 간 피처 엔지니어링이 "엄밀한 동형사상이 아닌 그럴듯한 유비"일 수 있다는 우려에 답하기 위해, 지배 방정식을 나란히 제시한다:

화학 반응속도론 -> 소비 활성화: Arrhenius: $k = Ae^{-E_a/RT}$ 여기서 E_a = 활성화 에너지. 소비: $p_{\text{reactivate}} = Ae^{-E_{\text{threshold}}/S}$ 여기서 S = 자극 강도. 둘 다 에너지 장벽과 외부 구동력의 함수로서 상태 전이 확률을 기술한다.

SIR -> 상품 채택: 역학: $d\frac{I}{d}t = \beta SI - \gamma I$ 채택: $d\frac{A}{d}t = \beta_{\text{exposure}} \cdot U \cdot A - \gamma_{\text{churn}} \cdot A$ 여기서 U = 미채택 고객, A = 채택 고객, β = 접촉/노출률. 구획 역학은 동일하며, 변수명만 바뀐다.

저자 기여

정선규 (PM / 총괄 설계자 / 데이터 사이언티스트): 프로젝트 방향 구상, 이종 전문가 아키텍처 및 2축 분해 프레임워크 설계, 구조적 동형사상에 기반한 다학제적 피처 엔지니어링 방법론 선정, 태스크 그룹 및 규제 준수 매핑 정의, AI 활용 개발 방법론 주도, 논문 작성. 전체 기술 리더십 및 스크럼 기반 신속 피드백 조율.

심은철: 데이터 인제스천 파이프라인, 피처 엔지니어링 구현, 피처 비즈니스 역매핑, 벡터 데이터베이스 파이프라인 관리. 청년 자문위원(서포터즈) 자격으로 참여.

김영찬: 모델 학습, 수학적 검증, 지식증류 구현. 청년 자문위원(서포터즈) 자격으로 참여.

전체 개발 과정은 스크럼 스프린트와 신속 피드백 사이클로 진행되었다.

연구비

본 연구는 외부 연구비, 보조금, 기관 인프라 지원을 일절 받지 않았다. AI 개발 도구(Claude Code, Gemini, Cursor 구독료), 하드웨어 부속기기, 모바일 데이터 통신비, AWS SageMaker 클라우드 학습(Spot 인스턴스), S3 스토리지, 운영 경비 등 모든 비용은 전적으로 제1저자의 개인 자금으로 충당하였다. 개발은 데스크톱 GPU 1대(NVIDIA RTX 4070, 12GB VRAM)로 냉방이 부적절한 재활용 작업 공간에서 수행되었으며, 기관 네트워크 지원이나 기관 클라우드 컴퓨팅 할당 없이 진행되었다. 데이터 수집은 Spark/Impala 전환이 거부된 레거시 HIVE 환경에서 I/O 병목을 극복하기 위한 병렬 쿼리 로직을 자체 설계하여 수행하였다.

감사의 말

항상 업계 상황과 마케팅 관점에서 좋은 아이디어를 제공해준 김연진에게 감사를 표한다.

불철주야 휴일도 저녁도 없이 개발에 헌신해준 두 명의 엔지니어 심은철, 김영찬에게 깊은 감사를 표한다. 정식 고용

이나 보상 없이도 프로젝트에 전력을 다해준 이들의 헌신이 이 시스템의 완성을 가능하게 했다.

마지막으로, 기관 지원 없이 3명의 소규모 팀으로 이 연구를 현실화할 수 있게 해준 AI 도구들에 감사를 표한다. Gemini는 아이디에이션과 설계 방향성 논의에서 지칠 줄 모르는 브레인스토밍 파트너였다. Claude Opus와 Sonnet은 아키텍처를 체계적으로 구축하고, 코드를 구현하고, 미묘한 버그를 진단하고, 아이디어를 글로 옮기는 거의 모든 과정에서 우리와 함께했다. Cursor는 병목 없이 효율적으로 작업할 수 있는 개발 환경을 제공해주었다. 한 개인의 상상이 공상으로 끝날 수 있었던 것을, 소수의 인원과 이 도구들의 협업이 현실로 만들어주었다. 아키텍처 설계, 도메인 지식, 실험 설계, 연구 방향은 인간 저자가 주도하였으며, AI 도구들은 이 규모의 작업을 달리 달성할 수 없었을 것을 가능하게 해주었다.

Bibliography

[1] AI21 Labs. 2024. Jamba: A Hybrid Transformer-Mamba Language Model. arXiv preprint arXiv:2403.19887 (2024).

[2] Mathieu Carrière, Frédéric Chazal, Yuichi Ike, Théo Lacombe, Martin Royer, and Yuhei Umeda. 2020. PersLay: A Neural Network Layer for Persistence Diagrams and New Graph Topological Signatures. Journal of Machine Learning Research (2020).

[3] Rich Caruana. 1997. Multitask Learning. Machine Learning 28, 1 (1997), 41–75.

[4] Ines Chami, Rex Ying, Christopher Ré, and Jure Leskovec. 2019. Hyperbolic Graph Convolutional Neural Networks. In Advances in Neural Information Processing Systems (NeurIPS), 2019.

[5] Wei Chen, Yong Liu, and Hao Zhang. 2024. Deep Learning-Powered Financial Product Recommendation System in Banks: Integration of Transformer and Transfer Learning. Journal of Organizational and End User Computing 36, 1 (2024).

[6] Marco Cuturi. 2013. Sinkhorn Distances: Lightspeed Computation of Optimal Transport. In Advances in Neural Information Processing Systems (NeurIPS), 2013.

[7] European Parliament and Council. 2024. Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (AI Act).

[8] William Fedus, Barret Zoph, and Noam Shazeer. 2022. Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity. Journal of Machine Learning Research (2022).

[9] Financial Services Commission (Korea). 2024. Financial Sector AI Guidelines.

[10] Milton Friedman. 1957. A Theory of the Consumption Function. Princeton University Press.

[11] Albert Gu and Tri Dao. 2024. Mamba: Linear-Time Sequence Modeling with Selective State Spaces. (2024).

[12] Huifeng Guo, Ruiming Tang, Yunming Ye, Zhenguo Li, and Xiuqiang He. 2017. DeepFM: A Factorization-Machine based Neural Network for CTR Prediction. In Proceedings of the 26th International Joint Conference on Artificial Intelligence (IJCAI), 2017.

[13] Ramin Hasani, Mathias Lechner, Alexander Amini, and others. 2021. Liquid Time-constant Networks. In Proceedings of the AAAI Conference on Artificial Intelligence, 2021.

[14] Xiangnan He, Kuan Deng, Xiang Wang, Yan Li, Yongdong Zhang, and Meng Wang. 2020. LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation. In Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval, 2020.

[15] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. 2015. Distilling the Knowledge in a Neural Network. In NIPS Deep Learning and Representation Learning Workshop, 2015.

[16] Kalervo Järvelin and Jaana Kekäläinen. 2002. Cumulated gain-based evaluation of IR techniques. ACM Transactions on Information Systems 20, 4 (2002), 422–446.

[17] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. 2017. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. In Advances in Neural Information Processing Systems (NeurIPS), 2017.

[18] Alex Kendall, Yarin Gal, and Roberto Cipolla. 2018. Multi-Task Learning Using Uncertainty

to Weigh Losses for Scene Geometry and Semantics. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2018.

[19] Jiaxin Li and others. 2024. HoME: Hierarchy of Multi-Gate Experts for Multi-Task Learning at Kuaishou. In Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 2024.

[20] Yankai Li and others. 2023. AdaTT: Adaptive Task-to-Task Fusion Network for Multi-task Learning in Recommendations. In Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 2023.

[21] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. 2017. Focal Loss for Dense Object Detection. In Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2017.

[22] Scott M Lundberg and Su-In Lee. 2017. A Unified Approach to Interpreting Model Predictions. In Advances in Neural Information Processing Systems (NeurIPS), 2017.

[23] Jiaqi Ma, Zhe Zhao, Xinyang Yi, Jilin Chen, Lichan Hong, and Ed H Chi. 2018. Modeling Task Relationships in Multi-task Learning with Multi-gate Mixture-of-Experts. In Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2018.

[24] Xiao Ma, Liqin Zhao, Guan Huang, Zhi Wang, Zelin Hu, Xiaoqiang Zhu, and Kun Gai. 2018. Entire Space Multi-Task Model: An Effective Approach for Estimating Post-Click Conversion Rate. In Proceedings of the 41st International ACM SIGIR Conference on Research and Development in Information Retrieval, 2018.

[25] Fernando Martinez-Plumed and others. 2023. Improving the Predictive Accuracy of the Cross-selling of Consumer Loans Using Deep Learning Networks. Annals of Operations Research (2023).

[26] Ali Met, Deniz Korkmaz, and Kerem Tuna. 2024. Product Recommendation System With Machine Learning Algorithms for SME Banking. International Journal of Intelligent Systems 2024, (2024).

[27] National Assembly of Korea. 2024. Act on the Development of Artificial Intelligence and Establishment of Trust (AI Basic Act).

[28] Huy Nguyen and others. 2024. Sigmoid Gating is More Sample Efficient than Softmax Gating in Mixture of Experts. In Advances in Neural Information Processing Systems (NeurIPS), 2024.

[29] Maximilian Nickel and Douwe Kiela. 2017. Poincaré Embeddings for Learning Hierarchical Representations. In Advances in Neural Information Processing Systems (NeurIPS), 2017.

[30] Neha Patki, Roy Wedge, and Kalyan Veeramachaneni. 2016. The Synthetic Data Vault. In IEEE International Conference on Data Science and Advanced Analytics (DSAA), 2016.

[31] Judea Pearl and Dana Mackenzie. 2018. The Book of Why: The New Science of Cause and Effect. Basic Books.

[32] Judea Pearl. 2009. Causality: Models, Reasoning, and Inference (2nd ed.). Cambridge University Press.

[33] Mark Raasveldt and Hannes Mühleisen. 2019. DuckDB: An Embeddable Analytical Database. (2019).

[34] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. 2016. Why Should I Trust You?: Explaining the Predictions of Any Classifier. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016.

[35] Amr Salih and others. 2023. Examining the Limitations of Post-hoc Explainability Methods in Finance. Frontiers in Artificial Intelligence (2023).

[36] Noam Shazeer, Azalia Mirhoseini, Krzysztof Mahdavi, and others. 2017. Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer. (2017).

[37] Xiang-Rong Sheng, Liqin Zhao, Guorui Zhou, Xinyao Ding, Binding Dai, Qiang Luo, Siran Yang, Jingshan Lv, Chi Zhang, Hongbo Deng, and Xiaoqiang Zhu. 2021. STAR: One-pass Single-Arch Multi-task Architecture for Cross-Domain CTR Prediction. In Proceedings of the 30th ACM International Conference on Infor-

mation and Knowledge Management (CIKM), 2021.

[38] Mukund Sundararajan, Ankur Taly, and Qiqi Yan. 2017. Axiomatic Attribution for Deep Networks. In Proceedings of the 34th International Conference on Machine Learning (ICML), 2017.

[39] Hongyan Tang, Junning Liu, Ming Zhao, and Xudong Gong. 2020. Progressive Layered Extraction (PLE): A Novel Multi-Task Learning (MTL) Model for Personalized Recommendations. In Proceedings of the 14th ACM Conference on Recommender Systems (RecSys), 2020.

[40] Lei Xu, Maria Skoularidou, Alfredo Cuesta-Infante, and Kalyan Veeramachaneni. 2019. Modeling Tabular Data using Conditional GAN. In Advances in Neural Information Processing Systems (NeurIPS), 2019.

[41] Hanqing Zeng and others. 2024. Mixture of Weak and Strong Experts on Graphs. In Advances in Neural Information Processing Systems (NeurIPS), 2024.

[42] Zijian Zhang and others. 2024. M3oE: Multi-Domain Multi-Task Mixture-of Experts Recommendation Framework. In Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval, 2024.

[43] Xun Zheng, Bryon Aragam, Pradeep Ravikumar, and Eric P Xing. 2018. DAGs with NO TEARS: Continuous Optimization for Structure Learning. (2018).