

이종 전문가 PLE: 금융 상품 추천을 위한 설명 가능한 멀티태스크 아키텍처

정선규¹, 심은철¹, 김영찬¹

¹Independent Research

교신저자: 정선규 (ORCID: 0009-0005-3291-9112)

초록. 금융 상품 추천은 예측 정확도뿐만 아니라 규제 준수가 가능한 설명 가능성을 요구한다. 기존 멀티태스크 학습(MTL) 접근법(MMoE, PLE)은 2-4개의 동질적 태스크를 대상으로 검증되었으며, 이진·다중클래스·회귀 태스크가 공유 용량을 놓고 경쟁하는 프로덕션 규모의 이종 워크로드로의 확장 가능성은 여전히 미지수이다. 본 연구는 세 가지 기여를 제시한다. **첫째**, 7개의 구조적으로 상이한 전문가 (DeepFM, Temporal Ensemble, Hyperbolic GCN, PersLay, Causal, LightGCN, Optimal Transport)가 공유 바스켓을 이루고 FeatureRouter가 각 전문가에 지정된 피처 그룹을 할당하는 이종 전문가 PLE를 제안한다. 이는 전문가 붕괴에 대한 구조적 보장과 비즈니스 해석 가능한 게이트 가중치를 통한 본질적 설명 가능성을 제공한다. **둘째**, 13개 태스크 벤치마크(이진 7개 + 다중클래스 3개 + 회귀 3개, 100만 고객)에서의 어블레이션 실험을 통해, 본 연구의 손실 수준 태스크 간 전이 메커니즘(내부에서 “adaTT” 약어로 유지하는 TAG + GradNorm 하이브리드로, [22]의 표현 수준 adaTT와는 구별됨)이 이 규모에서 **null 효과**를 보임을 발견하였다: 온프레임 포팅 과정의 5개 구현 버그를 수정한 후, adaTT 유/무의 AUC 차이는 -0.001에 그쳐 단일 seed 측정 노이즈와 구분할 수 없다. 가장 큰 성능 향상은 불확실성 가중치 구현에서 태스크별 손실 가중치가 묵시적으로 무시되던 미묘한 격차를 수정한 것에서 비롯됨을 발견하였다. **셋째**, 손실 수준 전이를 그래디언트 수준 충돌 해소로 대체하는 GradSurgery — 태스크 유형별 그래디언트 투영 방법 — 를 실험하였다. 이는 156개 태스크 쌍 문제를 3개 태스크 유형 그룹 투영으로 축소한다. 그러나 GradSurgery는 retain_graph로 인한 VRAM 오버헤드가 상당하며 PLE 단독 기준선 대비 의미 있는 개선을 보이지 않아 프로덕션에 채택하지 않았다. 어블레이션 결과: softmax 게이팅을 갖춘 PLE가 게이트 변형 중 최고 NDCG@3(0.714)을 달성하였으며, softmax가 이종 환경에서 sigmoid를 능가하여 (동질적 태스크 문헌의 결과를 역전), GradSurgery(AUC 0.673, F1-macro 0.203)와 수정된 adaTT 구현(sigmoid+adaTT AUC 0.672) 모두 기준선 성능을 유지하나 어느 쪽도 개선을 제공하지 않는다. 운영적 동기 — 13개 개별 모델을 단일 MTL 모델로 통합하여 학습·서빙·모니터링을 일원화 — 는 검증되었다: shared-bottom 기준선이 이미 태스크별 XGBoost 상한을 초과하고, PLE는 분류 성능 희생 없이 순위 지표에서 추가적 향상을 제공한다.

키워드: 멀티태스크 학습, Progressive Layered Extraction, Mixture of Experts, 금융 추천, 설명 가능한 AI, 어블레이션 연구

1 서론

1.1 문제 정의

금융 상품 추천은 전자상거래나 콘텐츠 추천과 근본적으로 다르다. 주요 산출물은 확률 점수가 아니라 고객이 수용할 수 있는 이유이다. 세 가지 대상을 설득해야 한다:

- **고객:** “왜 이 상품이 나에게 적합한가?” — 신뢰가 전환으로 이어진다.
- **영업 담당자:** “왜 이 고객에게 이 상품을 추천하는가?” — 영업 근거 제시.
- **규제기관** (한국 금융감독원 [11], EU AI Act [8]): “이 결정은 왜 내려졌는가?” — 규제 준수 의무. 한국의 AI 기본법 [29]은 금융 추천을 잠재적 고영향 AI로 분류한다.

기존 접근법은 이러한 설득 요건에 미흡하다:

- **단일 태스크 모델**은 이탈, 상품 선호도, 고객 생애가치를 동시에 예측할 수 없다 [3].
- **모델 앙상블** (N개 개별 모델)은 관리 부담과 서빙 비용을 배가시키며, “MLP #3이 28% 기여”라는 설명은 비즈니스적 의미를 가지지 못한다.
- **사후적 설명** (SHAP, LIME)은 모델 내부와 분리되어 있고, 서빙 시점에서 계산 비용이 높으며, 입력 변동에 대해 불안정한 것으로 입증되었다 [24, 36, 37].

1.2 핵심 통찰

기존 추천 모델은 “블랙박스 셰이커”로 기능한다 — 피처가 입력되면 확률이 출력되고, 근거는 통계적 상관관계뿐이다.

Pearl [34] 이 주장하듯, 보는 것(연관)과 이해하는 것(인과) 사이에는 근본적 격차가 존재한다. 인간은 상관관계에 의해 설득되지 않으며, 인과적 서사를 요구한다 [33].

멀티태스크 모델의 각 전문가가 서로 다른 종류의 “왜” — 시간적 추세, 계층적 상품 구조, 인과 경로, 협업 필터링 패턴 — 를 포착한다면, 게이팅 메커니즘 자체가 설명이 된다: “이 추천은 주로 소비 추세(Temporal, 35%)와 상품 카테고리 적합성(HGCN, 28%)에 의해 결정되었습니다.”

이것이 본 아키텍처의 핵심 설계 원리이다.

핵심적 인식은 금융 추천이 단일 예측 (“이 고객이 구매할 것인가?”)이 아니라 **하나의 고객을 다양한 관점에서 동시에 전인적으로 이해하는 것**이라는 점이다: 이탈할 것인가? (생애주기). 얼마나 소비할 것인가? (가치). 어떤 상품이 적합한가? (소비). 어떻게 행동하는가? (활동). 각 질문은 서로 다른 분석적 렌즈를 요구한다 — 시계열 분석은 계층적 상품 적합성에 답할 수 없고, 그래프 기반 협업 시그널은 소비 궤적을 예측할 수 없다. 이것이 이중 전문가가 단순한 성능 최적화가 아니라 다면적 고객 이해를 위한 구조적 필수 조건인 이유이다.

이러한 관점은 학계와 규제 양면에서의 광범위한 변화와 맥을 같이한다. Pearl의 인과의 사다리(Ladder of Causation) [33] 는 세 가지 수준을 구분한다: 연관, 개입, 반사실. 대부분의 추천 시스템은 1단계(연관)에서 작동하며, 본 아키텍처 역시 주로 1단계(연관)에서 작동하되, Causal 전문가의 CGC 게이트 가중치가 지배적인 태스크에 한해 2단계(개입)에 근접한다. 규제 프레임워크 — EU AI Act, 한국 금융감독원 가이드라인 및 AI 기본법 — 는 점차 구조적으로 투명한 설명으로의 전환을 요구하고 있다 (규제 분석의 상세 내용은 2.4절 참조).

1.3 기여

1. **구조적 붕괴 보장을 갖춘 이중 공유 전문가 바스켓**: 본 연구에서는 PLE의 동질적 MLP 전문가를 7개의 구조적으로 상이한 전문가(DeepFM, Temporal Ensemble, HGCN, PersLay, Causal, LightGCN, Optimal Transport)로 대체한다. 전문가 크기 [43] 또는 모달리티 [1] 를 변화시킨 기존의 “이중” MoE 연구와 달리, 본 연구는 근본적인 귀납적 편향을 다양화하여 전문가 붕괴에 대한 구조적 보장을 제공한다 — 이는 동질적 MoE/PLE 배포에서 지속적으로 발생하는 실패 모드이다 [21].
2. **FeatureRouter: 이중 아키텍처 × 이중 입력**: 아키텍처 다양성을 넘어, 각 전문가는 전체 1211D 입력이 아닌 지정된 피쳐 그룹만을 수신한다(feature_groups.yaml의

target_experts 필드로 선언, 그룹 단위 라우팅). 이 “이중 아키텍처 × 이중 입력” 설계는 전문가별 불필요한 피쳐를 제거하고(전문가별 차원: 32D-977D), 모델 파라미터를 상당히 감소시킨다 (V1 349-피쳐 스키마 측정값 2.70M; V2 1211-피쳐 스키마 측정은 재실행 후 보고).

3. **본질적 설명 가능성**: 각 전문가가 명명된 수학적 연산(범용 MLP가 아닌)을 인코딩하므로, Customized Gate Control(CGC) 게이트 가중치가 사후적 귀인 방법 없이 직접 비즈니스 해석 가능한 설명을 생성한다.
4. **다학제적 피쳐 엔지니어링**: 11개 학문 분야에서 도출된 피쳐 — 화학 반응속도론(소비 활성화율), 역학 모델링(상품 채택 확산), 범죄학의 일상 활동 이론(거래 규칙성), 파동 간섭(소비 주기성) 등의 비전통적 적용을 포함 — 는 이중 역할을 수행한다: **학습 신호인** 동시에, 고객 대면 설명을 위해 비즈니스 언어로 **역매핑(reverse-map)** 되는 **추천사유 컨텍스트** 역할을 한다.
5. **금융 DNA 태스크 그룹화**: 2축 분해(Financial DNA × 데이터 모달리티)에 정렬된 4개 태스크 그룹(활동, 생애주기, 가치, 소비). 전문가 선택 자체는 CGC 게이트를 통해 태스크 단위 로 수행(13개 독립 라우팅 결정)되며, 태스크 그룹은 라우터를 직접 게이팅하지 않고 사후 해석과를 기반 폴백 계층의 템플릿 선택을 위한 의미론적 구조를 제공한다.
6. **이중 MTL을 위한 게이트 유형 분석**: 13개 태스크 이중 환경(이진 7개 + 다중클래스 3개 + 회귀 3개)에서 softmax가 sigmoid를 능가함을 입증하며, 동질적 태스크 문헌 [30, 41] 의 통념을 역전시킨다. 이 역전은 softmax의 소수 유형 태스크에 대한 보호적 격리에 기인한다.
7. **손실 수준 vs. 그라디언트 수준 전이**: 본 구현의 손실 수준 태스크 간 전이 메커니즘(TAG [10] + GradNorm [6] 하 이브리드로, 내부 “adaTT” 약어를 유지하나 [22] 의 표현 수준 adaTT와는 구별됨 — 4.5절 참조)이 5개 구현 버그 수정 후 13-태스크 규모에서 null 효과를 보임을 확인하였다: adaTT 유/무의 AUC 변화는 -0.001로 단일 seed 측정 노이즈 범위. 초기 드래프트는 -0.019로 보고 하며 당시 알고리즘적 불안정성에 귀인하였으나, 수정 후 측정은 원인을 구현에 위치시킨다(5.4절 표 캡션 참조). GradSurgery(그라디언트 수준, 3개 유형 그룹 투영) 또한 이득을 보이지 않고 retain_graph로 인한 VRAM 오버헤드가 발생하여 프로덕션에 채택하지 않았다.

8. **불확실성 가중치 수정**: 불확실성 가중치 하에서 태스크별 `loss_weight`가 묵시적으로 무시되는 미묘한 구현 격차를 발견하고 수정 — 수정으로 $+0.018$ NDCG@3, $+0.031$ F1-macro 향상, 어떤 아키텍처 변경보다 큰 효과.
9. **포괄적 어블레이션**: Gaussian Copula + 잠재변수 분산 예산을 활용한 재현 가능한 100만 고객 벤치마크에서 23개 시나리오(14개 결합 피처+전문가 + 9개 구조 교차).
10. **Config 기반 파이프라인**: 3개 YAML 파일로 구성된 `split-config(pipeline.yaml` — 공통 모델/학습/종류/AWS 설정, `feature_groups.yaml` — 피처 그룹 라우팅, `configs/datasets/{name}.yaml` — 데이터셋별 태스크/레이블/어블레이션)로 제어되는 엔드투엔드 시스템(피처 엔지니어링 → 학습 → 종류 → 서빙)으로, 1-2명의 ML 엔지니어로 구성된 팀의 배포를 지원한다.
11. **재현 가능한 벤치마크**: 제어된 AUC 상한을 위한 분산 예산 [32]을 갖춘 합성 데이터 생성, XGBoost 기준선 대비 검증, 오픈소스 코드 및 고정 시드 제공.

2 관련 연구

2.1 추천을 위한 멀티태스크 학습

Shared-Bottom [3]에서 MME [25]를 거쳐 PLE [41]로의 발전은 태스크 간 부정적 전이(negative transfer)를 관리하는 정교함의 증가를 반영한다. MME는 공유 전문가 풀에 대한 태스크별 게이팅을 도입하였고, PLE는 점진적 추출(progressive extraction) 구조를 통해 공유 전문가와 태스크 전용 전문가를 더욱 분리하였다. AdaTT [22]는 **표현 수준**에서 적응적 태스크 간 전이(학습된 게이팅으로 expert 출력을 태스크별 융합)로 이를 확장하였다. 한편 Task Affinity Groupings [10]와 적응적 손실 균형 [6]은 표현을 섞지 않고 태스크별 기울기 통계를 이용해 **손실 스칼라**를 조절하는 병렬 계통이며, 본 구현(4.5절)은 이 두 번째 계통을 따른다. 기존 내부 문서와의 연속성을 위해 “adaTT” 약어를 유지하지만, [22]의 표현 수준 메커니즘과 혼동해서는 안 된다.

기타 주목할 만한 MTL 아키텍처로는 ESMM [26](전환율을 위한 전체 공간 모델링), STAR [39](다중 도메인 CTR을 위한 스타 토폴로지), M3oE [44](AutoML 구조 탐색을 통한 다중 도메인 다중 태스크 MoE) 등이 있다.

그러나 모든 기존 MoE/PLE 아키텍처는 **동질적 전문가** — 동일한 아키텍처를 가진 다수의 MLP에 서로 다른 초기화만 적용 — 를 사용한다. 이는 학습된 표현의 다양성을 파라미터 변

이만으로 달성할 수 있는 범위로 제한하며, 잘 알려진 실패 모드인 **전문가 붕괴**를 초래한다.

2.2 Mixture of Experts와 전문가 붕괴 문제

MoE 패러다임 [38]과 그 후속 연구(Switch Transformer [9])는 조건부 계산의 강력함을 입증한다. 그러나 동질적 MoE 아키텍처는 **전문가 붕괴**에 취약한데, 이는 모든 게이트가 단일 전문가로 입력을 라우팅하도록 수렴하여, 사실상 MoE를 shared-bottom 아키텍처로 축소시키는 현상이다. Pinterest Engineering은 자사의 MME 배포가 “모든 태스크가 동일한 단일 전문가를 사용하는 상태로 빈번하게 붕괴하였다”고 보고하였다. Kuaishou의 HoME [21]은 “모든 게이트가 단일 공유 전문가에 더 큰 가중치를 부여하고 다른 공유 전문가를 거의 무시할 때 전문가 붕괴가 발생한다”고 확인하였다.

기존 완화책은 사후적으로 작동한다: 다양한 전문가 표현을 강제하기 위한 Gram-Schmidt 직교화, 출력 분포를 정렬하기 위한 전문가 정규화, 라우팅을 분산시키기 위한 부하 균형 손실 등이 있다. 이들은 증상을 완화하지만, 문제의 구조적 원인을 제거하지는 못한다 — 동질적 전문가는 다양성의 유일한 원천이 무작위 초기화뿐이므로 다르게 특화될 본질적 이유가 없다.

최근 연구에서는 제한적 형태의 이종성이 탐색되었다: Jamba [1]는 LLM용 MoE 내에서 Transformer와 Mamba 레이어를 결합하고(2가지 아키텍처 유형), MOWST [43]는 경량 MLP “약한 전문가”와 GNN “강한 전문가”를 계층적으로 배치한다(2가지 유형, 비대칭 역할). M3oE [44]는 도메인별로 전문가를 분리하지만 각 도메인 내에서는 동일한 MLP 아키텍처를 사용한다. MoE++는 계산 수준의 이종성(zero-compute vs. FFN 전문가)을 도입하지만 아키텍처적 이종성은 아니다.

나아가, 최근 이론적 연구는 표준 softmax 게이팅 메커니즘 자체가 표현 붕괴에 기여함을 입증한다. Nguyen 등 [30]은 MoE 모델에서 sigmoid 게이팅이 softmax 게이팅보다 높은 표본 효율성을 달성함을 증명하였다: softmax의 합이 1이 되는 제약은 전문가 간 불필요한 경쟁을 강제하여, 한 전문가의 가중치를 높이려면 다른 전문가의 가중치를 낮추어야 하므로, 전문가들이 상호 보완적 신호를 제공하는 경우에도 표현 붕괴가 발생한다. Sigmoid 게이팅은 각 전문가의 기여를 독립적으로 평가함으로써 이러한 전문가 간 경쟁을 제거하여, 더 빠른 수렴과 전문가의 더 나은 활용을 달성한다. 이 발견은 전문가가 이종일 때 특히 관련성이 높다: 전문가의 출력이 근본적

으로 다른 스케일과 분포를 가지므로 (예: 쌍곡 임베딩 vs. 지수성 다이어그램), softmax 경쟁은 특히 해로운데 — 시간적 전문가의 가중치를 높이기 위해 위상적 전문가를 억제하는 것은 단순히 중복된 표현이 아닌 대체 불가능한 위상적 신호를 잃는 것을 의미하기 때문이다.

격차: 기존 연구 중 **근본적으로 다른 귀납적 편향**을 가진 전문가들 — 그래프 합성곱, 상태 공간 모델, 위상적 지속성, 인과 DAG 제약, 최적 수송 — 을 공유 전문가 바스켓 내에서 동등한 동료로 구성한 사례는 없다. 전문가 붕괴는 두 가지 형태로 발현된다: (1) 함수 공간 붕괴(function space collapse) — 동질적 전문가가 공유 아키텍처와 그래디언트 역학으로 인해 동일한 함수로 수렴하는 현상; (2) 라우팅 붕괴(routing collapse) — 게이트 가중치가 단일 전문가에 집중되어, 기능적 다양성과 무관하게 다른 전문가를 사실상 비활성화하는 현상. 본 연구의 이중 전문가 설계는 (1)을 구조적으로 방지한다. (2)에 대해서는, 기존 연구 [30] 가 sigmoid 게이팅이 독립적인 전문가 기여를 통해 라우팅 붕괴를 완화한다고 제안한다. 그러나 본 연구의 어블레이션(5.4절)은 이중 태스크 환경에서 softmax의 경쟁적 격리가 소수 유형 태스크를 더 잘 보호함을 드러내며 — 이는 동질적 태스크 연구의 결과를 역전시키는 것이다.

본 연구는 전문가 붕괴에 대한 **구조적 보장**을 제공한다: DeepFM 전문가가 HGCN 전문가와 동일한 기능적 거동으로 수렴할 가능성은 훨씬 낮는데, 이는 두 아키텍처가 근본적으로 다른 귀납적 편향과 수학적 연산을 인코딩하기 때문이다.

2.3 추천에서의 설명 가능성

SHAP [24] 과 LIME [36] 은 모델 비의존적 설명을 제공하지만 불안정성, 계산 비용, 모델 내부와의 괴리 문제를 겪는다. Integrated Gradients [40] 은 이론적으로 근거가 있는 귀인을 제공하지만 여전히 사후적으로 작동한다.

격차: 추가 계산 없이 순전파의 자연스러운 부산물로서 비즈니스적으로 의미 있는 설명을 생성하는 구조적(본질적) 설명 가능성.

2.4 금융 추천과 규제

금융 상품 추천을 위한 딥러닝에 관한 최근 연구 [5, 28] 는 협업 필터링 대비 개선을 입증하였으며, Martinez-Plumed 등 [27] 은 종단적 거래 데이터에 대한 순차 모델이 교차 판매 예

측을 개선함을 보였다. 그러나 이러한 시스템 중 규제 설명 가능성 요건을 다루는 것은 없다.

EU AI Act [8] 는 금융 추천을 고위험 AI로 분류하여 투명성(Art. 13), 인간 감독(Art. 14), 견고성(Art. 15)을 의무화한다. 한국 금융감독원 가이드라인 [11] 및 AI 기본법 [29] 도 유사한 요건을 부과한다. 현재 접근법은 규제 준수를 위해 사후적 SHAP/LIME에 의존하나, 이는 금융 맥락에서 한계가 있음이 문서화되었다 [37].

격차: 규제 요건에서 아키텍처 구성요소로의 검증 가능한 매핑을 제공하며, 설명이 사후적이 아닌 구조적으로 생성되는 추천 시스템은 존재하지 않는다.

3 아키텍처

3.1 환원주의 프레임워크: 두 축의 분해

아키텍처를 설명하기에 앞서, 이후 모든 설계 결정을 지배하는 분석적 프레임워크를 제시한다.

금융 고객 이해의 복잡성은 두 개의 직교 축을 따라 분해된다:

축 1: 고객은 누구인가? (금융 DNA)

“이 고객은 누구인가?”라는 질문을 4개의 환원 불가능한 차원으로 분해하며, 각 차원은 고객 정체성의 근본적으로 다른 측면을 포착한다:

1

nba_primary 타겟 설계. nba_primary는 개별 상품 인덱스가 아닌 상품 그룹(7개 클래스)을 타겟으로 한다. 7개 클래스는 다음과 같다: 0 = NBA 없음, 1 = 저축/보증, 2 = 당좌 계좌, 3 = 예금, 4 = 투자, 5 = 신용 대출, 6 = 직불. 이 재설계(기존 25개 개별 상품 클래스에서 변경)는 클래스 균형을 개선하고 의미 있는 순위 기반 평가를 가능하게 한다. 기존 25-way 분류는 희귀 상품이 지배하는 긴 꼬리 분포를 가져 macro-F1이 신뢰할 수 없었으며, 그룹 수준 순위 목표에는 NDCG@K가 적합하다.

축 2: 정보는 어떤 형태를 가지는가? (데이터 모달리티)

고객 데이터는 구조적으로 상이한 모달리티로 존재하며, 각각 의미 있는 신호를 추출하기 위해 서로 다른 수학적 도구를 필요로 한다:

교차곱(cross-product)은 아키텍처를 정의한다: 각 (DNA × 모달리티) 셀은 어떤 전문가가 어떤 태스크 그룹을 위해 어

¹초기 개발 단계에 포함되었던 4개 태스크(소득 구간, 재직 단계, 소비 수준, 참여 점수)는 결정론적 피쳐 변환으로 확인되어 진정한 예측 목표가 아니므로 제거하였다.

DNA	질문	태스크
활동(Engagement)	고객이 무엇을 하는가?	next_mcc mcc_diversity_trend top_mcc_shift
생애주기(Lifecycle)	고객이 어디에 있는가?	churn_signal segment_prediction
가치(Value)	고객의 가치는 얼마인가?	cross_sell_count product_stability
소비(Consumption)	고객이 무엇을 구매할 것인가?	will_acquire_* (5), nba_primary

Table 1: 금융 DNA 분해 (축 1). 고객 정체성의 4개 환원 불가능한 차원.

모달리티	예시	전문가	생성기
상태(State)	is_active, holdings	DeepFM	base
스냅샷(Snapshot)	balance, demographics	GMM, DeepFM	GMM clustering
단기 시계열	recent transactions	Transformer	temporal
장기 시계열	monthly trends	Mamba	mamba temporal
불연속 시계열	dormant→active	LNN	model derived
계층(Hierarchy)	MCC 가맹점 카테고리 트리	HGCN	merchant_hierarchy
관계(Relations)	customer-product graph	LightGCN	graph collab.
위상(Topology)	behavioral shape	PersLay	TDA global/local
인과(Causality)	behavioral causation	Causal	causal features

Table 2: 데이터 모달리티 분해 (축 2). 각 모달리티는 전문가와 피쳐 생성기에 매핑된다.

떤 피쳐를 처리하는지를 결정한다. 7개 이종 전문가, 17개 피쳐 그룹, 4개 태스크 그룹은 임의의 설계 선택이 아니라 이 두 축 분해의 필연적 결과이다. 동질적 MLP 전문가 바스켓은 축 2를 완전히 무시한다 — 계층적, 시간적, 위상적 데이터를 동일하게 취급하므로 — 본 연구의 어플리케이션이 입증하는 태스크 유형별 특화를 달성할 수 없다.

3.2 설계 철학

본 아키텍처는 한국 공공 금융기관의 심각한 현실적 제약에서 탄생하였다. 3인으로 구성된 팀 — PM 역할을 겸한 데이터 사이언티스트 1명과 엔지니어 2명 — 이 레거시 ALS 기반 협업 필터링 시스템을 차세대 추천 모델로 교체해야 했다. PM은 GARP 공인 Financial Risk Manager (FRM) 자격 소지자로, 신용/시장 리스크 분석, 규제 준수, 마이데이터 라이선싱, 빅데이터 플랫폼 운영, 데이터 사이언스 프로젝트, 추천 시스템 관리를 아우르는 경력을 보유하고 있으며 — 이 배경이 본 논문의 아키텍처 및 컴플라이언스 결정을 직접적으로 뒷받침한다.

제약은 상당했다: 전용 ML 인프라 예산 없음, 유일한 학습 하드웨어인 단일 데스크톱 GPU (NVIDIA RTX 4070, 12GB VRAM), 배포를 위한 GPU 추론 서버 없음, 엄격한 규제 요건 (한국 금융감독원 AI 가이드라인, EU AI Act).

팀은 이러한 제약을 한계로 취급하기보다 모든 수준에서 방법론을 적응시켰다:

- Claude (Anthropic), Gemini (Google), Cursor를 활용한 AI 증강 개발로, 각 팀원이 AI 에이전트 병렬 팀을 이끄는 방식;
- 대형 MLP의 무차별적 용량을 구조적 귀납적 편향으로 대체하는 파라미터 효율적 아키텍처 설계;
- AWS Lambda에서의 GPU 없는 CPU 추론을 위한 LGBM으로의 지식 증류;
- 2개의 YAML 파일로 전체 시스템을 제어하는 config 기반 파이프라인으로 최소 인원 팀의 운영을 지원.

초기 탐색에서는 Black-Litterman에서 영감을 받은 접근법을 고려하였으나, 다수 모델의 예측을 베이지안 업데이트를 통해 결합하는 “전문가 견해”로 취급하는 방식은, 결합 과정이

각 모델의 기여를 불투명하게 만들어 비즈니스적으로 의미 있는 설명을 불가능하게 하였기에 — 규제 준수에 치명적 결함으로 — 기각되었다.

핵심적 재구성: 모델을 외부에서 결합하는 대신, 단일 모델 내부에서 전문가를 결합하는 것이었다. 이는 PLE [41]의 선택으로 이어졌으며, 핵심적 수정이 적용되었다: 동질적 MLP 전문가를 각기 다른 귀납적 편향을 인코딩하는 구조적으로 이종인 전문가로 대체하였다.

3.2.1 구조적 동형사상: 학제 간 방법론이 작동하는 이유

본 연구의 다학제적 피쳐 엔지니어링은 관련 없는 분야에서의 임의적 차용이 아니다. 이는 구조적 동형사상(Structural Isomorphism)에 기반한다 — 수학적으로 동등한 구조가 서로 다른 분야에서 반복적으로 나타나며, 한 분야에서 개발된 도구를 구조적으로 동등한 다른 분야의 문제에 엄밀하게 적용할 수 있다는 관찰이다.

예를 들어: 휴면 고객이 소비를 재개하는 과정은 화학 반응이 활성화 에너지 장벽을 극복하는 역학과 동일한 구조를 따른다. 고객 네트워크를 통한 상품 채택의 확산은 SIR 감염병 모델의 구획 역학과 동일한 구조를 따른다. 이것은 비유가 아니다 — 지배 방정식이 동일하며, 해법이 수학적 엄밀성을 가지고 전이된다. 이것이 느슨한 유비가 아님을 강조한다: 지배 미분방정식이 구조적으로 동일하다 (나란히 비교는 부록 E 참조). 각 매핑의 타당성은 원천 분야 정리의 수학적 전제조건이 금융 분야에서도 성립하는지를 확인함으로써 독립적으로 검증할 수 있다.

이 원리는 과학과 공학에서 저명한 역사를 가진다: Shannon의 정보 엔트로피는 Boltzmann의 열역학 엔트로피에서 직접 차용되었고, Black-Scholes 옵션 가격 결정 모델은 열전도 방정식에서 유도되었으며, Google의 PageRank는 마르코프 체인 정상 분포의 응용이다. 각 사례에서 두 분야 사이의 구조적 동형사상을 인식한 것이 어느 한 분야만으로는 달성할 수 없었던 돌파구를 가능하게 했다.

본 연구의 기여는 이 원리를 금융 고객 이해에 체계적으로 적용한 것이다: 고객 행동의 각 측면에 대해, 기저 역학과 구조적으로 동형인 수학적 도구를 가진 분야를 식별하고, 해당 분야의 방법론을 피쳐(예측용)와 전문가 아키텍처(해석용)로 구체화하였다. 다학제적 접근은 임의적 피쳐의 집합이 아니라, 구조적 동등성을 통한 유비추론의 원리적 적용이다.

4가지 원칙이 아키텍처를 안내한다:

1. **강건한 설명 가능성:** 모델 구조 자체가 설명을 생성한다. 각 전문가의 이름이 비즈니스 의미를 담고 있으므로(예: "Temporal" = 시간 패턴, "HGCN" = 상품 계층구조), CGC 게이트 가중치는 사후적 방법 없이 직접 해석 가능하다.
2. **전문가 기여도 진단:** 이종 설계는 전문가별 기여도 분석을 가능하게 한다 — 주어진 데이터 환경에서 어떤 inductive bias가 beneficial한지 harmful한지 식별할 수 있다. 동질 전문가는 균일하고 정보가 없는 성능 저하만 보일 것이다.
3. **유연한 확장성:** 새로운 피쳐, 태스크, 전문가는 코드 변경이 아닌 YAML 설정으로 추가된다. 시스템은 4개에서 13개 태스크로 아키텍처 수정 없이 확장되었다.
4. **통합 관리성:** 전체 파이프라인(피쳐 엔지니어링 → 학습 → 증류 → 서빙 → 모니터링)이 3개 YAML 파일 split-config(pipeline.yaml + feature_groups.yaml + configs/datasets/{name}.yaml)로 제어되어, 제한된 ML 엔지니어링 리소스를 가진 팀의 운영 부담을 줄인다.

3.3 데이터 축 분류

금융 고객 데이터는 본질적으로 다중 모달 구조를 나타낸다. 데이터를 다수의 축을 따라 분류하며, 각각 최적의 피쳐 생성기와 전문가에 매핑된다.

데이터 축에서 전문가 및 피쳐 생성기로의 완전한 매핑은 Table 2에 나타나 있다.

참고: 단기/장기/불연속 시계열은 Temporal Ensemble 전문가의 세 하위 구성요소 (Transformer, Mamba, LNN)에 대응한다. GMM은 피쳐 생성기이며 독립 전문가가 아니다.

3.4 이종 전문가 바스켓

공유 전문가가 동일한 MLP인 표준 PLE와 달리, 본 연구의 공유 전문가 바스켓은 7개의 구조적으로 상이한 네트워크를 포함한다. 각 전문가는 하나 이상의 모달리티 축(Table 2)에 대응하여, 모든 구조적으로 상이한 데이터 유형이 그에 맞게 설계된 아키텍처에 의해 처리되도록 보장한다:

각 전문가가 명명된 귀납적 편향을 가지므로, 게이트 가중치는 고객에게 비즈니스적 용어로 왜인지를 전달한다 — "은닉 유닛 47이 활성화됨"이 아니라 "소비 추세가 이 추천을 주도하였습니다." 각 전문가는 다른 전문가 유형으로는 해결할 수 없는 금융 고객 이해의 특정 공백에 기반하여 선정되었다:




Figure 1: 이종 전문가 PLE 아키텍처 개요.

- **DeepFM** [14]: 금융 행동은 피쳐 상호작용에 의해 구동된다 (예: 소득 × 보유 상품 × 채널 선호도). FM의 저랭크 분해는 $O(nk)$ 로 2차 교차를 계산하며, 이는 무차별 열거의 $O(n^2)$ 와 비교된다. Deep 구성요소는 고차 상호작용을 포착한다.
- **HGCN** [4]: MCC 가맹점 카테고리 계층구조(10 L1 카테고리 → 30 L2 서브카테고리 → 109 리프 코드)는 본질적으로 트리 구조이다. 쌍곡 공간(Poincaré 볼, 8D)은 유클리드 공간보다 기하급수적으로 적은 왜곡으로 트리를 임베딩한다 [31] — 550K 노드 가맹점 계층구조에 필수적이다. HGCN은 FeatureRouter를 통해 merchant_hierarchy 피쳐(27D Poincaré 임베딩)를 수신하며, 상품 공동 보유

피쳐(이는 LightGCN의 product_hierarchy 그룹에 속함)를 수신하지 않는다.

HGCN과 LightGCN은 초기 실험에서 의도치 않게 혼용되었던 서로 다른 역할을 담당한다. HGCN은 MCC 가맹점 카테고리 계층구조(L1: 10개 카테고리 → L2: 30개 서브카테고리)를 Poincaré 디스크 공간에 임베딩하여 트리 구조의 카테고리 관계를 포착한다. LightGCN은 24개 상품 공동 보유 그래프에서 협업 필터링을 통해 고객-상품 이분 친화도를 학습한다. feature_groups.yaml의 target_experts 선언이 이 분리를 강제한다: merchant_hierarchy → HGCN 전용, product_hierarchy → LightGCN 전용.

전문가	귀납적 편향	포착 대상
DeepFM [14]	피쳐 상호작용	2차 교차 피쳐
Temporal Ensemble	다중 스케일 시간적	단기/장기/불연속 시계열
HGCN [4]	쌍곡 계층구조	MCC 가맹점 카테고리 트리 (Poincaré)
PersLay [2]	위상적 지속성	행동 형태 패턴
LightGCN [16]	그래프 합성곱	협업 필터링
Causal [45]	DAG 제약	피쳐 간 인과 방향
Optimal Transport [7]	분포 매칭	세그먼트 분포 이동

Table 3: 상이한 귀납적 편향을 가진 7개 이종 전문가.

- **PersLay** [2]: 위상적 데이터 분석(TDA)은 고객 소비 패턴의 형태 피쳐(연결 성분 H_0 , 순환 H_1 , 공동 H_2)를 포착한다. H_1 루프는 소비 순환을 드러내고, H_2 공동은 체계적 소비 회피를 감지한다. 이러한 피쳐는 잡음에 대해 증명 가능하게 안정적이다(안정성 정리).
- **Temporal Ensemble**: 금융 시계열은 규칙적 스냅샷, 돌발적 거래, 수개월 휴면을 결합한다. Mamba [13] 는 $O(n)$ 으로 장거리 추세를 처리하고, LNN [15] 은 불규칙 간격에 시간 상수를 적응시키며, Transformer는 단기 어텐션 패턴을 포착한다.
- **Causal** [45]: 학습 가능한 인접 행렬 $W \in \mathbb{R}^{d \times d}$ ($d = 32$ 압축 피쳐 차원)가 피쳐 간 인과 방향을 인코딩한다. 학습 중 NOTEARS 비순환 제약 ($\text{tr}(e^{W \circ W}) - d = 0$, 10차까지 Taylor 근사)이 정규화 손실에 추가되어 W 를 DAG 구조로 유도한다. 추론 시점에는 학습된 W 를 고정하여 $\hat{z} = z + z \cdot (W \circ W)$ 로 적용함으로써, 최적화 재실행 없이 발견된 인과 구조를 표현에 주입한다. 이를 통해 “A가 B와 상관관계가 있다” 대신 “A가 B를 유발한다”는 설명이 가능하다 [34].
- **LightGCN** [16]: 고객-상품 이분 그래프에서의 이웃 집계를 통한 협업 필터링. 이 전문가는 핵심만 남긴 구조(피쳐 변환 없음, 활성화 없음)로, 이것이 추천에서 더 복잡한 GCN 변형보다 우수한 성능을 보임이 입증되었다.
- **Optimal Transport** [7]: Sinkhorn 정규화 Wasserstein 거리는 고객 소비 프로필과 세그먼트 프로토타입 간의 분포 이동을 측정하며, (KL 발산과 달리) 피쳐 공간의 거리 구조를 존중한다.

이중 전문가의 근거는 하드웨어 제약에도 있다: 단일 데스크톱 GPU(12GB VRAM)로는 동질적 MLP 전문가를 높은 표현력을 위한 충분한 너비/깊이로 확장할 수 없다. 대신, 각 전문가는 구조적 귀납적 편향을 활용하여 MLP 파라미터로는 수차수 더 많은 파라미터가 필요한 패턴을 포착한다. 예를 들어, HGCN은 MCC 가맹점 카테고리 계층구조를 27개 쌍곡 차원으로 임베딩하며 — 유클리드 임베딩이 왜곡 없이 표현하려면 $O(2^d)$ 차원이 필요한 것을 $O(d)$ 파라미터로 달성한다 [4].

7개 shared 전문가 전체의 총 파라미터 수는 V1 349-피쳐 스키마에서 측정된 **2.70M**이고; V2 1211-피쳐 스키마는 재실행 후 보고 예정, FeatureRouter를 통한 전문가별 입력 서브셋 적용으로 4.77M 기준선 대비 감소하였다. 학습된 표현

의 다양성은 더 작은 파라미터 예산에도 불구하고 근본적으로 더 풍부하다.

3.4.1 FeatureRouter: 이중 입력 × 이중 아키텍처

FeatureRouter는 더 강력한 형태의 전문가 특화를 구현한다: 각 전문가는 **다른 아키텍처**(이중 바스켓)를 사용할 뿐만 아니라, **다른 입력 피쳐 서브셋**(이중 입력)도 수신한다. 이 “이중 아키텍처 × 이중 입력” 설계는 각 전문가에 대해 귀납적 편향과 무관한 피쳐를 제거함으로써 신호 대 잡음비를 극대화한다.

피쳐 그룹 할당은 `feature_groups.yaml`의 `target_experts` 필드를 통해 선언되어, 모델 코드에 데이터셋별 하드코딩이 전혀 없다. 전문가별 입력 차원은 다음과 같다:

전문가별 차원의 합(2419D)이 1211D를 초과하는 이유는, 일부 피쳐 그룹이 상보적 귀납적 편향이 동일한 신호에서 혜택을 받는 여러 전문가에게 공유되기 때문이다 (예: 상태 피쳐는 DeepFM의 상호작용 모델링과 Causal의 DAG 구조 추론 양쪽에 유용하다).

3.4.2 CGC 게이트 설계: Softmax vs. Sigmoid

표준 PLE는 경쟁적 제약을 부과하는 softmax CGC 게이트를 사용한다: 게이트 가중치의 합이 1이 되므로, 전문가들은 영향력을 두고 경쟁해야 한다. 동질적 MLP 전문가에서는 이것이 합리적이다 — 전문가들이 중복된 표현을 제공하므로 게이트가 최선의 것을 선택하면 된다.

이중 전문가에서는 이 경쟁이 해롭다: 각 전문가가 고유하고 비중복적인 정보를 제공하므로 (시간적 $\neq$ 계층적 $\neq$ 위상적), 하나를 억제하는 것은 대체 불가능한 신호를 잃는 것을 의미한다. 최근 이론적 연구 [30] 는 sigmoid 게이팅이 전문가 간 경쟁을 제거하여 더 높은 표본 효율성을 달성함을 증명하였다.

본 연구에서는 경험적 비교를 위해 두 가지 게이트 유형을 모두 구현한다:

- **Softmax**: $w_k = \text{softmax}(W \cdot h)_k$ — 경쟁적, 합이 1.
- **Sigmoid**: $w_k = \sigma(w_k \cdot h) / \sum_j \sigma(w_j \cdot h)$ — 독립적 평가, 정규화.

참고: 본 연구의 sigmoid 변형은 softmax와의 비교 가능성을 위해 사후 정규화를 포함한다. Nguyen 등의 이론적 분석은 비정규화 sigmoid에 적용되며, 여기서 사용하는 정규화 변형은 분모를 통해 경쟁을 부분적으로 재도입한다.

Sigmoid 변형은 각 전문가의 관련성을 정규화 전에 독립적으로 평가하여, 다수의 전문가가 동시에 높은 가중치를 받을 수

전문가	입력 차원	라우팅된 피쳐 그룹
DeepFM	977D	demographics, products, txn_behavior, derived_temporal, gmm, model_derived, txn_lag_tensor, txn_rolling_stats, nba_label_multihot, mcc_top30_multihot
Temporal Ensemble	116D	txn_behavior, hmm, mamba, model_derived
HGCN	58D	merchant_hierarchy, mcc_top30_multihot
PersLay	32D	tda_global, tda_local
Causal	129D	demographics, products, txn_behavior, derived_temporal, product_hierarchy, gmm, txn_rolling_stats
LightGCN	955D	product_hierarchy, graph_collaborative, txn_lag_tensor, nba_label_multihot, mcc_top30_multihot
Optimal Transport	95D	demographics, products, txn_behavior, derived_temporal, gmm, txn_rolling_stats

Table 4: FeatureRouter 적용 후 전문가별 입력 차원. 전체 피쳐 공간: 1211D (Phase 0 v3/v4, 17개 그룹).

있게 한다. 이론적 기대는 sigmoid가 비중복 신호를 보존하여 이중 전문가에게 유리하다는 것이다. 그러나 본 연구의 구조 어블레이션(5.4절)은 놀라운 역전을 드러낸다: softmax가 13-태스크 이중 환경에서 sigmoid를 능가하는데, 이는 경쟁적 전문가 할당이 소수 유형 태스크(다중클래스, 회귀)를 다수 유형(이진)의 그라디언트 오염으로부터 보호하기 때문이다. 이 발견은 이론적 예측에 도전하며, 태스크 유형 이중성이 — 전문가 이중성만이 아니라 — 최적 게이트 설계를 결정함을 강조한다.

3.4.3 Temporal Ensemble: 전문가 내의 전문가

금융 시계열은 다른 도메인에서 드물게 볼 수 있는 고유하게 복잡한 구조를 나타낸다. 단일 고객이 동시에 다음을 가질 수 있다: 월별 잔액 스냅샷(규칙적, 장거리), 일별 거래 시퀀스(불규칙, 돌발적), 수개월 휴면 갭(불연속). 단일 시간 모델로는 세 가지 모두를 잘 처리할 수 없다:

- **Mamba** [13] (State Space Model): 선택적 상태 공간을 통해 $O(n)$ 효율로 장거리 의존성을 포착한다. 12개월 이상의 월별/분기별 추세에 이상적이다.
- **LNN** [15] (Liquid Neural Network): 불규칙 샘플링 간격과 휴면 갭을 자연스럽게 처리하는 적응형 시간 상수. 고객이 3개월간 비활성 후 갑자기 활성화될 때, LNN의 연속 시간 역학이 보간 없이 적응한다.
- **Transformer**: 어텐션 기반 단기 문맥 추출. 위치 관계가 중요한 최근 30–90일 거래 시퀀스 내의 패턴을 포착한다.

세 모델의 출력은 연결(concatenate)되어 투영되며, 이는 더 미세한 세분화 수준에서 이중 전문가 철학을 반영한다. 이 설계는 시간 구성요소 어블레이션에서 검증되며, 단일 시간 구성요소의 제거가 서로 다른 태스크 그룹에서 성능을 저하시킴을 보인다.

3.5 다학제적 피쳐 엔지니어링

본 연구의 차별적 특징은 다양한 학문 분야의 방법론을 금융 고객 행동에 체계적으로 적용하는 것이다. 전문가 바스켓이 소개된 이상, 근거는 명확해진다: 각 분야의 피쳐는 해당 신호 유형을 가장 잘 활용할 수 있는 특정 전문가에 공급되도록 설계된다. 표준 통계 피쳐(평균, 분산, 추세)에만 의존하기보다, 동일한 기초 데이터에서 구조적으로 다른 신호를 추출하는 도메인 특화 수학적 도구를 적용한다.

참고: Phase 0 v3/v4에서 총 1211개 피쳐 생성 (17개 그룹, 이전 버전 349개 대비 증가). FeatureRouter가 각 전문가에게 피쳐 서브셋을 라우팅한다 (전문가별 차원: DeepFM 977D, MLP 57D, Temporal 116D, HGCN 58D, PersLay 32D, Causal 129D, LightGCN 955D, OT 95D); 모델 파라미터: 2.70M (V1, 349D 스키마 측정); V2 1211D 측정은 재실행 후. 전문가 라우팅은 feature_groups.yaml의 target_experts 선언(그룹 단위)으로 구성되어 각 전문가가 지정된 피쳐 그룹만 수신함을 보장한다.

이러한 적용 중 일부는 저자들이 아는 한 금융 추천에서 최초이다:

화학 반응속도론은 소비 행동을 반응 시스템으로 모델링한다: “활성화 에너지”는 휴면 고객이 소비를 재개하는 임계치를 나타내며, “촉매”(예: 급여 입금)는 이 임계치를 낮춘다. 정점 이

학문 분야	방법	차원	금융 해석
위상수학	Persistent Homology (TDA)	32	행동 형태 지속성: 일시적 vs. 구조적 소비 패턴
쌍곡 기하학	HGCN 임베딩	27	MCC 가맹점 카테고리 거리: 저차원에서의 계층구조 보존
제어 이론	Mamba (State Space)	50	장거리 행동 의존성: 과거 습관이 현재에 미치는 영향
확률 과정	HMM 상태 전이	25	잠재적 생애주기 단계: 휴면 → 성장 → 성숙 → 위험
화학 반응속도론	반응 속도 모델링	6	소비 활성화율, 반감기, 휴면 재활성화 촉매
역학(전염병학)	SIR 구획 모델	5	상품 채택을 "감염"으로 모델링: 미감염 → 채택 → 이탈
범죄학	일상 활동 이론	5	거래 규칙성: 돌발성, 일주기 분산, 루틴 이탈점
신호 처리	FFT + Hilbert 변환	8	소비 주기성: 스펙트럼 엔트로피, 고조파 전력, 위상 고정
경제학	Friedman 항상소득	8	소득 분해: 항상 vs. 일시 소득, 소비 평활화
그래프 이론	LightGCN	66	협업 필터링: 유사 고객 행동 전이
통계학	GMM 소프트 클러스터링	22	확률적 세분화: 다봉 고객 분포

Table 5: 다학제적 피처 엔지니어링 (11개 학문 분야).

후 소비 강도의 반감기는 단순 이동평균으로는 표현할 수 없는 감쇄 역학을 포착한다.

SIR 전염병 모델은 상품 채택을 전염 과정으로 취급한다: 고객은 "미감염"(미채택), "감염"(최근 채택), "회복"(이탈) 상태에 있다. 고객의 소셜 그래프에서 상품 카테고리의 기본 재생산수 R_0 는 채택 속도를 예측한다.

Friedman의 항상소득가설 [12]은 관측된 소득을 HP 필터 또는 칼만 필터를 사용하여 항상(안정적, 장기) 소득과 일시(보너스, 비정기) 소득으로 분해한다. 이 구분은 금융 추천에 핵심적이다: 일시 소득이 높은 고객에게 안정적 현금흐름을 가정하는 장기 투자 상품을 추천해서는 안 된다. FD-TVS 스코어링 시스템(동반 논문에서 상세 설명)은 이 분해를 활용하여 소득 안정성 유형별로 추천에 가중치를 부여한다.

이러한 피처는 예측 기여를 넘어 이중 목적을 수행한다: 표준 피처로는 제공할 수 없는 설명 어휘를 제공한다. 예를 들어 화학 반응속도론의 "활성화 에너지 감소"는 내부적으로 "소비 재개 가능성 상승"이라는 신호로 해석되고, SIR 모델의 상품 채택 곡선은 "신규 상품 관심도 증가"로 역매핑된다. interpretation_registry를 통해 비즈니스 용어로 변환된 후 추천사유 생성 에이전트에 전달된다. 과학적 프레임워크는 모델의 내부 추론을 근거하며, 고객은 비즈니스 언어를 수신한다.

3.6 금융 DNA 태스크 그룹화

13개 예측 태스크를 금융 고객 DNA에 기반하여 4개 그룹으로 조직한다. 각 태스크 그룹은 하나의 DNA 축(Table 1)에 대응하며, 각 그룹 내에서 서로 다른 모달리티 전문가(Table 2)

가 다르게 기여하고, CGC 게이트가 태스크별 최적 조합을 학습한다.

4개 태스크 그룹 — 활동(Engagement), 생애주기(Lifecycle), 가치(Value), 소비(Consumption) — 과 그 구성 태스크는 Table 1에 정의되어 있다.

adaTT는 차별화된 전이를 강제한다: 강한 그룹 내 전이(동일 DNA 관점)와 약한 그룹 간 전이(상이한 관점, 부정적 전이 최소화).

손실 수준 전이 — 용어와 출처. 본 구현의 태스크 간 전이 메커니즘은 원래 adaTT [22]와 두 가지 측면 모두에서 다르다:

1. **작동 층위.** [22]의 adaTT는 표현 수준 융합(per-task fusion layer)가 학습된 게이팅으로 task-specific expert와 shared expert의 출력을 적응적으로 결합)을 수행한다. 반면 본 구현은 **손실 수준**에서 작동한다:

$$\mathcal{L}_i^{\text{trans}} = \mathcal{L}_i + \lambda \sum_{j \neq i} w_{i \rightarrow j} \cdot \mathcal{L}_j$$

2. **친화도 원천.** [22]은 expert activation에 대한 미분 가능 게이팅으로 융합 가중치를 학습한다. 본 구현은 $w_{i \rightarrow j}$ 를 태스크별 손실 기울기 간의 **gradient cosine similarity**로 계산하고 EMA로 평활한다 — 이는 Task Affinity Groupings [10] 및 GradNorm 계열의 적응적 손실 균형 [6]에 더 가까우며 [22]과는 다른 계보이다.

즉 본 논문 전반의 "adaTT"는 [22]의 재구현이 아니라, **이중 전문가 PLE를 위한 TAG + GradNorm 하이브리드**이다. 기존 내부 문서와의 연속성을 위해 "adaTT" 약어를 유지하되, [22]에 익숙한 독자는 두 메커니즘을 구분하여 해석해야 한다

소스 → 타겟	방법	고객 경험	인과 방향
churn_signal → product_stability	output_concat	이탈 위험 → 상품 보유 안정성	인과
next_mcc → nba_primary	hidden_concat	다음 카테고리 의향 → NBA 선택	순차 / 피쳐 공유

Table 6: 자연스러운 고객 경험 흐름을 반영하는 로짓 전이 관계 (Santander, v12 benchmark — 출처: configs/datasets/santander.yaml::task_relationships).

다. 기본 태스크 손실 $\mathcal{L}_i$ 는 학습된 불확실성 [20]으로 추가가 중되며, 불균형이 심한 이진 분류(예: churn_signal)는 태스크별 α, γ 를 갖는 focal loss [23]를 사용한다.

[22]로부터의 이 차이는 이중 전문가 환경의 두 가지 고려에서 동기 부여되었다: (1) 표현 수준 전이는 원 출력이 형태와 의미 측면에서 서로 다른 전문가 간에 은닉 차원을 맞추어야 하므로(온프레미스 H-GCN은 128D, 나머지는 64D), 이중 전문가 간 융합이 아키텍처적으로 번거롭다; (2) 손실 수준 전이는 PLE 층에 대해 아키텍처적으로 직교하여 expert routing 수정 없이 on/off 가능하며, 그래디언트-코사인 친화도는 “서로 돕는 태스크는 기울기가 같은 방향으로 움직인다”는 해석이 가능해 규제 대응 MRM 문서화에 유리하다.

참고. 온프레임 포팅 과정의 5개 구현 버그(gradient 추출 빈도, adaTT config 로더, freeze_epoch 전달, uncertainty-weighting 순서, warmup_epochs 기본값)를 수정한 후, 본 연구의 어블레이션(5.4절)은 이 손실 수준 변종이 13-태스크 규모에서 **null 효과**를 보임을 확인한다: adaTT 유/무의 AUC 변화는 -0.001 에 불과하여 단일 seed 측정 노이즈 범위에 있다. 초기 드래프트는 -0.019 AUC 저하를 보고하였으나, 그 결과는 손실 수준 전이의 본질적 확장성 문제가 아니라 위 5개 구현 버그에 기인한 것이었다. 조사 과정의 투명성을 위해 이 note를 유지한다: “알고리즘적 발견”으로 보였던 결과가 실은 구현 artefact일 수 있으므로, 매끄러운 서사로 소급 수정하기보다 정정을 보고하는 편이 더 유용하다고 판단한다. GradSurgery(5.4절)도 그래디언트 수준 대안으로 실험하였으나 PLE 단독 대비 이득이 없고 VRAM 오버헤드가 있어 채택하지 않았다.

3.7 로짓 전이

adaTT가 대칭적 태스크 간 관계를 처리하는 반면, 로짓 전이는 고객 경험의 자연스러운 순서를 반영하는 방향적 의존관계를 포착한다:

두 전이는 고객 경험의 자연스러운 순서를 반영한다: 이탈 위험이 상품 보유 안정성을 게이팅하고(생애주기 축), 다음 카테고리 의향이 NBA 선택을 정보화한다(소비 축). 초기 드래프트는 engagement_score → nba_primary 엷지를 포함했으나,

해당 태스크는 2026-04-12 결정론적 피쳐 변환으로 제거되었고(\$3 태스크 축소 참조), has_nba → nba_primary 엷지는 nba_primary 자체로 흡수되었다. 전이 방향은 데이터로부터 학습되는 것이 아니라 고객 여정에 대한 도메인 지식에 기반하여 지정된다. 이는 의도적 설계 선택이다: 전이의 강도는 (adaTT 친화도를 통해) 학습되지만, 방향은 비즈니스 로직에 의해 고정되어 추가적인 해석 가능성 계층을 제공한다.

3.8 본질적 설명 가능성

본 연구의 핵심 주장은 이중 전문가 구조가 분석 관점 수준의 구조적 해석 가능성을 제공한다는 것이다 — 게이트 가중치가 각 예측을 명명된 분석 관점(시간 추세, 상품 계층, 인과 경로 등)으로 분해하며, 이는 순전파의 자연스러운 부산물이다. 이것이 Pearl의 인과적 설명은 아니다: 대부분의 전문가는 인과 사다리의 1단계(연관)에서 작동한다. 예외는 Causal 전문가로, NOTEARS DAG을 학습하여 2단계(개입) 추론에 근접한다. Causal 전문가의 게이트 가중치가 높다는 것은 단순한 상관관계가 아니라 구조적 인과 관계가 추천에 기여했음을 의미하며, 이는 질적으로 더 강한 형태의 설명이다.

메커니즘. CGC (Customized Gate Control) 모듈은 각 태스크 t 에 대해 K 개 전문가에 대한 어텐션을 계산한다. Soft-max 게이팅: $w_t = \text{softmax}(W_t \cdot h + b_t) \in \mathbb{R}^K$; sigmoid 게이팅: $w_{t,k} = \sigma(w_{t,k} \cdot h) / \sum_j \sigma(w_{t,j} \cdot h)$. 가중치 $w_{t,k}$ 는 전문가 k 가 태스크 t 의 예측에 얼마나 기여했는지를 직접 나타낸다.

비즈니스 해석 가능성. 각 전문가 k 가 명명된 귀납적 편향을 가지므로 (예: $k = \text{“Temporal”}$ 은 시계열 패턴, $k = \text{“HGCN”}$ 은 상품 계층구조), $w_{t,k}$ 는 추가 해석 없이 비즈니스 의미를 전달한다:

예시: 고객 c 에 대한 통근형 체크카드 추천은 다음에 의해 결정된다:

- Temporal (0.35) — 3개월간 카드 소비가 증가 추세
- HGCN (0.28) — 가맹점 카테고리 계층구조상 대중교통·편의점 MCC에 집중
- DeepFM (0.22) — 통근 관련 상품 × 채널 상호작용 패턴
- 기타 (0.15)

게이트 가중치가 설명하는 것과 설명하지 못하는 것. 게이트 가중치는 “어떤 분석 관점이 가장 중요했는가”에 답한다 — “왜 이 고객이 이 상품을 살 것인가”에 대한 인과적 답은 아니다. 대부분의 전문가(Temporal, HGCN, LightGCN, DeepFM, PersLay, OT)에서 가중치는 연관적 관련성을 나타낸다. Causal 전문가에 한해서는 높은 가중치가 학습된 DAG 구조의 기여를 신호하여 더 강한 설명적 근거를 제공한다. 이는 솔직한 중간 지점이다: SHAP의 피쳐 수준 귀인보다 풍부하지만, 완전한 반사실적 추론에는 미치지 못한다.

사후적 방법과의 비교. SHAP과 LIME은 피쳐 수준에서 작동하여 (“feature_237이 0.12 기여”), 피쳐 귀인을 비즈니스 서사로 변환하는 추가 매핑 단계를 필요로 한다. 또한 LIME의 국소 선형 근사는 불안정한 것으로 입증되었다 — 작은 입력 변동이 설명을 극적으로 변화시킬 수 있다 [36]. 반면, 게이트 가중치는 입력의 결정론적 함수이며 입력 변화에 따라 매끄럽게 변화한다.

피쳐의 이중 역할. 중요한 설계 통찰은 피쳐가 두 가지 목적을 수행한다는 것이다: (1) AUC에 대한 예측 기여, (2) 추천 사유를 위한 설명 자료. 한계적 예측 기여를 가진 피쳐 (예: TDA 위상 피쳐가 $\Delta AUC \approx 0.01$ 만 추가할 수 있음)도 대체 불가능한 설명 어휘를 제공한다. TDA의 persistence 값은 내부적으로 거래 패턴의 안정성을 나타내는 신호이며, interpretation_registry를 통해 “꾸준한 거래 패턴을 유지하고 계십니다”와 같은 비즈니스 언어로 변환된다. 이러한 설명은 다른 어떤 피쳐 유형으로도 생성할 수 없다. 이 이중 역할은 본 연구의 다학제적 피쳐 엔지니어링의 동기이며 어블레이션 연구에서 검증된다.

4 학습 파이프라인

4.1 Config 기반 설계

전체 파이프라인은 3개 YAML 파일 split-config 로 제어된다: pipeline.yaml (공통 모델, 학습, 종류, AWS 설정), feature_groups.yaml (피쳐 생성 및 전문가 라우팅), configs/datasets/{name}.yaml (데이터셋별 태스크, 레이블, 어블레이션 시나리오). 이 분리 덕분에 교차 데이터셋 공통 설정은 pipeline.yaml 에 유지되고, 새 데이터셋 추가 시 configs/datasets/example.yaml 을 복사하여 태스크/레이블 스키마만 재정의하면 된다. 새로운 태스크 또는 전문가 추가는 설정 변경만으로 가능하다.

4.2 데이터 처리

확장성을 위한 pandas-free 데이터 엔지니어링 원칙에 따라, 파이프라인은 계층적 백엔드 전략을 사용한다: 생성기 피팅/변환을 위한 cuDF (GPU 컬럼형), SQL 기반 집계 및 I/O를 위한 DuckDB [35] (CPU 컬럼형, 디스크 스푼), 학습 텐서로의 무복사 parquet 로딩을 위한 PyArrow. pandas는 10K 행 이하의 데이터셋에 대한 최후 수단으로만 사용된다.

이 백엔드 선택은 실용적 함의를 가진다: DuckDB는 4GB 메모리 제한으로 100만 행 데이터셋을 처리하며 자동으로 디스크로 스푼하여 범용 하드웨어에서의 처리를 가능하게 한다. cuDF는 생성기 피팅(GMM, HMM, Mamba)을 GPU에서 가속하여, Phase 0 피쳐 엔지니어링을 30분(pandas)에서 8분으로 단축한다.

4.3 데이터 리키지 방지

데이터 리키는 피쳐와 레이블이 별도 단계에서 처리되는 다단계 파이프라인에서 만연한 위험이다. 3가지 구조적 안전장치를 구현한다:

- 1. 생성기 레이블 제외:** 피쳐 생성기(GMM, model-derived 등)는 모든 레이블 컬럼을 입력에서 자동 제외한다. 이 안전장치 없이 생성된 피쳐에서 XGBoost AUC 1.0이 관측되었다 — 생성기가 레이블 정보를 피쳐에 직접 인코딩한 것이다.
- 2. 갭이 있는 시간 분할:** 설정 가능한 gap_days 파라미터가 학습과 검증 윈도우 간의 시간적 중첩을 방지한다. 횡단면(단일 스냅샷) 데이터의 경우, 시스템이 자동 감지하여 무작위 분할로 폴백한다.
- 3. 3단계 정규화 및 정규화 이후 그룹 레인지 재구축:** Stage 1은 skew + kurtosis 스크린에 이어 log-log R^2 검정으로 역법칙 컬럼을 감지하고, 각 컬럼의 log1p 복사본을 _log 접미사 컬럼으로 피쳐 행렬 말미에 추가한다; Stage 2는 학습 분할에서만 StandardScaler를 피팅하여 연속형(이진, 범주형 ID, 확률값 제외) 컬럼에 적용하므로 검증·테스트 분할은 학습 통계로 변환된다; Stage 3는 _log 파생 컬럼을 raw magnitude 그대로 유지(재스케일링 금지)하여 FeatureRouter가 heavy-tail 피쳐에 대해 centered view와 tail-preserving view를 모두 수신하도록 한다. Stage 1이 _log 컬럼을 피쳐 행렬 끝에 append하기 때문에 정규화 이전의 feature_group_ranges 는 stale 상태가 되며, runner는 각 그룹의 range를 정규화 이후 컬럼 순서에 대해 longest-contiguous-block 휴리스틱으로 재구축한다. 이는 역법칙 피쳐를 포함하는 그룹에

난이도	레이블	f_{obs}	f_{noise}	XGB AUC
Easy	segment ²	determ.	n/a	0.95–1.0
Core	churn_signal	0.04	0.68	0.58–0.65
Hard	will_acquire_*	0.03	0.72	0.50–0.56
V.Hard	next_mcc, top_mcc_shift	0.02	0.78	0.50–0.51

Table 7: 레이블 난이도별 분산 예산 (벤치마크 v4 난이도별 할당). XGB AUC 상한이 난이도 제어를 검증한다. 본 논문 전반에서 보고하는 최종 벤치마크 버전(v12)은 통합 전역 할당(obs_frac=0.15, lat_frac=0.35, noise_frac=0.50)과 3차–5차 곱셈적 레이블 상호작용을 사용하여 13개 전체 태스크에 걸쳐 의미 있는 클래스 분포를 생성한다(아래 단락에서 설명).

서 FeatureRouter가 잘못된 컬럼을 슬라이싱하던 silent routing 버그를 차단한다.

4. **LeakageValidator**: 학습 전 검사로 모든 피처와 모든 레이블 간 피어슨 상관관계를 계산한다(효율성을 위해 50K 부표본 사용). 0.95를 초과하는 상관관계는 경고를 트리거하고 조사를 유도한다.

5 실험

5.1 벤치마크 데이터

Synthetic Data Vault 프레임워크 [32] 와 조건부 생성적 접근법 [42] 에서 영감을 받되, 제어 가능한 난이도를 위한 새로운 분산 예산 메커니즘을 갖춘 4계층 생성 모델을 사용하여 100만 고객 합성 벤치마크를 구축한다:

1. **잠재 페르소나**: 5D 연속 잠재 벡터를 가진 6개 GMM 피팅 페르소나(70% 페르소나 조건부, 30% 독립 잡음).
2. **Gaussian Copula 인구통계**: 현실적 결합 분포를 보존하는 상관된 인구통계 변수 [32].
3. **벡터화된 거래**: LIST 컬럼으로서의 고객별 거래 시퀀스.
4. **분산 예산 레이블**: 각 레이블의 예측 가능성은 $\text{logit} = \sqrt{f_{\text{obs}}} \cdot z_{\text{obs}} + \sqrt{f_{\text{lat}}} \cdot z_{\text{lat}} + \sqrt{f_{\text{noise}}} \cdot \epsilon$ 로 제어되며, 사후적 레이블 잡음 뒤집기를 동반한다.

벤치마크는 여러 차례 반복을 거쳤다(v2에서 v12까지; 버전 이력은 부록 F 참조). 최종 버전인 v12(본 논문에서 보고)는 금융 DNA 축 정렬 상황 변수를 도입한다 — 각 고객은 DNA 축별로 독립적인 상황을 부여받는다(활동: 안정/급증/하락/변동; 생애주기: 안정/성장/통합/전환; 가치: 안정/상승/하락/충격; 소비: 일관/탐색/집중/전환). 상황은 정적 인구통계 피처를 변경하지 않으면서 거래 시퀀스 패턴(시간 간격, 금액 추세, MCC 분포 변화, 상품 취득률)을 조절하여, Phase 0 생성기

(Mamba, TDA, HGCN, GMM)를 통해서만 복원 가능한 신호를 생성한다. 레이블 상호작용은 obs_frac=0.15의 3차–5차 연속 곱셈 항을 사용하여, 13개 전체 태스크에서 의미 있는 클래스 분포를 생성한다.

레이블 신호는 선형 관측 가능 피처(obs_frac=0.15)와 행동 시퀀스 패턴을 통해 복원 가능한 잠재 성분(lat_frac=0.35)을 결합한다. 관측 가능 상호작용은 3차–5차 연속 곱셈항으로 구성되며 (예: 투자 성향을 위한 소득 × 소비 × 재직 × 상품 × 안정성), 트리 기반 모델과 얇은 네트워크가 효율적으로 근사할 수 없는 깊은 비선형 용량을 요구한다. 나머지 분산(noise_frac=0.50)은 환원 불가능한 노이즈로, 모델 성능의 상한을 설정한다.

5.2 실험 설정

어블레이션은 각 전문가가 서로 다른 태스크 유형에 대해 고유한 “왜”를 제공하는지를 검증한다 — 이종 전문가가 단순한 성능 트릭이 아니라 다면적 설득을 위한 구조적 요건임을 확인한다.

- **데이터**: 100만 고객, 1211개 피처(벤치마크_v12의 Phase 0, 17개 그룹), 13개 태스크.
- **하드웨어**: NVIDIA RTX 4070 (12GB VRAM, 64GB RAM) 로컬.
- **학습**: 10 에포크, 배치 5632, lr 0.0005, AMP (FP16), 워업 3 에포크 (코사인 어닐링), 조기 종료 없음. adaTT 시나리오는 warmup=3 에포크, grad_interval=10 사용. GradSurgery 시나리오는 warmup=2 에포크, conflict_threshold=0.0 사용.
- **손실 가중치**: 불확실성 가중치(Kendall et al.)에 학습된 정밀도 위에 태스크별 loss_weight를 적용 — 온프레임 참조 공식과 일치.

²segment_prediction은 deterministic feature transformation이 아닌 행동 클러스터링 기반 4-class 고객 생애주기 레이블이다. 높은 XGBoost 천장값은 강한 feature-label 상관을 반영하지만, 레이블 자체는 제거된 deterministic 레이블(income_tier, tenure_stage)과 달리 예측에 비자명한 multi-feature 상호작용을 요구한다.

- **지표:** 평가 지표는 각 태스크의 production 목적에 맞추어 선택하였다. 이진 분류는 AUC(임계값 비의존적, 불균형 강건)를 사용한다. 분류 멀티클래스(segment_prediction, 4개 클래스)는 F1-macro를 사용한다. 추천 멀티클래스(nba_primary — 7개 상품 그룹, next_mcc — top-50 MCC)는 NDCG@K 및 top-K accuracy [18] 를 사용하여 표준 추천 시스템 평가 관행을 따른다. 회귀는 MAE를 사용한다. 지표는 태스크 유형별로 보고하며, 13개 전체 태스크에 걸친 단일 전역 평균은 사용하지 않는다 — 태스크 유형 간 지표 의미가 상이하기 때문이다.

연구 질문. 본 어블레이션 연구는 다음 6가지 연구 질문을 다룬다:

- **RQ1:** 각 이종 전문가가 DeepFM baseline에 추가될 때 개별적으로 기여하는가? (bottom-up)
- **RQ2:** 어떤 전문가가 필수적인가 — 전체 모델에서 제거 시 성능이 저하되는가? (top-down)
- **RQ3:** 13-task 규모에서 게이트 유형(softmax / sigmoid / shared-bottom)과 태스크 간 전이(없음 / adaTT / GradSurgery)는 어떻게 상호작용하는가?
- **RQ4:** 어떤 전문가가 집계 메트릭에서 beneficial vs. negative transfer를 보이는가?

- **RQ5:** CGC 게이트 가중치가 비즈니스 의미를 갖는 라우팅 신호로 해석 가능한가?
- **RQ6:** 동질 MoE 문헌에서 보고된 라우팅 붕괴(routing collapse)가 발생하는가?

5.3 피쳐 + 전문가 결합 어블레이션 (RQ1 + RQ2)

상향식 어블레이션은 DeepFM 베이스라인에 전문가 1개(대응 피쳐 생성기 포함)를 추가하고, 하향식 어블레이션은 8-전문가 전체 모델에서 전문가 1개를 제거한다. 평균 F1m은 segment_prediction(F1-macro)만 포함하며, nba_primary와 next_mcc는 태스크별 보고에서 NDCG@3/Acc@3를 사용한다.

전문가 기여도 분석(Table 8)은 세 가지 패턴을 드러낸다. 모든 시나리오는 adaTT 비활성화 상태에서 PLE softmax 게이트를 사용한다.

합성 데이터에서 개별 전문가의 집계 AUC 기여는 제한적 차별성을 보인다. 8-전문가 전체 모델(AUC 0.6724)이 DeepFM 단독(0.6718) 대비 +0.0006 향상에 그치며, 태스크 유형별 기여(다중클래스 NDCG, 회귀 MAE)는 개별 지표 분석이 필요하고 실제 행동 패턴이 있는 운영 데이터에서 차별화될 것으로 예상된다. 상향식에서 LightGCN이 가장 큰 AUC 향상(DeepFM 베이스라인 대비 +0.0015)을 제공하는 반면, 하

시나리오	평균 AUC	평균 F1m	평균 MAE	Val Loss
베이스라인				
Full (7 전문가, PLE softmax)	0.6724	0.2010	0.9596	25.72
DeepFM only	0.6718	0.2031	0.9591	25.74
상향식: DeepFM + 단일 전문가 (AUC 내림차순)				
DeepFM + LightGCN	0.6733	0.2000	0.9598	25.75
DeepFM + HGCN	0.6725	0.1980	0.9577	25.74
DeepFM + PersLay (TDA)	0.6723	0.2025	0.9603	25.72
DeepFM + Temporal	0.6720	0.2015	0.9593	25.70
DeepFM + Causal	0.6715	0.1609†	0.9587	25.74
DeepFM + OT	0.6714	0.1596†	0.9591	25.75
하향식: Full에서 전문가 1개 제거 (AUC 내림차순)				
Full - LightGCN	0.6727	0.2016	0.9594	25.74
Full - PersLay	0.6726	0.2012	0.9582	25.73
Full - Temporal	0.6725	0.2012	0.9596	25.71
Full - HGCN	0.6724	0.2014	0.9586	25.72
Full - Causal	0.6724	0.2010	0.9617	25.73
Full - OT	0.6721	0.2020	0.9591	23.60

Table 8: 피쳐 + 전문가 결합 어블레이션 결과. 굵게 = 그룹 내 최고값. †segment_prediction 음전기로 인한 F1-macro 이상 하락 표시.

향식에서는 단일 전문가 제거로 AUC가 DeepFM 단독 수준 이하로 하락하지 않는다.

Causal 및 OT 전문가는 segment_prediction에서 음전이를 유발한다. DeepFM+Causal과 DeepFM+OT 양쪽에서 F1-macro가 -0.04 하락하며(표에 †로 표시), 이는 전적으로 segment_prediction F1이 0.40에서 0.28로 붕괴한 데 기인한다. 구조적으로 상이한 두 전문가(NOTEARS DAG vs. Sinkhorn Wasserstein)에서 동일한 하락폭이 나타나는 것은 softmax 게이트 재분배 효과를 시사한다.

HGCN 제거는 nba_primary 순위를 저하시킨다. 집계 AUC는 영향을 받지 않으나, 태스크별 분석에서 HGCN 제거 시 nba_primary NDCG@3가 -0.015 하락하며 — 하향식 어블레이션에서 가장 큰 태스크별 성능 저하로, 상품 계층 인코딩이 추천 순위에 필수적임을 확인한다.

5.4 태스크 × 구조 교차 어블레이션 (RQ3)

9개 구조 변형을 세 가지 차원에서 비교한다: 게이트 유형 (shared-bottom / softmax / sigmoid), 태스크 간 전이(없음 / adaTT 손실 수준 / GradSurgery 그래디언트 수준), 불확실성 가중치(모든 변형에서 태스크별 loss_weight가 학습된 정밀도 위에 적용되는 수정된 구현 사용). 모든 변형은 7개 이종 전문가 바스켓 전체와 10 에포크, 배치 크기 5632, AMP 활성화를 사용한다. 평균 AUC는 이진 태스크만 포함하

며, NDCG@3는 nba_primary(7-class 상품 추천)에 대해 보고한다; 평균 F1m은 다중클래스 태스크, 평균 MAE는 회귀 태스크를 포함한다. 결과는 Table 9에 제시된다.

구조 어블레이션에서 세 가지 발견이 도출된다.

발견 1: 이종 MTL에서 PLE softmax가 sigmoid를 능가한다. 이는 동질적 태스크 PLE 문헌 [41]에서 비경쟁적 전문가가 가중치를 위해 sigmoid 게이트가 선호되던 통념을 역전시킨다. 이진 7개 + 다중클래스 3개 + 회귀 3개로 구성된 13개 태스크 환경에서, softmax의 경쟁적 선택은 전문가 할당을 격리하여 소수 유형 태스크(다중클래스)를 이진 태스크 그라디언트의 오염으로부터 보호한다. 특히, 불확실성 가중치가 두 게이트 유형에서 동일한 값으로 수렴하여(nba_primary: 0.335), 성능 향상이 순전히 구조적임을 확인하였다.

발견 2: adaTT 손실 수준 전이는 13-태스크 규모에서 null 효과를 보인다. 표 캡션에 명시된 5개 포팅 버그 수정 후, adaTT 추가 시 AUC 변화는 -0.001에 불과하다(sigmoid+adaTT 0.6717 vs. sigmoid 단독 0.6728; softmax+adaTT 0.6722 vs. softmax 단독 0.6730). 다른 지표도 단일 seed 측정 노이즈를 벗어나지 않는다. 초기 드래프트가 보고한 -0.019 AUC 저하는 이제 손실 수준 전이의 알고리즘적 특성이 아닌 위 5개 구현 버그에 기인함이 확인된다(당시 추정 원인은 156 태스크 쌍 친화도 추정 한계였다). 따라서 본 연구의

변형	평균 AUC	최고 NDCG@3	최종 NDCG@3	평균 F1m	평균 MAE
게이트 유형 비교 (태스크 간 전이 없음)					
Shared Bottom	0.6711	0.7014	0.6831	0.2007	0.9602
PLE Softmax	0.6729	0.7144	0.6814	0.2009	0.9598
PLE Sigmoid	0.6728	0.7131	0.6820	0.2021	0.9601
adaTT 손실 수준 전이 (수정본)†					
SB + adaTT	0.6708	0.7048	0.6791	0.1999	0.9606
Sigmoid + adaTT	0.6717	0.7127	0.6646	0.2013	0.9598
Softmax + adaTT	0.6722	0.7022	0.6856	0.2015	0.9597
GradSurgery 그래디언트 수준 투영‡					
SB + GradSurgery (실험)	0.6704	0.6963	0.6860	0.1986	0.9614
Softmax + GradSurgery (실험)	0.6726	0.6918	0.6830	0.2027	0.9588
Sigmoid + GradSurgery (실험)	0.6721	0.6888	0.6811	0.2020	0.9603

Table 9: 13개 태스크 벤치마크(이진 7개 + 다중클래스 3개 + 회귀 3개)에서의 구조 어블레이션. 평균 AUC = 이진 태스크만; NDCG@3 = nba_primary (7-class 상품 추천); 평균 F1m = 다중클래스 태스크; 평균 MAE = 회귀 태스크. 굵게 = 게이트 비교 내 지표별 최고값. †adaTT 행은 온프레임 포팅 과정에서 유입된 5개 구현 버그(gradient 추출 빈도, adaTT config 로더 경로, freeze_epoch 전달, uncertainty-weighting 순서, warmup_epochs 기본값)를 식별·수정한 후의 수치이다. 초기 드래프트는 수정 전 Sigmoid+adaTT AUC 0.6541 및 -0.019 AUC 저하를 보고했으나, 본 수치가 수정본 결과이다. ‡GradSurgery 시나리오는 retain_graph VRAM 오버헤드로 인해 배치 크기 4096 사용 (기존 5632 대비).

손실 수준 그래디언트-코사인 변종은 13-태스크 규모에서 도움이 되지도 해롭지도 않다: 보조 loss 가중치가 만들어내는 전이 신호가 PLE 단독 기준선 대비 **0과 구별할 수 없는 수준**이다. 이 결과를 [22] 의 표현 수준 adaTT에 대한 negative 결과로 일반화해서는 안 된다. 그 메커니즘은 전문가 activation에 대해 학습된 게이팅으로 융합 가중치를 end-to-end로 결정하는 별개 알고리즘이며(4.5절 참조) 본 연구에서 직접 평가하지 않았다. 직접 비교는 후속 연구로 미룬다.

발견 3: 불확실성 가중치 수정이 아키텍처 변경보다 더 큰 성능 향상을 가져온다. 가장 큰 단일 성능 향상(NDCG@3 +0.018, F1-macro +0.031)은 게이트 유형이나 전이 메커니즘이 아닌, 불확실성 가중치 활성화 시 태스크별 `loss_weight`가 묵시적으로 무시되던 미묘한 구현 격차를 수정한 것에서 비롯되었다. 이 발견은 이종 MTL에서 손실 균형 정확성이 아키텍처적 정교함을 압도할 수 있음을 강조하는 — 아키텍처 중심 논문에서 간과되기 쉬운 실용적 교훈이다.

5.5 전문가 기여도 분석: 유익 vs. 부정적 전이 (RQ4)

전체 모델에서 각 전문가를 개별적으로 제거했을 때 성능 변화를 평가한다(베이스라인 AUC = 0.6724, `joint_full` 10-에포크). 양의 ΔAUC 는 해당 전문가가 부정적 전이를 유발함을 나타내며, 음의 ΔAUC 는 유익함을 나타낸다. 합성 데이터 한계로 크기가 작으며(< 0.001), 실제 행동 신호가 있는 운영 데이터에서는 전문가 차별화가 더 뚜렷할 것으로 예상된다. 결과는 Table 10에 요약된다.

제거된 전문가	ΔAUC	해석
-LightGCN	+0.0003	미미한 부정적 전이
-PersLay	+0.0002	미미한 부정적 전이
-Temporal	+0.0001	무시할 수준
-Causal	+0.0001	무시할 수준
-HGCN	0.0000	중립
-OT	-0.0004	미미한 유익

Table 10: 전문가 기여도 분석: 전체 8-전문가 모델(AUC = 0.6724) 대비 ΔAUC . top-down 어블레이션 결과에서 산출.

전문가별 ΔAUC 크기는 모두 작으며(< 0.001), 이는 합성 벤치마크가 전문가를 차별화하는 능력이 제한적임을 반영한다. 이 거의 균일한 결과는 세 가지 차원에서 신중하게 해석해야 한다.

합성 데이터 한계. LightGCN과 PersLay(TDA)의 미미한 부정적 전이는 합성 벤치마크의 데이터 특성에 기인한다. 합성 거래 시퀀스에는 진정한 협업 신호와 위상적 패턴이 없다 — MCC 코드는 페르소나 가중 분포와 점착성으로 생성되지만, 계절성, 생애 이벤트 트리거, 소비 레짐 전환(`spending regime changes`)과 같은 실제 행동 역학은 포함하지 않는다. 전문가의 귀납적 편향(그래프 협업 필터링, 위상적 지속성)과 일치하는 신호가 데이터에 없을 때, 해당 전문가는 공유 표현에 노이즈를 주입한다. 진정한 행동 시퀀스가 예측 신호를 담고 있는 운영 데이터에서는 이러한 전문가의 기여가 실질적으로 달라질 것으로 예상된다.

단일 지표 시각지대. 집계 AUC는 이진 7개 태스크를 평균화하며, 다중클래스 순위(NDCG@3)나 회귀(MAE) 기여를 포착하지 못한다. 전문가가 이진 AUC를 낮추면서 다중클래스나 회귀 성능을 개선할 수 있으며, 이는 집계에서 보이지 않는다. 전문가가 불필요한지 결론 내리기 전에 태스크 유형별 분석이 필요하다.

비대칭성의 진단적 가치. 가장 중요한 관찰은 어떤 전문가가 해롭냐가 아니라, 이종 설계가 이러한 진단을 가능하게 한다는 점이다. 동질적 MLP 전문가 풀은 균일하고 비차별적인 성능 저하를 보일 것이다. 이종 바스켓은 실행 가능한 진단을 제공한다: “LightGCN은 집계 AUC에서 미미한 부정적 전이를 보이지만, HGCN은 집계 이진 AUC 효과가 중립임에도 `nba_primary` 순위(NDCG@3)에 필수적이다”는 진술이 아키텍처 결정에 직접 반영될 수 있다.

5.6 설명 가능성 분석 (RQ5)

CGC 게이트는 해석 가능한 라우팅 가중치를 생성하여 태스크별 “어떤 전문가가 얼마나 기여했는지”를 직접 귀인할 수 있게 한다. 권장 softmax 구성에서 가중치의 합은 1이 되어 상대적 기여를 직접 비교할 수 있다. 13개 전체 태스크에 걸쳐 태스크별 게이트 가중치 분포를 조사하여 (a) 어떤 전문가가 어떤 태스크 유형을 지배하는지, (b) 학습된 라우팅이 도메인 직관과 일치하는지(예: 이탈 예측에서 시계열 전문가의 높은 가중치, 개입 민감 태스크에서 인과 전문가의 높은 가중치) 확인한다.

CGC 추출 레이어의 게이트 가중치는 태스크별 전문가 활용 프로파일을 제공한다. 낮은 엔트로피 비율의 태스크(예: `top_mcc_shift`, 0.347)는 1-2개 전문가에 집중하여 명확한 귀인이 가능하다: 추천은 주로 지배적 전문가의 피쳐 그룹에 의해 주도된다. 높은 엔트로피의 태스크(예:

will_acquire_payments, 0.882)는 다양한 전문가를 활용하므로 다인자 설명이 필요하다. 이 엔트로피 기반 설명 가능성은 금융 DNA 태스크 그룹과 직접 매핑되어, 규칙 기반 폴백(레이어 3)이 태스크별 적절한 설명 템플릿을 선택할 수 있게 한다.

태스크별 게이트 가중치 프로파일과 지배적 전문가 할당의 상세 내용은 아래 게이트 엔트로피 분석(RQ6)에서 제공하며, 라우팅 붕괴와 태스크-전문가 특화를 함께 다룬다.

5.7 에포크 예산 민감도 (RQ4 후속)

로컬 10-에포크 합동 어블레이션(Table 8)은 예상치 못한 순서를 드러냈다: shared_bottom(평균 AUC 0.8139)이 집계 AUC에서 PLE softmax(0.7980)를 앞서며, v13 프로토타입의 PLE 우위 서사와 상충하는 결과였다. 세 가지 경쟁 가설을 검토하였다: **(A) 신호 정제로 인해 게이트 라우팅이 불필요해졌다, (B) PLE+CGC 게이트가 수렴하기까지 10 에포크를 넘는 학습이 필요하다, (D) 게이트 파라미터가 도움보다 빠르게 과적합한다.**

네 개 핵심 시나리오(shared_bottom, PLE-softmax, PLE-full = sigmoid+CGC+GTE+LT+HMM-projectors, PLE-full+adaTT)를 ml.g4dn.2xlarge 위에서 동일한 하드웨어, 동일한 fp32 DuckDB 스트리밍 파이프라인(3.4절 메모리 예산)으로 **10 에포크와 15 에포크 모두** 재실행하여 결과를 SageMaker 에서 확보하였다. 일치된 10-에포크 컬럼은 fp64 pq.read_table 로컬 베이스라인과 fp32 SageMaker 파이프라인 사이의 정밀도 경로 드리프트를 분리하여 에포크 예산 효과만을 격리한다. 결과는 Table 11 에 정리된다.

변형	Local 10ep AUC	SM 10ep AUC	SM 15ep AUC	Δ AUC (15ep-10ep)	SM val_loss
shared_bottom	0.8139	0.8197	0.8015	— 0.0182	17.64
PLE softmax	0.7980	0.8233	0.8249	+ 0.0016	17.09
PLE full (sigmoid + 5개 토클)	—	0.8216	0.8203	— 0.0013	17.43
PLE full + adaTT	0.8200	0.8223	0.8213	— 0.0010	17.60

Table 11: 에포크 예산 민감도, v14 phase0 (1M행). Local 10ep: RTX 4070 fp64 pq.read_table. SM 10ep / 15ep: ml.g4dn.2xlarge fp32 DuckDB-stream. Δ AUC 는 SageMaker 상에서 일치된 15—10 차이를 비교한다. PLE 4개 변형 모두 10-15 에포크 사이 plateau ($|\Delta$ AUC| < 0.002) 에 도달하며, shared_bottom 만 —0.0182 의 강한 과적합을 보인다 — 이 데이터셋의 architecture-class 시그니처이다.

일치된 쌍 비교는 **가설 B**를 기각한다. SageMaker 10 에포크 시점에서 이미 PLE softmax(0.8233)는 shared_bottom(0.8197)을 +0.0036 AUC로 앞서며, 로컬 10ep 의 역전 순서는 fp64 pq.read_table 경로의 부산물이지 PLE 의 에포크 수렴 부족이 아니다. Table 11 가 실제로 드러내는 것은 **가설 D**(과적합 비대칭)이다: shared_bottom 은 10 → 15 에포크에서 —0.0182 AUC 가 떨어지고 val_loss 가 16.58 → 17.64 로 상승하는 반면, PLE softmax 는 사실상 정체한다(+0.0016 AUC, val_loss 16.04 → 17.09). 세 가지 함의를 도출한다.

함의 1: 10-에포크 예산에서 shared_bottom은 조기 종료 또는 정규화가 필요하다. 10 → 15 에포크 사이의 —0.018 AUC 감소와 동반된 val_loss 상승(16.58 → 17.64)은 구속받지 않는 공유 표현이 일반화보다 학습 잡음 암기를 더 빠르게 진행함을 보여준다. 정규화를 인식한 shared-bottom 배포는 조기 종료 epoch 의 체크포인트에 고정되어야 한다.

함의 2: adaTT 손실 수준 전이는 여전히 null 효과를 보인다. PLE-full(+ adaTT)의 AUC 0.8213은 adaTT 없는 PLE-full(0.8203)과 $pm0.001$ 이내에 머문다. 이는 v13 결과(Table 9 의 발견 2)를 보다 긴 15-에포크 예산과 정제된 v14 데이터에서 재확인한 것이다: 손실 수준 그래디언트-코사인 신호는 PLE 단독 베이스라인 대비 무시 가능한 효과만 보인다.

함의 3: 보조 토글 (GTE + LT + HMM-projector) 추가는 집계 AUC 에서 PLE softmax 를 개선하지 않는다. PLE-full(sigmoid + CGC + GTE + LT + HMM-proj) AUC 0.8203은 PLE-softmax 단독 AUC 0.8249 대비 -0.0046 낮다. GTE 단독 추가(PLE-sigmoid-GTE: 0.8214)와 GTE+LT(PLE-sigmoid-GTE-LT: 0.8204)는 softmax 베이스라인 약간 아래에서 평탄선을 그린다. 보조 스택은 본 데이터에서 AUC 이득 없이 복잡도만 누적하므로, 프로덕션은 더 단순한 PLE-softmax 구성으로 출시하고 라우팅 보조 메커니즘은 태스크별 fine-tune 단계로 미루는 편이 합리적이다.

정규화 변형 **PLE-softmax-reg(dropout 0.3, weight_decay 1×10^{-4})**는 AUC 0.8256과 val_loss 16.57로 추가 개선된다(PLE-softmax 0.8249, val_loss 17.09 대비). 이 $+0.0007$ AUC 와 -0.52 val_loss 는 게이트 과적합 가설을 확인한다: 최적 아키텍처 상태에서도 PLE 는 calibration loss 측면에서 여유 공간을 남기고 있으며, 일반적인 정규화가 아키텍처 추가 없이 그 여유를 회수한다.

adaTT 손실 수준 전이는 모든 gate 유형에서 val_loss 를 일관되게 증가시킨다 (Table 12). adaTT 추가는 shared_bottom 에서 val_loss 를 $+0.44$ (17.64 $\rightarrow$ 18.08), PLE-sigmoid 에서 $+1.54$ (16.99 $\rightarrow$ 18.53), PLE-softmax 에서 $+1.93$ (17.09 $\rightarrow$ 19.02) 만큼 끌어올리며, 평균 AUC 는 어느 방향으로도 최대 $pm0.005$ 이내에서만 움직인다. 보조 손실 수준 신호는 따라서 집계 AUC 보상 없이 calibration tail 을 불안정하게 만들며, v13 결과(Table 9 의 발견 2)인 “adaTT 는 이 규모에서 AUC 에 null” 은 더 긴 학습 예산 하에서 **adaTT 는 이 규모에서 val-loss 에 유해하다**로 갱신된다.

기준	Vanilla AUC	+adaTT AUC	Vanilla val_loss	+adaTT val_loss
shared_bottom	0.8015	0.8097	17.64	18.08
PLE sigmoid	0.8240	0.8217	16.99	18.53
PLE softmax	0.8249	0.8197	17.09	19.02
PLE full (sigmoid+5)	0.8203	0.8213	17.43	17.60

Table 12: 15 에포크 SageMaker g4dn.2xlarge 에서의 adaTT 쌍별 비교. 굵게 표시된 항목은 각 행에서 더 나은 선택(더 낮은 val_loss, 더 높은 AUC)을 표시한다. adaTT 는 shared_bottom 과 PLE-full 에서만 AUC 향상을 제공하지만 모든 쌍에서 val_loss 가 증가한다 — PLE-softmax ($+1.93$) 와 PLE-sigmoid ($+1.54$) 에서 가장 심각하다.

5.8 게이트 엔트로피 분석 (RQ6: 라우팅 붕괴가 발생하는가?)

함수 공간 붕괴(이중 전문가에 의해 구조적으로 방지됨)를 넘어, CGC 게이트 가중치가 단일 전문가에 집중될 때 라우팅 붕괴가 발생할 수 있다. 태스크별 게이트 엔트로피를 측정한다:

$$H_t = - \sum_k w_{t,k} \log w_{t,k}$$

여기서 $w_{t,k}$ 는 태스크 t 에 대한 전문가 k 의 게이트 가중치이다. 최대 엔트로피 $\log K$ ($K=7$ 전문가, $\log 7 \approx 1.95$)는 균일한 전문가가 활용을 나타내며, 0에 가까운 엔트로피는 라우팅 붕괴를 나타낸다. 비교 편의를 위해 정규화된 엔트로피 비율 $\frac{H_t}{\log K} \in [0, 1]$ 을 보고한다.

5.8.1 CGC 레이어 게이트 특화

PLE-softmax 체크포인트에서 측정된 결과, CGC 레이어 게이트 가중치는 13개 태스크와 2개 CGC 레이어에 걸쳐 엔트로피 비율 0.33 0.88의 유의미한 태스크 수준 특화를 보인다. 이는 라우팅 붕괴가 발생하지 않았음을 확인한다: 모든 태스크가 다수의 전문가를 활용하면서도, 서로 다른 태스크는 서로 다른 라우팅 패턴을 보인다.

추출 레이어와 어텐션 레이어 라우팅 간의 분기는 구조적으로 시사적이다. 낮은 엔트로피 태스크(top_mcc_shift: 0.347, product_stability: 0.428, segment_prediction 레이어 2: 0.332)는 주로 1-2개 전문가에 집중하며, 이는 해당 태스크가 좁은 분석적 렌즈(예: 시계열 추세 또는 그래

태스크	레이어 1 $\frac{H_t}{\log K}$	레이어 2 $\frac{H_t}{\log K}$	해석
top_mcc_shift	0.347	0.542	단일 전문가 지배
product_stability	0.428	0.705	집중된 라우팅
segment_prediction	0.612	0.332	레이어 2에서 집중
nba_primary	0.877	0.724	다양한 전문가 활용
will_acquire_payments	0.882	0.688	다양한 전문가 활용
CGC 어텐션 (전체 태스크)	1.000	1.000	균일 (미분화)

Table 13: 태스크별 CGC 게이트 엔트로피 비율 ($H_t / \log K$, 높을수록 균일). 낮은 엔트로피 태스크는 1-2개 전문가에 집중하며, 높은 엔트로피 태스크는 전문가 바스켓 전체에서 폭넓게 활용한다. CGC 어텐션 가중치는 전체 태스크에 걸쳐 완전히 균일하여, 전문가 선택이 어텐션 집계 레이어가 아닌 추출 레이어에서 작동함을 나타낸다.

프 구조 단독)로 해결됨을 시사한다. 높은 엔트로피 태스크 (will_acquire_payments: 0.882, nba_primary: 0.877)는 전문가 바스켓 전체에서 폭넓게 활용하며, 이는 다수의 행동 신호를 동시에 통합하는 다음 최적 행동 및 결제 획득 태스크의 특성과 일치한다.

주목할 점은 CGC 어텐션 가중치가 전체 태스크와 두 레이어에서 완전히 균일하게(엔트로피 비율 = 1.000) 유지된다는 것이다. 이는 어텐션 집계 메커니즘이 분화되지 않았음을 나타내며, 기능적으로 전문가 출력의 단순 평균과 동등하다. 이는 모델이 의미 있는 라우팅을 수행하기 위해 추출 레이어 게이트에 의존하는 반면, 어텐션 메커니즘은 잔차 혼합 레이어로 기능함을 시사한다. 향후 연구에서는 파라미터 중복성 감소를 위해 어텐션 집계를 정규화하거나 제거하는 방안을 검토할 수 있다.

6 논의

6.1 주요 발견 요약

어블레이션 실험에서 다음의 주요 발견을 도출하였다. 아래 다섯 가지 항목은 시스템 수준의 결과 요약이다. 가설 A-E (신호 정제, 에포크 예산, 앙상블, 게이트 과적합, 정규화) 전반의 가설 판별, 13-태스크 모두에 대한 v14 phase0 태스크별 수치, 9-way fusion 메커니즘 비교 (BRP-detached, NEAS, M1 complement, ECEB, AdaTT-sp), 그리고 30-에포크 손실-지표 분리 진단을 모두 수반한 전체 어블레이션 표가 필요한 독자는 companion Paper 3 (Findings 1-7) 을 참조한다. 본 Paper 1의 결론은 그곳의 분석에 근거한 시스템 수준 요약이다.

손실 균형 정확성이 아키텍처 선택을 압도한다. 모든 실험에서 가장 큰 단일 성능 향상은 불확실성 가중치(Kendall et al.)의 미묘한 구현 격차를 수정한 것에서 비롯되었다. 파이프라인 설정에서 제공된 태스크별 loss_weight가 묵시적으로 무시되던 것을 수정한 공식 — $\text{loss_weight} \times (\text{precision} \times L$

$+ \log_var)$, $\log_var$ 는 $[-4, 4]$ 로, precision은 $[10^{-3}, 100]$ 으로 클램핑 — 은 온프레임 참조 구현과 일치하며, shared-bottom 기준선 단독에서 NDCG@3 +0.018, F1-macro +0.031을 달성하였다. 이는 혼합 손실 유형을 가진 이중 MTL에서 손실 가중치를 올바르게 설정하는 것이 아키텍처적 정보보다 중요함을 강조한다.

이중 MTL에서 softmax 게이팅이 sigmoid를 능가한다. 이 발견은 PLE 문헌 [41] 및 최근 sigmoid MoE 연구 [30]에서의 sigmoid 게이팅 선호도를 뒤집는다. 13개 태스크(이진 7개 + 다중클래스 3개 + 회귀 3개)를 다루는 환경에서, softmax의 경쟁적 전문가 선택은 전담 전문가를 할당하여 다중클래스 태스크를 보호하는 반면, sigmoid의 협력적 혼합은 이진 태스크 그래디언트가 다중클래스 관련 표현을 오염시키도록 허용한다. 효과는 지표별로 다르다: softmax가 NDCG@3에서 우세(shared-bottom 대비 +0.013)하고, AUC에서는 sigmoid와 거의 동일하다. 이 역전은 태스크 유형 이중성에 기인한다: 모든 태스크가 동일한 손실 유형을 공유하는 경우(기존 연구)에는 협력적 혼합이 유익하지만, 손실 유형이 근본적으로 다른 경우에는 경쟁적 격리가 보호적이다.

손실 수준 전이(adaTT)는 13개 태스크 규모에서 측정 가능한 이득이 없다. 표 Table 9 캡션의 5개 포팅 버그를 수정한 후, adaTT 유/무의 AUC 변화는 양쪽 게이트 유형(sigmoid, softmax) 모두 -0.001에 그치며, 단일 seed 측정 노이즈 범위 내이다. 메커니즘 — 그래디언트 코사인 유사도로 $w_{i \rightarrow j}$ 를 추정된 가중 보조 손실 $L_i^{\text{adaTT}} = L_i + \lambda \sum_{j \neq i} w_{i \rightarrow j} L_j$ 추가 — 이 만들어내는 전이 신호는 PLE 단독 기준선과 **0에서 구별되지 않는다**. 초기 드래프트는 -0.019 AUC 저하를 보고하며 156 태스크 쌍 친화도 추정 한계에 귀인하였으나, 버그 수정 후 효과가 사라졌으므로 그 귀인은 본 데이터에서 더 이상 지지되지 않는다. 정직한 결론은 운영적이다: 13-태스크 이중 환경에서 그래디언트-코사인 손실 수준 변종(TAG [10] +

GradNorm [6] 에 가까운)은 도움도 해도 되지 않으며, 계산 비용만 추가하므로 비활성화해도 무방하다. [22] 의 표현 수준 adaTT는 전문가 activation에 대해 학습된 게이팅으로 융합 가중치를 end-to-end로 결정하는 별개 메커니즘으로 본 연구에서 직접 평가하지 않았으며, 그 비교는 후속 연구로 미룬다. 손실 수준 adaTT 를 일곱 개의 다른 fusion-augmentation 메커니즘 (AdaTT-sp, M1 complement, ECEB, BRP-MV, BRP-detached, NEAS, NEAS+BRP-detached) 과 함께 비교한 9-way 어블레이션은 companion Paper 3 의 Finding 7 에 보고되어 있으며, v14 결론은 disjoint axes 위의 두 비자명 recipe (M1 complement, NEAS) 만 추출하고 손실 수준 adaTT 의 null verdict 를 재확인한다.

대안으로서의 GradSurgery: 그래디언트 수준 투영. 손실 수준 전이의 한계를 해소하기 위해 태스크 유형 그래디언트 서저리(GradSurgery)를 실험하였다. 이는 손실 수준 전이를 그래디언트 수준 충돌 해소로 대체한다. 156개 쌍별 친화도를 추정하는 대신, GradSurgery는 태스크 그래디언트를 3개 유형 그룹 (이진, 다중클래스, 회귀)으로 집계하고 충돌하는 그룹 사이에만 PCGrad 방식의 투영을 적용한다. 이는 추정 문제를 태스크 수에 대해 $O(k^2)$ 에서 $O(3^2) = O(1)$ 로 축소한다. Softmax+GradSurgery는 AUC 0.6726(softmax 단독 0.6729 대비), 전체 변형 중 최고 F1-macro(0.2027)와 최저 MAE(0.9588)를 달성하였으나, 최고 NDCG@3(0.6918)는 softmax 단독(0.7144)보다 낮다. GradSurgery도 성능을 저하시키지 않으나, 수정된 adaTT와 마찬가지로 PLE softmax 단독 대비 의미 있는 개선을 보이지 않는다. retain_graph 오버헤드가 12GB GPU에서 배치 크기를 제약하며, NDCG 격차는 그래디언트 수준 투영이 PLE의 표현 수준 게이팅 라우팅이 제공하는 순위 신호를 완전히 포착하지 못할 수 있음을 시사한다. 따라서 GradSurgery는 프로덕션에 채택하지 않았다. 가장 강력한 구성은 전이 메커니즘 없는 PLE softmax로 남는다.

운영적 동기 검증. shared-bottom 기준선(AUC 0.6711, NDCG@3 0.7014)이 13개 태스크 모두에서 태스크별 XGBoost 상한을 이미 초과하여, MTL 통합의 운영적 동기를 검증하였다: 단일 모델이 성능 손실 없이 13개 개별 모델을 대체하여 통합 학습서빙·모니터링을 가능하게 한다. PLE softmax는 추가적인 서빙 비용 없이 점진적 향상(NDCG@3 +0.013)을 제공한다.

6.2 학습 동역학: 손실-지표 분리와 에포크 선택

30 에포크 학습 실험(코사인 LR, $T_0 = 10$, 워밍 재시작)은 이중 MTL에서의 최적 모델 선택에 실용적 시사점을 가지는 검증 손실과 판별 지표 간의 체계적 분리를 드러낸다.

참고: 이 30-epoch 진단 실험은 표 8-9에 보고된 10-epoch 어블레이션 결과와 별개이다. 수렴 동역학 분석을 위해 수행되었으며, 보고된 어블레이션 수치에는 영향을 주지 않는다.

관찰: 지표는 에포크 30이 아닌 에포크 10에서 정점. 검증 손실은 30 에포크 전체에 걸쳐 단조적으로 감소하여 (32.11 → 22.68, -29.4%), 표준 조기 종료 기준으로는 학습이 계속 진행되고 있음을 시사한다. 그러나 판별 지표는 에포크 10에서 정점을 찍고 이후 하락한다: AUC는 에포크 10에서 정점(0.6726)에 도달하고 에포크 30에서 0.6687로 하락(-0.4pp), NDCG@3는 에포크 10에서 정점(0.6976)에 도달하고 에포크 30에서 0.6673으로 하락(-3.0pp).

메커니즘: 손실 함수에 대한 회귀 태스크 지배. 집계 검증 손실은 이진 교차 엔트로피 크기 대비 큰 MAE 값을 생성하는 세 개의 회귀 태스크에 의해 지배된다. 지속적인 학습은 회귀 MAE를 실질적으로 개선하지만 (에포크 30에서 0.9596 → 0.9580), 분류 및 순위 태스크에서 합성 벤치마크 노이즈에 대한 과적합을 대가로 치른다. 벤치마크의 수식 기반 피쳐-레이블 관계는 에포크 10에 의해 완전히 학습되며, 이후 에포크는 판별 지표에 대응물이 없는 잔차 노이즈에 과적합한다.

코사인 LR 재시작이 효과를 증폭. $T_0 = 10$ 을 사용한 코사인 스케줄은 사이클 경계(에포크 11, 20, 29)에서 급격한 지표 진동을 유발한다: 학습률이 급상승하고 게이팅 가중치가 축적한 표현 정렬을 교란할 때마다 NDCG@3가 갑자기 하락한다. 이는 코사인 워밍 재시작이 손실 고원 탈출에는 유익하지만, 이중 환경에서 순위 관련 표현을 주기적으로 손상시킬 수 있음을 시사한다.

시사점: 최적 모델 선택을 위한 복합 지표. 태스크 유형이 이중적이고 회귀 손실이 지배하는 경우, 검증 손실만으로는 신뢰할 수 있는 조기 종료 기준이 되지 않는다. 최소 val_loss 대신 복합 지표 — 예: $\alpha \cdot \text{AUC} + \beta \cdot \text{NDCG@3} + \gamma \cdot (1 - \text{MAE})$ — 를 사용하여 최적 체크포인트를 선택하는 것을 권장한다. 본 설정에서 이는 에포크 30 대신 에포크 10을 선택하는 것에 해당하며, +0.4pp AUC와 +3.0pp NDCG@3를 회복한다.

6.3 실용적 합의

자원 제약 환경에서의 개발. 본 시스템은 전용 ML 인프라 예산 없이, 단일 데스크톱 GPU에서, AI 개발 에이전트의 지원을

받는 3인 팀에 의해 구축되었다. 이는 복잡한 멀티태스킹 추천 시스템이 더 이상 대규모 ML 팀과 GPU 클러스터를 보유한 조직만의 전유물이 아님을 입증한다. 핵심 동인은: (1) 코드 변경을 최소화하는 config 기반 아키텍처, (2) 인간의 아키텍처적 지도 하에 병렬 구현 태스크를 처리하는 AI 에이전트, (3) 파라미터 규모가 아닌 구조적 편향을 통해 표현력을 달성하는 이중 전문가 설계, (4) GPU 서버 비용을 제거하는 지식 종류.

프로덕션 ML에서 공격보다 수비. 금융 추천 서비스에서는 AUC를 더 높이는 것보다 운영 임계치 이상을 유지하는 것이 훨씬 중요하다. 이중 전문가 설계는 이러한 수비적 자세를 직접 지원한다: 우아한 성능 저하(어블레이션에서 단일 전문가가 단일 실패점이 아님을 확인), 드리프트 감지 시 자동 재학습 트리거, 그리고 fidelity 안전 floor와 --force-promote 운영자 오버라이드를 갖춘 오프라인 ModelCompetition 유의성 검정을 통해 champion 교체 가능 여부를 결정하는 champion-challenger 게이트(모든 판정은 HMAC 서명된 감사 체인에 기록) 등이 그것이다. 이 아키텍처는 더 좋아지는 것보다 나빠지지 않는 것을 우선시하며, 이는 모델리스크관리와 운영 회복력을 강조하는 금융 규제기관의 관점과 일치한다.

피처 엔지니어링 철학. 본 연구에서 도출되는 심층적 교훈은 무엇을 관찰할 것인가가 어떻게 모델링할 것인가보다 중요하다는 점이다. 이중 전문가 아키텍처가 효과적인 것은 아키텍처의 새로움만이 아니라, 각 전문가가 고객에 대한 **특정 질문**을 묻는 피처와 짝을 이루기 때문이다: “소비가 반감기를 가지고 감쇄하는가?” (화학 반응속도론), “상품 채택이 전염처럼 확산되는가?” (SIR 역학), “소득이 항상적인가 일시적인가?” (Friedman 항상소득가설 [12]). 모델은 단지 이러한 질문에 대한 답을 결합할 뿐이다. 질문이 기존 통계 수준에 머물면 — 평균, 분산, 추세 — 아무리 정교한 아키텍처라도 고객 행동의 구조적 복잡성을 포착할 수 없다. 이는 종종 전처리로 취급되는 다학제적 피처 엔지니어링이 일급 아키텍처 설계 결정으로 격상될 자격이 있으며, 각 피처 그룹을 소비할 전문가 유형과 공동 설계되어야 함을 시사한다.

금융 분야를 넘어선 일반화 가능성. 본 연구는 금융 상품 추천을 대상으로 하지만, 기저 원리 — 이중 전문가를 통해 단일 사용자를 다수의 관점에서 동시에 이해하는 것 — 는 다면적 사용자 모델링이 필요한 모든 도메인에 적용 가능하다. 의료(진단 + 치료 + 위험 + 생활양식), 교육(지식 수준 + 학습 스타일 + 참여도 + 진로), 보험(위험 평가 + 상품 적합성 + 보험금

예측 + 유지) 모두 구조적으로 유사한 과제에 직면한다: 동일 개인에 대한 다수의 상호 의존적 예측 태스크로, 서로 다른 분석적 렌즈가 서로 다른 측면을 포착한다. 이중 전문가 PLE 패턴은 이러한 도메인으로 일반화될 것으로 기대하며, 도메인별 전문가 유형이 금융 전문가를 대체하되 붕괴 저항성과 본질적 설명 가능성의 구조적 이점은 유지될 것이다.

설계 반복에서 얻은 교훈. 최종 아키텍처는 반복적인 시도와 기각을 거쳐 도출되었다. 첫 번째 후보인 Black-Litterman 베이저안 모델 결합은 혼합된 사후분포가 개별 모델의 기여도를 불투명하게 만들어, 프로젝트 전체를 이끄는 설명 가능성 요건에 부합하지 못해 기각되었다. 두 번째 후보인 N-모델 앙상블은 N배의 관리 부담으로 기각되었다. 이러한 실패가 핵심적 리프레이밍으로 이어졌다: 전문가를 모델 밖에서 결합하는 것이 아니라 단일 모델 안에서 결합하는 것.

초기 어블레이션(불확실성 가중치 수정 이전)에서는 sigmoid가 softmax를 능가하였고, 이는 softmax 경쟁이 이중 전문가에게 해롭다는 NeurIPS 2024 연구 결과 [30]를 확인하는 것처럼 보였다. 그러나 손실 가중치 구현을 수정한 후, softmax가 역전하여 주요 순위 지표(NDCG@3)에서 sigmoid를 능가하였다. 이는 **손실 균형 버그가 아키텍처적 발전으로 위장할 수 있음**을 보여주는 — MTL 실무자를 위한 경계 교훈이다.

특히 교훈적인 실패 사례가 있다: 설정 버그로 인해 PLE가 비활성화되어 7개 전문가 바스켓을 단일 MLP로 축소시켜, 해당 초기 실행의 모든 어블레이션 시나리오가 동일한 AUC(0.913)를 산출하였다.³ 이는 체계적 결과 비교를 통해서만 발견되었으며, 어블레이션 결과는 결론 도출 전에 반드시 예상 변동량 대비 검증되어야 한다는 원칙을 재확인시켰다.

인프라 선택: LLM 서버를 넘어 GPU ROI 확장. 금융기관은 GPU 인프라에 대한 투자를 늘리고 있지만, 주로 생성형 AI 워크로드 — 챗봇, 문서 요약, LLM 기반 고객 서비스 —를 위한 것이다. 추천 모델 학습은 여전히 대부분 CPU 기반(XGBoost, LightGBM)으로 수행되어, LLM 추론 외 시간에는 GPU 용량이 활용되지 않는다.

본 연구의 아키텍처는 LLM 서버를 위해 이미 배포된 동일한 GPU 하드웨어가 13-task MTL 학습도 동시에 지원할 수 있음을 입증한다. 단일 소비자용 GPU(RTX 4070)에서 12GB VRAM만으로 충분하다. 이는 추가 하드웨어 구매 없이 기존

³0.913 AUC는 다른 시나리오 수와 데이터 분포를 가진 이전 벤치마크 버전(v4)을 반영하며, 최종 구성(v12)은 AUC 0.67 범위에서 23개 시나리오를 보고한다.

GPU 투자의 수익(ROI)을 확장하며 — 신규 하드웨어 조달에 수개월이 소요되는 기관에서 현실적인 고려사항이다. 온프레미스 GPU가 없는 기관을 위해, 본 연구의 SageMaker + Lambda 서버리스 아키텍처가 대안을 제공한다: GPU 스팟 인스턴스(60~70% 할인)가 학습 시 온디맨드로 프로비저닝되고 완료 즉시 해제되며, 서버는 지식 종류를 통한 LGBM의 CPU 전용 Lambda 함수에서 실행된다(동반 논문에서 상세 설명).

운영 단순성. config 기반 설계(2개의 YAML 파일이 전체 인프라를 제어)는 1-2명의 ML 엔지니어로 시스템 운영을 가능하게 한다. 새로운 상품 카테고리, 태스크, 피쳐 그룹의 추가는 코드 수정이 아닌 설정 변경만으로 가능하다. 이는 각 모델이 자체 학습 파이프라인, 서빙 엔드포인트, 모니터링 대시보드를 가진 별도 관리 포인트인 모델 양상블 접근법과 대비된다.

6.4 한계

- **합성 벤치마크 한계:** 모든 실험은 수식 기반 피쳐-레이블 관계를 가진 100만 고객 합성 벤치마크를 사용한다. 벤치마크가 분산 예산 메커니즘으로 난이도를 제어하고 XGBoost AUC 상한에 대해 검증하지만, 실제 금융 고객 데이터에 존재하는 복잡한 교차 피쳐 상호작용을 재현할 수 없다. 특히 수식 기반 레이블 생성은 전문가 특화의 이점을 과소평가할 수 있다 — 시간적 패턴, 그래프 구조, 인과 경로가 진정으로 다른 신호를 담고 있는 실제 데이터에서는 shared-bottom 대비 PLE의 우위가 더 두드러질 수 있다. 독점적 금융 데이터에 대한 검증은 이후 버전에서 계획되어 있으나, 규제상 데이터 접근 제약으로 인해 본 논문에서는 포함하지 않는다.
- **제한된 에포크 예산에서의 adaTT 평가:** 수정된 adaTT 구현의 null 효과는 부분적으로 10 에포크 학습 예산에 기인할 수 있다. 50+ 에포크에서는 156개 태스크 쌍에 대한 친화도 추정이 충분히 안정화되어 유의한 양의 효과로 이어질 가능성도 있다. 다만 10 에포크 예산은 현실적 제약(단일 GPU의 어블레이션 처리량)을 반영하며, 전이 미적용 변형의 수렴에는 충분하다.
- **단일 GPU 학습:** 현재 구현은 단일 GPU(RTX 4070, 12GB)에서 실행된다. DDP 지원이 아키텍처적으로 설계되었으나 아직 실험적으로 검증되지 않았다.
- **LLM 의존성:** 추천 사유 생성이 LLM 추론에 의존하여 지연 시간과 비용 트레이드오프가 발생한다(동반 논문에서 상세 설명).

6.5 윤리 및 데이터 성명

본 버전의 모든 실험은 **완전 합성 벤치마크 데이터**(Gaussian Copula + 고정 시드 seed=42)를 사용한다. 실제 고객 데이터는 포함되지 않았다. 실제 데이터 검증은 후속 개정판에서 계획되어 있다. 벤치마크 데이터 생성기와 모든 설정 파일은 저장소에 공개되어 있다. 본 시스템은 저위험 체크카드 상품 배포를 대상으로 설계되었으며, 투자 및 보험 상품 추천은 운영 범위에서 명시적으로 제외된다(동반 논문 Section 6.3 참조).

6.6 향후 과제: 스케일 확장 고려사항

현재 아키텍처는 의도적으로 경량 설계되었다 — 각 전문가가는 파라미터를 확장하는 대신 소형 도메인 특화 구조(예: DeepFM의 2계층 MLP, HGNC의 사전 계산 임베딩)를 사용한다. 이는 단순한 자원 제약이 아닌 의도적 설계 선택이다: 구조적 귀납적 편향이 순수 파라미터 수를 대체한다.

전용 GPU 인프라를 갖춘 대형 기관으로 확장 시, 자연스러운 진행 순서는 다음과 같다:

- **데이터 풍부화** — 더 긴 거래 이력, 더 넓은 상품 범위, 더 풍부한 상호작용 신호 — 를 모델 용량 증가보다 우선;
- **전문가별 입력 차원 확장** — 각 전문가의 특화된 귀납적 편향에 공급되는 피쳐 그룹 확대;
- **전문가 깊이/폭 확장** — 개별 전문가 내부 레이어 추가, 특히 Temporal(더 긴 시퀀스 모델링)과 HGNC(더 깊은 계층 인코딩);
- DDP를 통한 **멀티 GPU 학습**(아키텍처적으로 지원되나 아직 미검증).

주목할 점은 전문가 바스켓 크기 확장(더 많은 전문가 유형 추가)보다 개별 전문가 용량 확장이 더 유망하다는 것이다. 이중 설계가 이미 금융 행동에 관련된 주요 수학적 관점을 포괄하고 있기 때문이다.

7 결론

본 연구에서는 금융 상품 추천을 위한 멀티태스크 학습 아키텍처인 이중 전문가 PLE를 제안하였다. 이는 13개의 이중 태스크(이진 7개 + 다중클래스 3개 + 회귀 3개)를 단일 모델로 통합하여, 태스크별 성능을 유지하거나 초과하면서 13개 개별 모델을 대체한다.

본 연구에서 세 가지 기여가 도출된다. **첫째**, FeatureRouter 기반 입력 특화를 갖춘 이중 전문가 바스켓은 비즈니스 해석

가능한 게이트 가중치를 통해 구조적 붕괴 저항성과 본질적 설명 가능성을 제공하며, 사후적 귀인 방법에 의존하지 않는다.

둘째, 13개 태스크 규모에서의 어블레이션을 통해 손실 수준 태스크 간 전이(adaTT)가 온프레임 포팅 과정의 5개 구현 버그를 수정한 후 null 효과를 보임을 확인하였고(−0.001 AUC 변화, 단일 seed 노이즈 범위 내), 가장 큰 단일 성능 향상은 아키텍처 변경이 아닌 손실 균형 수정에서 비롯됨을 밝혔다. 이 발견은 아키텍처적 정교함이 MTL 개선의 주요 레버라는 일반적인 가정에 의문을 제기하며, 손실 가중치의 구현 정확성이 아키텍처 설계와 동등한 면밀한 검토를 받아야 함을 강조한다.

셋째, GradSurgery를 실험하였다. 이는 태스크 간 간섭을 손실 수준이 아닌 그래디언트 수준에서 해소하는 태스크 유형 그래디언트 투영 방법으로, $O(k^2)$ 태스크 쌍 추정 문제를 $O(1)$ 유형 그룹 투영으로 축소한다. GradSurgery는 PLE 단독 성능을 유지하나(F1-macro 0.203 vs. 수정된 adaTT의 0.201) 1차 순위 지표에서 PLE softmax 단독을 초과하지는 못하고(NDCG@3 0.692 vs. 0.714) retain_graph로 인한 VRAM 오버헤드가 상당하여 프로덕션에 채택하지 않았다. 따라서 가장 효과적인 구성은 전이 메커니즘 없는 PLE softmax이며 — 게이팅을 통한 구조적 전문가 격리가 수치적 그래디언트 조작보다 강건함을 입증한다.

이 이중 환경에서 softmax 게이팅이 sigmoid를 능가하며, 동질적 태스크 문헌의 결과를 역전시킨다 — softmax의 소수 유형 태스크(다중클래스)를 다수 유형 그래디언트(이진)로부터 보호하는 격리 효과에 기인하는 결과이다.

아키텍처, 벤치마크 데이터, 어블레이션 프레임워크는 오픈소스로 공개된다.⁴ 동반 논문에서는 하루 파이프라인을 다룬다: LGBM [19] 으로의 지식 종류 [17], 다중 에이전트 추천 사유 생성, 한국 금융감독원 및 EU AI Act 요건에 대한 규제 준수 매핑.

부록

A. 설정 스키마

전체 시스템은 3개 YAML 설정 파일 split-config 로 제어된다: pipeline.yaml (모델 아키텍처, 학습 하이퍼파라미터, 종류, AWS 배포 설정 — 데이터셋 간 공유 설정), feature_groups.yaml (피처 그룹 정의, 생성기 파라미터, 전문가 라우팅 규칙), configs/datasets/{name}.yaml (데이터셋별 태스크 정의, 레이블 파생, 어블레이션 시나리오).

load_merged_config() 가 런타임에 데이터셋 파일을 공통 설정에 deep-merge 한다. 전체 설정 파일은 동반 저장소에서 제공된다.

B. 어블레이션 시나리오 정의

23개 어블레이션 시나리오(14개 결합 피처+전문가 + 9개 구조 교차)는 두 단계로 구성된다:

Phase 1 — 피처 + 전문가 결합 어블레이션 (14개 시나리오):

전체 모델(7 전문가, PLE softmax)과 DeepFM 단독 베이스 라인; 6개 상향식 시나리오(DeepFM + Temporal, HGCN, PersLay, LightGCN, Causal, OT 중 1개, 대응 피처 포함); 6개 하향식 시나리오(전체 모델에서 동일 6 전문가 중 1개 제거).

Phase 2 — 태스크 × 구조 교차 어블레이션 (9개 시나리오):

세 가지 차원에 걸친 9개 구조 변형 — shared-bottom, PLE-softmax, PLE-sigmoid(태스크 간 전이 없음); shared-bottom+adaTT, PLE-softmax+adaTT, PLE-sigmoid+adaTT(손실 수준 전이); 그리고 세 가지 GradSurgery 변형(shared-bottom+GradSurgery, softmax+GradSurgery, sigmoid+GradSurgery) — 모두 13개 태스크 전체와 7개 이중 전문가를 사용하며 10 에포크로 수행.

C. 벤치마크 데이터 생성

합성 벤치마크는 4계층 생성 모델을 사용한다: (1) 5D 연속 잠재 벡터를 가진 6성분 GMM을 통한 잠재 페르소나 (70% 페르소나 조건부, 30% 독립 노이즈); (2) 현실적 상관관계를 보존하는 Gaussian Copula 인구통계; (3) LIST 컬럼으로서의 벡터화된 거래 시퀀스; (4) 사후 노이즈 플리핑(6–8%)을 갖춘 분산 예산 레이블. 시드=42로 재현 가능성을 보장한다. 전체 생성 코드는 동반 저장소에서 제공된다.

D. AMP FP16 NaN 진단 및 GradScaler 튜닝

온프레임 정렬 활성화 함수(ODE 기반 LNN, 선형 HGCN 출력, Softplus TDA 가중치)를 가진 이중 전문가는 동질적 MLP보다 더 넓은 중간값 범위를 생성한다. AMP(FP16)에서 이는 초기 GradScaler 오버플로우를 유발하여 NaN 손실로 이어졌으며 — 기본 GradScaler 설정의 PLE 구성에서 에포크 2부터 관찰되었다. 보고된 모든 실험에서 AMP FP16 학습을 사용하며, 이는 T4/RTX GPU에서 약 2배 처리량을 제공한다. NaN 문제는 세 가지 GradScaler 파라미터 튜닝으로 해결되었다: init_scale=1024(낮은 초기 스케일로 시작 시 오버플

⁴https://github.com/bluethestyle/aws_ple_for_financial

로우 감소), growth_interval=2000(느린 스케일 증가로 오버플로우 이벤트 후 빠른 재상승 방지), max_scale=4096(광범위 전문가 활성화에 대한 폭주 스케일링 방지). 또한 불확실성 가중치 헤드의 태스크별 log-variance 파라미터를 $[-4, 4]$ 로 클램핑하여 Softplus 오버플로우가 손실을 통해 전파되는 것을 방지한다. 이 완화책 적용 후 모든 어블레이션 실행에서 NaN 배치가 관찰되지 않았다.

E. 구조적 동형사상 검증

학제 간 피처 엔지니어링이 “엄밀한 동형사상이 아닌 그럴듯한 유비”일 수 있다는 우려에 답하기 위해, 지배 방정식을 나란히 제시한다:

화학 반응속도론 → 소비 활성화: Arrhenius: $k = Ae^{-E_a/RT}$
여기서 E_a = 활성화 에너지. 소비: $p_{\text{reactivate}} = Ae^{-E_{\text{threshold}}/S}$
여기서 S = 자극 강도. 둘 다 에너지 장벽과 외부 구동력의 함수로서 상태 전이 확률을 기술한다.

SIR → 상품 채택: 역학: $d_t^I = \beta SI - \gamma I$ 채택: $d_t^A = \beta_{\text{exposure}} \cdot U \cdot A - \gamma_{\text{churn}} \cdot A$ 여기서 U = 미채택 고객, A = 채택 고객, β = 접촉/노출률. 구획 역학은 동일하며, 변수명만 바뀐다.

F. 벤치마크 버전 이력

벤치마크는 v12로 수렴하기 전에 네 차례 주요 반복을 거쳤다:

- **v2:** 페르소나와 무관한 균등 무작위 MCC 코드와 고정된 거래 금액으로, MCC 의존 태스크에서 거의 무작위에 가까운 레이블을 산출하였다.
- **v3:** 페르소나 가중 MCC 분포(4-5배 부스트)와 시간적 점착성(30%), 페르소나별 거래 금액, 분위수 기반 spend_level 경계를 도입하였다. MCC 태스크 신호는 개선되었으나 취득 태스크의 레이블 분포는 여전히 거의 균등하였다.
- **v4:** 페르소나 MCC 선호도 강화(8-12배 부스트), 시간적 점착성 60%로 상향, 상품별 취득률 상향 조정(8-12%), top_mcc_shift 감지 윈도우를 30 거래로 확대.
- **v12 (보고됨):** 금융 DNA 축 정렬 상황 변수, obs_frac=0.15의 3차-5차 연속 곱셈적 레이블 상호작용으로 13개 전체 태스크에서 의미 있는 클래스 분포를 생성한다.

저자 기여

정선규 (PM / 총괄 설계자 / 데이터 사이언티스트): 프로젝트 방향 구상, 이종 전문가 아키텍처 및 2축 분해 프레임워크 설계, 구조적 동형사상에 기반한 다학제적 피처 엔지니어링 방법

론 선정, 태스크 그룹 및 규제 준수 매핑 정의, AI 활용 개발 방법론 주도, 논문 작성. 전체 기술 리더십 및 스크럼 기반 신속 피드백 조율.

심은철: 데이터 인제스천 파이프라인, 피처 엔지니어링 구현, 피처 비즈니스 역매핑, 벡터 데이터베이스 파이프라인 관리. 청년 자문위원(서포터즈) 자격으로 참여.

김영찬: 모델 학습, 수학적 검증, 지식증류 구현. 청년 자문위원(서포터즈) 자격으로 참여.

전체 개발 과정은 스크럼 스프린트와 신속 피드백 사이클로 진행되었다.

연구비

본 연구는 외부 연구비, 보조금, 기관 인프라 지원을 일절 받지 않았다. AI 개발 도구(Claude Code, Gemini, Cursor 구독료), 하드웨어 부속기기, 모바일 데이터 통신비, AWS SageMaker 클라우드 학습(Spot 인스턴스), S3 스토리지, 운영 경비 등 모든 비용은 전적으로 제1저자의 개인 자금으로 충당하였다. 개발은 데스크톱 GPU 1대(NVIDIA RTX 4070, 12GB VRAM)로 전용 ML 인프라 예산, 기관 네트워크 지원, 기관 클라우드 컴퓨팅 할당 없이 진행되었다. 데이터 수집은 Spark/Impala에 접근할 수 없는 레거시 HIVE 환경에서 I/O 병목을 극복하기 위한 병렬 쿼리 로직을 자체 설계하여 수행하였다.

감사의 말

항상 업계 상황과 마케팅 관점에서 좋은 아이디어를 제공해준 김연진에게 감사를 표한다.

불철주야 휴일도 저녁도 없이 개발에 헌신해준 두 명의 엔지니어 심은철, 김영찬에게 깊은 감사를 표한다. 정식 고용이나 보상 없이도 프로젝트에 전력을 다해준 이들의 헌신이 이 시스템의 완성을 가능하게 했다.

마지막으로, 기관 지원 없이 3명의 소규모 팀으로 이 연구를 현실화할 수 있게 해준 AI 도구들에 감사를 표한다. Gemini는 아이디어이션과 설계 방향성 논의에서 지칠 줄 모르는 브레인 스토밍 파트너였다. Claude Opus와 Sonnet은 아키텍처를 체계적으로 구축하고, 코드를 구현하고, 미묘한 버그를 진단하고, 아이디어를 글로 옮기는 거의 모든 과정에서 우리와 함께 했다. Cursor는 병목 없이 효율적으로 작업할 수 있는 개발 환경을 제공해주었다. 한 개인의 상상이 공상으로 끝날 수 있었던 것을, 소수의 인원과 이 도구들의 협업이 현실로 만들어주었다. 아키텍처 설계, 도메인 지식, 실험 설계, 연구 방향은 인

간 저자가 주도하였으며, AI 도구들은 이 규모의 작업을 달리 달성할 수 없었을 것을 가능하게 해주었다.

Bibliography

- [1] AI21 Labs. 2024. Jamba: A Hybrid Transformer-Mamba Language Model. arXiv preprint arXiv:2403.19887 (2024).
- [2] Mathieu Carrière, Frédéric Chazal, Yuichi Ike, Théo Lacombe, Martin Royer, and Yuhei Umeda. 2020. PersLay: A Neural Network Layer for Persistence Diagrams and New Graph Topological Signatures. *Journal of Machine Learning Research* (2020).
- [3] Rich Caruana. 1997. Multitask Learning. *Machine Learning* 28, 1 (1997), 41–75.
- [4] Ines Chami, Rex Ying, Christopher Ré, and Jure Leskovec. 2019. Hyperbolic Graph Convolutional Neural Networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.
- [5] Wei Chen, Yong Liu, and Hao Zhang. 2024. Deep Learning-Powered Financial Product Recommendation System in Banks: Integration of Transformer and Transfer Learning. *Journal of Organizational and End User Computing* 36, 1 (2024).
- [6] Zhao Chen, Vijay Badrinarayanan, Chen-Yu Lee, and Andrew Rabinovich. 2018. GradNorm: Gradient Normalization for Adaptive Loss Balancing in Deep Multitask Networks. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, 2018.
- [7] Marco Cuturi. 2013. Sinkhorn Distances: Light-speed Computation of Optimal Transport. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2013.
- [8] European Parliament and Council. 2024. Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (AI Act).
- [9] William Fedus, Barret Zoph, and Noam Shazeer. 2022. Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity. *Journal of Machine Learning Research* (2022).
- [10] Christopher Fifty, Ehsan Amid, Zhe Zhao, Tianhe Yu, Rohan Anil, and Chelsea Finn. 2021. Efficiently Identifying Task Groupings for Multi-Task Learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
- [11] Financial Services Commission (Korea). 2024. Financial Sector AI Guidelines.
- [12] Milton Friedman. 1957. *A Theory of the Consumption Function*. Princeton University Press.
- [13] Albert Gu and Tri Dao. 2024. Mamba: Linear-Time Sequence Modeling with Selective State Spaces. (2024).
- [14] Huifeng Guo, Ruiming Tang, Yunming Ye, Zhen-guo Li, and Xiuqiang He. 2017. DeepFM: A Factorization-Machine based Neural Network for CTR Prediction. In *Proceedings of the 26th International Joint Conference on Artificial Intelligence (IJCAI)*, 2017.
- [15] Ramin Hasani, Mathias Lechner, Alexander Amini, and others. 2021. Liquid Time-constant Networks. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2021.
- [16] Xiangnan He, Kuan Deng, Xiang Wang, Yan Li, Yongdong Zhang, and Meng Wang. 2020. LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2020.
- [17] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. 2015. Distilling the Knowledge in a Neural Network. In *NIPS Deep Learning and Representation Learning Workshop*, 2015.
- [18] Kalervo Järvelin and Jaana Kekäläinen. 2002. Cumulated gain-based evaluation of IR tech-

- niques. *ACM Transactions on Information Systems* 20, 4 (2002), 422–446.
- [19] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. 2017. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
 - [20] Alex Kendall, Yarin Gal, and Roberto Cipolla. 2018. Multi-Task Learning Using Uncertainty to Weigh Losses for Scene Geometry and Semantics. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.
 - [21] Jiaxin Li and others. 2024. HoME: Hierarchy of Multi-Gate Experts for Multi-Task Learning at Kuaishou. In *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2024.
 - [22] Yankai Li and others. 2023. AdaTT: Adaptive Task-to-Task Fusion Network for Multi-task Learning in Recommendations. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2023.
 - [23] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. 2017. Focal Loss for Dense Object Detection. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017.
 - [24] Scott M Lundberg and Su-In Lee. 2017. A Unified Approach to Interpreting Model Predictions. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
 - [25] Jiaqi Ma, Zhe Zhao, Xinyang Yi, Jilin Chen, Lichan Hong, and Ed H Chi. 2018. Modeling Task Relationships in Multi-task Learning with Multi-gate Mixture-of-Experts. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2018.
 - [26] Xiao Ma, Liqin Zhao, Guan Huang, Zhi Wang, Zelin Hu, Xiaoqiang Zhu, and Kun Gai. 2018. Entire Space Multi-Task Model: An Effective Approach for Estimating Post-Click Conversion Rate. In *Proceedings of the 41st International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2018.
 - [27] Fernando Martinez-Plumed and others. 2023. Improving the Predictive Accuracy of the Cross-selling of Consumer Loans Using Deep Learning Networks. *Annals of Operations Research* (2023).
 - [28] Ali Met, Deniz Korkmaz, and Kerem Tuna. 2024. Product Recommendation System With Machine Learning Algorithms for SME Banking. *International Journal of Intelligent Systems* 2024, (2024).
 - [29] National Assembly of Korea. 2024. Act on the Development of Artificial Intelligence and Establishment of Trust (AI Basic Act).
 - [30] Huy Nguyen, Nhat Ho, and Alessandro Rinaldo. 2024. Sigmoid Gating is More Sample Efficient than Softmax Gating in Mixture of Experts. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.
 - [31] Maximilian Nickel and Douwe Kiela. 2017. Poincaré Embeddings for Learning Hierarchical Representations. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
 - [32] Neha Patki, Roy Wedge, and Kalyan Veeramachaneni. 2016. The Synthetic Data Vault. In *IEEE International Conference on Data Science and Advanced Analytics (DSAA)*, 2016.
 - [33] Judea Pearl and Dana Mackenzie. 2018. *The Book of Why: The New Science of Cause and Effect*. Basic Books.
 - [34] Judea Pearl. 2009. *Causality: Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press.

- [35] Mark Raasveldt and Hannes Mühleisen. 2019. DuckDB: An Embeddable Analytical Database. (2019).
- [36] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. 2016. Why Should I Trust You?: Explaining the Predictions of Any Classifier. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016.
- [37] Amr Salih and others. 2023. Examining the Limitations of Post-hoc Explainability Methods in Finance. *Frontiers in Artificial Intelligence* (2023).
- [38] Noam Shazeer, Azalia Mirhoseini, Krzysztof Mahdavi, and others. 2017. Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer. (2017).
- [39] Xiang-Rong Sheng, Liqin Zhao, Guorui Zhou, Xinyao Ding, Binding Dai, Qiang Luo, Siran Yang, Jingshan Lv, Chi Zhang, Hongbo Deng, and Xiaoqiang Zhu. 2021. STAR: One-pass Single-Arch Multi-task Architecture for Cross-Domain CTR Prediction. In Proceedings of the 30th ACM International Conference on Information and Knowledge Management (CIKM), 2021.
- [40] Mukund Sundararajan, Ankur Taly, and Qiqi Yan. 2017. Axiomatic Attribution for Deep Networks. In Proceedings of the 34th International Conference on Machine Learning (ICML), 2017.
- [41] Hongyan Tang, Junning Liu, Ming Zhao, and Xudong Gong. 2020. Progressive Layered Extraction (PLE): A Novel Multi-Task Learning (MTL) Model for Personalized Recommendations. In Proceedings of the 14th ACM Conference on Recommender Systems (RecSys), 2020.
- [42] Lei Xu, Maria Skoularidou, Alfredo Cuesta-Infante, and Kalyan Veeramachaneni. 2019. Modeling Tabular Data using Conditional GAN. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.
- [43] Hanqing Zeng and others. 2024. Mixture of Weak and Strong Experts on Graphs. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.
- [44] Zijian Zhang and others. 2024. M3oE: Multi-Domain Multi-Task Mixture-of Experts Recommendation Framework. In Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval, 2024.
- [45] Xun Zheng, Bryon Aragam, Pradeep Ravikumar, and Eric P Xing. 2018. DAGs with NO TEARS: Continuous Optimization for Structure Learning. (2018).