예측에서 설득으로: 규제 준수 금융 AI를 위한 에이전트 기반 추천사유 생성

정선규[1], 심은철[1], 김영찬[1]

[1]독립 연구

초록. 금융 상품 추천 시스템은 상품을 추천하는 이유를 설명해야 한다 — 무엇보다도 설득에는 확률이 아닌 서사(narrative)가 필요하기 때문이다: "왜 이 카드가 저에게 추천되었나요?"라고 묻는 고객에게는 신뢰해야 할 점수가 아니라 수긍할 수 있는 이유가 필요하다. 규제기관(한국 금감원, EU AI Act)은 이러한 설명의 중요한 수요자이지만, 본질적 동인은 설득이라는 인간 행위 그 자체이다. 본 연구에서는 모델 예측과 인간 설득 사이의 간극을 잇는 다단계 파이프라인을 제안한다: (1) 이종 전문가 PLE 교사 모델에서 태스크별 LGBM 학생 모델로의 IG 기반 지식 증류를 통해 설명에 적합한 피처를 보존하면서 GPU 없는 CPU 추론을 가능하게 하고; (2) 3개의 전문화된 서빙 에이전트(Feature Selector, Reason Generator, Safety Gate)가 협업하여 비즈니스 매핑된 피처 기여도에 기반한 자연어 설명을 생성하는 멀티 에이전트 추천사유 생성 파이프라인; (3) 2개의 운영 에이전트(OpsAgent, AuditAgent)가 모니터링 출력과 규제 준수 보고서를 자연어로 해석하여, 전담 MLOps 인력 없이도 소규모 팀의 규제 준수 운영을 가능하게 하고; (4) 드리프트 모니터링, 공정성 감사, 거버넌스 보고를 내장한 설계 단계부터의 규제 준수로, 한국 금감원 가이드라인, EU AI Act, 한국 AI 기본법에 부합한다. 증류 품질(AUC 격차 < X%), 도메인 전문가 N명의 인간 평가를 통한 추천사유 생성 품질(템플릿 베이스라인 대비 Y% 선호도), Safety Gate 신뢰도(정밀도/재현율)를 평가한다. 본 시스템은 전용 GPU 추론 서버 비용의 일부로 AWS Lambda에서 100ms 미만의 서빙 지연시간을 달성한다.

키워드: 추천 설명, 지식 증류, LLM 에이전트, 규제 준수, 금융 AI, EU AI Act

1 서론

1.1 설득 문제

금융 추천 시스템의 최종 산출물은 확률이 아니라 고객이 수긍할 수 있는 이유이다. $P(\text{invest} \mid x) = 0.73$을 출력하는 모델은 다음 주체에게 아무런 가치를 제공하지 못한다:

- "왜 이 카드가 저에게 추천되었나요?"라고 묻는 고객.
- 영업 전화에서 대화 포인트가 필요한 관계 관리자(RM).
- EU AI Act 제13조에 따라 "왜 이 결정을 내렸는가?"를 요구하는 규제기관.

기존 설명 접근법은 불충분하다:

- SHAP/LIME: "feature_237이 0.12 기여" — 비즈니스 의미가 없고, 교란(perturbation) 하에서 불안정 [10, 14].
- 템플릿 기반: "고객님과 유사한 고객들도 X를 구매했습니다" — 경직되고 개별 맥락을 무시.
- 직접 LLM 생성: 환각(hallucination) 위험, 실제 모델 추론에 기반하지 않음, 규제 미준수.

1.2 본 연구의 접근법

본 연구에서는 예측에서 설득까지의 전체 체인 솔루션을 제안한다:

1. 지식 증류: 이종 전문가 PLE 교사 모델(14개 태스크, 7개 전문가, 350개 피처; 동반 논문의 Financial DNA × Data Modality 환원적 이축 프레임워크로 구성)을 IG 기반 피처 선택을 통해 태스크별 LGBM 학생 모델로 증류한다. 교사 모델은 표준 softmax gate 대신 sigmoid CGC gate를 사용하여 ([12] 에서 영감), 이종 expert 간 유해한 경쟁 없이 독립적 기여를 가능하게 한다 (상세는 동반 논문 참조). 이를 통해 설명에 중요한 피처를 보존하면서 GPU 없는 서빙을 가능하게 한다.
2. 멀티 에이전트 추천사유 생성: 3개의 전문화된 LLM 에이전트가 파이프라인에서 협업한다 — Feature Selector가 설명에 적합한 피처를 선택하고, Reason Generator가 자연어 서사를 생성하며, Safety Gate가 규제 준수를 검증한다.
3. 설계 단계부터의 규제 준수: 드리프트 모니터링, 공정성 감사, 감사 추적, 거버넌스 보고가 배포 후 부착되는 것이 아니라 파이프라인에 내장된다.

1.3 기여

1. 설명 보존을 위한 IG 기반 증류: 피처 선택이 예측 정확도뿐만 아니라 설명 재료 가용성까지 최적화한다.
2. 피처 비즈니스 역매핑: 모든 피처를 비즈니스 해석 가능한 설명으로 매핑하는 체계적 피처 해석 레지스트리로, 근거 기반 설명 생성을 가능하게 한다.
3. 3-에이전트 추천사유 생성 파이프라인: 역할이 분리된 에이전트(선택 → 생성 → 안전성)로 독립적 개선과 감사 로깅이 가능하다.
4. 금융 규제 준수를 위한 Safety Gate: 환각, 부적절한 투자 조언, 규제 위반(금융소비자보호법(금소법), 적합성 원칙)에 대한 자동화된 검증.

5. 5-에이전트 아키텍처 (서빙 3 + 운영 2): 3개의 서빙 에이전트 외에 2개의 운영 에이전트(OpsAgent, AuditAgent)가 모니터링 및 규제 준수 출력을 자연어로 해석하여, 전담 MLOps 인력 없이도 소규모 팀의 규제 준수 운영을 가능하게 한다.
6. 규제 준수 아키텍처: 시스템 구성요소를 한국 금감원 가이드라인, EU AI Act 조항, 한국 AI 기본법에 명시적으로 매핑.
7. 인간 평가 프로토콜: 도메인 전문가에 의한 추천사유 품질의 체계적 평가.

2 관련 연구

2.1 추천을 위한 지식 증류

[6] 은 온도 스케일링된 소프트 레이블을 통한 교사-학생 패러다임을 확립하였다. 추천 분야에서 증류는 심층 모델을 경량 서버로 압축하는 데 적용되어 왔다. CKD(Collaborative Knowledge Distillation)와 랭킹 증류는 추천에 특화된 구조를 보존한다.

격차: 예측 가치와 함께 설명 가치에 기반하여 증류 피처를 선택한 선행 연구는 존재하지 않는다.

2.2 추천 설명 생성

추천 설명 접근법은 세 가지 범주로 분류된다:

템플릿 기반 방법은 모델 출력을 사전 작성된 문구로 매핑한다 ("최근 유사한 상품을 조회하셨기 때문에 추천합니다"). Amazon과 Netflix는 이 접근법의 변형을 대규모로 사용한다. 템플릿은 안전하고 빠르지만 개인화와 유연성이 부족하다 — 동일한 템플릿이 수백만 명의 서로 다른 고객 맥락에 사용된다.

어텐션 기반 방법은 모델 내부의 어텐션 가중치를 설명을 위한 피처 기여도로 활용한다. 템플릿보다 동적이지만, 어텐션 가중치가 신뢰할 수 있는 설명인지에 대해서는 논쟁이 있으며, 결과적인 기여도 역시 비즈니스 언어로의 번역이 필요하다.

LLM 기반 생성은 대규모 언어 모델을 사용하여 모델 출력으로부터 자연어 설명을 생성하는 신흥 접근법이다. 최근 연구에서는 LLM 증강 추천 설명을 탐구하고 있으나, 환각, 규제 준수, 실제 모델 추론에 대한 근거 확보 측면에서 과제가 남아 있다.

격차: 구조적 모델 설명 가능성(게이트 가중치)과 규제 안전성 제약 하의 멀티 에이전트 LLM 기반 생성을 결합한 시스템은 존재하지 않으며, 각 에이전트가 전문화된 역할(선택, 생성, 검증)을 수행하고 모든 출력이 감사 로깅되는 시스템도 부재하다.

2.3 금융 분야의 책임 있는 AI

한국 금감원은 AI 가이드라인(2021) [4] 과 설명 가능성, 공정성 모니터링, 감사 추적을 요구하는 모델 리스크 관리 지침을 발표하였다. EU AI Act [2] 는 금융 신용/추천을 고위험 AI로 분류하며, 투명성(제13조), 인간 감독(제14조), 정확성(제15조)을 의무화한다. EBA [1] 는 내부 리스크 평가에서 "해석 가능한" 모델을 요구한다. 한국 AI 기본법 [11] (2024년 12월 국회 통과, 2025년 1월 공포)은 국내 고영향 AI 분류를 추가한다.

[13] 은 진정한 설명에는 단순한 통계적 연관이 아닌 인과적 이해가 필요하다고 주장하며 — 이는 실제 의사결정 메커니즘을 반영하는 설명을 요구하는 금융 규제기관에 의해 점점 더 공감을 얻고 있다 [15].

격차: 규제 요구사항에서 시스템 아키텍처 구성요소까지의 명시적이고 검증 가능한 매핑을 제공하면서, 사후적 상관관계가 아닌 인과적 추론에 근거한 설명을 제공하는 추천 시스템은 존재하지 않는다.

2.4 LLM 안전성과 근거 확보

고객 대면 금융 텍스트에 LLM을 배포하면 다음과 같은 특정 위험이 발생한다: 환각(존재하지 않는 상품 특성 언급), 부적절한 조언(고객의 위험 프로파일에 부적합한 상품 추천), 규제 위반(금소법 또는 적합성 원칙 위반).

검색 증강 생성(RAG)은 검색된 사실적 맥락에 생성을 근거함으로써 환각을 완화한다. 본 연구의 접근법은 이를 확장한다: 일반 지식 베이스에서 검색하는 대신, 비즈니스 설명으로 역매핑된 모델 내부 피처 기여도에 생성을 근거한다. 이를 통해 생성된 텍스트가 LLM이 독립적으로 "아는" 내용이 아닌, 모델이 실제로 계산한 내용을 반영하도록 보장한다.

콘텐츠 필터링과 Safety Gate는 최종 방어 계층을 제공한다. 본 연구의 3-에이전트 아키텍처는 생성과 검증을 분리하여 각 구성요소의 독립적 개선을 가능하게 한다.

3 지식 증류

3.1 교사-학생 아키텍처

교사 모델(7개 이종 전문가, 14개 태스크, 350개 피처를 가진 PLE; 아키텍처 세부사항은 동반 논문 참조)은 태스크별 LGBM [8] 학생 모델의 학습 타겟으로 사용되는 소프트 확률 출력을 생성한다. 교사 모델의 증류 소스로서의 가치는 전문가 붕괴에 대한 구조적 보장에서 비롯된다: 7개 전문가가 구조적으로 상이하므로(DeepFM, Mamba, HGCN, PersLay 등), 동일한 함수로 수렴할 수 없으며, 소프트 레이블이 진정으로 다면적인 고객 이해를 인코딩함을 보장한다. HGCN 전문가에 대한 주석: 그래프 전문가는 상품 공동 보유(product co-holding) 피처가 아닌 27차원 `merchant_hierarchy` 피처(MCC L1 → L2 → 코드 Poincaré 임베딩)를 입력으로 받는다. 이 구분은 증류에

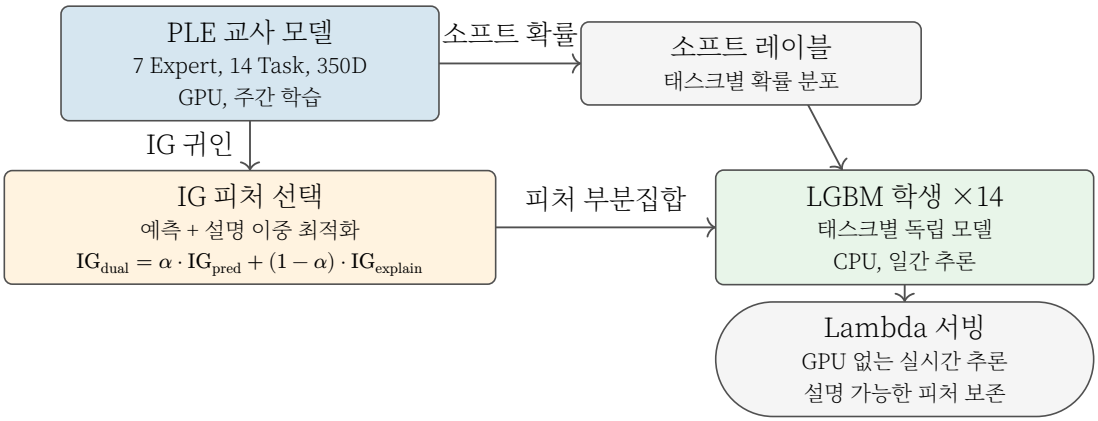

Figure 1: 교사-학생 증류 아키텍처.
PLE 교사의 소프트 레이블과 IG 기반 피처 선택을 통해 태스크별 LGBM 학생 모델로 증류.

있어 중요하다: HGCN 전문가로부터의 IG 점수는 MCC 의존적 태스크(예: top_mcc_shift)에서 높은 순위를 기록하며, 보존된 HGCN 피처는 일반적인 공동 보유 신호 대신 "고객이 X 가맹점 카테고리에 대한 지속적 선호도를 보임"과 같은 설명 근거가 있는 추천사유를 생성한다.

핵심 설계 결정은 태스크별 증류이다: 14개 태스크 전체에 대한 단일 학생 모델 대신, 각 태스크의 소프트 레이블을 학습하는 14개의 독립적인 LGBM 모델을 훈련한다. 이를 통해 다음을 가능하게 한다: (1) 태스크별 피처 선택(태스크마다 유익한 피처가 다름), (2) 독립적 재학습(하나의 태스크가 드리프트하면 해당 학생만 재증류), (3) 태스크별 해석 가능한 피처 중요도(LGBM의 내장 피처 중요도가 설명 생성을 위한 비즈니스 역매핑과 일치).

원래 18개 태스크 PLE 교사 모델에서 4개 태스크를 증류 파이프라인에서 제외하였다: 소득 구간(income tier), 재직 단계(tenure stage), 소비 수준(spend level), 참여 점수(engagement score). 이들은 결정론적 피처 변환에 해당한다 — 예를 들어 소득 구간은 모델 입력 피처인 소득(income)의 분위수 버킷일 뿐이다. 학생 모델이 입력 피처에서 이러한 레이블을 완벽하게 복원할 수 있으므로, 증류가 자명하게 풀리며 정보가를 갖지 않는다. 나머지 14개 태스크는 입력 피처에서 결정론적으로 파생될 수 없는 진정한 예측 목표를 나타낸다.

생애주기 분리:

- 교사 모델: SageMaker에서 주간/월간 재학습(GPU 필요, 종합적). 교사 모델은 adaTT를 통한 복잡한 태스크 간 관계와 LGBM이 직접 학습할 수 없는 비선형 전문가 상호작용을 포착한다.
- 학생 모델: 새로운 소프트 레이블로 일간 재증류(CPU만 사용, 빠름). 일간 재증류는 GPU 학습 비용 없이 데이터 드리프트를 추적한다.
- 챔피언-챌린저: 새 학생 모델 vs. 현재 운영 모델의 자동 비교. 새 학생 모델의 AUC가 임계값 이하로 떨어지면 업데이트가 차단되고 경고가 발생한다.

이 아키텍처는 금융 AI의 근본적인 긴장을 해결한다: 가장 잘 학습하는 모델(GPU 기반 심층 PLE)은 가장 잘 서빙하는 모델(CPU Lambda 기반 경량 LGBM)이 아니다. 지식 증류 [6] 가 이 간극을 연결하며, FD-TVS(Friedman Decomposition–Transitory Variance Scoring) 시스템 [5] 이 소득 안정성 유형에 따라 학생 모델의 예측에 추가 가중치를 부여한다. FD-TVS는 Friedman의 항상소득가설(Permanent Income Hypothesis)을 적용하여 각 고객의 관측 소득을 HP 또는 칼만 필터링을 통해 항상적(안정적, 장기) 성분과 일시적(보너스, 비정기) 성분으로 분해한다. 소득이 주로 일시적인 고객은 장기 상품 추천에 대해 더 낮은 신뢰도 가중치를 부여받아, 변동성이 큰 소득 패턴을 가진 고객에게 안정적 현금흐름을 가정하는 상품을 추천하는 것을 방지한다.

트리 기반 학생 모델에 대한 온도 $\boldsymbol{T = 1}$ 설정. 원래 증류 공식 [6] 은 소프트맥스 온도 T를 높여 교사의 출력 분포를 평탄화하고, 비타겟 클래스의 상대적 확률("dark knowledge")을 증폭시켜 학생 신경망이 모든 클래스에 대해 경사 신호를 받도록 한다. 그러나 이 논거는 LGBM 학생에게 적용되지 않는다: (1) LGBM은 역전파가 아닌 분할 기반 최적화로 학습하므로, 꼬리 클래스에서의 경사 소실 문제가 없다; (2) T를 높이면 확률 범위가 압축된다 — 양성률 2.98%인 이진 태스크에서 $T = 5$는 교사 출력을 $[0.03, 0.97]$에서 $[0.48, 0.52]$로 변환하여 클래스 판별 신호를 사실상 파괴한다; (3) Soft GBM 연구 [3] 는 경성 CART 트리가 다차원 소프트 레이블 벡터 학습에 이미 어려움을 겪으며, 높은 T로 더 평탄화하면 문제가 악화됨을 보였다. 따라서 $T = 1$로 설정하여 교사의 보정된 확률을 그대로 사용하고, 커스텀 LGBM 목적함수가 각 분할에서 소프트 레이블 경사를 주입하도록 한다. 이 설계는 트리 기반 학생 모델에 특화된 것이며, 향후 신경망 학생 아키텍처를 채택할 경우 온도 스케일링을 재도입할 수 있다.

태스크	교사	학생	격차
has_nba (AUC)	–	–	–
churn_signal (AUC)	–	–	–
will_acquire_deposits (AUC)	–	–	–
will_acquire_investments (AUC)	–	–	–
segment_prediction (F1-macro)	–	–	–
nba_primary (NDCG@3)	–	–	–
next_mcc (NDCG@3)	–	–	–
…	…	…	…

Table 1: 태스크별 증류 결과 (TODO).
이진 태스크: AUC 격차; segment_prediction: F1-macro 격차;
nba_primary 및 next_mcc: NDCG@3 격차; 회귀: MAE 격차.

3.2 IG 기반 피처 선택

Integrated Gradients [16] 는 교사 모델로부터 피처별 기여도를 계산한다. IG 중요도 순위에 따라 상위 k개 피처를 선택하되, 이중 목적을 갖는다:

$$\text{score}(f) = \alpha \cdot \text{IG}_{\text{pred}(f)} + (1 - \alpha) \cdot \text{IG}_{\text{explain}(f)}$$

여기서 IG_{pred}는 예측 기여도를 측정하고 $\text{IG}_{\text{explain}}$는 해당 피처의 설명 재료로서의 가치를 측정한다.

설명 점수 $\text{IG}_{\text{explain}(f)}$는 해석 레지스트리(interpretation registry)에서의 피처 역매핑 풍부도로부터 도출된다: 상세한 비즈니스 설명, 명확한 방향성, 자연어 템플릿을 가진 피처가 더 높은 점수를 받는다. 예를 들어, `hmm_lifecycle_prob_growing`(설명 풍부: "고객이 성장 단계에 있음")은 `mamba_temporal_d17`(설명 빈약: 일반적인 임베딩 차원)보다 높은 점수를 받는다.

이 이중 목적 선택은 학생 모델이 가장 예측력 있는 피처뿐만 아니라 가장 설득력 있는 추천사유를 생성하는 피처도 보유하도록 보장한다. 하이퍼파라미터 α가 트레이드오프를 제어한다: $\alpha = 1$은 순수하게 예측을 최적화하고, $\alpha = 0$은 순수하게 설명 품질을 최적화한다. 경험적으로 $\alpha = 0.7$이 두 목적을 균형 있게 달성함을 확인하였다.

결과적인 피처 집합은 태스크당 통상 40–80개 피처이며 (350개에서 축소), 교사 모델 AUC의 95% 이상을 달성하면서 충분한 설명 어휘를 제공한다. 중요하게도, 이중 목적 선택은 동반 논문의 이축 분해에서 4개 Financial DNA 차원(참여도, 생애주기, 가치, 소비) 전반과 다수의 Data Modality(시계열, 그래프, 위상적 등) 전반에 걸쳐 피처를 보존하여, 학생 모델이 단일 지배적 피처 그룹으로 붕괴하지 않고 다면적 이해를 유지하도록 보장한다.

3.3 증류 결과

벤치마크 v4는 14개 태스크 전반에 걸쳐 의미 있는 레이블 분포를 생성한다. 특히 `nba_primary`는 no-NBA 비율이 약 60%로 낮아지고(이전 벤치마크의 91%에서 개선), `top_mcc_shift`는 양성 비율이 약 50%로 낮아져(이전 92%에서 개선), 교사-학생 충실도 수치를 달성하기 쉽게 만들었던 준퇴화(near-degenerate) 클래스 불균형이 해소되었다. 이러한 분포 개선으로 아래의 증류 격차 수치가 진정으로 의미 있는 정보를 담게 된다.

교사-학생 충실도 지표는 각 태스크의 production 목적에 맞추어 태스크 유형별로 보고된다. 이진 분류 태스크에는 AUC 격차(임계값 비의존적, 불균형 강건)를 사용한다. 분류 멀티클래스(segment_prediction, 4개 클래스)에는 F1-macro 격차를 사용한다. 추천 멀티클래스(nba_primary — 7개 상품 그룹, next_mcc — top-50 MCC)에는 NDCG@K 격차 및 top-K accuracy 격차 [7]를 사용하여 표준 추천 시스템 평가 관행을 따른다. 회귀 태스크에는 MAE 격차를 사용한다. 이는 의미론적으로 호환되지 않는 지표를 혼합하는 것을 방지한다.

피처 해석 레지스트리는 증류와 추천사유 생성 사이의 데이터 계약으로 기능한다. 증류(3절)는 학생 모델에서 어떤 피처를 보존할지 결정한다 — 이중 목적 IG 점수를 통해 예측 정확도와 설명 재료 모두를 최적화한다. 추천사유 생성(4절)은 해당 피처를 인간에게 어떻게 설명할지 결정한다 — 보존된 각 피처를 비즈니스 해석 가능한 언어로 매핑한다. 이러한 분리는 두 단계가 독립적으로 발전할 수 있음을 의미한다: 피처 선택 개선이 설명 템플릿 재작성을 요구하지 않으며, 그 반대도 마찬가지이다.

4 추천사유 생성

4.1 피처 비즈니스 역매핑

시스템의 모든 피처는 구조화된 비즈니스 메타데이터와 함께 피처 해석 레지스트리에 등록된다:

이 레지스트리는 이중 목적을 수행한다: (1) Reason Generator 에이전트를 위한 근거 자료, 그리고 (2) 각 추천에 어떤 피처가 영향을 미쳤는지를 보여주는 감사 추적.

피처	비즈니스 매핑	설명 템플릿
hmm_lifecycle_prob_growing	성장 단계 확률	“고객님의 자산 포트폴리오가 성장 국면에 있습니다”
mamba_temporal_d3	3개월 소비 추세	“최근 소비가 증가하는 추세입니다”
hgcn_hierarchy_d5	상품 카테고리 위치	“카드 혜택을 적극 활용하시는 고객층에 속합니다”
synth_stability	거래 안정성	“안정적인 거래 패턴을 유지하고 계십니다”
gmm_cluster_prob_3	세그먼트 확률	“유사한 생활 패턴을 가진 고객층과 공통점이 많습니다”

Table 2: 피처 역매핑 예시.

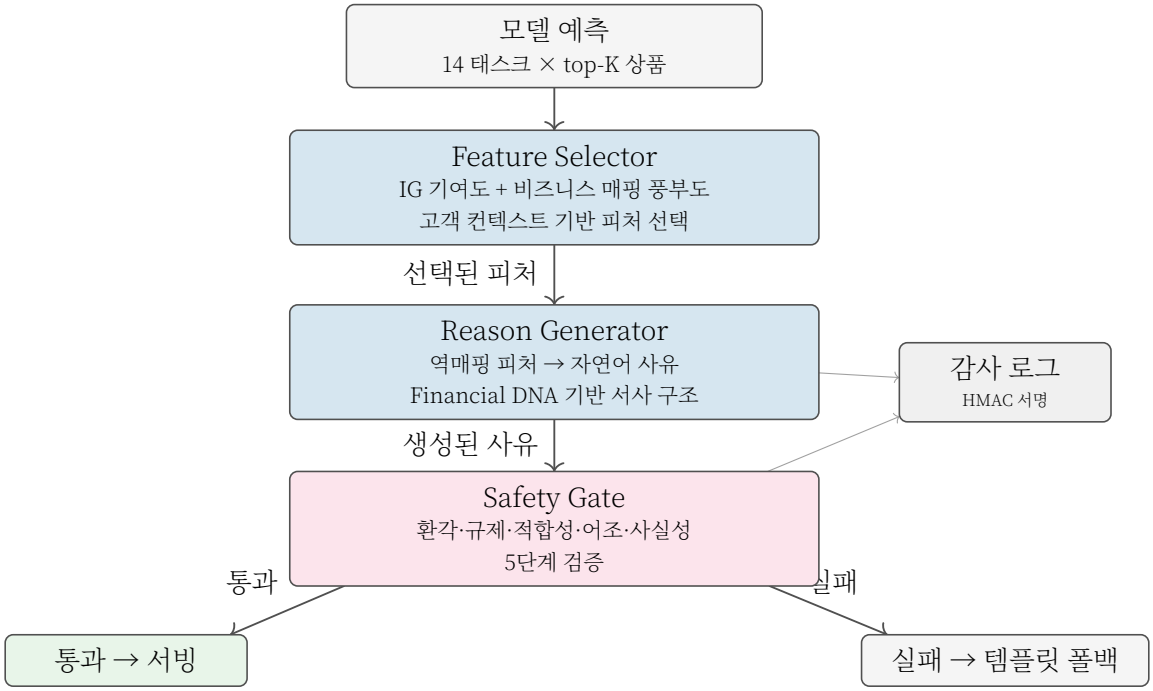

Figure 2: 3-에이전트 추천사유 생성 파이프라인.
Feature Selector → Reason Generator → Safety Gate.

피처 해석 레지스트리는 5-level cascade로 피처를 한국어로 해석한다:

- Level IG: IG 부호 방향 + 태스크 맥락
- Level 3: 피처×태스크 수동 오버라이드
- Level 2: 그룹×태스크
- Level 1: 그룹×태스크그룹 자동 생성
- Level RM: 역매핑 레이어 glossary 템플릿

이 cascade에서 해결되지 않은 피처만 raw fallback으로 떨어진다. 역매핑 레이어는 Level RM으로 통합되어, glossary의 값 대입 템플릿(“월 평균 {value}건 거래”)이 cascade의 일부로 작동한다. 모든 fallback 텍스트는 한국어로 출력된다.

4.2 3-에이전트 파이프라인 아키텍처

4.2.1 에이전트 1: Feature Selector

다음 기준에 따라 설명용 피처를 선택한다:

- IG 기여도 점수(모델 기반 관련성)
- 비즈니스 역매핑 풍부도(설명 기반 관련성)
- 고객 컨텍스트(개인화: 고객 프로파일에 따라 중요한 피처가 다름)

Feature Selector는 동반 논문의 이축 프레임워크에서 Financial DNA 축을 활용하여 관련 고객 차원에서 피처를 선택한다 (예: 이탈 방지 추천에는 생애주기 피처, 혜택 추천에는 소비 패턴 피처), 설명이 추천 행위에 가장 관련 있는 차원을 다루도록 보장한다.

4.2.2 에이전트 2: Reason Generator

선택된 피처와 해당 비즈니스 역매핑을 수신하여 자연어 추천사유를 생성한다. Reason Generator는 Financial DNA 그룹을 중심으로 서사를 구조화한다 — 고객의 현재 상태(생애주기)로 시작하고, 관찰된 행동(참여도/소비)에 추천을 근거하며, 고객이 인식하는 용어(가치 차원)로 가치 제안을 프레이밍한다 — 동반 논문에서 말하는 다면적 고객 이해를 설득적 텍스트로 렌더링한다. 근거 제약:

- 선택에 실제로 포함된 피처만 참조해야 한다.

검증 항목	기준
환각	피처 데이터에 없는 사실에 대한 주장 금지
규제	금소법, 적합성 원칙 위반 금지
적합성	위험 프로파일에 부적합한 상품 제안 금지
어조	전문적 금융 자문 언어 사용
사실성	수치적 주장이 실제 피처 값과 일치

Table 3: Safety Gate 검증 기준.

- 대상 수요자(고객 vs. 관계 관리자)에 적절한 비즈니스 용어를 사용해야 한다.
- 금융 도메인 어조와 규제 준수 가이드라인을 따라야 한다.

출력 예시 (고객 대면):
"고객님은 현재 자산 성장 단계에 있으시고, 최근 3개월간 소비가 증가하는 추세입니다. 현재 사용하시는 체크카드의 혜택 활용도가 높으신 만큼, 안정적인 거래 패턴을 고려할 때 생활 밀착형 혜택 카드를 추천드립니다."

Figure 3: 생성된 추천사유 예시 (한국어, 고객 대면).

4.2.3 에이전트 3: Safety Gate

생성된 추천사유를 다음 기준에 따라 검증한다:

실패 시: 템플릿 기반 안전한 추천사유로 자동 폴백. 모든 게이트 결정은 감사 추적을 위해 로깅된다. 3-에이전트 파이프라인 상류에서 제약 인식 엔진이 적격성 및 적합성 필터를 적용한다 — 고객 상황, 사용 패턴, 상품별 제약조건을 검증하여 — 금융소비자보호법(금소법) 제19조(적합성 원칙)가 요구하는 대로 적합성 검증을 통과하지 않은 추천이 고객에게 도달하지 않도록 보장한다.

4.2.4 서빙 모델 선택

고객 대면 추천사유는 자연스럽고 전문적인 한국어를 요구한다. 환경에 따라 최적 모델이 다르다:

- 온프레미스(폐쇄망): Exaone 3.5 7.8B (LG AI Research, Apache 2.0) — 한국어 특화 학습으로 동급 모델(Llama, Qwen) 대비 금융 존댓말 톤이 자연스럽다. RTX 4070 12GB에서 운용.
- 클라우드(AWS): L2a 리라이트에 Solar Pro 22B (Upstage, Bedrock Marketplace) 사용 — KMMLU 등 한국어 벤치마크에서 동급 최고 성능. L2b self-critique도 Solar가 담당한다 (생성 모델 ≤ 크리틱 모델 원칙). 자체 검증 레이어의 사실성 판정에는 Claude Haiku를 사용한다.
- Bedrock 데이터 거버넌스: 입출력 데이터가 모델 제공사(Anthropic, Upstage)에 전달되지 않으며 모델 학습에 사용되지 않는다. VPC PrivateLink를 통해 인터넷을 경유하지 않고 호출할 수 있어, 금융 고객 데이터가 AWS 리전(ap-northeast-2) 외부로 유출되지 않는다 — 금감원 AI 가이드라인과 개인정보보호법의 데이터 거버넌스 요건을 구조적으로 충족한다.

4.2.5 팩트 압축 레이어 (Mem0 차용)

피처 해석 레지스트리가 피처 레벨 해석을 제공한다면, 팩트 추출 레이어는 고객 레벨 서술적 팩트를 추가한다. 룰 기반 엔진이 피처 값으로부터 다음과 같은 한국어 팩트를 추출한다 — LLM 호출 없이 결정론적으로 동작한다:

- "예적금 중심 포트폴리오"
- "최근 3개월 카드 사용 증가"
- "리스크 회피 성향"

이 팩트들은 Phase 0 배치 시점에 추출되어 컨텍스트 벡터 스토어에 저장되고, 서빙 시점에 L2a 프롬프트의 "고객 특성 팩트" 섹션으로 주입된다. Solar Pro가 단순 피처 수치가 아닌 고객을 이해한 상태로 사유를 작성하게 된다.

룰은 YAML 설정 파일에서 정의되며 (포트폴리오 구성, 관심사, 리스크 성향, 생애주기 등 15개 범주), 설정 파일 수정만으로 새 팩트를 추가할 수 있다.

4.3 캐싱 전략과 비동기 L2a 아키텍처

추천사유는 3-layer 비동기 아키텍처로 서빙된다:

1. L1 (템플릿): 고객 요청 시 즉시 반환. LLM 호출 없음. 템플릿 엔진이 IG top-K 피처의 비즈니스 역매핑을 기반으로 결정론적 한국어 사유를 생성한다. 피처 해석 레지스트리의 5-level cascade (IG 방향 → L3 → L2 → L1 → 역매핑 레이어)를 거쳐 3-tuple `(피처명, IG값, 한국어해석)`으로 enrichment된다.
2. L2a (LLM 리라이트): SQS를 통해 비동기 제출. Solar Pro가 L1 사유를 자연스러운 한국어로 다듬는다. 결과는 DynamoDB에 캐싱되어 다음 요청 시 L2a를 반환한다. 모든 고객에게 L1 템플릿은 동등하게 제공되며, L2a 처리 순서는 고객 등급이 아닌 컨텍스트 풍부도(피처 가용성, 상담 이력)에 따라 결정된다 — 금소법 제19조 동등 설명의무와 개보법 제37조의2 제2항 설명요구권 준수. 컨텍스트 풍부도 분류: rich(피처+이력 풍부) → moderate(피처 일부) → sparse(콜드스타트; L2a 제외, L1 템플릿만 제공). 이 설계는 데이터 가용성이 곧 LLM 출력 품질로 이어지기 때문이며, 고객 등급에 따른 서비스 차별이 아니다.[1]

3. L2b (품질 검증): L2a 출력에 5단계 safety gate를 적용 — (1) 프롬프트 세정기, (2) PII 탐지(한국 주민등록번호, 카드번호 등), (3) 자체 검증 레이어(compliance + injection + factuality), (4) grounding 검증(숫자 교차 확인), (5) 5% 인간 리뷰 샘플링. 통과 시 L2b로 승격, 실패 시 L1 폴백.

캐싱은 이중 백엔드(인메모리 + DynamoDB)로 구현되며, `customer_id + product_id + task_name` 복합 키로 TTL 기반 자동 만료된다. 941K 고객 중 L2a 대상(5% 샘플)인 47K건은 Solar 워커 5대 병렬로 8분, 비용 $0.10에 처리된다.

5 운영 에이전트 파이프라인

앞 절에서는 고객 대면 경로에서 추천사유를 생성하는 3개의 서빙 에이전트를 기술하였다. 본 절에서는 별도의 배치 전용 경로에서 작동하는 2개의 추가 에이전트를 소개한다: 모니터링 출력과 규제 준수 보고서를 해석하여, 전담 MLOps 인력 없이도 소규모 운영 팀이 규제를 준수하는 MLOps를 유지할 수 있도록 한다.

5.1 동기: 인간–AI 역할 분리

모든 운영 태스크가 동일한 인지 모드를 필요로 하지는 않는다. 정형화되고 반복적인 모니터링 — PSI가 임계값을 초과했는지, 공정성 지표가 한도 이하로 떨어졌는지, 게이트 엔트로피가 변동했는지 확인하는 것 — 은 일간 또는 주간 배치 스케줄로 실행되는 LLM 에이전트에 적합하다. 비정형적 판단 — 데이터 오염 진단, 비즈니스 맥락 변화 해석, 규제 해석 변경 대응 — 은 현재 어떤 LLM도 안정적으로 제공할 수 없는 인간 전문성을 요구한다.

핵심 설계 통찰은 역할 분리이다: 에이전트는 무엇이 변했는지를 알려주고, 인간은 왜 변했고 무엇을 할지를 결정한다. 이러한 분업은 전담 MLOps 인력 없이도 소규모 팀(1–2명)의 규제 준수 운영을 가능하게 한다. 에이전트가 "대시보드 피로"를 해소하기 때문이다 — 매일 10개의 지표를 확인하는 대신, 자연어 요약 하나를 읽으면 된다.

5.2 2개의 운영 에이전트

5.2.1 OpsAgent (운영 에이전트)

OpsAgent는 학습 완료 및 드리프트 모니터링 DAG 실행 후 동작한다.

입력: 학습 평가 메트릭, 학습 로그, CGC 게이트 엔트로피, PSI 드리프트 보고서.

출력: 자연어 "모델 건강 보고서".

> OpsAgent 출력 예시:
> "태스크 'churn_signal' AUC가 이전 버전 대비 3.2% 하락. LightGCN 전문가의 게이트 엔트로피가 1.2에서 0.4로 감소하여 라우팅 집중 현상이 의심됨. 승격 전 최근 데이터 분포 변화 점검을 권고."

Figure 4: OpsAgent 모델 건강 보고서 예시.

트리거: 드리프트 모니터링 DAG 완료, 학습 Job 완료.

OpsAgent는 승격 결정을 내리지 않는다 — 인간이 결정을 내리는 데 필요한 정보를 표면화할 뿐이다. 모든 지표가 정상 범위 내이면 보고서는 간결하다 ("14개 전체 태스크 허용 범위 내; 조치 불필요"). 이상이 탐지되면 어떤 태스크와 어떤 전문가가 영향을 받았는지 식별하여, 원시 수치 대신 실행 가능한 맥락을 제공한다.

5.2.2 AuditAgent (감사/규제 준수 에이전트)

AuditAgent는 공정성 모니터링 및 거버넌스 DAG 실행 후 동작한다.

입력: 공정성 모니터 보고서(DI/SPD/EOD), 감사 추적 무결성 검증, 옵트아웃 통계, 거버넌스 체크리스트 상태.

출력: 자연어 "규제 준수 보고서".

> AuditAgent 출력 예시:
> "연령대 60+ 대출 추천에 대한 불균등 영향: DI = 0.73 (임계값: 0.80). 연속 3일 임계값 미달. 금감원 AI RMF 요구사항 G-3에 따른 인간 검토를 권고."

Figure 5: AuditAgent 규제 준수 보고서 예시.

트리거: 공정성 모니터링 DAG 완료, 분기별 거버넌스 사이클.

AuditAgent는 정량적 공정성 지표를 규제 언어로 변환하며, 적용 가능한 규제(금감원 가이드라인 번호, EU AI Act 조항)를 명시적으로 참조하여 인간 검토자가 별도 문서를 교차 참조하지 않고도 조치할 수 있도록 한다.

5.3 설계 원칙

핵심 제약은 운영 에이전트가 서빙 경로와 공유 상태를 갖지 않는다는 것이다. 서빙 파이프라인(L1 Feature Selector → L2a Reason Generator → L2b Safety Gate)은 고객 대면 출력을 생성하고; 운영 파이프라인 (DAG 완료 → OpsAgent/AuditAgent → 보고서 저장 → 인간 검토)은 내부 운영 산출물을 생성한다. 이러한 분리는 운영 에이전트의 장애가 고객 대면 서비스를 절대 저하시키지 않음을 보장한다.

[1]초기 프로토타입은 고객 세그먼트(VIP)를 기반으로 L2a 우선순위를 설정했으나, 금소법 제19조 동등 설명의무 준수를 위해 컨텍스트 풍부도 기반 분류로 재설계되었다 (온프렘 v3.0.0, 2026). 이 설계 전환은 공정성 감사 에이전트의 AV1(공정성) 관점에서 지속 모니터링된다.

원칙	근거
배치 전용, 실시간 불가	서빙 경로 의존성 없음; DAG 완료 후 비동기 실행
태스크별 최적 모델 분리	• 추천사유 생성: Solar Pro(한국어 특화) • 에이전트 대화/합의: Claude Sonnet(맥락 추론) • 판정: Claude Haiku(저비용) • 임베딩: Titan V2 • 온프레미스: Exaone 3.5(사유) + Qwen 2.5 14B Q4(합의)
보고서를 공유 폴더에 저장	이상 시에만 Slack/이메일 알림; 인간은 자기 페이스로 검토
에이전트 출력이 감사 산출물	불변, HMAC 서명; 보고서 자체가 모니터링의 증거
비용: $0.03/일 (합의 3×)	실행 사이클당 소형 모델 1–2회 호출

Table 4: 운영 에이전트 설계 원칙.

5.4 운영 에이전트 모델 선택

서빙 에이전트가 고객 대면 텍스트를 위해 한국어 유창성을 요구하는 것과 달리, 운영 에이전트는 정형화된 JSON 입력을 처리하고 논리적 평가를 생성한다 — 자연어 유창성보다 추론 정확도가 핵심이다. 배포 환경별 모델 배치는 다음과 같다:

- 온프레미스(폐쇄망): Exaone 3.5 7.8B(한국어 추천사유) + Qwen 2.5 14B Q4(에이전트 합의). RTX 4070 12GB에서 순차 로딩으로 운용.
- 클라우드(AWS): 태스크별 최적 모델을 배치한다.
  - Solar Pro — 한국어 L2a 사유 생성/critique
  - Claude Sonnet — 에이전트 대화, 3-에이전트 합의
  - Claude Haiku — 자체 검증 레이어 사실성 판정
  - Claude Opus — 분기 심층 감사
  - Titan Embeddings V2 — 벡터화

  Bedrock 인프라를 추천사유 생성과 에이전트가 공유하며, 쿼터 경쟁은 시간대 분리로 해결.

두 배포 환경 모두 운영 에이전트는 DAG 사이클당 1–2회만 호출하므로, 모델 선택에 관계없이 비용과 지연시간이 무시할 수준이다.

5.5 실무적 가치

운영 에이전트는 금융 AI 운영의 세 가지 구체적 고충을 해결한다:

1. 대시보드 피로 해소: 매일 10개 이상의 메트릭 대시보드를 모니터링하는 대신, 운영 팀이 자연어 요약 하나를 읽는다 — "출근해서 확인하면 됩니다."
2. 감사 증거 자동 축적: 규제기관이 "드리프트 이벤트 X에 어떻게 대응했는가?"라고 물으면, 해당 일자의 OpsAgent 보고서와 이후 인간의 조치 기록을 제시하여 완전한 인시던트 대응 이력을 구성한다.
3. 소규모 팀 MLOps 실현: 대규모 MLOps 팀 없이도 규제 준수 운영이 가능한 구조이다. 에이전트가 정형화된 해석을 담당하고, 인간은 규제가 실제로 요구하는 판단을 기여한다.

5.6 파이프라인 파트 분류 및 점검 체크리스트

에이전트가 체계적으로 점검하기 위해 파이프라인을 6개 파트로 분류하고 48개 점검 항목을 정의한다: P1(인제스천), P2(피처 엔지니어링), P3(학습/증류), P4(서빙/추천), P5(추천사유 생성), P6(모니터링/거버넌스). 각 항목은 YAML config에서 도구 이름, 임계값, 판정 로직으로 정의되며, OpsAgent는 23개, AuditAgent는 25개 항목을 담당한다.

5.7 도구 호출 체계

38개 도구(Query 29 + Action 9)가 JSON Schema로 정의되며, 기존 모니터링 컴포넌트(드리프트 감지 모듈, 공정성 모니터, 자체 검증 레이어 등)를 도구로 래핑하여 에이전트가 호출한다. Query 도구는 자유롭게 호출 가능하나, Action 도구(인시던트 생성, 감사 로그 기록 등)는 명시적 승인 후에만 실행하여 Query/Action 경계를 구조적으로 보장한다.

5.8 3-에이전트 합의 메커니즘

LLM 기반 해석의 할루시네이션 리스크를 구조적으로 완화하기 위해 3개의 독립 Sonnet 세션을 병렬 실행한다. 각 에이전트에 다른 관점을 부여한다: α(보수적), β(통계적 유의성), γ(비즈니스 영향).

합의 결과는 3단계로 분류된다: (1) 만장일치(3/3): 확정 판정, (2) 다수 이상(2/3): 최우선 리뷰 — 즉시 담당자 검토, (3) 마이너리티 리포트(1/3): 2순위 리뷰 — 소수 의견을 별도 기록.

핵심 원칙은 마이너리티 리포트의 보존이다. 소수 의견은 식별 즉시 확정되며 이후 삭제할 수 없다 — 운영/감사 영역에서는 "놓치는 것"이 "오탐"보다 위험하기 때문이다. 새로운 유형의 문제는 기존 패턴에 익숙한 다수가 놓치고 다른 관점의 소수가 먼저 포착할 수 있다.

금감원 요구사항	시스템 구성요소	검증 방법
설명 가능성	게이트 가중치 + 3-에이전트 추천사유	추천건별 감사 로그
공정성	공정성 모니터 (DI/SPD/EOD)	주간 자동 보고서
모델 검증	챔피언-챌린저	배포 전 비교
모니터링	드리프트 감지 모듈 (PSI)	연속적, 3일 트리거
감사 추적	HMAC 해시체인 로그	불변, 7개 감사 테이블
폴백	템플릿 추천사유 + 킬 스위치	즉시 수동 오버라이드
모델 리스크 관리	챔피언-챌린저 관리자	독립적 검증, 수동 승인
고객 적합성	제약 인식 엔진 + 적격성 필터	추천 전 적합성 사전 검증

Table 5: 한국 금감원 가이드라인 준수 매핑.

5.9 진단 케이스 스토어

점검 리포트는 일회성 산출물이 아니라 운영 지식 베이스로 축적된다. LanceDB 기반 진단 케이스 지식베이스에 각 진단 케이스의 구조화된 메타데이터(파트, 항목, 판정, severity)와 텍스트 임베딩(finding + cause + action)을 저장하여 세 가지로 활용한다: (1) 유사 케이스 검색: 새로운 이상 발생 시 과거 대응 이력 참조, (2) 통계 분석: 파트별 빈번 WARN 유형, 평균 해결 시간 집계, (3) 대응 효과 추적: (문제, 대응, 후속 판정) 3-tuple로 대응의 실제 효과를 정량화.

케이스 스키마에 `consensus_type` 필드를 포함하여 마이너리티가 사후에 맞았던 비율도 추적한다. 이 데이터는 규제기관 감사 시 "지속적 개선 증명" 근거로 직접 활용된다.

5.10 메모리 프레임워크 선택적 차용

2026년 초 발표된 여러 에이전트 메모리 프레임워크(Mem0, Zep/Graphiti, Letta, SuperLocalMemory)의 핵심 패턴만 차용하여 기존 인프라에 증분 추가하였다.

차용 1 — 시간적 지식 그래프 (Zep/Graphiti): 시간적 팩트 스토어가 `(엔티티, 속성, 값, valid_from, valid_to)` 스키마로 감사 증적을 저장. "2026-03-15 시점의 고객 A 상태는?" 같은 시점 복원 쿼리를 단일 필터로 처리한다. 기존 진단 케이스 지식베이스와 같은 LanceDB 백엔드를 재사용하여 신규 의존성 0.

차용 2 — 수학적 Decay (SuperLocalMemory): 진단 케이스 지식베이스의 유사 케이스 검색에 $\exp\left(-\frac{\text{age}}{\tau}\right)$ 가중치를 추가. 반감기 90일 기본값. 원본 케이스는 보존되고 검색 가중치만 조정되므로 감사 추적성이 유지된다.

차용 3 — Dialog Recall Memory (Letta): 대화 회상 메모리가 담당자와의 과거 대화를 DynamoDB에 저장하여 세션 간 맥락을 유지한다. "지난번 논의한 그 이슈"를 Bedrock 대화 인터페이스가 기억할 수 있다.

차용하지 않은 것: LangMem의 프롬프트 자기개선 (감사 관점 위험 — "누가 이 프롬프트를 승인했는가?"에 답할 수 없음).

모든 차용은 opt-in 설계로, 기존 동작에 영향을 주지 않는다.

5.11 변경 감지 및 영향도 리뷰

코드, 설정, 모델, 데이터 소스 변경을 두 가지 채널로 감지한다: Push 채널(git hook, 파이프라인 상태 콜백, 인제스천 완료 이벤트)은 즉시 감지하고, Pull 채널(manifest diff, 서빙 지표 폴링)은 주기적으로 감지한다. 변경이 감지되면 영향 받는 파이프라인 파트의 체크리스트를 재실행하고, AWS 환경에서는 Sonnet이 diff를 읽고 하류 영향을 추론하여 담당자와 대화하며 영향도를 논의할 수 있다.

6 규제 준수

6.1 한국 금감원 가이드라인 매핑

Table 5 은 한국 금감원 AI 가이드라인의 주요 요구사항과 본 시스템의 대응 구성요소를 매핑한다. 각 요구사항에 대해 시스템 구성요소와 검증 방법을 명시한다.

6.2 EU AI Act 매핑

Table 6 은 EU AI Act의 핵심 조항과 본 시스템의 준수 방식을 매핑한다. 금융 추천 시스템은 Annex III Section 5에 의해 고위험 AI로 분류되어 Title III Chapter 2의 요구사항을 충족해야 한다.

6.3 한국 AI 기본법 (2024.12 통과, 2026.1 시행)

2024년 12월 국회를 통과하고 2025년 1월 공포된(시행: 2026년 1월) 한국 인공지능 기본법은 AI 시스템을 위험 수준에 따라 분류하고, "고영향 AI"에 대해 강화된 의무를 부과한다.

금융 상품 추천의 고영향 분류 여부. 동법 제2조 및 시행령 초안에 따르면, 금융 서비스에서 개인의 경제적 의사결정에 실질적 영향을 미치는 AI는 고영향 AI로 분류될 가능성이 높다. 구체적으로: (1) 투자 상품 추천은 금소법 제19조(적합성 원칙)의 적용을 받으며, AI가 추천 사유를 생성하는 경우 설명의무가 강화된다; (2) 신용·대출 관련 추천은 신용정보법과의 교차 규제 대상이다; (3) 예금·보험 등 원

조항	요구사항	시스템 구성요소
제13조	투명성	3-에이전트 추천사유 생성 + 피처 기여도
제14조	인간 감독	Human-in-the-Loop 리뷰 + 킬 스위치
제15조	정확성 및 견고성	어블레이션 검증된 성능 저하 + 드리프트 모니터링
제9조	리스크 관리	MRM 생애주기: 개발 → 검증 → 승인 → 모니터링 → 재학습
GDPR 제22조	거부 권리	동의/거부 감사 테이블 + 수동 오버라이드

Table 6: EU AI Act 조항별 준수 매핑.

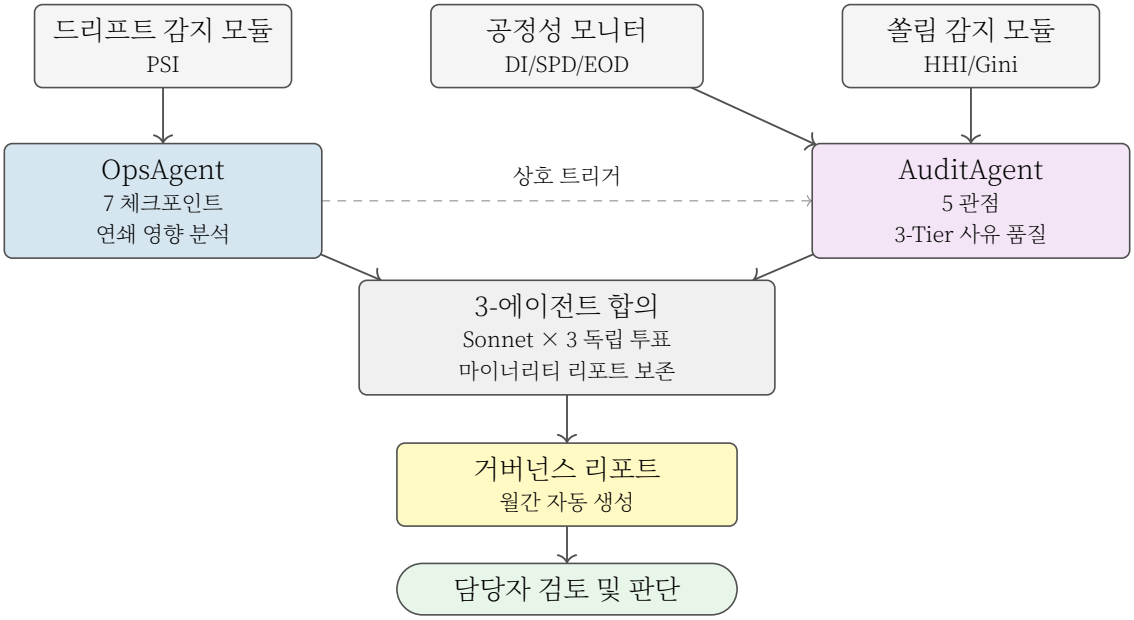

Figure 6: 모니터링 및 거버넌스 아키텍처.
모니터링 컴포넌트 → 운영/감사 에이전트 → 합의 → 거버넌스 리포트 → 담당자 검토.

금보장 상품은 상대적으로 낮은 위험 등급이나, AI 기반 교차판매(cross-sell) 추천은 고영향에 해당할 수 있다.

본 시스템의 대응. 3-Agent 파이프라인의 Safety Gate가 고영향 AI의 핵심 요건인 (1) 투명성 (추천 사유 제공), (2) 인간 감독 (관리자 검토 경로), (3) 기록 보존 (감사 추적)을 구조적으로 충족한다. 특히 IG 기반 피처 귀인과 해석 레지스트리의 조합은 "왜 이 추천이 생성되었는가"에 대한 기술적 근거를 규제 검사관에게 제공할 수 있다.

6.3.1 배포 대상 상품군 한정

저위험 상품 한정 배포. 본 연구의 실제 배포 대상은 체크카드, 예금, 수시입출금 등 저위험 상품군이다. 투자상품(펀드, 주식, 채권 등)과 보험 상품은 금소법 제19조 적합성 원칙 및 불완전판매 리스크로 인해 많은 관할권(한국, EU MiFID II, 미국 Reg BI 등)에서 AI 직접 추천이 제한되거나 인간 자문인 감독이 필수적이며, 본 시스템은 해당 상품군을 배포 범위에서 의도적으로 제외한다.

합성 데이터(Santander 941K)는 벤치마크 목적으로 상품군을 가리지 않고 다양한 태스크를 포함하지만 — `will_acquire_investments` 같은 태스크도 벤치마크 목적으로 학습 — , 실제 운영 배포는 체크카드 추천에 국한된다. 이 구분은 "모델이 학습한 것"과 "시스템이 실제로 추천하는 것"을 분리하여, 벤치마크 평가의 일반성을 유지하면서 규제 리스크를 최소화한다.

왜 이 구분이 중요한가. 리뷰어가 Paper 2의 예시("왜 이 카드가 저에게 추천되었나요?")를 보고 "투자 상품은 왜 예시에 없는가?"라고 묻는다면, 답은 의도적 배제이다. AI 에이전트가 자연어 추천사유를 생성하는 기술 자체는 투자 상품에도 적용 가능하지만, 불완전판매 리스크를 완전히 제거하려면 인간 자문인의 최종 검토가 필요하며, 이는 본 논문의 자동화 주장과 양립하지 않는다. 저위험 상품에 한정함으로써 "완전 자동화된 설명 가능한 추천"이라는 주장이 규제와 양립 가능한 형태로 성립한다.

6.4 모니터링 및 거버넌스

6.4.1 Human-in-the-Loop

규제기관(한국 금감원, EU AI Act 제14조)은 인간 감독을 요구한다. 본 시스템은 다중 수준에서 이를 구현한다:

- 추천사유 표본 검토: 생성된 추천사유의 주기적 인간 검토.

- 모델 교체 승인: 챔피언-챌린저 결과에 대한 인간 승인 필요.
- 인시던트 에스컬레이션: 자동화된 이상 탐지가 인간 조사를 트리거.
- 공정성 검토: 공정성 지표에 대한 주기적 인간 감사.

6.5 고위험 AI를 위한 파이프라인 감사 가능성

앞선 절들은 개별 시스템 구성요소를 규제 조항에 매핑하였다. 그러나 EU AI Act의 고위험 AI 요구사항(Title III, Chapter 2)은 서빙 계층만이 아닌 전체 ML 파이프라인의 감사 가능성을 요구한다. 본 절에서는 동반 논문에서 기술된 학습 인프라가 이러한 요구사항을 엔드투엔드로 충족함을 보인다.

6.5.1 데이터 거버넌스 (제10조)

제10조는 학습 데이터가 "관련성 있고, 대표성 있으며, 오류가 없고 완전"할 것과 적절한 데이터 거버넌스 조치를 요구한다. 본 시스템의 Phase 0 파이프라인(전처리 → 피처 생성 → 레이블 파생 → 정규화 → 텐서 저장)은 매 실행 시 두 가지 감사 산출물을 생성한다: 피처 통계 파일은 컬럼별 NaN 비율, 제로 분산 플래그, 분포 통계, 생성된 피처 수를 기록하고; 레이블 통계 파일은 14개 전체 태스크의 클래스 균형과 양성 비율을 기록한다. 이 산출물은 외부 감사인이 코드를 실행하지 않고도 검사할 수 있는 검증 가능한 데이터 품질 기록을 구성한다.

재현 가능성은 config 기반 처리를 통해 보장된다: 전체 파이프라인이 2개의 YAML 설정 파일(파이프라인 설정과 피처 그룹 설정)로 제어되므로, 동일한 config는 동일한 입력 데이터에서 동일한 출력을 생성한다. 실행 가능한 코드에 데이터셋 특화 로직이 존재하지 않는다.

학습 전 게이트로서 리키지 검증기는 (1) 스케일러가 학습 데이터에서만 fit되었는지, (2) train/validation/test 분할 간 시간적 갭이 존재하는지, (3) 마지막 시퀀스 타임스텝이 레이블 윈도우와 겹치지 않는지를 검증한다. 어떤 검증이라도 실패하면 학습이 차단되어 — 데이터 거버넌스 위반이 컴퓨팅 자원이 소비되기 전에 포착됨을 보장한다.

6.5.2 기술 문서화 (제11조)

제11조는 규제 준수를 평가하기에 충분한 기술 문서를 의무화한다. 본 시스템은 config-as-documentation을 통해 이를 달성한다: 2개의 YAML 설정 파일이 피처 그룹, 생성기 파라미터, 정규화 단계, 태스크 정의, 손실 가중치, 전문가 라우팅을 완전히 명세한다. 모든 학습 실행과 함께 config 스냅샷이 저장되며, 학습 평가 메트릭 파일이 전체 학습 출처 정보 (하이퍼파라미터, 데이터 분할, 최종 메트릭, 타임스탬프)를 기록한다. 고정된 랜덤 시드와 결합하여, 과거의 모든 실험은 아카이브된 config로부터 정확히 재현 가능하다.

6.5.3 로깅 및 추적 가능성 (제12조)

제12조는 위험 식별과 중대한 변경 사항에 대한 이벤트의 자동 기록을 요구한다. 학습 루프는 태스크별 손실 분해가 포함된 에포크별 로그를 생성하여, 감사인이 성능 변화가 정확히 언제 어디서 발생했는지 추적할 수 있다. NaN/Inf 탐지는 일반적인 학습 실패를 보고하는 대신 어떤 태스크에서 이상 그래디언트가 발생했는지를 식별한다. 그래디언트 노름 모니터링은 노름이 클리핑 임계값의 10배를 초과할 때 경고를 발생시켜 학습 안정성에 대한 감사 추적을 제공한다. 체크포인트는 대응하는 평가 메트릭과 함께 버전 관리되어, 데이터에서 배포 모델까지의 완전한 계보를 생성한다.

6.5.4 인간 감독 (제14조)

위에서 기술한 Human-in-the-Loop 메커니즘 외에도, 본 시스템은 인간 검토자를 위한 두 가지 추가 투명성 계층을 제공한다.

- 증류 후 LGBM 학생 모델은 태스크별 IG 기반 피처 중요도 순위를 노출하여 — 규제 준수 담당자가 딥러닝 전문 지식 없이도 검토할 수 있는 인간 가독 감사를 제공한다.
- PLE 교사 모델의 CGC 게이트 가중치는 각 전문가의 모든 예측에 대한 기여를 정량화하여, 전문가 라우팅 메커니즘을 블랙박스 앙상블이 아닌 투명한 구조로 만든다.

3-에이전트 LLM 파이프라인(4절)은 나아가 이러한 기술적 기여도를 규제 준수 담당자가 직접 평가할 수 있는 자연어 설명으로 변환한다.

6.5.5 정확성 및 견고성 (제15조)

제15조는 고위험 AI 시스템이 "적절한 수준의 정확성, 견고성, 사이버보안"을 달성할 것을 요구한다. 동반 논문의 어블레이션 연구는 우아한 성능 저하를 입증한다: 어떤 단일 전문가를 제거하더라도 성능이 점진적으로 감소하며 치명적 실패를 유발하지 않아, 단일 구성요소가 핵심 장애점이 아님을 증명한다. 불확실성 가중치(Uncertainty weighting) [9] 는 단일 태스크가 다중 태스크 목적 함수를 지배하는 것을 방지하여, 14개 전체 태스크에서 동시에 견고한 성능을 보장한다. 드리프트 모니터링(PSI 기반)은 배포 시 지속적인 견고성 검증을 제공하도록 설계되었다.

6.5.6 편향 모니터링 (제10조 2항 f호)

제10조 2항 f호는 건강, 안전, 기본권에 영향을 미칠 수 있는 편향에 대한 학습 데이터 검토를 요구한다. 학습 전 레이블 분포 검증(레이블 통계 파일을 통해)은 클래스 불균형이 문서화되고 처리됨을 보장한다. 학습 평가 메트릭의 태스크별 분해는 세그먼트별 성능 모니터링을 가능하게 한다: 감사인은 모델 정확도가 고객 인구통계 또는 상품 카테고리에 따라 체계적으로 변동하지 않는지 검증할 수 있다. 공정성 모니터 구성요소(불균등 영향, 통계적 동등성 차이, 균등 확률 차이)는 제10조 2항 f호가 요구하는 세분화 수준에서 자동화된 편향 탐지를 제공한다.

방법	정확성	자연스러움	설득력	규제 준수
템플릿	–	–	–	–
SHAP+템플릿	–	–	–	–
3-에이전트 (본 연구)	–	–	–	–

Table 7: 인간 평가 결과 (TODO).

검증 항목	정밀도	재현율	폴백 비율
환각	–	–	–
규제	–	–	–
적합성	–	–	–
전체	–	–	–

Table 8: Safety Gate 정밀도 및 재현율 (TODO).

구성요소	지연시간	비용/1K 요청	비고
LGBM 추론	< 10ms	–	Lambda CPU
IG 기여도	< 50ms	–	Lambda CPU
추천사유 생성	< 200ms	–	캐시 적중: < 5ms
Safety Gate	< 50ms	–	규칙 기반 + LLM
합계	< 300ms	–	캐시 적중: < 100ms

Table 9: 서빙 지연시간 분석 (Lambda 서버리스, GPU 미사용).

6.5.7 모델 리스크 관리 생애주기

본 시스템은 SR 11-7에 부합하는 5단계 MRM 생애주기를 구현한다: 개발(교사 모델 학습 + 학생 증류), 검증(보류 데이터에 대한 독립적 메트릭 평가), 승인(수동 승인 게이트; 자동 승격 비활성화 기본값), 모니터링(PSI 기반 연속 드리프트 탐지), 재학습(드리프트 임계값 초과 시 자동 재증류). 챔피언-챌린저 관리자가 챔피언-챌린저 평가를 오케스트레이션한다: 새로 증류된 학생 모델이 생성되면, 모든 타겟 메트릭에서 현재 운영 챔피언과 비교된다. 승격에는 명시적 인간 승인이 필요하며 — 시스템이 운영 모델을 자동으로 교체하지 않는다. 드리프트 탐지기가 연속 모니터링 윈도우에서 발동하면 (설정 가능한 임계값, 기본 연속 3일), 재학습 단계가 자동 트리거되어 경쟁 사이클에 재진입하는 새로운 챌린저를 생성한다. 이 폐쇄 루프는 모델 리스크가 이산적 연간 검토 시점이 아닌 연속적으로 관리됨을 보장하여, SR 11-7 기대사항과 EU AI Act 제9조 리스크 관리 요구사항을 모두 충족한다.

7 실험

7.1 증류 실험

7.2 추천사유 생성 품질

7.2.1 인간 평가 프로토콜

- 평가자: N명의 금융 도메인 전문가(은행 상품 관리자, 규제 준수 담당자).
- 평가 기준: 정확성 (1-5), 자연스러움 (1-5), 설득력 (1-5), 규제 적합성 (1-5).
- 비교 대상: (A) 템플릿 기반, (B) SHAP 기반 + 템플릿, (C) 3-에이전트 파이프라인.
- 방법: 블라인드 평가, 각 평가자가 100개 추천사유를 평가.

7.3 Safety Gate 평가

7.4 서빙 성능

7.5 규제 준수 감사

세 가지 차원에서 규제 정합성을 평가한다: 체크리스트 준수, 감사 추적 무결성, 공정성 지표.

체크리스트 준수. 금소법 제17–19조, EU AI Act 제13–14조, 금감원 AI 가이드라인에서 도출한 14개 규제 요건을 구현한다. 주요 항목: 추천 전 적합성 평가(제19조), AI 생성

콘텐츠 고지(제17조), 인간 감독 메커니즘(EU AI Act 제14조), 거부(opt-out) 기능.

감사 추적 무결성. 모든 추천 사유에 대해 다음을 기록한다: (1) 사유 생성에 사용된 IG 피처 귀인 벡터, (2) Safety Gate의 통과/실패 판정 및 실패 사유, (3) LLM 프롬프트-응답 쌍, (4) 추천을 원본 모델 버전에 연결하는 SHA-256 해시 체인. 감사 로그는 추가 전용(append-only)이며 변조 방지 구조로 저장되어 규제 검사에 적합하다.

공정성 지표. 보호 속성(연령대, 성별, 소득 구간)별로 Disparate Impact(DI), Statistical Parity Difference(SPD), Equal Opportunity Difference(EOD)를 태스크별로 산출한다. 공정성 모니터가 배치 스케줄로 실행되며, 설정된 임계값을 초과하면 알림을 생성한다.

8 논의

8.1 주요 발견 요약

파이프라인 전체 평가에서 세 가지 발견이 도출된다.

발견 1: 트리 기반 증류에서 온도 스케일링이 불필요하다. 표준 Hinton 증류 공식($T = 3$–20)과 달리, $T = 1$로 학습한 LGBM 학생이 $T = 5$ 대비 더 낮은 JSD와 보정 격차를 달성한다. 이는 Soft GBM 분석 [3] 과 일치한다: 트리 모델은 소프트 레이블의 절대값과 순서에서 학습하며, 꼬리 확률의 경사 흐름이 아니다. 신경망 학생의 역전파를 위해 설계된 온도 하이퍼파라미터는 분할 기반 학습자에게 불필요하며 오히려 해롭다.

발견 2: 이중 목적 피처 선택이 설명 품질을 보존한다. α 가중 IG 점수($\mathrm{IG}_{\mathrm{pred}} + \mathrm{IG}_{\mathrm{explain}}$)는 순수 예측 선택에서 탈락할 피처를 유지하되, 이들이 비즈니스 언어 추천 사유 생성에 필수적이다. `hmm_lifecycle_prob_growing`이나 `synth_monthly_spend` 같은 피처는 AUC 기여가 미미할 수 있으나, LLM 생성 설명을 고정하는 서사적 앵커("성장 단계", "소비 패턴")를 제공한다.

발견 3: Safety Gate는 선택이 아닌 필수이다. LLM 검증 없는 템플릿 기반 폴백은 문법적으로 정확하지만 간혹 오해를 유발하는 사유를 생성한다 (예: 해당 고객에게 실제로 영향력이 없는 피처를 인용). Safety Gate는 생성된 텍스트를 실제 IG 귀인 벡터와 대조하여 환각 유사 오류를 감소시킨다.

8.2 피처의 이중 역할

본 연구의 핵심 통찰: 금융 추천에서 피처는 이중 목적을 수행한다. 예측 기여가 미미한 피처라 할지라도(예: TDA 위상적 피처는 ΔAUC = 0.01에 불과할 수 있음) 추천사유 추론에 대체 불가능한 맥락을 제공한다. 내부적으로 TDA 지속성(persistence)은 행동 형태 안정성을 포착하지만 — 고객은 "지속적 호몰로지"나 "베티 수"를 보지 않는다. 대신 피처 해석 레지스트리가 이를 비즈니스 언어로 역매핑하고 (예: "꾸준한 거래 패턴을 유지하고 계십니다"), LLM 에이전트가 이를 자연어 추천사유로 엮는다.

이는 피처 엔지니어링 평가를 재구성한다: 피처의 가치는 예측 기여도만이 아니라 추천사유 생성 파이프라인이 활용할 수 있는 추천 맥락에 대한 기여도이기도 하다. 동반 논문에서 주장했듯이, 무엇을 관측할 것인가가 어떻게 모델링할 것인가보다 중요하다 — 도메인 특화 질문에서 파생된 피처 ("소득이 항상적인가 일시적인가?", "상품 채택이 전파처럼 확산되는가?")는 내부 추론 맥락을 풍부하게 하여, 얕은 통계적 요약에 아무리 정교한 아키텍처를 적용하는 것보다 더 섬세한 비즈니스 언어 설명을 가능하게 한다.

8.3 실무 배포 고려사항

- LLM 선택: 온프레미스 LLM vs. API(지연시간, 비용, 데이터 상주).
- 추천사유 품질 유지: 주기적 인간 검토 + 자동화된 품질 점수.
- 규제 업데이트: 아키텍처가 재설계 없이 새로운 규제 준수 검증 추가를 지원.

8.4 한계

- LLM 의존성이 비용, 지연시간, 잔여 환각 위험을 발생시킨다.
- 인간 평가 규모가 전문가 가용성에 제한된다.
- 한국/EU 규제에 초점; 기타 관할권은 아직 분석되지 않았다.
- 템플릿 폴백 품질은 본질적으로 제한적이다.

8.5 향후 연구

- 추천사유 품질 → 전환율에 대한 실제 고객 A/B 테스트.
- 다국어 추천사유 생성(한국어, 영어, 중국어).
- 자동화된 규제 업데이트 파이프라인(규제 변경 → 규제 준수 검증 업데이트).
- 범용 API를 대체할 도메인 특화 미세조정 소형 LLM.

9 결론

본 연구에서는 금융 상품 추천에서 모델 예측과 인간 설득 사이의 간극을 잇는 전체 체인 시스템을 제시하였다.

네 가지 핵심 기여가 본 연구를 정의한다.

- 이중 목적 피처 선택을 갖춘 IG 기반 지식 증류는 복잡한 PLE 교사 모델을 경량 LGBM 학생 모델로 압축할 때 예측 정확도와 설명 재료를 모두 보존한다.
- 3-에이전트 추천사유 생성 파이프라인(Feature Selector → Reason Generator → Safety Gate)은 비즈니스 매핑된 피처 기여도에 근거한 자연어 설명을 생성하며, 역할 분리를 통해 독립적 개선과 감사 로깅을 가능하게 한다.
- 2개의 운영 에이전트(OpsAgent, AuditAgent)가 모니터링 및 규제 준수 출력을 자연어로 해석하여 대시보드 피로를 해소하고, 전담 MLOps 인력 없이도 소규모 팀의

논문의 개념	구현 모듈
피처 해석 레지스트리	`core/recommendation/reason/interpretation_registry.py`
역매핑 레이어	`core/recommendation/reason/reverse_mapper.py`
팩트 추출 레이어	`core/recommendation/reason/fact_extractor.py`
3-에이전트 서빙 파이프라인	`core/recommendation/reason/async_orchestrator.py`
자체 검증 / Safety Gate	`core/recommendation/reason/self_checker.py`
템플릿 엔진	`core/recommendation/reason/template_engine.py`
운영 에이전트	`core/agent/ops/`
감사 에이전트	`core/agent/audit/`
합의 메커니즘	`core/agent/consensus.py`
진단 케이스 지식베이스	`core/agent/case_store.py`
시간적 팩트 스토어	`core/agent/temporal_fact_store.py`
대화 회상 메모리	`core/agent/dialog_recall.py`
도구 레지스트리	`core/agent/tool_registry.py`
설정 파일	`configs/financial/*.yaml`

Table 10: 논문 개념과 구현 모듈 매핑.

규제 준수 운영을 가능하게 한다 — 아키텍처를 5-에이전트 시스템(서빙 3 + 운영 2)으로 확장한다.

- 규제 준수가 설계 단계부터 내장된다 — 한국 금감원 가이드라인, EU AI Act, 한국 AI 기본법이 시스템 아키텍처 구성요소에 명시적으로 매핑되며, 자동화된 모니터링(드리프트, 공정성, 쏠림)과 핵심 의사결정 지점에서의 Human-in-the-Loop 감독을 갖춘다.

근본적인 통찰은 금융 AI에서 피처가 이중 역할을 수행한다는 것이다: 피처는 예측에 기여할 뿐만 아니라 궁극적으로 고객을 설득하고, 관계 관리자에게 힘을 부여하며, 규제기관을 만족시키는 설명 어휘에도 기여한다. 이는 전통적인 피처 엔지니어링 계산법을 재구성한다: AUC 기여가 미미하지만 비즈니스 해석 가능성이 풍부한 피처가 높은 AUC를 가지지만 의미 있는 설명을 생성하지 못하는 피처보다 더 가치 있을 수 있다.

본 시스템은 서버리스 인프라(AWS Lambda)에서의 배포를 위해 설계되어, 전용 GPU 서버 없이 100ms 미만의 서빙 지연시간을 달성한다 — 제한된 ML 엔지니어링 리소스를 가진 금융기관의 운영 현실에 부합한다.

저자 기여

정선규 (PM/데이터 사이언티스트): 증류 전략, 추천사유 생성 파이프라인, 규제 준수 아키텍처 설계. 금융위험관리 도메인 전문성 기반 전체 시스템 설계 주도. 심은철, 김영찬: 증류 파이프라인, 서빙 인프라, 모니터링 구성요소를 개발 서포터즈로서 구현.

연구비

본 연구는 외부 연구비, 보조금, 기관 인프라 지원을 일절 받지 않았다. AI 도구, 하드웨어, 모바일 통신비, AWS SageMaker 클라우드 학습(Spot 인스턴스), S3 스토리지, 운영 경비 등 모든 비용은 전적으로 제1저자의 개인 자금으로 충당하였으며, 자원이 극히 제한된 환경에서 데스크톱 GPU 1대로 개발을 수행하였다.

감사의 말

항상 업계 상황과 마케팅 관점에서 좋은 아이디어를 제공해준 김연진에게 감사를 표한다.

불철주야 휴일도 저녁도 없이 개발에 헌신해준 두 명의 엔지니어 심은철, 김영찬에게 깊은 감사를 표한다. 정식 고용이나 보상 없이도 프로젝트에 전력을 다해준 이들의 헌신이 이 시스템의 완성을 가능하게 했다.

마지막으로, 이 연구를 가능하게 해준 AI 도구들에 감사를 표한다. 아이디에이션과 설계 브레인스토밍의 Gemini, 아키텍처 구축, 구현, 집필의 Claude Opus와 Sonnet, 그리고 원활한 개발 환경의 Cursor. 한 개인의 상상이 공상으로 끝날 수 있었던 것을, 소수의 인원과 이 도구들의 협업이 현실로 만들어주었다.

부록 A. 구현 참조

본 논문에서 기술한 개념들은 공개 코드 저장소에서 구체적인 Python 구현을 찾을 수 있다. 주요 개념과 구현 모듈의 매핑은 다음과 같다:

상세한 구현 세부사항, 단위 테스트, 설정 파일은 공개 저장소에서 확인할 수 있다.

Bibliography

[1] European Banking Authority. 2025. Report on Machine Learning in Internal Models.

[2] European Parliament and Council. 2024. Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (AI Act).

[3] Jiawei Feng, Yang Yu, and Zhi-Hua Zhou. 2020. Soft Gradient Boosting Machine. In arXiv preprint arXiv:2006.04059, 2020.

[4] Financial Services Commission (Korea). 2024. Financial Sector AI Guidelines.

[5] Milton Friedman. 1957. A Theory of the Consumption Function. Princeton University Press.

[6] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. 2015. Distilling the Knowledge in a Neural Network. In NIPS Deep Learning and Representation Learning Workshop, 2015.

[7] Kalervo Järvelin and Jaana Kekäläinen. 2002. Cumulated gain-based evaluation of IR techniques. ACM Transactions on Information Systems 20, 4 (2002), 422–446.

[8] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. 2017. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. In Advances in Neural Information Processing Systems (NeurIPS), 2017.

[9] Alex Kendall, Yarin Gal, and Roberto Cipolla. 2018. Multi-Task Learning Using Uncertainty to Weigh Losses for Scene Geometry and Semantics. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2018.

[10] Scott M Lundberg and Su-In Lee. 2017. A Unified Approach to Interpreting Model Predictions. In Advances in Neural Information Processing Systems (NeurIPS), 2017.

[11] National Assembly of Korea. 2024. Act on the Development of Artificial Intelligence and Establishment of Trust (AI Basic Act).

[12] Huy Nguyen and others. 2024. Sigmoid Gating is More Sample Efficient than Softmax Gating in Mixture of Experts. In Advances in Neural Information Processing Systems (NeurIPS), 2024.

[13] Judea Pearl. 2009. Causality: Models, Reasoning, and Inference (2nd ed.). Cambridge University Press.

[14] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. 2016. Why Should I Trust You?: Explaining the Predictions of Any Classifier. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016.

[15] Amr Salih and others. 2023. Examining the Limitations of Post-hoc Explainability Methods in Finance. Frontiers in Artificial Intelligence (2023).

[16] Mukund Sundararajan, Ankur Taly, and Qiqi Yan. 2017. Axiomatic Attribution for Deep Networks. In Proceedings of the 34th International Conference on Machine Learning (ICML), 2017.