예측에서 설득으로: 규제 준수 금융 AI를 위한 에이전트 기반 추천 사유 생성

Author 1[1], Author 2[1], Author 3[1]

[1]독립 연구
(한국 공공 금융기관 소속)

초록. 금융 상품 추천 시스템은 상품을 추천하는 이유를 설명해야 한다 — 무엇보다도 설득에는 확률이 아닌 서사(narrative)가 필요하기 때문이다: "왜 이 펀드를 사야 하나요?"라고 묻는 고객에게는 신뢰해야 할 점수가 아니라 수긍할 수 있는 이유가 필요하다. 규제기관(한국 금감원, EU AI Act)은 이러한 설명의 중요한 수요자이지만, 본질적 동인은 설득이라는 인간 행위 그 자체이다. 본 연구에서는 모델 예측과 인간 설득 사이의 간극을 잇는 3단계 파이프라인을 제안한다: (1) 이종 전문가 PLE 교사 모델에서 태스크별 LGBM 학생 모델로의 IG 기반 지식 증류를 통해 설명에 적합한 피처를 보존하면서 GPU 없는 CPU 추론을 가능하게 하고; (2) 3개의 전문화된 에이전트(Feature Selector, Reason Generator, Safety Gate)가 협업하여 비즈니스 매핑된 피처 기여도에 기반한 자연어 설명을 생성하는 멀티 에이전트 추천사유 생성 파이프라인; (3) 드리프트 모니터링, 공정성 감사, 거버넌스 보고를 내장한 설계 단계부터의 규제 준수로, 한국 금감원 가이드라인, EU AI Act, 한국 AI 기본법에 부합한다. 증류 품질(AUC 격차 $<$ X%), 도메인 전문가 N명의 인간 평가를 통한 추천사유 생성 품질(템플릿 베이스라인 대비 Y% 선호도), Safety Gate 신뢰도(정밀도/재현율)를 평가한다. 본 시스템은 전용 GPU 추론 서버 비용의 일부로 AWS Lambda에서 100ms 미만의 서빙 지연시간을 달성한다.

키워드: 추천 설명, 지식 증류, LLM 에이전트, 규제 준수, 금융 AI, EU AI Act

1 서론

1.1 설득 문제

금융 추천 시스템의 최종 산출물은 확률이 아니라 고객이 수긍할 수 있는 이유이다. $P(\text{invest} \mid x) = 0.73$을 출력하는 모델은 다음 주체에게 아무런 가치를 제공하지 못한다:

- "왜 이 펀드를 사야 하나요?"라고 묻는 고객.
- 영업 전화에서 대화 포인트가 필요한 관계 관리자 **(RM)**.
- EU AI Act 제13조에 따라 "왜 이 결정을 내렸는가?"를 요구하는 규제기관.

기존 설명 접근법은 불충분하다:

- **SHAP/LIME**: "feature_237이 0.12 기여" — 비즈니스 의미가 없고, 교란(perturbation) 하에서 불안정 [7, 10].
- 템플릿 기반: "고객님과 유사한 고객들도 X를 구매했습니다" — 경직되고 개별 맥락을 무시.
- 직접 **LLM** 생성: 환각(hallucination) 위험, 실제 모델 추론에 기반하지 않음, 규제 미준수.

1.2 본 연구의 접근법

본 연구에서는 예측에서 설득까지의 전체 체인 솔루션을 제안한다:

1. 지식 증류: 이종 전문가 PLE 교사 모델(18개 태스크, 7개 전문가, 318개 피처; 동반 논문의 Financial DNA × Data Modality 환원적 이축 프레임워크로 구성)을 IG 기반 피처 선택을 통해 태스크별 LGBM 학생 모델로 증류한다. 이를 통해 설명에 중요한 피처를 보존하면서 GPU 없는 서빙을 가능하게 한다.
2. 멀티 에이전트 추천사유 생성: 3개의 전문화된 LLM 에이전트가 파이프라인에서 협업한다 — Feature Selector가 설명에 적합한 피처를 선택하고, Reason Generator가 자연어 서사를 생성하며, Safety Gate가 규제 준수를 검증한다.
3. 설계 단계부터의 규제 준수: 드리프트 모니터링, 공정성 감사, 감사 추적, 거버넌스 보고가 배포 후 부착되는 것이 아니라 파이프라인에 내장된다.

1.3 기여

1. 설명 보존을 위한 **IG** 기반 증류: 피처 선택이 예측 정확도뿐만 아니라 설명 재료 가용성까지 최적화한다.
2. 피처 비즈니스 역매핑: 모든 피처를 비즈니스 해석 가능한 설명으로 매핑하는 체계적 레지스트리(`interpretation_registry`)로, 근거 기반 설명 생성을 가능하게 한다.
3. **3-**에이전트 추천사유 생성 파이프라인: 역할이 분리된 에이전트(선택 → 생성 → 안전성)로 독립적 개선과 감사 로깅이 가능하다.

4. 금융 규제 준수를 위한 **Safety Gate**: 환각, 부적절한 투자 조언, 규제 위반(금융소비자보호법(금소법), 적합성 원칙)에 대한 자동화된 검증.
5. 규제 준수 아키텍처: 시스템 구성요소를 한국 금감원 가이드라인, EU AI Act 조항, 한국 AI 기본법에 명시적으로 매핑.
6. 인간 평가 프로토콜: 도메인 전문가에 의한 추천사유 품질의 체계적 평가.

2 관련 연구

2.1 추천을 위한 지식 증류

[5] 은 온도 스케일링된 소프트 레이블을 통한 교사-학생 패러다임을 확립하였다. 추천 분야에서 증류는 심층 모델을 경량 서버로 압축하는 데 적용되어 왔다. CKD(Collaborative Knowledge Distillation)와 랭킹 증류는 추천에 특화된 구조를 보존한다.

격차: 예측 가치와 함께 설명 가치에 기반하여 증류 피처를 선택한 선행 연구는 존재하지 않는다.

2.2 추천 설명 생성

추천 설명 접근법은 세 가지 범주로 분류된다:

템플릿 기반 방법은 모델 출력을 사전 작성된 문구로 매핑한다 ("최근 유사한 상품을 조회하셨기 때문에 추천합니다"). Amazon과 Netflix는 이 접근법의 변형을 대규모로 사용한다. 템플릿은 안전하고 빠르지만 개인화와 유연성이 부족하다 — 동일한 템플릿이 수백만 명의 서로 다른 고객 맥락에 사용된다.

어텐션 기반 방법은 모델 내부의 어텐션 가중치를 설명을 위한 피처 기여도로 활용한다. 템플릿보다 동적이지만, 어텐션 가중치가 신뢰할 수 있는 설명인지에 대해서는 논쟁이 있으며, 결과적인 기여도 역시 비즈니스 언어로의 번역이 필요하다.

LLM 기반 생성은 대규모 언어 모델을 사용하여 모델 출력으로부터 자연어 설명을 생성하는 신흥 접근법이다. 최근 연구에서는 LLM 증강 추천 설명을 탐구하고 있으나, 환각, 규제 준수, 실제 모델 추론에 대한 근거 확보 측면에서 과제가 남아 있다.

격차: 구조적 모델 설명 가능성(게이트 가중치)과 규제 안전성 제약 하의 멀티 에이전트 LLM 기반 생성을 결합한 시스템은 존재하지 않으며, 각 에이전트가 전문화된 역할(선택, 생성, 검증)을 수행하고 모든 출력이 감사 로깅되는 시스템도 부재하다.

2.3 금융 분야의 책임 있는 AI

한국 금감원은 AI 가이드라인(2021) [3] 과 설명 가능성, 공정성 모니터링, 감사 추적을 요구하는 모델 리스크 관리 지침을 발표하였다. EU AI Act [2] 는 금융 신용/추천을 고위험 AI로 분류하며, 투명성(제13조), 인간 감독(제14조), 정확성(제15조)을 의무화한다. EBA [1] 는 내부 리스크 평가에서 "해석 가능한" 모델을 요구한다. 한국 AI 기본법 [8] (2024년 12월)은 국내 고위험 AI 분류를 추가한다.

[9] 은 진정한 설명에는 단순한 통계적 연관이 아닌 인과적 이해가 필요하다고 주장하며 — 이는 실제 의사결정 메커니즘을 반영하는 설명을 요구하는 금융 규제기관에 의해 점점 더 공감을 얻고 있다 [11].

격차: 규제 요구사항에서 시스템 아키텍처 구성요소까지의 명시적이고 검증 가능한 매핑을 제공하면서, 사후적 상관관계가 아닌 인과적 추론에 근거한 설명을 제공하는 추천 시스템은 존재하지 않는다.

2.4 LLM 안전성과 근거 확보

고객 대면 금융 텍스트에 LLM을 배포하면 다음과 같은 특정 위험이 발생한다: 환각(존재하지 않는 상품 특성 언급), 부적절한 조언(고객의 위험 프로파일에 부적합한 상품 추천), 규제 위반(금소법 또는 적합성 원칙 위반).

검색 증강 생성(RAG)은 검색된 사실적 맥락에 생성을 근거함으로써 환각을 완화한다. 본 연구의 접근법은 이를 확장한다: 일반 지식 베이스에서 검색하는 대신, 비즈니스 설명으로 역매핑된 모델 내부 피처 기여도에 생성을 근거한다. 이를 통해 생성된 텍스트가 LLM이 독립적으로 "아는" 내용이 아닌, 모델이 실제로 계산한 내용을 반영하도록 보장한다.

콘텐츠 필터링과 Safety Gate는 최종 방어 계층을 제공한다. 본 연구의 3-에이전트 아키텍처는 생성과 검증을 분리하여 각 구성요소의 독립적 개선을 가능하게 한다.

3 지식 증류

3.1 교사-학생 아키텍처

증류 다이어그램 플레이스홀더
PLE 교사 모델 (GPU, 주간) → 소프트 레이블 → LGBM 학생 모델 (CPU, 일간)
1. IG 피처 선택

Figure 1: 교사-학생 증류 아키텍처.

교사 모델(7개 이종 전문가, 18개 태스크, 318개 피처를 가진 PLE; 아키텍처 세부사항은 동반 논문 참조)은 태스크별 LGBM [6] 학생 모델의 학습 타겟으로 사용되는 소프트 확률 출력을 생성한다. 교사 모델의 증류 소스로서의 가치는 전문가 붕괴에 대한 구조적 보장에서 비롯된다: 7개 전문가가 구조적으로 상이하므로(DeepFM, Mamba, HGCN, PersLay 등), 동일한 함수로 수렴할 수 없으며, 소프트 레이블이 진정으로 다면적인 고객 이해를 인코딩함을 보장한다.

핵심 설계 결정은 태스크별 증류이다: 18개 태스크 전체에 대한 단일 학생 모델 대신, 각 태스크의 소프트 레이블을 학습하는 18개의 독립적인 LGBM 모델을 훈련한다. 이를 통해 다음을 가능하게 한다: (1) 태스크별 피처 선택(태스크마다 유익한 피처가 다름), (2) 독립적 재학습(하나의 태스크가 드리프트하면 해당 학생만 재증류), (3) 태스크별 해석 가능한 피처 중요도(LGBM의 내장 피처 중요도가 설명 생성을 위한 비즈니스 역매핑과 일치).

생애주기 분리:

- 교사 모델: SageMaker에서 주간/월간 재학습(GPU 필요, 종합적). 교사 모델은 adaTT를 통한 복잡한 태스크 간 관계와 LGBM이 직접 학습할 수 없는 비선형 전문가 상호작용을 포착한다.
- 학생 모델: 새로운 소프트 레이블로 일간 재증류(CPU만 사용, 빠름). 일간 재증류는 GPU 학습 비용 없이 데이터 드리프트를 추적한다.
- 챔피언-챌린저: 새 학생 모델 vs. 현재 운영 모델의 자동 비교. 새 학생 모델의 AUC가 임계값 이하로 떨어지면 업데이트가 차단되고 경고가 발생한다.

이 아키텍처는 금융 AI의 근본적인 긴장을 해결한다: 가장 잘 학습하는 모델(GPU 기반 심층 PLE)은 가장 잘 서빙하는 모델(CPU Lambda 기반 경량 LGBM)이 아니다. 지식 증류 [5] 가 이 간극을 연결하며, FD-TVS(Friedman Decomposition–Transitory Variance Scoring) 시스템 [4] 이 소득 안정성 유형에 따라 학생 모델의 예측에 추가 가중치를 부여한다. FD-TVS는 Friedman의 항상소득가설(Permanent Income Hypothesis)을 적용하여 각 고객의 관측 소득을 HP 또는 칼만 필터링을 통해 항상적(안정적, 장기) 성분과 일시적(보너스, 비정기) 성분으로 분해한다. 소득이 주로 일시적인 고객은 장기 상품 추천에 대해 더 낮은 신뢰도 가중치를 부여받아, 변동성이 큰 소득 패턴을 가진 고객에게 안정적 현금흐름을 가정하는 상품을 추천하는 것을 방지한다.

3.2 IG 기반 피처 선택

Integrated Gradients [12] 는 교사 모델로부터 피처별 기여도를 계산한다. IG 중요도 순위에 따라 상위 k개 피처를 선택하되, 이중 목적을 갖는다:

$$\text{score}(f) = \alpha \cdot \text{IG}_{\text{pred}(f)} + (1-\alpha) \cdot \text{IG}_{\text{explain}(f)}$$

여기서 IG_{pred}는 예측 기여도를 측정하고 $\text{IG}_{\text{explain}}$는 해당 피처의 설명 재료로서의 가치를 측정한다.

설명 점수 $\text{IG}_{\text{explain}(f)}$는 해석 레지스트리(interpretation registry)에서의 피처 역매핑 풍부도로부터 도출된다: 상세한 비즈니스 설명, 명확한 방향성, 자연어 템플릿을 가진 피처가 더 높은 점수를 받는다. 예를 들어, `hmm_lifecycle_prob_growing`(설명 풍부: "고객이 성장 단계에 있음")은 `mamba_temporal_d17`(설명 빈약: 일반적인 임베딩 차원)보다 높은 점수를 받는다.

이 이중 목적 선택은 학생 모델이 가장 예측력 있는 피처뿐만 아니라 가장 설득력 있는 추천사유를 생성하는 피처도 보유하도록 보장한다. 하이퍼파라미터 α가 트레이드오프를 제어한다: $\alpha = 1$은 순수하게 예측을 최적화하고, $\alpha = 0$은 순수하게 설명 품질을 최적화한다. 경험적으로 $\alpha = 0.7$이 두 목적을 균형 있게 달성함을 확인하였다.

결과적인 피처 집합은 태스크당 통상 40–80개 피처이며(318개에서 축소), 교사 모델 AUC의 95% 이상을 달성하면서 충분한 설명 어휘를 제공한다. 중요하게도, 이중 목적 선택은 동반 논문의 이축 분해에서 4개 Financial DNA 차원(참여도, 생애주기, 가치, 소비) 전반과 다수의 Data Modality(시계열, 그래프, 위상적 등) 전반에 걸쳐 피처를 보존하여, 학생 모델이 단일 지배적 피처 그룹으로 붕괴하지 않고 다면적 이해를 유지하도록 보장한다.

3.3 증류 결과

태스크	교사 **AUC**	학생 **AUC**	격차
has_nba	–	–	–
churn_signal	–	–	–
will_acquire_deposits	–	–	–
will_acquire_investments	–	–	–
…	…	…	…

Table 1: 태스크별 증류 결과 (TODO).

`interpretation_registry`는 증류와 추천사유 생성 사이의 데이터 계약으로 기능한다. 증류(3절)는 학생 모델에서 어떤 피처를 보존할지 결정한다 — 이중 목적 IG 점수를 통해 예측 정확도와 설명 재료 모두를 최적화한다. 추천사유 생성(4절)은 해당 피처를 인간에게 어떻게 설명할지 결정한다 — 보존된 각 피처를 비즈니스 해석 가능한 언어로 매핑한다. 이러한 분리는 두 단계가 독립적으로 발전할 수 있음을 의미한다: 피처 선택 개선이 설명 템플릿 재작성을 요구하지 않으며, 그 반대도 마찬가지이다.

4 추천사유 생성

4.1 피처 비즈니스 역매핑

시스템의 모든 피처는 구조화된 비즈니스 메타데이터와 함께 `interpretation_registry`에 등록된다:

피처	비즈니스 매핑	설명 템플릿
hmm_lifecycle_prob_growth	성장 단계 확률	"고객님의 자산 포트폴리오가 성장 국면에 있습니다"
mamba_temporal_30d_13	13월 소비 추세	"최근 소비가 증가하는 추세입니다"
hgcn_hierarchy_d5_3	상품 카테고리 위치	"투자 상품이 자연스러운 다음 단계입니다"
synth_stability	거래 안정성	"안정적인 거래 패턴을 유지하고 계십니다"
gmm_cluster_prob_3	세그먼트 확률	"활발한 투자자들과 유사한 특성을 공유하고 계십니다"

Table 2: 피처 역매핑 예시.

이 레지스트리는 이중 목적을 수행한다: (1) Reason Generator 에이전트를 위한 근거 자료, 그리고 (2) 각 추천에 어떤 피처가 영향을 미쳤는지를 보여주는 감사 추적.

4.2 3-에이전트 파이프라인 아키텍처

3-에이전트 파이프라인 다이어그램 플레이스홀더

에이전트 1: Feature Selector
(IG 기여도 → 상위 피처 → 설명 적합 피처 보충)
↓
에이전트 2: Reason Generator
(역매핑된 컨텍스트 → 자연어 추천사유)
↓
에이전트 3: Safety Gate
(규제 검증 → 환각 검증 → 적합성 검증)
↓
통과 → 서빙 | 실패 → 템플릿 폴백

Figure 2: 3-에이전트 추천사유 생성 파이프라인.

4.2.1 에이전트 1: Feature Selector

다음 기준에 따라 설명용 피처를 선택한다:

- IG 기여도 점수(모델 기반 관련성)

- 비즈니스 역매핑 풍부도(설명 기반 관련성)
- 고객 컨텍스트(개인화: 고객 프로파일에 따라 중요한 피처가 다름)

Feature Selector는 동반 논문의 이축 프레임워크에서 Financial DNA 축을 활용하여 관련 고객 차원에서 피처를 선택한다 (예: 이탈 추천에는 생애주기 피처, 투자 추천에는 가치 피처), 설명이 추천 행위에 가장 관련 있는 차원을 다루도록 보장한다.

4.2.2 에이전트 2: Reason Generator

선택된 피처와 해당 비즈니스 역매핑을 수신하여 자연어 추천사유를 생성한다. Reason Generator는 Financial DNA 그룹을 중심으로 서사를 구조화한다 — 고객의 현재 상태(생애주기)로 시작하고, 관찰된 행동(참여도/소비)에 추천을 근거하며, 고객이 인식하는 용어(가치 차원)로 가치 제안을 프레이밍한다 — 동반 논문에서 말하는 다면적 고객 이해를 설득적 텍스트로 렌더링한다. 근거 제약:

- 선택에 실제로 포함된 피처만 참조해야 한다.
- 대상 수요자(고객 vs. 관계 관리자)에 적절한 비즈니스 용어를 사용해야 한다.
- 금융 도메인 어조와 규제 준수 가이드라인을 따라야 한다.

출력 예시 (고객 대면):
"고객님은 현재 자산 성장 단계에 있으시고, 최근 3개월간 소비가 증가하는 추세입니다. 보유하신 상품 구조상 투자 펀드가 자연스러운 다음 단계이며, 안정적인 거래 패턴을 고려할 때 중위험 균형형 펀드를 추천드립니다."

Figure 3: 생성된 추천사유 예시 (한국어, 고객 대면).

4.2.3 에이전트 3: Safety Gate

생성된 추천사유를 다음 기준에 따라 검증한다:

검증 항목	기준
환각	피처 데이터에 없는 사실에 대한 주장 금지
규제	금소법, 적합성 원칙 위반 금지
적합성	위험 프로파일에 부적합한 투자 조언 금지
어조	전문적 금융 자문 언어 사용
사실성	수치적 주장이 실제 피처 값과 일치

Table 3: Safety Gate 검증 기준.

실패 시: 템플릿 기반 안전한 추천사유로 자동 폴백. 모든 게이트 결정은 감사 추적을 위해 로깅된다.

4.3 캐싱 전략

추천사유는 고객 세그먼트 × 상품 카테고리 × 피처 패턴 해시별로 캐싱된다. 캐시 적중 시 LLM 호출을 완전히 우회하여 지연시간과 비용을 절감한다.

5 규제 준수

5.1 한국 금감원 가이드라인 매핑

금감원 요구사항	시스템 구성요소	검증 방법
설명 가능성	게이트 가중치 + 3-에이전트 추천사유	추천건별 감사 로그
공정성	FairnessMonitor (DI/SPD/EOD)	주간 자동 보고서
모델 검증	챔피언-챌린저	배포 전 비교
모니터링	DriftDetector (PSI)	연속적, 3일 트리거
감사 추적	HMAC 해시체인 로그	불변, 7개 감사 테이블
폴백	템플릿 추천사유 + 킬 스위치	즉시 수동 오버라이드

Table 4: 한국 금감원 가이드라인 준수 매핑.

5.2 EU AI Act 매핑

조항	요구사항	시스템 구성요소
제13조	투명성	3-에이전트 추천사유 생성 + 피처 기여도
제14조	인간 감독	Human-in-the-Loop 리뷰 + 킬 스위치
제15조	정확성 및 견고성	어블레이션 검증된 성능 저하 + 드리프트 모니터링
GDPR 제22조	거부 권리	동의/거부 감사 테이블 + 수동 오버라이드

Table 5: EU AI Act 조항별 준수 매핑.

5.3 한국 AI 기본법 (2024.12)

5.4 모니터링 및 거버넌스

모니터링 아키텍처 플레이스홀더

DriftDetector (PSI) → FairnessMonitor (DI/SPD/EOD) → HerdingDetector (HHI/Gini)
↓
IncidentReporter → GovernanceReportGenerator
↓
월간/분기별 자동 보고서

Figure 4: 모니터링 및 거버넌스 아키텍처.

5.4.1 Human-in-the-Loop

규제기관(한국 금감원, EU AI Act 제14조)은 인간 감독을 요구한다. 본 시스템은 다중 수준에서 이를 구현한다:

- 추천사유 표본 검토: 생성된 추천사유의 주기적 인간 검토.
- 모델 교체 승인: 챔피언-챌린저 결과에 대한 인간 승인 필요.
- 인시던트 에스컬레이션: 자동화된 이상 탐지가 인간 조사를 트리거.
- 공정성 검토: 공정성 지표에 대한 주기적 인간 감사.

6 실험

6.1 증류 실험

6.2 추천사유 생성 품질

6.2.1 인간 평가 프로토콜

- 평가자: N명의 금융 도메인 전문가(은행 상품 관리자, 규제 준수 담당자).
- 평가 기준: 정확성 (1-5), 자연스러움 (1-5), 설득력 (1-5), 규제 적합성 (1-5).
- 비교 대상: (A) 템플릿 기반, (B) SHAP 기반 + 템플릿, (C) 3-에이전트 파이프라인.
- 방법: 블라인드 평가, 각 평가자가 100개 추천사유를 평가.

방법	정확성	자연스러움	설득력	규제 준수
템플릿	–	–	–	–
SHAP+템플릿	–	–	–	–
3-에이전트 (본 연구)	–	–	–	–

Table 6: 인간 평가 결과 (TODO).

6.3 Safety Gate 평가

검증 항목	정밀도	재현율	폴백 비율
환각	–	–	–
규제	–	–	–
적합성	–	–	–
전체	–	–	–

Table 7: Safety Gate 정밀도 및 재현율 (TODO).

6.4 서빙 성능

구성요소	지연시간	비용/1K 요청	비고
LGBM 추론	< 10ms	–	Lambda CPU
IG 기여도	< 50ms	–	Lambda CPU
추천사유 생성	< 200ms	–	캐시 적중: < 5ms
Safety Gate	< 50ms	–	규칙 기반 + LLM
합계	< 300ms	–	캐시 적중: < 100ms

Table 8: 서빙 지연시간 분석 (Lambda 서버리스, GPU 미사용).

6.5 규제 준수 감사

7 논의

7.1 주요 발견 요약

7.2 피처의 이중 역할

본 연구의 핵심 통찰: 금융 추천에서 피처는 이중 목적을 수행한다. 예측 기여가 미미한 피처라 할지라도(예:

TDA 위상적 피처는 ΔAUC = 0.01에 불과할 수 있음) 추천사유 추론에 대체 불가능한 맥락을 제공한다. 내부적으로 TDA 지속성(persistence)은 행동 형태 안정성을 포착하지만 — 고객은 "지속적 호몰로지"나 "베티 수"를 보지 않는다. 대신 `interpretation_registry`가 이를 비즈니스 언어로 역매핑하고 (예: "꾸준한 거래 패턴을 유지하고 계십니다"), LLM 에이전트가 이를 자연어 추천사유로 엮는다.

이는 피처 엔지니어링 평가를 재구성한다: 피처의 가치는 예측 기여도만이 아니라 추천사유 생성 파이프라인이 활용할 수 있는 추천 맥락에 대한 기여도이기도 하다. 동반 논문에서 주장했듯이, 무엇을 관측할 것인가가 어떻게 모델링할 것인가보다 중요하다 — 도메인 특화 질문에서 파생된 피처 ("소득이 항상적인가 일시적인가?", "상품 채택이 전파처럼 확산되는가?")는 내부 추론 맥락을 풍부하게 하여, 얕은 통계적 요약에 아무리 정교한 아키텍처를 적용하는 것보다 더 섬세한 비즈니스 언어 설명을 가능하게 한다.

7.3 실무 배포 고려사항

- **LLM** 선택: 온프레미스 LLM vs. API(지연시간, 비용, 데이터 상주).
- 추천사유 품질 유지: 주기적 인간 검토 + 자동화된 품질 점수.
- 규제 업데이트: 아키텍처가 재설계 없이 새로운 규제 준수 검증 추가를 지원.

7.4 한계

- LLM 의존성이 비용, 지연시간, 잔여 환각 위험을 발생시킨다.
- 인간 평가 규모가 전문가 가용성에 제한된다.
- 한국/EU 규제에 초점; 기타 관할권은 아직 분석되지 않았다.
- 템플릿 폴백 품질은 본질적으로 제한적이다.

7.5 향후 연구

- 추천사유 품질 → 전환율에 대한 실제 고객 A/B 테스트.
- 다국어 추천사유 생성(한국어, 영어, 중국어).
- 자동화된 규제 업데이트 파이프라인(규제 변경 → 규제 준수 검증 업데이트).
- 범용 API를 대체할 도메인 특화 미세조정 소형 LLM.

8 결론

본 연구에서는 금융 상품 추천에서 모델 예측과 인간 설득 사이의 간극을 잇는 전체 체인 시스템을 제시하였다. 세 가지 핵심 기여가 본 연구를 정의한다. 첫째, 이중 목적 피처 선택을 갖춘 IG 기반 지식 증류는 복잡한 PLE 교사 모델을 경량 LGBM 학생 모델로 압축할 때 예측 정확도와 설명 재료를 모두 보존한다. 둘째, 3-에이전트 추천사유 생성 파이프라인 (Feature Selector → Reason Generator → Safety Gate)은 비즈니스 매핑된 피처 기여도에 근거한 자연어 설명을 생성하며, 역할 분리를 통해 독립적 개선과 감사 로깅을 가능하게 한다. 셋째, 규제 준수가 설계 단계부터 내장된다 — 한국 금감원 가이드라인, EU AI Act, 한국 AI 기본법이 시스템 아키텍처 구성요소에 명시적으로 매핑되며, 자동화된 모니터링(드리프트, 공정성, 쏠림)과 핵심 의사결정 지점에서의 Human-in-the-Loop 감독을 갖춘다.

근본적인 통찰은 금융 AI에서 피처가 이중 역할을 수행한다는 것이다: 피처는 예측에 기여할 뿐만 아니라 궁극적으로 고객을 설득하고, 관계 관리자에게 힘을 부여하며, 규제기관을 만족시키는 설명 어휘에도 기여한다. 이는 전통적인 피처 엔지니어링 계산법을 재구성한다: AUC 기여가 미미하지만 비즈니스 해석 가능성이 풍부한 피처가 높은 AUC를 가지지만 의미 있는 설명을 생성하지 못하는 피처보다 더 가치 있을 수 있다.

본 시스템은 서버리스 인프라(AWS Lambda)에서의 배포를 위해 설계되어, 전용 GPU 서버 없이 100ms 미만의 서빙 지연시간을 달성한다 — 제한된 ML 엔지니어링 리소스를 가진 금융기관의 운영 현실에 부합한다.

감사의 글

코드 구현과 원고 작성은 Claude(Anthropic)를 AI 코딩 및 작문 도구로 활용하여 지원받았다. 아키텍처 결정, 도메인 지식, 실험 설계, 연구 방향은 인간 저자가 주도하였다.

Bibliography

[1] European Banking Authority. 2025. Report on Machine Learning in Internal Models.

[2] European Parliament and Council. 2024. Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (AI Act).

[3] Financial Services Commission (Korea). 2024. Financial Sector AI Guidelines.

[4] Milton Friedman. 1957. *A Theory of the Consumption Function*. Princeton University Press.

[5] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. 2015. Distilling the Knowledge in a Neural Network. In

NIPS Deep Learning and Representation Learning Workshop, 2015.

[6] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. 2017. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[7] Scott M Lundberg and Su-In Lee. 2017. A Unified Approach to Interpreting Model Predictions. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[8] National Assembly of Korea. 2024. Act on the Development of Artificial Intelligence and Establishment of Trust (AI Basic Act).

[9] Judea Pearl. 2009. *Causality: Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press.

[10] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. 2016. Why Should I Trust You?: Explaining the Predictions of Any Classifier. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016.

[11] Amr Salih and others. 2023. Examining the Limitations of Post-hoc Explainability Methods in Finance. *Frontiers in Artificial Intelligence* (2023).

[12] Mukund Sundararajan, Ankur Taly, and Qiqi Yan. 2017. Axiomatic Attribution for Deep Networks. In *Proceedings of the 34th International Conference on Machine Learning (ICML)*, 2017.