

예측에서 설득으로: 규제 준수 금융 AI를 위한 에이전트 기반 추천사유 생성

정선규¹, 심은철¹, 김영찬¹

¹Independent Research

교신저자: 정선규 (ORCID: 0009-0005-3291-9112)

초록. 금융 상품 추천 시스템은 상품을 추천하는 이유를 설명해야 한다 — 무엇보다도 설득에는 확률이 아닌 서사(narrative)가 필요하기 때문이다: “왜 이 카드가 저에게 추천되었나요?”라고 묻는 고객에게는 신뢰해야 할 점수가 아니라 수궁할 수 있는 이유가 필요하다. 규제기관(한국 금감원, EU AI Act)은 이러한 설명의 중요한 수요자이지만, 본질적 동인은 설득이라는 인간 행위 그 자체이다. 본 연구에서는 모델 예측과 인간 설득 사이의 간극을 잇는 다단계 파이프라인을 제안한다: (1) 적응적 3방향 임계값 게이팅(DISTILL / DIRECT / SKIP)과 3계층 풀백을 통해 이종 전문가 PLE 교사서에서 태스크별 LGBM 학생으로 증류하여 서비스 연속성을 보장하며, 서빙 모델인 LGBM의 gain 기반 피쳐 중요도가 추천사유 생성에 직접 활용된다; (2) 3개의 전문화된 서빙 에이전트(Feature Selector, Reason Generator, Safety Gate)가 협업하여 비즈니스 매핑된 피쳐 기여도에 기반한 자연어 설명을 생성하는 멀티 에이전트 추천사유 생성 파이프라인; (3) 2개의 운영 에이전트(OpsAgent, AuditAgent)가 모니터링 출력과 규제 준수 보고서를 자연어로 해석하여, 전담 MLOps 인력 없이도 소규모 팀의 규제 준수 운영을 가능하게 하고; (4) 드리프트 모니터링, 공정성 감사, 거버넌스 보고를 내장한 설계 단계부터의 규제 준수로, 한국 금감원 가이드라인, EU AI Act, 한국 AI 기본법에 부합한다. 증류 품질(v13 기준 7개 이진 태스크에서 AUC 격차 < 3.6 퍼센트포인트, 평균 2.6 pp; 논의 절의 fidelity 게이트 교정 후 v14 재실행에서는 평균 격차가 0.58 pp로 감소), 자동화된 규제 준수 검증을 통한 추천사유 생성 품질 (L1 템플릿 커버리지 100%, 13/13 태스크; 적용 규제 규칙: 적합성, 동의, 거부권, 프로파일링, 고지), Safety Gate 신뢰도(PII 패턴 5개, 규제 검증 범주 5개)를 평가한다. 본 시스템은 저위험 상품(체크카드, 예금)을 대상으로 하며 투자·보험 상품 추천은 배포 범위에서 제외된다. 전용 GPU 추론 서버 비용의 일부로 AWS Lambda에서 120ms 씩 지연시간(L1 예측 + 13 태스크)을 달성하며(CPU 전용 서빙), L2a DynamoDB 캐시 적중 시 6ms, 콜드 스타트 약 6초이다.

키워드: 추천사유 생성, 지식 증류, LLM 에이전트, 규제 준수, 금융 AI, EU AI Act

1 서론

1.1 설득 문제

금융 추천 시스템의 최종 산출물은 확률이 아니라 고객이 수궁할 수 있는 이유이다. $P(\text{invest} | x) = 0.73$ 을 출력하는 모델은 다음 주체에게 아무런 가치를 제공하지 못한다:

- “왜 이 카드가 저에게 추천되었나요?”라고 묻는 **고객**.
- 영업 전화에서 대화 포인트가 필요한 **관계 관리자(RM)**.
- EU AI Act 제13조에 따라 “왜 이 결정을 내렸는가?”를 요구하는 **규제기관**.

기존 설명 접근법은 불충분하다:

- **SHAP/LIME**: “feature_237이 0.12 기여” — 비즈니스 의미가 없고, 교란(perturbation) 하에서 불안정 [12, 15].
- **템플릿 기반**: “고객님과 유사한 고객들도 X를 구매했습니다” — 경직되고 개별 맥락을 무시.

- **직접 LLM 생성**: 환각(hallucination) 위험, 실제 모델 추론에 기반하지 않음, 규제 미준수.

1.2 본 연구의 접근법

본 연구에서는 예측에서 설득까지의 전체 체인 솔루션을 제안한다:

1. **지식 증류**: 이종 전문가 PLE 교사 모델(13개 태스크, 7개 전문가, 1211개 피쳐 — v14 전처리 개정 후 1210개; 아키텍처 및 어블레이션은 동반 논문 참조)을 적응적 임계값 게이팅을 통해 태스크별 LGBM 학생 모델로 증류한다. 교사 성능에 따라 각 태스크는 DISTILL(소프트 레이블 증류), DIRECT(하드 레이블 직접 학습), SKIP(룰 엔진) 중 하나로 라우팅된다. CPU 전용 서빙과 3계층 풀백으로 어떠한 모델 장애 시나리오에서도 서비스 연속성을 보장한다.
2. **멀티 에이전트 추천사유 생성**: 3개의 전문화된 LLM 에이전트가 파이프라인에서 협업한다 — Feature Selector

가 설명에 적합한 피처를 선택하고, Reason Generator가 자연어 서사를 생성하며, Safety Gate가 규제 준수를 검증한다.

3. **설계 단계부터의 규제 준수:** 드리프트 모니터링, 공정성 감사, 감사 추적, 거버넌스 보고가 배포 후 부착되는 것이 아니라 파이프라인에 내장된다.

1.3 기여

1. **적응적 종류와 3계층 풀백:** 교사 임계값 게이팅이 13개 태스크 각각을 2× 무작위 기준선 대비 교사 품질에 따라 DISTILL(소프트 레이블, 7개 태스크), DIRECT(하드 레이블, 3개 태스크), SKIP(룰 엔진, 3개 태스크)으로 자동 라우팅하여 SR 11-7 모델 리스크 관리 요건에 따른 서비스 연속성을 보장한다. 피처 선택은 서빙 모델 관점과 일치하는 LGBM gain 중요도를 사용한다.
2. **피처 비즈니스 역매핑:** 모든 피처를 비즈니스 해석 가능한 설명으로 매핑하는 체계적 피처 해석 레지스트리로, 근거 기반 설명 생성을 가능하게 한다.
3. **3-에이전트 추천사유 생성 파이프라인:** 역할이 분리된 에이전트(선택 → 생성 → 안전성)로 독립적 개선과 감사 로깅이 가능하다.
4. **금융 규제 준수를 위한 Safety Gate:** 환각, 부적절한 투자 조언, 규제 위반(한국 금융소비자보호법(금소법, KFCPA), 적합성 원칙)에 대한 자동화된 검증.
5. **5-에이전트 아키텍처 (서빙 3 + 운영 2):** 3개의 서빙 에이전트 외에 2개의 운영 에이전트(OpsAgent, AuditAgent)가 모니터링 및 규제 준수 출력을 자연어로 해석하여, 전담 MLOps 인력 없이도 소규모 팀의 규제 준수 운영을 가능하게 한다.
6. **규제 준수 아키텍처:** 시스템 구성요소를 한국 금감원 가이드라인, EU AI Act 조항, 한국 AI 기본법에 명시적으로 매핑.
7. **인간 평가 프로토콜:** 도메인 전문가에 의한 추천사유 품질의 체계적 평가.

2 관련 연구

2.1 추천을 위한 지식 종류

[8]은 온도 스케일링된 소프트 레이블을 통한 교사-학생 패러다임을 확립하였다. 추천 분야에서 종류는 심층 모델을 경량 서버로 압축하는 데 적용되어 왔다. CKD(Collaborative

Knowledge Distillation)와 랭킹 종류는 추천에 특화된 구조를 보존한다.

격차: 교사 품질 측정값에 기반하여 태스크별로 종류 경로를 적응적으로 라우팅하고, 서빙 모델(LGBM) 자체의 피처 중요도를 설명 근거로 직접 활용한 선행 연구는 존재하지 않는다.

2.2 추천 설명 생성

추천 설명 접근법은 세 가지 범주로 분류된다:

템플릿 기반 방법은 모델 출력을 사전 작성된 문구로 매핑한다 (“최근 유사한 상품을 조회하셨기 때문에 추천합니다”). Amazon과 Netflix는 이 접근법의 변형을 대규모로 사용한다. 템플릿은 안전하고 빠르지만 개인화와 유연성이 부족하다 — 동일한 템플릿이 수백만 명의 서로 다른 고객 맥락에 사용된다.

어텐션 기반 방법은 모델 내부의 어텐션 가중치를 설명을 위한 피처 기여도로 활용한다. 템플릿보다 동적이지만, 어텐션 가중치가 신뢰할 수 있는 설명인지에 대해서는 논쟁이 있으며, 결과적인 기여도 역시 비즈니스 언어로의 번역이 필요하다.

LLM 기반 생성은 대규모 언어 모델을 사용하여 모델 출력으로부터 자연어 설명을 생성하는 신흥 접근법이다. 최근 연구에서는 LLM 증강 추천 설명을 탐구하고 있으나, 환각, 규제 준수, 실제 모델 추론에 대한 근거 확보 측면에서 과제가 남아 있다.

격차: 구조적 모델 설명 가능성(게이트 가중치)과 규제 안전성 제약 하의 멀티 에이전트 LLM 기반 생성을 결합한 시스템은 존재하지 않으며, 각 에이전트가 전문화된 역할(선택, 생성, 검증)을 수행하고 모든 출력이 감사 로깅되는 시스템도 부재하다.

2.3 금융 분야의 책임 있는 AI

한국 금감원은 AI 가이드라인(2021) [6]과 설명 가능성, 공정성 모니터링, 감사 추적을 요구하는 모델 리스크 관리 지침을 발표하였다. EU AI Act [3]는 금융 신용/추천을 고위험 AI로 분류하며, 투명성(제13조), 인간 감독(제14조), 정확성(제15조)을 의무화한다. EBA [2]는 내부 리스크 평가에서 “해석 가능한” 모델을 요구한다. 한국 AI 기본법 [13] (2024년 12월 국회 통과, 2025년 1월 공포)은 국내 고영향 AI 분류를 추가한다.

[14]은 진정한 설명에는 단순한 통계적 연관이 아닌 인과적 이해가 필요하다고 주장하며 — 이는 실제 의사결정 메커니즘




Figure 1: 교사-학생 종류 아키텍처.

PLE 교사의 소프트 레이블과 적응적 임계값 게이팅(DISTILL/DIRECT/SKIP)을 통해 태스크별 LGBM 학생 모델로 증류. LGBM gain이 추천사유 생성의 피쳐 근거로 직접 활용된다.

을 반영하는 설명을 요구하는 금융 규제기관에 의해 점점 더 공감을 얻고 있다 [16].

격차: 규제 요구사항에서 시스템 아키텍처 구성요소까지의 명시적이고 검증 가능한 매핑을 제공하면서, 사후적 상관관계가 아닌 인과적 추론에 근거한 설명을 제공하는 추천 시스템은 존재하지 않는다.

2.4 LLM 안전성과 근거 확보

고객 대면 금융 텍스트에 LLM을 배포하면 다음과 같은 특정 위험이 발생한다: 환각(존재하지 않는 상품 특성 언급), 부적절한 조언(고객의 위험 프로파일에 부적합한 상품 추천), 규제 위반(금소법 또는 적합성 원칙 위반).

검색 증강 생성(RAG)은 검색된 사실적 맥락에 생성을 근거함으로써 환각을 완화한다. 본 연구의 접근법은 이를 확장한다: 일반 지식 베이스에서 검색하는 대신, 비즈니스 설명으로 역매핑된 모델 내부 피쳐 기여도에 생성을 근거한다. 이를 통해 생성된 텍스트가 LLM이 독립적으로 “아는” 내용이 아닌, 모델이 실제로 계산한 내용을 반영하도록 보장한다.

콘텐츠 필터링과 Safety Gate는 최종 방어 계층을 제공한다. 본 연구의 3-에이전트 아키텍처는 생성과 검증을 분리하여 각 구성요소의 독립적 개선을 가능하게 한다.

3 지식 종류

3.1 교사-학생 아키텍처

교사 모델(7개 이종 전문가, 13개 태스크, 1211개 피쳐를 가진 PLE; 아키텍처 세부사항은 동반 논문 참조)은 태스크별 LGBM [10] 학생 모델의 학습 타겟으로 사용되는 소프트 확

률 출력을 생성한다. 교사 모델의 증류 소스로서의 가치는 전문가 붕괴에 대한 구조적 보장에서 비롯된다: 7개 전문가가 구조적으로 상이하므로(DeepFM, Mamba, HGCN, PersLay 등), 동일한 함수로 수렴할 수 없으며, 소프트 레이블이 진정으로 다면적인 고객 이해를 인코딩함을 보장한다. HGCN 전문가에 대한 주석: 그래프 전문가는 상품 공동 보유(product co-holding) 피쳐가 아닌 27차원 merchant_hierarchy 피쳐(MCC L1 → L2 → 코드 Poincaré 임베딩)를 입력으로 받는다. 이 구분은 적응적 라우팅에 있어 중요하다: MCC 의존적 태스크(예: top_mcc_shift)에서 교사가 충분한 성능을 보이면 DISTILL 경로가 활성화되고, 학생 LGBM의 gain 기반 피쳐 중요도가 “고객이 X 가맹점 카테고리에 대한 지속적 선호도를 보임”과 같은 설명 근거가 있는 추천사유 생성에 직접 사용된다.

핵심 설계 결정은 태스크별 증류이다: 13개 태스크 전체에 대한 단일 학생 모델 대신, 각 태스크의 소프트 레이블을 학습하는 13개의 독립적인 LGBM 모델을 훈련한다. 이를 통해 다음을 가능하게 한다: (1) 태스크별 피쳐 선택(태스크마다 유익한 피쳐가 다름), (2) 독립적 재학습(하나의 태스크가 드리프트하면 해당 학생만 재증류), (3) 태스크별 해석 가능한 피쳐 중요도(LGBM의 내장 피쳐 중요도가 설명 생성을 위한 비즈니스 역매핑과 일치).

개발 과정에서 5개 태스크를 태스크 세트에서 제외하였다. 4개(소득 구간, 재직 단계, 소비 수준, 참여 점수)는 결정론적 피쳐 변환에 해당한다 — 예를 들어 소득 구간은 모델 입력 피쳐인 소득(income)의 분위수 버킷일 뿐이다. 학생 모델이 입력 피쳐에서 이러한 레이블을 완벽하게 복원할 수 있

으므로, 종류가 자명하게 풀리며 정보가 갖지 않는다. 5번 짜인 `has_nba`(이진 “어떤 상품이든 신규 가입하는가?”)는 `nba_primary` 클래스 0으로 통합되었다 — 어떤 상품을 추천 할지 예측하는 것이 추천 여부 예측을 포함하기 때문이다. 나머지 13개 태스크는 입력 피처에서 결정론적으로 파생될 수 없는 진정한 예측 목표를 나타낸다.

생애주기 분리:

- **교사 모델:** SageMaker에서 주간/월간 재학습(GPU 필요, 종합적). 교사 모델은 이중 전문가가 게이팅을 통한 복잡한 비선형 상호작용을 포착하며, 이는 LGBM이 직접 학습할 수 없는 표현이다.
- **학생 모델:** 새로운 소프트 레이블로 일간 재증류(CPU만 사용, 빠름). 일간 재증류는 GPU 학습 비용 없이 데이터 드립트를 추적한다.
- **챔피언-챌린저:** 새 학생 모델 vs. 현재 운영 모델의 자동 비교. 새 학생 모델의 AUC가 임계값 이하로 떨어지면 업데이트가 차단되고 경고가 발생한다.

이 아키텍처는 금융 AI의 근본적인 긴장을 해결한다: 가장 잘 학습하는 모델(GPU 기반 심층 PLE)은 가장 잘 서빙하는 모델(CPU Lambda 기반 경량 LGBM)이 아니다. 지식 증류 [8] 가 이 간극을 연결하며, FD-TVS(Friedman Decomposition-Transitory Variance Scoring) 시스템 [7] 이 소득 안정성 유형에 따라 학생 모델의 예측에 추가 가중치를 부여한다. FD-TVS는 Friedman의 항상소득가설(Permanent Income Hypothesis)을 적용하여 각 고객의 관측 소득을 HP 또는 칼만 필터링을 통해 항상적(안정적, 장기) 성분과 일시적(보너스, 비정기) 성분으로 분해한다. 소득이 주로 일시적인 고객은 장기 상품 추천에 대해 더 낮은 신뢰도 가중치를 부여받아, 변동성이 큰 소득 패턴을 가진 고객에게 안정적 현금흐름을 가정하는 상품을 추천하는 것을 방지한다. 소득 안정성 가중치 외에도 FD-TVS는 스코어링 단계에서 동적 태스크 레벨 가중치를 적용한다. 기본 태스크 가중치는 config에서 읽어오며, 여기에 세그먼트 기반 동적 승수(1.0-1.5 클리핑)와 행동 기반 규칙(특정 피처가 임계값을 초과하면 해당 태스크 가중치를 부스팅)이 곱해진다. 온프레미스와 AWS 모두 동일한 태스크 단위 동적 가중치 설계를 공유하며, AWS 버전은 클라우드 네이티브 config 관리(`scoring.segment_task_weights`, `scoring.dynamic_weight_rules`)를 추가로 지원한다.

트리 기반 학생 모델에 대한 온도 $T = 1$ 설정. 원래 증류 공식 [8] 은 소프트맥스 온도 T 를 높여 교사의 출력 분포를 평탄화하고, 비타겟 클래스의 상대적 확률(“dark knowledge”)을

증폭시켜 학생 신경망이 모든 클래스에 대해 경사 신호를 받도록 한다. 그러나 이 논거는 LGBM 학생에게 적용되지 않는다: (1) LGBM은 역전파가 아닌 분할 기반 최적화로 학습하므로, 꼬리 클래스에서의 경사 소실 문제가 없다; (2) T 를 높이면 확률 범위가 압축된다 — 양성률 2.98%인 이진 태스크에서 $T = 5$ 는 교사 출력을 $[0.03, 0.97]$ 에서 $[0.48, 0.52]$ 로 변환하여 클래스 판별 신호를 사실상 파괴한다; (3) Soft GBM 연구 [5] 는 경성 CART 트리가 다차원 소프트 레이블 벡터 학습에 이미 어려움을 겪으며, 높은 T 로 더 평탄화하면 문제가 악화됨을 보였다. 따라서 $T = 1$ 로 설정하여 교사의 보정된 확률을 그대로 사용하고, 커스텀 LGBM 목적함수가 각 분할에서 소프트 레이블 경사를 주입하도록 한다. 이 설계는 트리 기반 학생 모델에 특화된 것이며, 향후 신경망 학생 아키텍처를 채택할 경우 온도 스케일링을 재도입할 수 있다.

3.1.1 적응형 증류 전략

모든 태스크가 증류로부터 동등한 혜택을 얻는 것은 아니다. 교사 모델의 특정 태스크 성능이 무작위 기준선의 약 2배 이하로 떨어질 경우 (이진: $AUC < 0.60$; 멀티클래스: $F1\text{-macro} < 2/K$ (K 개 클래스 기준); 회귀: $R^2 < 0.05$), 소프트 레이블이 학생 학습을 안내하기에 충분한 클래스 간 정보를 담지 못한다. 이 경우 파이프라인이 자동으로 LGBM 학생 모델을 하드 레이블로 직접 훈련하는 경로로 전환한다.

이 적응형 라우팅은 모델 리스크 관리(MRM) 안전장치이다: 품질 낮은 교사 지식을 운영 환경에 전파하는 대신, 시스템이 자가 진단하여 더 안전한 훈련 경로를 활성화한다. 폴백을 통해 서비스 연속성이 보장된다 — 증류 가능 여부에 관계없이 모든 태스크에 학생 모델이 서빙된다 — 한편 모니터링 대시보드는 교사 개선이 필요한 태스크를 표시한다.

벤치마크 실험에서 7개의 이진 태스크가 AUC 임계값(0.63-0.72)을 초과하여 성공적으로 증류되었다(AUC 격차 2-3 퍼센트포인트). 2개의 멀티클래스 태스크(`nba_primary`, `segment_prediction`)는 F1 임계값 이하로 판정되어 직접 하드 레이블 훈련(DIRECT)으로 라우팅되었고, 3번째 태스크인 `next_mcc`(50-클래스)는 floor 미달로 SKIP(3계층 룰 엔진)으로 라우팅되었다. 회귀 태스크 중 `mcc_diversity_trend`($R^2=0.031$)는 경계선에 해당하여 직접 훈련(DIRECT)을 사용하였고, 나머지 2개(`product_stability`, `cross_sell_count`)는 $R^2 < 0.01$ 로 SKIP(3계층)으로 라우팅되었다.

3.1.2 3계층 풀백 아키텍처

적응적 라우팅 전략은 각 태스크를 1계층(종류), 2계층(직접 하드 레이블 학습), 또는 3계층(룰 엔진) 중 하나로 라우팅하는 풀백 아키텍처의 기반이 된다. 교사 종류와 직접 LGBM 학습 모두 허용 임계값을 넘어 열화되면, 시스템은 금융 마케팅 이론에 근거한 룰 기반 풀백(3계층)을 활성화한다. 서빙 시점에서 1계층과 2계층은 모두 동일한 Lambda 추론 경로를 통해 LGBM 예측을 생성하며, 차이는 학습 방식(소프트 레이블 종류 vs. 하드 레이블 직접 학습)에 있고 서빙 아키텍처는 동일하다. 각 계층은 금융 DNA 태스크 그룹별로 구조화된다:

계층	메커니즘	트리거	지연시간
1. 종류	PLE 교사 → LGBM 소프트 레이블	기본 경로	< 10ms
2. 직접 학습	LGBM 하드 레이블 (교사 우회)	교사 임계값 < 2× 랜덤	< 10ms
3. 룰 기반	금융 DNA 그룹 휴리스틱	LGBM 학습 실패 / 드리프트	< 1ms

Table 1: 3계층 서빙 풀백 아키텍처. 각 계층은 이전 계층이 사용 불가하거나 열화될 때 활성화된다.

3계층 룰은 금융 DNA 태스크 그룹 분류에 부합하며, 도메인에서 검증된 휴리스틱에 기반한다:

- **Engagement 그룹** (이탈, 행동 변화): RFM 스코어링 [4] — 운영 이력에서 도출된 최근성, 빈도, 금액 임계값.
- **Lifecycle 그룹** (세그먼트, 상품 추천): 상품 인접 행렬 — 경험적으로 관찰된 교차판매 경로(예금 → 적금 → 투자 → 보험)가 고객 생애주기 단계를 따른다.
- **Value 그룹** (상품 안정성, 교차판매 수): CLV 기반 등급화 — 고객 생애가치 구간을 상품 복잡도 등급에 매핑하며, 금융 적합성 요건과 연관된다.
- **Consumption 그룹** (MCC 패턴, 소비 다양성): Friedman 항상소득가설 [7]에 기반한 거래 카테고리 빈도 분석 — 일시적 소비 변동과 항구적 변동을 구분한다.

결정적으로, 모든 3계층 룰은 규제 적합성 원칙(금융소비자보호법 제17조)을 준수한다: 고객의 위험 감수 등급이 상품의 위험 등급 이상이어야 한다. 이 제약은 어떤 계층이 추천을 생성하든 항상 적용되어, 전체 아키텍처 아래에 규제적 하한선을 제공한다.

3계층 설계는 모델 장애로 인해 서비스가 중단되지 않도록 보장한다 — 금융 운영 시스템의 핵심 요구사항이자 SR 11-7 모델 리스크 관리 [1]의 기본 원칙이다.

3.1.3 Lambda 서빙 통합

3개 계층 모두 단일 Lambda 서빙 경로에 통합된다:

```

고객 요청 → Lambda Handler
    → RecommendationService.predict()
    → FallbackRouter.route_all()
    └─ 1/2계층: LGBM 예측 → Platt 보정 → 응답
    └─ 3계층: RuleBasedRecommender.predict() →
응답
    → contributing_features →
InterpretationRegistry 역매핑
    → 3-에이전트 사유 파이프라인 (FactExtractor →
TemplateEngine → SelfChecker)
    → 예측 + 추천사유 + 감사 추적을 포함한 응답
  
```

주요 통합 특성:

- FallbackRouter는 가용성과 지표 임계값에 따라 각 태스크를 적절한 계층으로 자동 라우팅한다. 호출자는 어느 계층이 예측을 서빙했는지 알 수 없다.
- 확률이 중요한 이진 분류 태스크의 1/2계층 출력에 Platt 스케일링 기반 보정 확률을 적용한다. 보정 대상 태스크 집합은 데이터셋별 종류 설정(예: distillation.calibration.tasks)에서 선언되어, 벤치마크와 무관하게 확률을 소비하는 하류 로직(임계 판정, 기대값 스코어링, 리스크 예산 배분)이 일관되게 정합 보정 확률을 받도록 한다. 점수 순서만 필요한 랭킹 계열 이진 태스크와 3계층(룰 엔진)으로 라우팅되는 회귀 태스크에는 Platt 스케일링을 적용하지 않는다.
- 3계층의 경우, 룰 발동에서 나온 contributing_features가 피쳐 해석 레지스트리를 통해 사유 파이프라인에 직접 라우팅된다. 이를 통해 모델이 없는 상황에서도 해석 가능한 추천사유 생성이 가능하다.
- 세 계층 모두 동일한 응답 스키마(예측값, 확률, 기여 피쳐, 추천사유 텍스트, 감사 토큰)를 생성하여, 어느 계층이 서빙했는지에 무관하게 API 계약이 호출자에게 투명하다.

3.2 피쳐 선택

서빙 모델이 LGBM이므로, 추천사유 생성에 올바른 피쳐 중 요도 기준은 교사 PLE 모델의 Integrated Gradients가 아닌 **LGBM gain**이다. LGBM gain은 각 피쳐가 실제 서빙 모델에서 예측에 기여한 정도를 직접 반영하며, 추천사유 생성에

이전트가 “왜 이 상품이 추천되었는가”를 설명할 때 실제 의사 결정 근거와 일치하는 설명을 생성할 수 있게 한다.

교사 IG를 사용하지 않는 이유는 세 가지이다: (1) **서빙 모델 불일치**: 교사 PLE는 추론 시 사용되지 않으므로, 교사 IG는 실제 서빙 결정을 반영하지 않는다; (2) **추천사유 근거 오류**: LLM 에이전트는 LGBM 피처를 기반으로 추천사유를 생성하므로, 교사 IG는 에이전트가 참조하는 피처와 불일치한다; (3) **OOM 위험**: 대규모 배포 환경에서 교사 IG 계산은 GPU 메모리를 과도하게 소비하며, 서빙 경로에 불필요한 의존성을 추가한다.

LGBM gain 기반 피처 중요도는 태스크당 상위 k 개 피처를 선택하며, 이 피처들이 피처 해석 레지스트리(interpretation registry)에서 비즈니스 언어로 역매핑된다. 예를 들어, `hmm_lifecycle_prob_growing`(LGBM gain 상위: “고객이 성장 단계에 있음”)은 추천사유에 직접 활용되는 반면, gain 이 낮은 `mamba_temporal_d17`(일반적인 임베딩 차원)은 제외된다.

결과적인 피처 집합은 태스크당 통상 40–80개 피처이며 (1211개에서 축소), 학생 AUC 격차를 평균 2.6 pp 이내로 유지하면서 설명 어휘를 충분히 확보한다. 이 접근법은 동반 논문의 이측 분해에서 4개 Financial DNA 차원(참여도, 생애주기, 가치, 소비) 전반과 다수의 Data Modality(시계열, 그래프, 위상적 등) 전반에 걸쳐 피처를 보존하여, 학생 모델이 단일 지배적 피처 그룹으로 붕괴하지 않고 다면적 이해를 유지하도록 보장한다.

3.3 증류 결과

벤치마크 v12는 13개 태스크 전반에 걸쳐 의미 있는 레이블 분포를 생성한다. 특히 `nba_primary`는 no-NBA 비율이 약 60%로 낮아지고(이전 벤치마크의 91%에서 개선), `top_mcc_shift`는 양성 비율이 약 50%로 낮아져(이전 92%에서 개선), 교사-학생 충실도 수치를 달성하기 쉽게 만들었던 준퇴화(near-degenerate) 클래스 불균형이 해소되었다. 이러한 분포 개선으로 아래의 증류 격차 수치가 진정으로 의미 있는 정보를 담게 된다.

교사-학생 충실도 지표는 각 태스크의 production 목적에 맞추어 태스크 유형별로 보고된다. 이진 분류 태스크에는 AUC 격차(임계값 비의존적, 불균형 강건)를 평가 지표로 사용한다. 멀티클래스 태스크에는 F1-macro를 라우팅 지표(임계값 게이트 결정)로 사용하며, 추천형 멀티클래스 태스크(`nba_primary`, `next_mcc`)에는 NDCG@K 및 top-K

accuracy [9] 를 태스크별 분석에서 별도로 보고한다. 회귀 태스크에는 R^2 를 라우팅 지표로, MAE 격차를 평가 지표로 사용한다. 이는 태스크 유형 간 의미론적으로 호환되지 않는 지표를 혼용하는 것을 방지한다.

피처 해석 레지스트리는 증류와 추천사유 생성 사이의 **데이터 계약**으로 기능한다. 증류(3절)는 적응적 임계값 게이팅을 통해 각 태스크의 학습 경로를 결정하고, 서빙 모델(LGBM)의 gain 기반 피처 중요도를 통해 어떤 피처가 설명에 활용될지 결정한다. 추천사유 생성(4절)은 해당 피처를 인간에게 어떻게 설명할지 결정한다 — 보존된 각 피처를 비즈니스 해석 가능한 언어로 매핑한다. 이러한 분리는 두 단계가 독립적으로 발전할 수 있음을 의미한다: 피처 선택 개선이 설명 템플릿 재작성을 요구하지 않으며, 그 반대도 마찬가지이다.

4 추천사유 생성

4.1 피처 비즈니스 역매핑

시스템의 모든 피처는 구조화된 비즈니스 메타데이터와 함께 피처 해석 레지스트리에 등록된다:

이 레지스트리는 이중 목적을 수행한다: (1) Reason Generator 에이전트를 위한 근거 자료, 그리고 (2) 각 추천에 어떤 피처가 영향을 미쳤는지를 보여주는 감사 추적.

피처 해석 레지스트리는 5-level cascade(최고 우선순위 순)로 피처를 한국어로 해석한다:

- **Level SHAP** (최고 우선순위) — SHAP 부호 방향 + 태스크 맥락
- **Level 3** — 피처×태스크 수동 오버라이드
- **Level 2** — 그룹×태스크
- **Level 1** — 그룹×태스크그룹 자동 생성
- **Level RM** (최저 우선순위) — 역매핑 레이어 glossary 템플릿

이 cascade에서 해결되지 않은 피처만 raw fallback으로 떨어진다. 역매핑 레이어는 Level RM으로 통합되어, glossary의 값 대입 템플릿(“월 평균 {value}건 거래”)이 cascade의 일부로 작동한다. 모든 fallback 텍스트는 한국어로 출력된다.

4.2 3-에이전트 파이프라인 아키텍처

3개 에이전트와 구현 클래스의 대응 관계는 다음과 같다: (1) **Feature Selector** (FactExtractor로 구현), (2) **Reason Generator** (InterpretationRegistry + TemplateEngine으로 구현), (3) **Safety Gate**

태스크	교사	학생	격차	일치율
이진 (소프트 레이블 분류)				
churn_signal (AUC)	0.687	0.665	0.022	88.9%
will_acquire_accounts (AUC)	0.721	0.697	0.024	92.5%
will_acquire_payments (AUC)	0.693	0.661	0.032	90.8%
will_acquire_deposits (AUC)	0.671	0.653	0.018	79.8%
will_acquire_investments (AUC)	0.675	0.652	0.023	79.7%
will_acquire_lending (AUC)	0.666	0.640	0.026	81.2%
top_mcc_shift (AUC)	0.630	0.594	0.036	99.9%
멀티클래스 (임계값 라우팅)				
nba_primary (F1-macro, 7클래스)	0.187	0.373	0.186	F1 < 2/7 → DIRECT
segment_prediction (F1-macro, 4클래스)	0.403	0.376	0.028	F1 < 2/4 → DIRECT
next_mcc (F1-macro, 50클래스)	0.012	—	—	F1 < floor → SKIP (L3)
회귀 (임계값 라우팅)				
product_stability (R ²)	< floor	—	—	R ² < floor → SKIP (L3)
mcc_diversity_trend	R ² =0.031 ^R	MAE 0.025 ^E	n/a	R ² < 0.05 → DIRECT
cross_sell_count (R ²)	0.008	—	—	R ² < floor → SKIP (L3)

Table 2: 태스크별 분류 결과. 이진 태스크: AUC 격차(평가 지표). 멀티클래스 태스크: F1-macro를 라우팅 지표(임계값: $2/K$)로 사용하며, NDCG@K는 태스크별 분석에서 별도 보고. 회귀 태스크: R²를 라우팅 지표(위첨자 R)로, MAE를 평가 지표(위첨자 E)로 사용하며, 두 지표가 다를 경우 격차는 n/a로 표기. DIRECT 라우팅 태스크는 하드 레이블 LGBM 결과를, SKIP 라우팅 태스크는 3계층 룰 엔진이 서빙한다. 주: 위 **Teacher AUC 값(0.63–0.72)**은 **v13 phase0 teacher** 기준이다. **v14 SageMaker 재실행에서 HMM mode-split, GMM K=14, probability 컬럼 정규화 제외 수정이 적용된 후 teacher**의 태스크별 AUC가 0.82+ 영역으로 상승하였다 (Paper 1의 joint-ablation 및 epoch-budget 표 참조). Platt scaling과 gain-importance 피처 선택은 스케일 불변이므로 fidelity gap과 student-teacher agreement 백분율은 동일 자릿수에서 유지될 것으로 예상되나, v14 teacher 위에서의 LGBM 분류는 후속 릴리즈로 미룬다.

피처	비즈니스 매핑	설명 템플릿
hmm_lifecycle_prob_growing	성장 단계 확률	“고객님의 자산 포트폴리오가 성장 국면에 있습니다”
mamba_temporal_d3	3개월 소비 추세	“최근 소비가 증가하는 추세입니다”
hgc_n_hierarchy_d5	상품 카테고리 위치	“카드 혜택을 적극 활용하시는 고객층에 속합니다”
synth_stability	거래 안정성	“안정적인 거래 패턴을 유지하고 계십니다”
gmm_cluster_prob_3	세그먼트 확률	“유사한 생활 패턴을 가진 고객층과 공통점이 많습니다”

Table 3: 피처 역매핑 예시.

(SelfChecker로 구현). 이하 본절에서 마케팅 명칭은 본문에서, 구현 명칭은 기술/코드 맥락에서만 사용한다.

4.2.1 에이전트 1: Feature Selector

FactExtractor로 구현된다. 다음 기준에 따라 설명용 피처를 선택한다:

- 서빙 시점의 LGBM SHAP 값(모델 기반 관련성, 서빙 모델과 정합)
- 비즈니스 역매핑 풍부도(설명 기반 관련성)

- 고객 컨텍스트(개인화: 고객 프로파일에 따라 중요한 피처가 다름)

Feature Selector는 동반 논문의 이측 프레임워크에서 Financial DNA 축을 활용하여 관련 고객 차원에서 피처를 선택한다 (예: 이탈 방지 추천에는 생애주기 피처, 혜택 추천에는 소비 패턴 피처), 설명이 추천 행위에 가장 관련 있는 차원을 다루도록 보장한다. 3계층(룰 기반) 예측의 경우, 룰 발동에서 나온 contributing_features가 피처 해석 레지스트리




Figure 2: 3-에이전트 추천사유 생성 파이프라인.

Feature Selector → Reason Generator → Safety Gate.

를 통해 이 에이전트에 직접 전달된다. 이를 통해 어느 서빙 계층이 예측을 생성했는지에 무관하게 동일한 에이전트 인터페이스가 유지된다.

4.2.2 에이전트 2: Reason Generator

InterpretationRegistry + TemplateEngine으로 구현된다. 선택된 피처와 해당 비즈니스 역매핑을 수신하여 자연어 추천사유를 생성한다. InterpretationRegistry는 5-level cascade(SHAP 방향 → L3 → L2 → L1 → 역매핑 레이어)를 통해 각 피처명을 한국어 비즈니스 설명으로 역매핑하고, TemplateEngine이 이를 일관된 추천사유로 조합한다. Reason Generator는 Financial DNA 그룹을 중심으로 서사를 구조화한다 — 고객의 현재 상태(생애주기)로 시작하고, 관찰된 행동(참여도/소비)에 추천을 근거하며, 고객이 인식하는 용어(가치 차원)로 가치 제안을 프레이밍한다 — 동반 논문에서 말하는 다면적 고객 이해를 설득적 텍스트로 렌더링한다. 근거 제약:

- 선택에 실제로 포함된 피처만 참조해야 한다.
- 대상 수요자(고객 vs. 관계 관리자)에 적절한 비즈니스 용어를 사용해야 한다.
- 금융 도메인 어조와 규제 준수 가이드라인을 따라야 한다.

L1 (템플릿, 0.1ms):

“소비 패턴의 변화에 맞춘 혜택입니다. 다양한 소비 카테고리를 활용하시는 고객님의게 맞춤 소비 혜택을 추천드립니다.”

L2a (Bedrock Sonnet 4.6 리라이트, 2.4s):

“고객님의 다양한 소비 패턴에 맞춰 여러 카테고리에서 실질적인 혜택을 누리실 수 있도록 맞춤 소비 혜택 상품을 추천드립니다.”

SelfChecker 판정: pass

Figure 3: Lambda 실서비스 출력 (태스크 top_mcc_shift, 고객 10). L1 템플릿 0.1ms, L2a Bedrock 리라이트 캐시 시 6ms.

4.2.3 에이전트 3: Safety Gate

SelfChecker로 구현된다. 생성된 추천사유를 다음 기준에 따라 검증한다:

실패 시: 템플릿 기반 안전한 추천사유로 자동 폴백. 모든 게이트 결정은 감사 추적을 위해 로깅된다. 3-에이전트 파이프라인 상류에서 제약 인식 엔진이 적격성 및 적합성 필터를 적용한다 — 고객 상황, 사용 패턴, 상품별 제약조건을 검증하여 — 금융소비자보호법(금소법) 제17조(적합성 원칙)가 요구하는 대로 적합성 검증을 통과하지 않은 추천이 고객에게 도달하지 않도록 보장한다.

검증 항목	기준
환각	피쳐 데이터에 없는 사실에 대한 주장 금지
규제	금소법 제19조(설명 의무) 위반 금지 — 허위 또는 과장 설명 금지
적합성	위험 프로파일에 부적합한 상품 제안 금지
어조	전문적 금융 자문 언어 사용
사실성	수치적 주장이 실제 피쳐 값과 일치

Table 4: Safety Gate 검증 기준.

4.2.4 서빙 모델 선택

고객 대면 추천사유는 자연스럽고 전문적인 한국어를 요구한다. 환경에 따라 최적 모델이 다르다:

- **온프레미스(폐쇄망):** Exaone 3.5 7.8B (LG AI Research, Apache 2.0) — 한국어 특화 학습으로 동급 모델 (Llama, Qwen) 대비 금융 존댓말 톤이 자연스럽다. RTX 4070 12GB에서 운용.
- **클라우드(AWS):** L2a 리라이트에 Bedrock Claude Sonnet 4.6 사용 — 자연스러운 한국어 생성, Bedrock 네이티브로 Marketplace 온보딩 없이 즉시 사용 가능. L2b self-critique도 Claude Sonnet 4.6이 담당한다 (생성 모델 $\leq$ 크리티크 모델 원칙). 자체 검증 레이어의 사실성 판정은 Claude Haiku 4.5를 사용한다. Ops/Audit 에이전트는 Claude Sonnet 4.6을 사용한다. 모든 호출은 교차 리전 추론 프로파일(us.anthropic.*)을 경유한다.
- **Bedrock 데이터 거버넌스:** 입출력 데이터가 모델 제공사(Anthropic)에 전달되지 않으며 모델 학습에 사용되지 않는다. VPC PrivateLink를 통해 인터넷을 경유하지 않고 호출할 수 있다. 교차 리전 추론 프로파일(예: us.anthropic.*)은 지리적으로 최적화된 엔드포인트로 요청을 라우팅하되, Bedrock은 API 페이로드 내 고객 데이터가 호출자의 계약된 데이터 경계 내에서 처리되고 제공사에 의해 저장되지 않음을 보장한다. 금융 고객 식별자(계좌번호, 주민등록번호)는 LLM 프롬프트에 진입하기 전에 PIIEncryptor가 제거하므로, 프롬프트에는 익명화된 행동 피쳐만 포함된다. 이 계층적 접근(애플리케이션 경계에서의 PII 제거 + Bedrock의 제공자 측 데이터 격리)은 금감원 AI 가이드라인과 개인정보보호법의 데이터 거버넌스 요건을 준수하도록 설계되었다.

백엔드는 config-driven으로, 코드 변경 없이 배포 환경을 전환할 수 있다:

```
llm_provider:
  backend: bedrock # or openai / gemini /
solar / local / dummy
```

추천사유 생성 파이프라인은 별도의 계층 명칭(L1/L2a/L2b)을 사용하며, 이는 Table 1의 서빙 폴백 계층(Layer 1/2/3, 모델 학습 방식 구분)과는 다른 개념이다. 추천사유 생성 계층이 Bedrock 호출로 다음과 같이 매핑된다:

- **L1 (동기):** 템플릿 기반, 지연시간 1ms, 항상 사용 가능. Bedrock 호출 없음; TemplateEngine이 InterpretationRegistry 역매핑에서 결정론적 한국어를 생성한다. 모든 고객에게 보장된 폴백.
- **L2a (온디맨드):** 고객이 상품 상세를 클릭하면 Bedrock Claude Sonnet이 동기적으로 L1 템플릿을 더 풍부하고 자연스러운 한국어로 리라이트한다(첫 호출 2.4s). 결과는 DynamoDB에 캐싱되어 이후 요청은 즉시 반환된다(캐시 적중 6ms). 처리 우선순위는 고객 등급이 아닌 컨텍스트 풍부도(데이터 가용성)에 따라 결정되며, 이는 금소법 §19 동등 설명의무를 충족한다(KFCPA §19).
- **L2b (비동기):** Bedrock이 L2a 출력을 PII 누출, 환각, 규제 준수 관점에서 검증한 후 승격한다. 품질 보증을 위해 5% 샘플링 인간 검토가 적용된다.

Bedrock 인프라는 추천사유 생성과 운영 에이전트(5절) 간에 공유되며, 쿼터 경쟁은 시간대 분리로 해결한다.

4.2.5 팩트 압축 레이어 (Mem0 차용)

피쳐 해석 레지스트리가 피쳐 레벨 해석을 제공한다면, 팩트 추출 레이어는 **고객 레벨 서술적 팩트**를 추가한다. 룰 기반 엔진이 피쳐 값으로부터 다음과 같은 한국어 팩트를 추출한다 — LLM 호출 없이 결정론적으로 동작한다:

- “예적금 중심 포트폴리오”
- “최근 3개월 카드 사용 증가”
- “리스크 회피 성향”

이 팩트들은 서빙 시점에 config 기반 룰(15개 카테고리)로 추출되어 L2a 프롬프트의 “고객 특성 팩트” 섹션으로 주입된다. L2a 모델(AWS에서는 Claude Sonnet 4.6, 온프레미스에서는 Exaone 3.5)이 단순 피쳐 수치가 아닌 **고객을 이해한 상태**로 사유를 작성하게 된다.

룰은 YAML 설정 파일에서 정의되며 (포트폴리오 구성, 관심사, 리스크 성향, 생애주기 등 15개 범주), 설정 파일 수정만으로 새 팩트를 추가할 수 있다.

4.3 캐싱 전략과 비동기 L2a 아키텍처

추천사유는 3-layer 비동기 아키텍처로 서빙된다:

1. **L1 (템플릿)**: 고객 요청 시 즉시 반환. LLM 호출 없음. 템플릿 엔진이 LGBM SHAP top-K 피처의 비즈니스 역매핑을 기반으로 결정론적 한국어 사유를 생성한다. 피처 해석 레지스트리의 5-level cascade (SHAP 방향 → L3 → L2 → L1 → 역매핑 레이어)를 거쳐 3-tuple (피처명, shap_값, 한국어해석)으로 enrichment된다.
2. **L2a (온디맨드 + 캐싱)**: 고객이 상품 상세를 클릭하면 Bedrock Claude Sonnet 4.6(AWS) 또는 Exaone 3.5(온프레미스)가 L1 사유를 자연스러운 한국어로 동기적으로 다듬는다(첫 호출 2.4s). 결과는 DynamoDB에 캐싱되어 동일 고객×상품의 다음 요청은 즉시 반환된다(캐시 적중 6ms). 이 온디맨드 방식은 초기 SQS 비동기 설계를 대체하며 — 클릭 즉시 응답을 제공하고 캐싱으로 반복 접근을 즉각 처리한다. **모든 고객에게 L1 템플릿은 동등하게 제공되며**, L2a 호출은 고객 등급이 아닌 **고객의 상세 조회 요청**에 의해 트리거된다 — 금소법 제19조 동등 설명의무와 개보법 제37조의2 제2항 설명요구권 준수. 컨텍스트 풍부도 분류: rich(피처+이력 풍부) → moderate(피처 일부) → sparse(콜드스타트; L2a 제외, L1 템플릿만 제공). 이 설계는 **데이터 가용성**이 곧 LLM 출력 품질로 이어지기 때문이며, 고객 등급에 따른 서비스 차별이 아니다.¹
3. **L2b (품질 검증)**: L2a 출력에 5단계 safety gate를 적용 — (1) 프롬프트 세정기, (2) PII 탐지(한국 주민등록번호, 카드번호 등), (3) 자체 검증 레이어(compliance + injection + factuality), (4) grounding 검증(숫자 교차 확인), (5) 5% 인간 리뷰 샘플링. 통과 시 L2b로 승격, 실패 시 L1 폴백.

캐싱은 이중 백엔드(인메모리 + DynamoDB)로 구현되며, customer_id + product_id + task_name 복합 키로 TTL 기반 자동 만료된다. 941K 고객 중 L2a 대상(5% 샘플)인 47K건은 Sonnet 워커 5대 병렬로 8분, 비용 \$0.21에 처리된다(47K × 입력 500 + 출력 200 토큰 기준).

4.3.1 서빙 보안

금융 고객 데이터는 인바운드(원시 피처 입력)와 아웃바운드(생성된 추천사유 텍스트) 양방향 모두에서 PII 보호가 필요하다. 두 개의 모듈이 서빙 경계에서 이를 집행한다:

- **PIIEncryptor (인바운드)**: 추론 전에 피처 입력 벡터에서 PII 패턴(주민등록번호, 카드번호, 계좌번호)을 스캔한다. 탐지된 PII 필드는 고객별 솔트(salt)를 적용한 HMAC-SHA256으로 인플레이스(in-place) 해싱되어, 모델 추론이 익명화된 값에서 작동한다. SECURITY_FEATURE_SCAN=true 환경 변수로 제어된다.
- **PromptSanitizer (아웃바운드)**: 고객 인터페이스로 반환되기 전에 생성된 추천사유 텍스트에서 PII를 제거한다. 또한 프롬프트 민감도를 3단계로 분류한다 — HIGH(금융 식별자 또는 계정 수준 데이터 포함), MEDIUM(행동 패턴 포함), LOW(일반 추천 컨텍스트) — 하여 라우팅에 적용한다: HIGH 프롬프트는 Amazon Bedrock 전용(데이터가 AWS 리전 내 유지), MEDIUM 및 LOW는 PII가 제거된 경우에만 대체 공급자(예: Gemini)로 라우팅될 수 있으며, 고객 식별 정보가 포함된 원시 데이터는 Bedrock 경계를 이탈하지 않는다. 이 계층적 라우팅은 원시 고객 데이터가 아닌 프롬프트 컨텍스트에 적용된다. SECURITY_PII_SCRUB=true 환경 변수로 제어된다.

이 2계층 경계는 원시 PII도, PII를 포함한 LLM 생성 출력도 서빙 경계를 이탈할 수 없도록 보장하며, GDPR 및 한국 개인정보보호법의 개인정보 최소화 원칙을 준수하도록 설계되었다.

5 운영 에이전트 파이프라인

앞 절에서는 고객 대면 경로에서 추천사유를 생성하는 3개의 서빙 에이전트를 기술하였다. 본 절에서는 별도의 배치 전용 경로에서 작동하는 2개의 추가 에이전트를 소개한다: 모니터링 출력과 규제 준수 보고서를 해석하여, 전담 MLOps 인력 없이도 소규모 운영 팀이 규제를 준수하는 MLOps를 유지할 수 있도록 한다.

5.1 동기: 인간-AI 역할 분리

모든 운영 태스크가 동일한 인지 모드를 필요로 하지는 않는다. 정형화되고 반복적인 모니터링 — PSI가 임계값을 초과했는지, 공정성 지표가 한도 이하로 떨어졌는지, 게이트 엔트로피가 변동했는지 확인하는 것 — 은 일간 또는 주간 배치 스케줄로 실행되는 LLM 에이전트에 적합하다. 비정형적 판단 —

¹초기 프로토타입은 고객 세그먼트(VIP)를 기반으로 L2a 우선순위를 설정했으나, 금소법 제19조 동등 설명의무 준수를 위해 컨텍스트 풍부도 기반 분류로 재설계되었다 (온프레임 v3.0.0, 2026). 이 설계 전환은 공정성 감사 에이전트의 AV1(공정성) 관점에서 지속 모니터링된다.

데이터 오염 진단, 비즈니스 맥락 변화 해석, 규제 해석 변경 대응 —은 현재 어떤 LLM도 안정적으로 제공할 수 없는 인간 전문성을 요구한다.

핵심 설계 통찰은 역할 분리이다: 에이전트는 무엇이 변했는지를 알려주고, 인간은 왜 변했고 무엇을 할지를 결정한다. 이러한 분업은 전담 MLOps 인력 없이도 소규모 팀(1-2명)의 규제 준수 운영을 가능하게 한다. 에이전트가 “대시보드 피로”를 해소하기 때문이다 — 매일 10개의 지표를 확인하는 대신, 자연어 요약 하나를 읽으면 된다.

5.2 2개의 운영 에이전트

5.2.1 OpsAgent (운영 에이전트)

OpsAgent는 학습 완료 및 드리프트 모니터링 DAG 실행 후 동작한다.

입력: 학습 평가 메트릭, 학습 로그, CGC 게이트 엔트로피, PSI 드리프트 보고서.

출력: 자연어 “모델 건강 보고서”.

OpsAgent CP4 진단 (실측):

“종류 fidelity gap 0.1858 > 임계값 0.05. 8/10 태스크 calibration_gap 초과. 교사 모델 변경 또는 피쳐 분포 변동 가능성. 해당 태스크의 교사-학생 예측 분포 비교 분석 권장.”
3-agent 합의: 3/3 FAIL (만장일치)

Figure 4: OpsAgent CP4 종류 품질 실측 진단 결과 및 3-agent 합의 판정.

트리거: 드리프트 모니터링 DAG 완료, 학습 Job 완료. ChangeDetector가 파이프라인의 모든 단계(학습, 평가, 종류, 서빙, 추천사유 생성) 완료 시 스테이지 완료 이벤트를 발행하며, OpsAgent는 이 이벤트 스트림에서 입력 윈도우를 선택한다. Lambda 핸들러의 {"action": "heartbeat"} 엔드포인트는 추론을 실행하지 않고 시스템 상태를 반환하여, OpsAgent가 상태 보고서 제출 전 서빙 가용성을 확인할 수 있다. 챔피언 모델 버전이 변경되면 Lambda 콜드 스타트 시 이벤트가 발행되어, OpsAgent가 다음 보고서에서 해당 전환을 표시할 수 있다.

OpsAgent는 승격 결정을 내리지 않는다 — 인간이 결정을 내리는 데 필요한 정보를 표면화할 뿐이다. 모든 지표가 정상 범위 내이면 보고서는 간결하다 (“13개 전체 태스크 허용 범위 내; 조치 불필요”). 이상이 탐지되면 어떤 태스크와 어떤 전문가가 영향을 받았는지 식별하여, 원시 수치 대신 실행 가능한 맥락을 제공한다.

5.2.2 AuditAgent (감사/규제 준수 에이전트)

AuditAgent는 공정성 모니터링 및 거버넌스 DAG 실행 후 동작한다.

입력: 공정성 모니터 보고서(DI/SPD/EOD), 감사 추적 무결성 검증, 옴트아웃 통계, 거버넌스 체크리스트 상태.

출력: 자연어 “규제 준수 보고서”.

AuditAgent 진단 (실측):

“추천사유 grounding score 0.33 (임계값 0.50): top-3 태스크 중 1개만 한글 키워드 매칭. 편향 DI = 1.0 (4개 보호그룹 동등 처리). KFCPA 위반 0건 (5개 규칙 검증 완료).”
3-agent 합의: grounding FAIL (1W+2F), fairness WARN (2P+1W), KFCPA PASS (3/3 만장일치)

Figure 5: AuditAgent 실측 규제 준수 보고서 및 3-agent 합의 판정.

트리거: 공정성 모니터링 DAG 완료, 분기별 거버넌스 사이클. AuditAgent는 정량적 공정성 지표를 규제 언어로 변환하며, 적용 가능한 규제(금감원 가이드라인 번호, EU AI Act 조항)를 명시적으로 참조하여 인간 검토자가 별도 문서를 교차 참조하지 않고도 조치할 수 있도록 한다. AuditLogger는 학습 및 종류 완료 이벤트를 불변 감사 항목으로 기록하여, AuditAgent의 입력이 위변조 불가능한 시간순 파이프라인 활동 기록임을 보장한다.

5.3 설계 원칙

핵심 제약은 운영 에이전트가 서빙 경로와 공유 상태를 갖지 않는다는 것이다. 서빙 파이프라인(Feature Selector → Reason Generator → Safety Gate)은 고객 대면 출력을 생성하고; 운영 파이프라인 (DAG 완료 → OpsAgent/AuditAgent → 보고서 저장 → 인간 검토)은 내부 운영 산출물을 생성한다. 이러한 분리는 운영 에이전트의 장애가 고객 대면 서비스를 절대 저하시키지 않음을 보장한다.

5.4 운영 에이전트 모델 선택

서빙 에이전트가 고객 대면 텍스트를 위해 한국어 유창성을 요구하는 것과 달리, 운영 에이전트는 정형화된 JSON 입력을 처리하고 논리적 평가를 생성한다 — 자연어 유창성보다 추론 정확도가 핵심이다. 배포 환경별 모델 배치는 다음과 같다:

- **온프레미스(폐쇄망):** Exaone 3.5 7.8B(한국어 추천사유), Qwen 2.5 7B(도구호출 추론), Exaone 3.5 2.4B(해석/합의), bge-m3(임베딩). RTX 4070 12GB에서 순차 로딩으로 운용. 도구사용 역할은 4개 시나리오 내부 벤치마크

원칙	근거
배치 전용, 실시간 불가	서빙 경로 의존성 없음; DAG 완료 후 비동기 실행
태스크별 최적 모델 분리	- 추천사유 생성: Claude Sonnet 4.6(AWS) / Exaone 3.5(온프레미스) - 에이전트 대화/합의: Claude Sonnet 4.6(맥락 추론), Ops/Audit 에이전트 포함 - 판정(사실성): Claude Haiku 4.5(저비용) - 임베딩: Titan V2 - 온프레미스: Exaone 3.5 7.8B(사유) + Qwen 2.5 7B(도구사용) + Exaone 3.5 2.4B(합의)
보고서를 공유 폴더에 저장	이상 시에만 Slack/이메일 알림; 인간은 자기 페이스로 검토
에이전트 출력이 감사 산출물	불변, HMAC 서명; 보고서 자체가 모니터링의 증거
비용: \$0.03/일 (합의 3x)	실행 사이클당 소형 모델 1-2회 호출

Table 5: 운영 에이전트 설계 원칙.

에서 기존 Qwen 2.5 14B Q4 대신 7B가 선정되었다: 양자화된 14B가 실패한 도구호출 시나리오 3건을 더 작은 모델이 모두 완수했다 — 모델이 크다고 도구호출을 더 잘하는 것은 아니다.

• 클라우드(AWS): 태스크별 최적 모델을 배치한다.

- ▶ Claude Sonnet 4.6 (추론 프로파일: `us.anthropic.claude-sonnet-4-5-20251101-v1:0`) — 한국어 L2a 사유 생성/critique (온프레미스는 Exaone 3.5)
- ▶ Claude Sonnet 4.6 — Ops/Audit 에이전트 대화, 3-에이전트 합의
- ▶ Claude Haiku 4.5 (추론 프로파일: `us.anthropic.claude-haiku-4-5-20251001-v1:0`) — 자체 검증 레이어 사실성 판정
- ▶ Claude Opus — 분기 심층 감사
- ▶ Titan Embeddings V2 — 벡터화

Bedrock 인프라를 추천사유 생성과 에이전트가 공유하며, 쿼터 경쟁은 시간대 분리로 해결.

두 배포 환경 모두 운영 에이전트는 DAG 사이클당 1-2회만 호출하므로, 모델 선택에 관계없이 비용과 지연시간이 무시할 수준이다.

5.5 실무적 가치

운영 에이전트는 금융 AI 운영의 세 가지 구체적 고충을 해결한다:

1. **대시보드 피로 해소:** 매일 10개 이상의 메트릭 대시보드를 모니터링하는 대신, 운영 팀이 자연어 요약 하나를 읽는다 — “출근해서 확인하면 됩니다.”

2. **감사 증거 자동 축적:** 규제기관이 “드리프트 이벤트 X에 어떻게 대응했는가?”라고 물으면, 해당 일자의 OpsAgent 보고서와 이후 인간의 조치 기록을 제시하여 완전한 인시던트 대응 이력을 구성한다.

3. **소규모 팀 MLOps 실현:** 대규모 MLOps 팀 없이도 규제 준수 운영이 가능한 구조이다. 에이전트가 정형화된 해석을 담당하고, 인간은 규제가 실제로 요구하는 판단을 기여한다.

5.6 파이프라인 파트 분류 및 점검 체크리스트

에이전트가 체계적으로 점검하기 위해 파이프라인을 6개 파트로 분류하고 48개 점검 항목을 정의한다: P1(인제스천), P2(피처 엔지니어링), P3(학습/증류), P4(서빙/추천), P5(추천사유 생성), P6(모니터링/거버넌스). 각 항목은 YAML config에서 도구 이름, 임계값, 판정 로직으로 정의되며, OpsAgent는 7개 운영 체크포인트(CP1-CP7, Table 7 참조)에 묶인 23개 항목을, AuditAgent는 5개 감사 관점에 묶인 25개 항목을 담당한다.

5.7 도구 호출 체계

39개 도구(Query 30 + Action 9)가 JSON Schema로 정의되며, 기존 모니터링 컴포넌트(드리프트 감지 모듈, 공정성 모니터, 자체 검증 레이어 등)를 도구로 래핑하여 에이전트가 호출한다. Query 도구는 자유롭게 호출 가능하나, Action 도구(인시던트 생성, 감사 로그 기록 등)는 명시적 승인 후에만 실행하여 Query/Action 경계를 구조적으로 보장한다.

에이전트와 이 도구 표면 사이에는 세 가지 강화 메커니즘이 있다. 첫째, focus 기반 동적 도구 라우팅: 매 호출마다 39개 도구 전부를 노출하는 대신, 대화 계층이

현재 점검 focus 에 관련된 부분집합을 라우팅 테이블(agent_tool_routing.yaml, 파일 부재 시 내장 폴백 맵)에서 선택하여 프롬프트를 줄이고 잘못된 도구 선택을 감소시킨다.

둘째, 시그니처 기반 파라미터 필터링: 어떤 도구는 실행 전에 인자가 래핑된 함수의 실제 시그니처와 대조되어 걸러지므로(tool_registry.py::_filter_params), LLM 이 스키마에 없는 인자를 지어내더라도 점검 도중 TypeError 로 중단되는 대신 해당 파라미터가 탈락하는 수준으로 완충된다.

셋째, 경고 triage: 경고 수준의 도구 출력은 서사 생성 전에 IGNORE / MONITOR / FIX_NOW 로 분류되며, 증가 추세에 있는 지표는 아직 알람 임계값 미만이라도 FIX_NOW 로 격상된다. 이는 증류 게이트에 적용된 SR 11-7 품질 triage 원칙 — 출력을 모니터링하고 열화를 조기에 격리한다 — 을 운영 모니터링 계층 자체로 확장한 것이다.

5.8 판정 계층화와 에이전트 자기검증

LLM 해석 계층의 감사 가능성은 두 가지 설계 규칙으로 유지된다. 첫째, 판정은 롤엔진의 몫이다: 모든 PASS/WARN/FAIL 판정은 재현 가능한 결정론적 임계값 규칙이 완전한 감사 추적과 함께 계산하며, LLM 계층(과 그 위의 합의 메커니즘)은 그 판정을 해석하고 우선순위를 매기고 서술할 뿐이다. 따라서 감사인은 어떤 판정이든 LLM 없이 재연할 수 있다.

둘째, 보고 전 자기검증: verify_grounding 단계가 대화 이력을 다시 읽어 결론 초안의 각 사실 주장을 이력에 실제로 기록된 도구 결과와 대조하고, 구조화된 {grounded, issues} 판정을 반환하며, 검증 실패 시 결론은 인간 검토용 플래그가 붙은 초안으로 강등된다. 이 단계는 양 환경에 구현되어 있다: 온프레미스 참조 시스템에서는 기본 활성화이며, AWS에서는 대화 계층의 호출 단위 플래그(API 수준 기본 비활성)로 제공되고, 프로덕션 보고서 경로에서는 opt-in LLM 후속 배선이 켜진 경우 기본 활성화로 동작한다.

로그 분석도 LLM 을 진짜 모호한 곳에만 아껴 쓰는 같은 철학을 따른다: 로그 파일은 증분 스캔되고(마지막 점검 이후 추가된 줄만), ERROR 줄은 LLM 개입 없이 결정론적으로 FIX_NOW 로 격상되며, 심각도가 정말로 모호한 WARNING 줄만 LLM triage 로 전달된다.

5.9 환경 적응형 합의 메커니즘

LLM 기반 해석의 할루시네이션 리스크를 구조적으로 완화하기 위해 합의 메커니즘은 배포 환경에 맞게 적응된다. 클라우드와 온프레미스 환경은 모델 역량이 근본적으로 다르기 때문

이다. 단일 합의 설계는 두 환경 모두를 만족할 수 없다: 클라우드 규모의 모델은 독립 병렬 투표가 가능하지만, 소형 온프레미스 모델은 순응 편향(conformity bias)에 대한 구조적 안전장치가 필요하다.

5.9.1 AWS: 독립 병렬 투표 (배심원 모델)

AWS에서는 3개의 독립 Claude Sonnet 세션이 병렬로 실행된다. 각 에이전트에 다른 관점을 부여한다: α (보수적), β (통계적 유의성), γ (비즈니스 영향). 에이전트들은 서로의 출력을 볼 수 없으며 — 판정은 집계를 통해 사후에 도출된다. 지연시간은 체크포인트당 약 5초, 비용은 단일 Sonnet 호출의 3배이다.

5.9.2 온프레미스: 2-Round 하이브리드 (독립 투표 → 순차 심의)

온프레미스 배포는 단일 RTX 4070(12GB VRAM)에서 합의는 Exaone 3.5 2.4B로, 도구사용 추론은 Qwen 2.5 7B로 실행한다. 이 파라미터 규모에서 순수 순차 심의(Delphi 방식)는 수렴 편향(convergence bias)을 보인다: 이후 에이전트가 앞선 의견에 편승하여 소수 반론이 사라진다. 운영 및 감사 맥락에서는 신호를 놓치는 것이 오탐보다 훨씬 비용이 크므로, 프로세스를 두 라운드로 분리한다:

- **1라운드 (독립 투표, 5개 에이전트):** 각 에이전트가 다른 에이전트의 출력을 보지 않고 투표한다. 소수 의견은 이 라운드 종료 시 잠금 처리되어 이후 처리에서 삭제될 수 없다.
- **2라운드 (순차 심의, 2개 에이전트):** 두 추가 에이전트가 1라운드 전체 출력을 읽고 각 입장(다수 및 소수 모두)의 논거를 강화하여 최종 구조화된 판정을 생성한다. 2라운드는 1라운드에서 보존된 소수 의견을 덮어쓰지 않고 논거의 품질을 향상시킨다.

각 체크포인트에서 1라운드는 단일 GPU 제약에 따라 5표를 순차 실행하고 2라운드는 심의 2회를 추가하며; 규칙 엔진이 WARN 또는 FAIL로 표시한 항목만 합의에 진입한다(보통 점검당 5-10개). 2.4B 합의 모델에서는 표당 지연이 기존 14B Q4 구성(점검 사이클당 약 45분 소요)보다 크게 낮아, 배치 전용 사후 점검 프로세스의 운영 허용 범위 안에 충분히 들어온다.

이 하이브리드 설계를 순수 Delphi 방식 대신 선택한 이유는 네 가지이다: (1) 소수 의견 보존 — 1라운드 독립성으로 확보되며 이후 구조적으로 수정 불가; (2) 논거 품질 — 2라운드 심의로 달성되며, 순수 Delphi의 이점과 동등; (3) 소형 모델 적합성 — 1라운드 독립성이 소형 모델이 특히 취약한 순응 편향

등급	AWS (3개 에이전트)	온프레임 (5개 R1 에이전트)	조치
합의 (만장일치)	3/3 동의	5/5 동의	확정 판정
다수 (우선 검토)	$\geq 2/3$	$\geq 3/5$	즉시 담당자 검토
마이너리티 리포트	1/3 반론	1-2/5 반론	2순위 검토 목록, 별도 보존

Table 6: 환경별 판정 분류. 온프레임 R1 집단이 더 큰 것(5 vs 3)은 에이전트당 추론 역량이 낮은 것을 보완하기 위함이며, 추가 R2 심의는 잠금 처리된 R1 판정을 변경하지 않는다.

OpsAgent 체크포인트	투표	판정	마이너리티
CP2: Phase 0 데이터 품질	3/3 FAIL	FAIL	없음 (만장일치)
CP4: 종류 충실도	3/3 FAIL	FAIL	없음 (만장일치)
CP6: 서버 지연시간 120ms	1 WARN + 2 PASS	WARN	α (보수적)

Table 7: OpsAgent 3-에이전트 합의 결과. CP2, CP4 만장일치 FAIL은 합성 데이터 한계에서 기인 (벤치마크 맥락에서 예상된 결과). CP6 WARN은 α 에이전트가 120ms 씬 지연시간에 보수적 임계값을 적용한 것을 반영.

AuditAgent 항목	투표	판정	마이너리티
추천사유 근거 (점수 0.33)	1 WARN + 2 FAIL	FAIL	α (덜 엄격)
공정성 DI = 1.0	2 PASS + 1 WARN	WARN	α (보수적)
금소법 준수 (KFCPA)	3/3 PASS	PASS	없음 (만장일치)

Table 8: AuditAgent 3-에이전트 합의 결과. 근거 점수 0.33이 FAIL을 트리거함 (표본 3개 태스크 중 1개만 키워드 매칭 검증). 공정성 DI = 1.0은 통계적으로 이상적이나 α 에이전트가 소표본 주의를 표명. 금소법(KFCPA) 준수는 만장일치 PASS — 5개 규칙 검사, 0건 위반.

을 회피; (4) 감사 적합성 — 모든 의견이 보존되어 감사인이 “소수 의견이 에스컬레이션되었는지(또는 되지 않았는지) 왜 인지”를 항상 추적 가능.

5.9.3 공통 분류 규칙

두 환경 모두 세 가지 판정 등급을 생성한다(에이전트 구성에 따라 수치는 다름):

두 환경 모두에서 핵심 원칙은 **마이너리티 리포트 보존**이다. 새로운 유형의 문제는 익숙한 패턴에 편향된 다수가 놓치고 반론 관점을 가진 소수가 먼저 포착하는 경우가 많다.

독립성에 대한 주석: AWS 변형에서 이 파이프라인은 **동일한 Sonnet 모델을 서로 다른 시스템 프롬프트와 샘플링 온도 변동으로 3회 호출한다**. 따라서 실제로 확보되는 것은 가중치 수준 독립성(weight-level independence)이 아니라 **조건부 여된 다양성(conditioned diversity)**이다. 만장일치는 세 조건부 관점이 같은 수렴점에 도달했음을 뜻할 뿐이며, 동일한 학습 계보가 같은 편향을 공유할 수 있으므로 **만장일치를 약한 신호로 취급**한다. 고위험 체크(AV1 공정성, AV2 PII 검출 등)는 마이너리티 의견이 단 하나라도 발생하면 다수 판정과 무관

하게 인간 검토로 에스컬레이션된다. 온프레임 변형도 모든 합의 투표를 단일 소형 모델 체크포인트에서 실행하므로 동일한 주의가 적용되며, 1라운드 독립성이 공유 계보 편향을 완화하지만 완전히 제거하지는 않는다.

5.9.4 운영 테스트 합의 결과 (AWS 변형)

Table 7 와 Table 8 는 운영 Lambda 서버 파이프라인에서 수행한 실제 합의 테스트 결과이다 (AWS 3-에이전트 변형). 온프레임 2-Round 결과는 온프레임 배포가 벤치마크 구성이 아닌 운영 폴백 대상이므로 여기서는 보고하지 않는다. 판정 원칙: **PASS는 만장일치(3/3) 필요**; 단 1건이라도 이견이 있으면 WARN; FAIL 투표가 하나라도 있으면 다수 무관하게 FAIL 판정.

5.10 진단 케이스 스토어

점검 리포트는 일회성 산출물이 아니라 운영 지식 베이스로 축적된다. LanceDB 기반 진단 케이스 지식베이스에 각 진단 케이스의 구조화된 메타데이터(파트, 항목, 판정, severity)와 텍스트 임베딩(finding + cause + action)을 저장하여 세 가지로 활용한다: (1) **유사 케이스 검색**: 새로운 이상 발생 시 과거 대응 이력 참조, (2) **통계 분석**: 파트별 빈번 WARN 유형,

금감원 요구사항	시스템 구성요소	검증 방법	구현 상태
설명 가능성	게이트 가중치 + 3-에이전트 추천사유	추천건별 감사 로그	기본 배선
공정성	공정성 모니터 (DI/SPD/EOD)	주간 자동 보고서	기본 배선
모델 검증	챔피언-챌린저 (오프라인 + 온라인)	배포 전 메트릭 게이트 + 배포 후 트래픽 게이트	기본 배선
모니터링	드리프트 감지 모듈 (PSI)	연속적, 3일 트리거	기본 배선
감사 추적	HMAC 해시체인 로그	불변, 7개 감사 테이블	기본 배선
폴백	템플릿 추천사유 + 킬 스위치	즉시 수동 오버라이드	기본 배선(템플릿) / opt-in(킬 스위치)
모델 리스크 관리	오프라인 ModelCompetition 게이트 + --force-promote 오버라이드	유의성 게이트 판정 + 운영자 서명; 모든 등록 건의 판정 감사 기록	기본 배선
고객 적합성	제약 인식 엔진 + 적격성 필터	추천 전 적합성 사전 검증	기본 배선

Table 9: 한국 금감원 가이드라인 준수 매핑. 구현 상태 칼럼은 배포 기본 설정에서 가동되는 구성요소(기본 배선)와 명시적 활성화가 필요한 구성요소(opt-in)를 구분한다 — 이 표를 읽는 규제 독자가 코드베이스에 존재하기만 하는 것과 기본으로 돌아가는 것을 구별할 수 있어야 하기 때문이다.

평균 해결 시간 집계, (3) **대응 효과 추적**: (문제, 대응, 후속 판정) 3-tuple로 대응의 실제 효과를 정량화.

케이스 스키마에 consensus_type 필드를 포함하여 마이너리티가 사후에 맞았던 비율도 추적한다. 이 데이터는 규제기관 감사 시 “지속적 개선 증명” 근거로 직접 활용된다.

5.11 메모리 프레임워크 선택적 차용

2026년 초 발표된 여러 에이전트 메모리 프레임워크(Mem0, Zep/Graphiti, Letta, SuperLocalMemory)의 **핵심 패턴**만 차용하여 기존 인프라에 증분 추가하였다.

차용 1 — 시간적 지식 그래프 (Zep/Graphiti): 시간적 팩트 스토어가 (엔티티, 속성, 값, valid_from, valid_to) 스키마로 감사 증적을 저장. “2026-03-15 시점의 고객 A 상태는?” 같은 시점 복원 쿼리를 단일 필터로 처리한다. 추천 사례(LGBM 기여 피쳐 + 생성 사유, 요청별 추적), 진단 케이스 (OpsAgent 점검 결과), 시간적 팩트 — 세 스토어 모두 같은 LanceDB 백엔드를 공유하여 신규 의존성이 없다. LanceDB의 벡터 검색 + 컬럼 필터링 결합으로 “특정 시점의 유사 고객 검색” 같은 복합 쿼리를 단일 호출로 처리한다. 임베딩 모델 선택은 한국어 텍스트에서 유독 중요하다: 자체 평가에서 all-MiniLM 임베딩은 한국어 문장 쌍을 내용과 무관하게 코사인 유사도 ≈ 1.0 으로 붕괴시켜 변별력이 없었던 반면, bge-m3는 유사 쌍(0.76)과 무관 쌍(0.41)을 분리했다. 따라서 온프레미스 배포는 bge-m3로 표준화하며, AWS에서는 Titan Embeddings V2가 같은 역할을 맡는다.

차용 2 — 수학적 Decay (SuperLocalMemory): 진단 케이스 지식베이스의 유사 케이스 검색에 $\exp\left(-\frac{\text{age}}{\tau}\right)$ 가중치를

추가. 반감기 90일 기본값. **원본 케이스는 보존**되고 검색 가중치만 조정되므로 감사 추적성이 유지된다.

차용 3 — Dialog Recall Memory (Letta): 대화 회상 메모리가 담당자와의 과거 대화를 DynamoDB에 저장하여 세션 간 맥락을 유지한다. “지난번 논의한 그 이슈”를 Bedrock 대화 인터페이스가 기억할 수 있다.

차용하지 않은 것: LangMem의 프롬프트 자기개선 (감사 관점 위험 — “누가 이 프롬프트를 승인했는가?”에 답할 수 없음).

모든 차용은 **opt-in** 설계로, 기존 동작에 영향을 주지 않는다.

5.12 변경 감지 및 영향도 리뷰

코드, 설정, 모델, 데이터 소스 변경을 두 가지 채널로 감지한다: Push 채널(git hook, 파이프라인 상태 콜백, 인제스천 완료 이벤트)은 즉시 감지하고, Pull 채널(manifest diff, 서빙 지표 폴링)은 주기적으로 감지한다. 변경이 감지되면 영향 받는 파이프라인 파트의 체크리스트를 재실행하고, AWS 환경에서는 Sonnet이 diff를 읽고 하류 영향을 추론하여 담당자와 대화하며 영향도를 논의할 수 있다.

6 규제 준수

6.1 한국 금감원 가이드라인 매핑

Table 9은 한국 금감원 AI 가이드라인의 주요 요구사항과 본 시스템의 대응 구성요소를 매핑한다. 각 요구사항에 대해 시스템 구성요소와 검증 방법을 명시한다.

조항	요구사항	시스템 구성요소	구현 상태
제13조	투명성	3-에이전트 추천사유 생성 + 피쳐 기여도	기본 배선
제14조	인간 감독	Human-in-the-Loop 리뷰 + 킬 스위치	기본 배선(리뷰) / opt-in(킬 스위치)
제15조	정확성 및 견고성	어블레이션 검증된 성능 저하 + 드리프트 모니터링	기본 배선
제9조	리스크 관리	MRM 생애주기: 개발 → 검증 → 승인 → 모니터링 → 재학습	기본 배선
GDPR 제22조	거부 권리	동의/거부 감사 테이블 + 수동 오버라이드	기본 배선

Table 10: EU AI Act 조항별 준수 매핑. 구현 상태 의미는 Table 9 과 같다.

6.2 EU AI Act 매핑

Table 10 은 EU AI Act의 핵심 조항과 본 시스템의 준수 방식을 매핑한다. 본 논문은 금융 추천을 Annex III Section 5(b) (신용도 평가 및 신용 점수산정)에 부합하여 규제 준수 매핑 목적상 고위험 AI로 취급하며, Title III Chapter 2의 의무 준수를 요구한다.

6.2.1 규제 준수 파이프라인 구현

위에 나열된 GDPR/금소법 규제 의무는 Lambda 핸들러 및 RecommendationService에 연결된 4개의 모듈로 구성된 파이프라인을 통해 집행된다:

- **ConsentManager**: 예측이 실행되기 전에 고객이 AI 추천 동의를 부여했는지 검증한다. 동의가 없으면 피쳐 데이터를 기록하지 않고 규정에 맞는 차단 응답을 반환하며 파이프라인을 단락시킨다.
- **AIDecisionOptOut**: GDPR 제22조 및 한국 개인정보보호법(PIPA)에 따른 AI 프로파일링 거부권을 구현한다. 고객의 옵트아웃 플래그가 설정된 경우, 모델 추론 실행 전에 즉시 차단 응답을 반환한다.
- **RegulatoryComplianceChecker**: 추천 생성 전에 금소법 §17 적합성 사전 검증을 실행한다. 상품 위험 등급을 고객의 등록된 위험 수용 성향과 비교하여, 부적합한 추천은 감사 기록과 함께 차단된다.
- **ProfilingRightsManager**: GDPR 제15조 및 제17조에 따른 데이터 열람 및 삭제 요청을 처리하며, 피쳐 저장소 및 감사 테이블로 전파되는 단일 정보주체 권리 요청 진입점을 제공한다.
- **ComplianceAuditStore**: 실행된 태스크 목록, 활성화된 서빙 계층, 경과 시간, 규제 준수 검사 결과를 포함하여 모든 예측을 실시간으로 기록한다. 이 로그는 AuditAgent가 수행하는 감사 추적 무결성 검사의 신뢰 원천이다.

모든 검사는 두 가지 명시적 장애 posture 중 하나로 동작한다. 기본값인 fail-open 경로에서는 규제 준수 서비스가 일시적으로 비가용 상태이면 추천을 사전 승인된 저위험 상품(체크카드, 요구불예금)으로만 제한하고, 해당 이벤트를 단순 경고가 아닌 ERROR 레벨 + CloudWatch metric filter 알림용 구조화 마커([COMPLIANCE_DISABLED_UNCHECKED])로 기록하며, 인시던트를 다음 모니터링 사이클 내 인간 검토를 위해 에스컬레이션한다. 추가로 fail-closed posture 가 설정 옵션(compliance.hooks.strict)으로 구현되어 있다: 활성화 시 hook 구성 실패가 Lambda 콜드 스타트를 중단시키므로 어떤 요청도 미검사 상태로 서빙되지 않으며, 프로덕션에서는 이 posture 를 권장한다. 배포 기본값은 여전히 strict: false 이며, 이 경우 위의 보완 통제 — 적합성 평가가 필요 없는 상품으로의 제한과 알림 등급의 구조화 로깅 — 가 일시적 인프라 장애가 고객 대면 서비스 중단이나 조용한 규제 우회로 번지는 것을 막는다.

6.3 한국 AI 기본법

2024년 12월 국회를 통과하고 2025년 1월 공포된(시행: 2026년 1월) 한국 인공지능 기본법은 AI 시스템을 위험 수준에 따라 분류하고, “고영향 AI”에 대해 강화된 의무를 부과한다.

금융 상품 추천의 고영향 분류 여부. 동법 제2조 및 시행령 초안에 따르면, 금융 서비스에서 개인의 경제적 의사결정에 실질적 영향을 미치는 AI는 고영향 AI로 분류될 가능성이 높다. 구체적으로: (1) 투자 상품 추천은 금소법 제17조(적합성 원칙)의 적용을 받으며, AI가 추천 사유를 생성하는 경우 설명의무가 강화된다; (2) 신용·대출 관련 추천은 신용정보법과의 교차 규제 대상이다; (3) 예금·보험 등 원금보장 상품은 상대적으로 낮은 위험 등급이나, AI 기반 교차판매(cross-sell) 추천은 고영향에 해당할 수 있다.

본 시스템의 대응. 3-Agent 파이프라인의 Safety Gate가 고영향 AI의 핵심 요건인 (1) 투명성 (추천 사유 제공), (2) 인간




Figure 6: 모니터링 및 거버넌스 아키텍처.

모니터링 컴포넌트 → 운영/감사 에이전트 → 합의 → 거버넌스 리포트 → 담당자 검토.

감독 (관리자 검토 경로), (3) 기록 보존 (감사 추적)을 구조적으로 충족한다. 특히 LGBM gain 기반 피쳐 중요도와 해석 레지스트리의 조합은 “왜 이 추천이 생성되었는가”에 대한 기술적 근거를 규제 검사관에게 제공할 수 있다.

6.3.0.1 배포 대상 상품군 한정

저위험 상품 한정 배포. 본 연구의 실제 배포 대상은 체크카드, 예금, 수시입출금 등 **저위험 상품군**이다. 투자상품(펀드, 주식, 채권 등)과 보험 상품은 금소법 제17조 적합성 원칙 및 불완전판매 리스크로 인해 많은 관할권(한국, EU MiFID II, 미국 Reg BI 등)에서 AI 직접 추천이 제한되거나 인간 자문인 감독이 필수적이며, 본 시스템은 해당 상품군을 배포 범위에서 **의도적으로 제외**한다.

합성 데이터(Santander 941K)는 벤치마크 목적으로 상품군을 가리지 않고 다양한 태스크를 포함하지만 — will_acquire_investments 같은 태스크도 벤치마크 목적으로 학습 —, 실제 운영 배포는 체크카드 추천에 국한된다. 이 구분은 “모델이 학습한 것”과 “시스템이 실제로 추천하는 것”을 분리하여, 벤치마크 평가의 일반성을 유지하면서 규제 리스크를 최소화한다.

왜 이 구분이 중요한가. 리뷰어가 Paper 2의 예시(“왜 이 카드가 저에게 추천되었나요?”)를 보고 “투자 상품은 왜 예시에 없는가?”라고 묻는다면, 답은 **의도적 배제**이다. AI 에이전트

가 자연어 추천사유를 생성하는 기술 자체는 투자 상품에도 적용 가능하지만, 불완전판매 리스크를 완전히 제거하려면 인간 자문인의 최종 검토가 필요하며, 이는 본 논문의 **자동화** 주장과 양립하지 않는다. 저위험 상품에 한정함으로써 “완전 자동화된 설명 가능한 추천”이라는 주장이 규제와 양립 가능한 형태로 성립한다.

6.4 모니터링 및 거버넌스

6.4.1 확장 규제 모듈 (v2)

본 논문의 v2 개정에서는 통합된 ComplianceStore / SLATracker foundation 위에 구축된 확장 규제 모듈 세트를 추가한다. 이 중 7종의 hook(M1/M4/M5/M6/M9/M10/M12)은 단일 config 기반 진입점 build_compliance_hooks(core/serving/hook_builder.py)가 pipeline.yaml의 compliance.hooks 블록을 읽어 일괄 생성하며, 두 서빙 진입점(Lambda handler와 컨테이너 app) 모두 기동 시 이를 호출하므로 확장 규제 경로는 배포별 수동 조립이 아니라 기본 배선된다(compliance.hooks.enabled: true). 각 모듈은 여전히 **플러그형**이다: RecommendationService는 이들을 선택적 생성자 주입(optional constructor injection)으로도 받으며 주입이 없으면 v1 이전과 동일하게 동작한다 —

다만 이 주입 fallback 은 테스트 격리와 환경별 opt-out 용도로 유지되는 것이지, 프로덕션 배선 메커니즘이 아니다.

- **사용자 권리 관리자** (core/compliance/rights/). OptOutManager, ProfilingWorkflow, ExplanationSLATracker 3-클래스 조합으로 한국 개인정보보호법 §37의2(opt-out + 설명권), 신용정보법 §36의2(프로파일링 접근 / 정정 / 삭제 / 재산출), 그리고 개인정보 보호법 시행령 §44의3㉔의 법정 응답 기한 30일을 커버한다(추적기는 이보다 엄격한 내부 SLA 10일을 적용). §36의2 에 대해서는 구조화된 CREDIT_EXPLANATION 공시(CreditExplanationElements: 자동화평가 실시 여부, 평가 결과, 주요 평가 기준, 기초정보의 피처 → 소스 lineage)를 추가로 생성하며, 두 법률이 요구하는 공시 요소가 다르기 때문에 PIPA §37의2 일반 설명과는 별도 분기로 유지한다. 모든 요청은 자동 SLA 마감에 설정된 ComplianceRequest 로 영속화되며, 마감을 초과하면 SLA_BREACH 이벤트가 발생한다 — 단, 배포 기본 backend 는 in_memory(pipeline.yaml)라는 한정이 붙는다: “영속화”가 보존 등급의 내구 저장이 되는 것은 동봉된 IaC 로 프로비저닝되는 DynamoDB backend 를 활성화했을 때이며, AI기본법 §35㉔ 같은 다년 보존 기대는 이를 전제한다. 코드 존재와 실제 가동의 구분은 휴먼 리뷰 큐에도 동일하게 적용된다 — 그 배포 기본 store 역시 in-memory 다.
- **한국 AI기본법 FRIA** (core/compliance/fria_assessment.py::KoreanFRIAAssessor). AI기본법 시행령 §27 에 열거된 7차원 평가(데이터 민감도, 자동화 수준, 영향 범위, 모델 복잡도, 외부 의존성, 공정성 리스크, 설명가능성 갭)를 구현하며 §35㉔ 에 따라 5년 보관 기간을 강제한다. 감사 리포트에서 법적 근거를 분리 유지하기 위해 EU AI Act 제9조 평가기와 별도 클래스 로 관리한다.
- **금감원 AI RMF 분류기** (core/compliance/ai_risk_classifier.py). 6차원 가중 리스크 등급 (high / medium / low)을 계산하며, 연속된 모델 버전 간 등급 상승을 명시적으로 탐지한다. ‘high’ 로 상승한 경우 승격 게이트를 통해 추가 운영자 승인이 요구된다.
- **36항목 규제 레지스트리** (core/compliance/compliance_registry.py). A-group (구현 완료 18개) 과 GAP-group (식별된 18개 갭, 각 항목이 구체적 Sprint 산출물에 연결됨). 항목 체크는 선언형(module_exists / file_exists / config_key / custom_check)이므로 분기

별 규제 리포트를 현재 코드 상태에서 자동 재생성할 수 있다.

- **승격 게이트** (core/evaluation/promotion_gate.py). FRIA + AI Risk 평가를 ModelCompetition 의 사후 체크로 감싸며, CLAUDE.md §1.10 의 단일 승격 진입점 원칙에 따라 scripts/submit_pipeline.py::decide_promotion 에서 호출된다. UNACCEPTABLE FRIA 등급 또는 ‘high’ 등급 상승은 승격을 차단하고 GateVerdict 가 감사 로그에 기록된다. 게이트는 세 개의 협력 서브시스템으로 구성된다:
 - **차원 점수 제공자** (core/compliance/dimension_scores.py). earliest-wins 복합 체인: ManualScoreProvider(모델 버전 단위 운영자 override), MetricsDerivedScoreProvider(7개 HEURISTIC_RULES 가 메타데이터 경로 → 차원 점수를 identity / one_minus / log10_ratio 변환으로 매핑, [0, 1] 로 클리핑), 그리고 기본 0.5 fallback. 각 룰은 메타데이터 경로, 변환, fallback 발동 여부를 기록하여 감사 가능한 유도 트레일을 남긴다.
 - **MetadataAggregator** (core/compliance/metadata_aggregator.py). 메트릭 기반 제공자에 공급하는 6개 내장 소스: (i) 피처 lineage, (ii) 공정성 아카이브, (iii) 휴먼 리뷰 큐 깊이, (iv) 모델 레지스트리, (v) LLM 설정 슬롯, (vi) 정적 override. 이 중 두 소스(lineage YAML, 공정성 Parquet)는 archive-backed 라 submit_pipeline 프로세스가 새로 시작되어도 메타데이터가 생존한다(빈 런타임 인스턴스에 의존하지 않음). 결과는 TTL 캐시(기본 300초)로 단일 승격 결정 내 반복 조회를 상쇄한다.
 - **감사 + tracker 통합**. GateVerdict.details 는 메타데이터 스냅샷과 차원별 유도 트레일(경로, 원시값, 변환, fallback 사용 여부, 최종 점수)을 함께 싣는다. AuditLogger.log_model 이 이 페이로드를 HMAC 서명 + 해시 체인 레코드에 임베드하며, 동시에 _run_promotion_gate 가 non-skip verdict 를 SageMakerComplianceTracker 에 promotion_gate_verdict artifact 로 기록한다. tracker 실패는 swallow 된다 — 컴플라이언스 추적 장애가 승격 결정을 절대 차단하지 않으며, 누락된 항목은 감사 로그만으로도 탐지 가능하다. 이 best-effort posture 는 tracker 에만 적용된다: 감사 로그 자체는

AUDIT_FAIL_CLOSED 로 fail-closed 구성이 가능하므로, 두 채널은 의도적으로 서로 반대 방향으로 실패한다.

게이트는 pipeline.yaml 에서 compliance.promotion_gate.enabled: true 로 배포된다. 제공자 체인이 기본 와이어링되었기 때문이다. 이전 릴리스는 모든 차원이 0.5 fallback 으로 수렴하여 보수적 LIMITED 로 collapse 하는 상황을 피하기 위해 비활성 상태로 배포했었다. 환경별로 여전히 비활성화는 가능하되 제공자는 제거하지 않는다.

- **휴먼 리뷰 큐 + LLM 마커** (core/serving/review/human_review_queue.py, core/recommendation/reason/marker_applier.py). AI기본법 §34 인간 감독을 위한 3-tier 검토 큐(5% 사후 샘플 / 100% 필수 에이전트 / 100% 휴먼 fallback). MarkerApplier 는 §31 에서 의무화한 AI 생성 표지를 모든 L2a LLM 생성 추천사유 문자열에 역등적으로 추가한다.
- **동적 item universe 로더** (core/recommendation/universe/dynamic_loader.py). DuckDB 를 통해 Parquet 에서 후보 캠페인 + 상품 집합을 읽으며(로컬 및 s3:// 경로 지원), 설정된 캠페인 상태 집합(approved / running)으로 필터링한다. 취소되거나 미승인된 캠페인에 대한 추천 서빙을 방지한다.
- **감사 아카이브 확장** (core/recommendation/audit_archiver.py). 5-에이전트 아키텍처의 감사 요구사항을 지원하기 위해 5개 컬럼(thinking_trace, hallucination_flags, tools_used, critique_verdict, agent_tier)을 추가하며 v1 Parquet 파일과의 하위 호환성을 유지한다.

모든 확장 모듈은 Sprint 0 foundation 프리미티브(ComplianceRequest, ComplianceEvent, SLATracker)를 공유하므로, ComplianceStore 에 대한 감사 쿼리 하나로 임의의 사용자, 모델 버전, 또는 요청 유형의 전체 규제 이력을 단일 이벤트 스트림에서 재구성할 수 있다.

6.4.2 Phase 2 Hardening Layer (v2)

온프레미스 참조 시스템의 운영 성숙도에 맞추기 위해 9개의 추가 안전장치를 핵심 규제 모듈 위에 적층하였다. 각 항목은 특정한 감독 / 견고성 / 유효 도전(effective challenge) 요구사항을 다룬다.

- **Human-Fallback Layer-4 라우팅** (core/recommendation/fallback_router.py). 기존 3계층 폴

백 라우터(증류 LGBM → 직접 LGBM → 룰 엔진)에 네 번째 계층이 명시적으로 추가되어, 희망 없는 케이스를 조용히 열화시키는 대신 휴먼 리뷰 큐로 라우팅한다. serving.review.tier_3_human_fallback 로 활성화되며 route_all() 의 계층별 카운트로 노출된다.

- **L2a Safety Gate 3-layer** (core/recommendation/reason/l2a_safety_gate.py). 모든 LLM 생성 L2a 출력은 이제 세 개의 독립적 검사를 통과한다: (1) 구조적 파싱(길이, 문장 수), (2) 룰 기반 스크리닝(금지 구문, 정규식, 한국 주민등록번호 + 카드 PII 패턴), (3) 선택적 LLM 품질 점수. 어느 한 계층의 거부권도 L1 템플릿 출력으로 폴백을 강제하며, SafetyVerdict 가 어느 계층에서 실패했는지를 사후 분석용으로 기록한다.
- **금소법 §17 suitability filter** (core/recommendation/constraint_engine.py::SuitabilityFilter). 제약 엔진 필터로 등록되어 기존의 fatigue / eligibility / owned-product 필터와 조합된다. risk_tolerance ≥ risk_level 을 강제하며, 고령 고객(≥ 65세, max risk 2) 과 저소득 고객(연 < 3천만원, max risk 3) 에 대한 hard cap 을 추가로 적용한다.
- **Counterfactual Champion-Challenger** (core/evaluation/counterfactual_cc.py). paired-bootstrap 신뢰구간을 갖는 off-policy IPS 와 SNIPS 추정기. EU AI Act 제15조(정확성) 와 SR 11-7 effective challenge 를 지원하며, 로그된 관찰 데이터상에서 챌린저가 챔피언보다 나은 결과를 냈을 것이라는 증거를 제공한다.
- **auto-promote=False 강제** (core/evaluation/model_competition.py). 코드 수준 CompetitionConfig default 는 레거시 테스트 픽스처와의 하위 호환성을 위해 True 로 보존되며, 프로덕션 posture 는 pipeline.yaml::serving.competition.auto_promote: false 로 강제되어 런타임에 우선한다. 이 posture 에서는 모든 메트릭 임계값을 통과한 챌린저도 승격되지 않는다: 운영자가 --force-promote 로 재실행해야 하며, EU AI Act 제14조(인간 감독) 및 SR 11-7 모델 리스크 관리 요건을 만족하고 감사 로그에 운영자 서명을 명시적으로 남긴다. 코드 default 를 뒤집는 것은 CompetitionConfig() 만으로 테스트하는 단위 테스트를 유지하기 위해 의도적으로 피한다.
- **Annex IV 기술문서 매퍼** (core/compliance/annex_iv_mapper.py). 12개 Annex IV 섹션 각각에 대해

증거 소스(Python 모듈, 문서, config 키) 목록을 resolve 하고 전체 / 부분 / 누락 증거 상태를 보고하는 전용 매파. coverage rate 가 자동 추적되므로 매 적합성 평가 전에 기술 파일을 재생성할 수 있다.

- **공정성 메트릭 아카이브 및 PromotionGate wiring** (core/monitoring/fairness_monitor.py, containers/lambda/fairness_evaluation.py). 모니터는 모든 측정값을 in-memory 히스토리에 추가하며, monitoring.fairness.archive_parquet_path 가 설정되면 거버넌스 리포터가 직접 쿼리할 수 있는 S3 Parquet 파일에도 추가한다. get_archive(attribute, limit) 가 재계산 없이 drill-down 대시보드를 지원한다. 결정적으로, fairness Lambda 가 매 평가마다 monitor.archive_metrics() 를 호출하도록 연결되어, 아카이브가 실제로 시간에 걸쳐 채워진다. 이는 이전의 gap — MetadataAggregator.fairness_archive_parquet_path 가 기록자 없는 아카이브를 가리켜 PromotionGate fairness_risk 차원이 heuristic 0.5 fallback 으로 silent collapse 하고 gate 가 챌린저와 무관하게 보수적 LIMITED 판정으로 수렴하던 문제 — 를 해소한다. 기록자가 wire 된 현재, MetadataAggregator 는 실제 공정성 증거를 읽고 gate 판정은 챌린저의 실제 거동을 반영한다.
- **드리프트 영속화 + markdown 리포트** (core/monitoring/drift_detector.py). 각 detect_drift() 호출이 선택적으로 피처당 한 행을 Parquet 아카이브에 기록하여 PSI 점수, 심각도 라벨, 평가 시점의 임계값을 보존한다. 동반 메서드 generate_markdown_report() 는 주간 거버넌스 번들에 적합한 인간 가독 요약을 생성한다. 아카이브 기록기는 S3 인식이며(전용 parquet_io helper 가 로컬과 s3:// 경로를 모두 처리), 드리프트 → 자동 재학습 체인은 2-D ndarray 가 PSI 체크에 전달되면 swallow 되는 TypeError 가 발생해 재학습 트리거가 영구히 False 로 남던 버그를 수정한 뒤 end-to-end 로 재검증되었다.
- **Lineage 카탈로그 확장** (core/monitoring/lineage_tracker.py). Lineage 추적기가 런타임 등록(register_feature_mapping), YAML 정의 카탈로그 로드(load_mapping_from_yaml), 커버리지 리포트(coverage_report — 현재 피처 집합 중 소스 테이블 매핑을 가진 비율) 를 지원한다. 피처 개수가 증가할 때 AI기본법 §34(학습 데이터 출처) 요구사항을 충족하기 위해 필요하다.

test_phase2_should.py 스위트(36 tests, all passing) 가 9개 모듈을 모두 실행하며, pipeline.yaml 이 auto_promote: false 를 강제하는지 확인한다.

6.4.3 Learning-Stack & Interpretation Layer (v2)

4개의 추가 모듈이 hardening layer 를 학습 스택(피처 선택, evidential head, temporal ensemble) 및 추천사유 생성 컨텍스트로 확장하여, 실데이터 안전성과 다학제 해석에 관한 Paper 2 v2 의 잔여 근거 갭을 닫는다.

- **IG 3-stage 피처 선택** (core/training/feature_selector.py::select). 최종 select() 호출은 이제 Stage 1 (IG 누적 중요도), Stage 2 (LGBM-gain pruning), Stage 3 (필수 피처 보장 — Stage 1-2 가 드롭했더라도 도메인 필수 피처는 selection 에 복원) 을 실행한다. Stage 3 는 현재 피처 스키마에 존재하지 않는 필수 피처에 대해 경고를 로그하며, 복원된 피처를 FeatureSelectionResult.mandatory_included 에 기록한다.
- **Evidential valid_mask 결측 데이터 가드** (core/model/layers/evidential.py). Evidential head 는 이제 명시적 valid_mask: Tensor[B] 를 받으며, 부재 시 torch.isfinite 를 통해 non-finite 행을 자동 탐지한다. 유효하지 않은 행은 task-type 별 중립 예측값(binary 0.5, multiclass 1/K, regression 0.0) 과 canonical max-uncertainty 값을 받는다. NaN / Inf gradient 는 nan_to_num 으로 scrub 한 복사본에서 linear layer 를 실행하여 방지한다. 유효 마스크는 evidence-info dict 로 반환되어 downstream loss 가 유효하지 않은 행을 제외할 수 있다.
- **HMM-smoothed ensemble 게이팅** (core/model/experts/temporal.py::set_hmm_routing). TemporalEnsembleExpert 는 런타임 set_hmm_routing(enabled, smoothing, transition_prior) 메서드와 이에 상응하는 hmm_routing config 블록을 노출한다. 활성화 시 학습된 게이트가 생성한 게이팅 가중치에 row-stochastic 전이 행렬을 post-multiply 하고 재정규화하여, 1-step HMM forward smoothing 으로 작동해 게이팅 결정의 per-sample variance 를 감소시킨다. 전이 행렬은 non-persistent buffer 로 보유되어 .to(device) 에는 따라가지만 학습되지 않는다.

- **다학제 interpreter hook** (core/recommendation/reason/context_assembler.py). ContextAssembler 가 선택적 multidisciplinary_interpreter 인자를 받는다 — interpret(context_dict) -> dict 메서드를 가진 객체이거나 동일 시그니처의 plain callable. 각 assemble() 호출이 interpreter 를 호출하고 출력을 AssembledContext.multidisciplinary_insights 에 부착한다. 실패는 swallow 되어 버그가 있는 interpreter 가 추천사유 생성을 깨트리지 못한다; 부착된 interpreter 는 attach_interpreter(...) 로 런타임 교체 가능하다.

4개 모듈 모두 하위 호환이다: 신규 인자를 넘기지 않는 레거시 호출자는 v2 이전 동작을 그대로 보존한다. tests/test_phase2_remaining.py (23 tests, all passing) 가 각 안전장치를 레거시 / 확장 코드 경로 모두로 실행한다.

6.4.4 SageMaker-Native 규제 추적 (v2)

온프레미스 참조 시스템은 실험 추적에 MLflow 를, 데이터셋 버전 관리에 DVC 를 사용하며, 이는 de-facto 오픈소스 조합이다. AWS 는 MLflow + DVC 가 담당하던 모든 역할에 대해 관리형 동등물을 제공하므로, 오픈소스 스택을 클라우드 로 이식하는 대신 네이티브 서비스를 규제 인식(regulation-aware) 추적기 뒤에 래핑한다:

- **MLflow tracking → SageMaker Experiments** (Trials / TrialComponents)
- **MLflow model registry → SageMaker Model Registry** (이미 core/serving/model_registry.py 에서 처리)
- **MLflow lineage → SageMaker Lineage** + 피쳐-테이블 DataLineageTracker
- **DVC 데이터셋 버전 관리 → S3 versioning** (추적기가 버킷을 가리키도록 하는 artifact_s3_prefix config 키 포함)
- **Managed MLflow (2024) → SageMaker Managed MLflow** (compliance.tracking 의 backend 를 sagemaker 로 전환하면 자동 picked up)

core/compliance/sagemaker_compliance_tracker.py 가 이 래퍼를 구현한다:

- **Backend 추상화**(ComplianceTrackerBackend) 에 두 개의 구체 구현: 테스트 및 로컬 개발용 InMemoryTrackerBackend, 프로덕션용 SageMakerTrackerBackend. 둘 다 동일한

put_artifact / list_artifacts 표면을 노출하므로 호출자는 backend-agnostic 이다.

- 5개 artifact 유형이 Sprint 0 4 규제 표면을 커버한다: fria_assessment, ai_risk_assessment, compliance_registry_sweep, promotion_gate_verdict, custom. 각 유형은 도메인 데이터클래스에서 관련 파라미터와 메트릭을 추출하고 artifact-type + grade / risk-category 태그를 부착하는 전용 log_* helper 로 매핑되므로, SageMaker 콘솔(및 Athena export) 에서 규제 관심사별 필터링이 가능하다.
- TrialComponent 이름은 SageMaker 의 120자 제한으로 cap 된다; 실패한 boto3 호출은 로그되고 best-effort 로 처리되어 추적 장애가 규제 결정을 절대 차단하지 않는다.
- **Backend**
는 pipeline.yaml::compliance.tracking.backend 로 선택되며, 현재 배포 기본값은 sagemaker 이다 (프로덕션 IAM 도달성 사전 검증: list_experiments 성공 및 미생성 experiment 이름에 대한 describe_experiment 가 access-denied 가 아닌 ResourceNotFound 를 반환하여 training-job 역할이 필요 Experiments 권한을 보유함을 확인). in_memory backend 는 hermetic 이 필요한 단위 테스트와 로컬 개발용으로 유지되며 플래그를 override 할 때만 사용된다.

tests/test_sagemaker_compliance_tracker.py (24 tests) 가 양쪽 backend 를 합성 boto3 클라이언트 stub 으로 실행하여 각 create_experiment / create_trial_component / list_trial_components 호출의 정확한 요청 형태(필수 필드, artifact-type 태그 존재, risk-category 태그 존재, 120자 이름 cap, Completed 상태 등) 를 실제 AWS 호출 없이 단언한다.

이는 MLflow / DVC 스택에 의존하지 않고 **규제 artifact 버전 관리** 에 관한 Paper 2 v2 근거 갭을 닫으며, docs/pipeline_comparison_matrix.md 에 문서화된 "온프레임의 클라우드 확장, 별개 시스템이 아님" 포지셔닝에 AWS 배포를 정렬시킨다.

6.4.5 DuckDB-over-Parquet 규제 SQL (v2)

온프레미스 참조 시스템은 Parquet 감사 아카이브에 대한 SQL 엔진으로 DuckDB 를 사용한다; AWS 의 유료 동등물(Athena, Redshift Spectrum, S3 Select) 은 관찰된 쿼리 볼륨이 정당화하지 못하는 인프라 비용

과 운영 오버헤드를 발생시킨다. 대신 `core/compliance/audit_sql.py::ComplianceSQLHelper` 가 DuckDB 의 `https` 확장을 래핑하여, 온프레임 배포가 이미 사용 중인 동일한 SQL 로 `s3://` 감사 아카이브를 쿼리할 수 있게 한다 — 추가 인프라 비용 0.

- `register_view(name, parquet_uri)` 가 Parquet glob / 디렉토리 / `s3://` URI 를 명명된 DuckDB view 로 부착한다. View 는 재생성 가능하므로 동일 prefix 에 append 되는 새 배치는 on-demand 로 picked up 된다.
- `query(sql, params)` 가 파라미터화된 SQL 을 실행하고 row dict 를 반환한다.
- 규제기관 지향 편의 메서드 4개 — `recent_opt_outs`, `consent_changes_for_user`, `sla_breaches`, `promotion_gate_history` — 가 설정된 30일 윈도우를 기본값으로 하는 since 인자를 받으며, 전형적 분기별 감사 요청 형태를 커버한다.
- `counts_by_column(view, column)` 이 대시보드용 {value: count} 요약을 생성한다.
- `pipeline.yaml::compliance.audit_sql.paths` 가 생성 시점에 view 를 자동 등록하므로 helper 는 한 줄로 사용 가능하다.

View 는 `s3://` 와 로컬 경로의 임의 조합에 대해 등록되므로, InMemoryComplianceStore 기반 테스트 fixture 와 프로덕션 S3ParquetComplianceStore export 에 대해 동일한 SQL 을 실행하는 감사자는 동일한 결과를 얻는다. `tests/test_compliance_sql.py` (22 cases) 가 config 표면, view 생명주기, 파라미터화된 쿼리, 각 편의 메서드, 그리고 opt_out 과 consent view 간 cross-view JOIN 을 검증하여 추가 인프라 없이 다중 테이블 분석 쿼리가 작동함을 확인한다.

`docs/pipeline_comparison_matrix.md` 가 검토된 다른 유료 대안들과 함께 설계 선택의 근거를 기록한다.

6.4.6 Pearl 사다리 완성 & LLM Hardening (v2)

Paper 2 v1 은 Pearl 의 인과 사다리를 두 rung 에서 커버한다고 주장했다 — Rung 1(관찰) 은 Causal Explainability Head 로, Rung 3(반사실) 은 CCP + Counterfactual Champion-Challenger 로. v2 는 uplift-learner 모듈로 Rung 2(개입) 갭을 채우고, 기존 PromptSanitizer 를 보완하는 두 번째 LLM hardening 계층을 추가한다.

Rung 2 uplift learners (`core/evaluation/uplift_learner.py`). T-Learner 와 X-Learner 구현 모두 numpy-only fallback 회귀기 및 logistic propensity 추정기와 함께 배포된다. T-Learner 는 처치군과 대조군에 대해 독립 outcome 모델을 적합시키고 $\tau(x) = \mu_1(x) - \mu_0(x)$ 를 반환한다; X-Learner 는 imputed residual 을 propensity 로 재가중하는 cross-fit 단계를 추가하여 처치군 불균형 하에서 더 안정적인 CATE 를 산출한다. 평가는 Qini coefficient(Qini curve 아래 면적을 perfect-targeting ideal 로 정규화) 와 top-K-percent uplift 지표(예측 상위 분위 내 평균 관찰 효과) 를 사용한다. 두 learner 모두 `fit(X, T, Y) / predict(X)` 인터페이스를 노출하므로 stage-1 모델로 임의의 sklearn 또는 LightGBM 회귀기를 평가 파이프라인 변경 없이 swap in 할 수 있다. numpy-only 구현은 오프라인 평가, 단위 테스트, CI 모두 무거운 의존성 없이 실행됨을 의미한다.

규제 포지셔닝. Rung 2 는 추천기가 추정된 이질적 효과에 근거하여 개별 고객을 treating / not-treating 하는 것을 정당화할 수 있는 층위이며, AI기본법 §35(FRIA) 와 PIPA §37 의2(자동화된 결정 권리) 가 모두 정밀 검토하는 영역이다. Uplift 추정기 출력은 게이트 활성화 시 SageMaker 규제 추적기를 통해 규제 artifact 로 감사 로그되므로, 특정 세그먼트를 타겟팅한 선택의 근거는 재현 가능하다.

LLM hardening — AI security checker (`core/security/ai_security_checker.py`). 기존 PromptSanitizer 는 민감도 분류, PII scrubbing, VPC 라우팅을 담당한다; security checker 는 두 개의 보완 계층을 추가한다. 요청 측에서는 14개 기본 prompt-injection / jailbreak 패턴(ignore previous instructions, DAN mode, reveal system prompt, tool-call breakout, base64 인코딩 페이로드) 이 LLM 공급자에게 프롬프트가 전송되기 전에 스캔된다. 응답 측에서는 8개 output-leak 패턴 이 system-prompt echo, meta-instruction 누출, role-breakout 구문, 한국 주민등록번호 / 카드번호 PII 를 잡아낸다. Finding 은 finding 별 심각도를 가진 SecurityVerdict 를 반환한다; wrap_provider 는 임의의 LLM 공급자에 대한 drop-in replacement 를 생성하여 차단된 교환을 안전한 거부(configurable callback) 로 재작성한다.

Sprint 2 의 L2a Safety Gate(`core/recommendation/reason/l2a_safety_gate.py`) 와 결합하여, LLM 경로는 이제 네 개의 독립적 hardening 계층을 갖는다 — 민감도 기

반 라우팅, 룰 기반 safety gate, AI security checker (prompt + output), LLM 생성 마커 — 각 계층이 독립적으로 거부권을 행사할 수 있고 각 계층이 config-driven 이라 보안 운영팀이 코드 변경 없이 룰 카탈로그를 확장할 수 있다.

tests/test_phase3_could.py (39 cases) 가 T-Learner / X-Learner CATE 복원, 합성 uplift 데이터에 서의 qini 및 top-K-percent uplift 지표, 모든 기본 보안 패턴, provider-wrapping end-to-end 흐름, 커스텀 거부 callback 주입을 커버한다. Phase 1 및 Phase 2 스위트에 PromotionGate MetadataAggregator live-wiring 테스트와 정규화 이후 feature-group-range 재구축 회귀 스위트까지 합쳐, AWS 측 규제 / 학습 / 보안 스택은 785 tests (785 passing) 로 실행된다.

6.4.7 Human-in-the-Loop

규제기관(한국 금감원, EU AI Act 제14조)은 인간 감독을 요구한다. 본 시스템은 다중 수준에서 이를 구현한다:

- **추천사유 표본 검토:** 생성된 추천사유의 주기적 인간 검토.
- **모델 교체 승인:** 오프라인 Champion-Challenger 게이트가 승격 판정을 산출하며, 배포 기본값인 auto_promote: false posture 에서는 명시적 운영자 서명(--force-promote)이 추가로 요구된다 — 통계적 유의성만으로 프로덕션에 도달하는 모델은 없다. 모든 판정은 HMAC 서명 + 해시 체인 감사 로그에 기록된다.
- **인시던트 에스컬레이션:** 자동화된 이상 탐지가 인간 조사를 트리거.
- **공정성 검토:** 공정성 지표에 대한 주기적 인간 감사.

매핑 표에서 언급된 킬 스위치는 fail-closed 의미론으로 구현된다: 서빙이 전용 DynamoDB 테이블(ple-kill-switch, laC 로 프로비저닝)을 조회하며, 읽기 실패는 ACTIVE 로 간주된다 — 스위치 상태를 확인할 수 없으면 허용을 가정한 대신 통제 대상 경로를 멈춘다. 온프레미스 대응물은 opt-in 주입으로 가동 가능하며, 기본 비활성이고 next-best-action 추천에 한정된다.

6.4.8 모니터링 구현 세부사항

모니터링 계층은 거버넌스 파이프라인에 데이터를 공급하는 세 가지 전용 모듈로 구성된다:

- **DriftDetector:** 연속된 증류 실행 간 피처별 PSI(Population Stability Index)를 계산한다. 피처 수준 PSI는 기존 예측 수준 드리프트 신호를 보완하여, 모델 성능 저하 전에 입력 분포 변화를 조기에 탐지한다.

- **FairnessMonitor:** 배치 서빙 예측에서 보호 속성(연령대, 성별, 소득 분위, 지역 유형, 생애주기)별 인구통계학적 편향을 평가한다. 태스크별 불균등 영향(DI), 통계적 동등성 차이(SPD), 균등화 오즈 차이(EOD)를 출력하여, EU AI Act 제10조 제2항 f호에서 요구하는 세그먼트별 감사 추적을 제공한다.

- **GovernanceReportGenerator:** 증류 사이클별 드리프트 현황, 공정성 결과, 감사 추적 무결성, 체크리스트 준수를 통합한 거버넌스 보고서를 생성한다. 보고서는 HMAC 서명과 함께 S3에 저장되어 규제 제출용 문서 코퍼스를 형성한다.

AuditLogger는 학습 및 증류 이벤트의 시작과 완료를 구조화된 로그 항목으로 기록하여, 배포된 모든 모델 버전을 해당 학습 실행 및 입력 데이터 스냅샷과 연결하는 출처 체인을 생성한다.

6.5 고위험 AI를 위한 파이프라인 감사 가능성

앞선 절들은 개별 시스템 구성요소를 규제 조항에 매핑하였다. 그러나 EU AI Act의 고위험 AI 요구사항(Title III, Chapter 2)은 서빙 계층만이 아닌 전체 ML 파이프라인의 감사 가능성을 요구한다. 본 절에서는 동반 논문에서 기술된 학습 인프라가 이러한 요구사항을 엔드투엔드로 충족함을 보인다.

6.5.1 데이터 거버넌스 (제10조)

제10조는 학습 데이터가 “관련성 있고, 대표성 있으며, 오류가 없고 완전”할 것과 적절한 데이터 거버넌스 조치를 요구한다. 본 시스템의 Phase 0 파이프라인(전처리 → 피처 생성 → 레이블 파생 → 정규화 → 텐서 저장)은 매 실행 시 두 가지 감사 산출물을 생성한다: 피처 통계 파일은 컬럼별 NaN 비율, 제로 분산 플래그, 분포 통계, 생성된 피처 수를 기록하고; 레이블 통계 파일은 13개 전체 태스크의 클래스 균형과 양성 비율을 기록한다. 이 산출물은 외부 감사인이 코드를 실행하지 않고도 검사할 수 있는 검증 가능한 데이터 품질 기록을 구성한다.

재현 가능성은 config 기반 처리를 통해 보장된다: 전체 파이프라인이 3개의 YAML 설정 파일 분할 구성(파이프라인 설정, 피처 그룹 설정, 데이터셋별 태스크/레이블 설정)으로 제어되므로, 동일한 config는 동일한 입력 데이터에서 동일한 출력을 생성한다. 실행 가능한 코드에 데이터셋 특화 로직이 존재하지 않는다.

학습 전 게이트로서 리키지 검증기는 (1) 스케일러가 학습 데이터에서만 fit되었는지, (2) train/validation/test 분할 간 시간적 갭이 존재하는지, (3) 마지막 시퀀스 타임스텝이 레이블

윈도우와 겹치지 않는지를 검증한다. 어떤 검증이라도 실패하면 학습이 차단되어 — 데이터 거버넌스 위반이 컴퓨팅 자원이 소비되기 전에 포착됨을 보장한다.

6.5.2 기술 문서화 (제11조)

제11조는 규제 준수를 평가하기에 충분한 기술 문서를 의무화한다. 본 시스템은 config-as-documentation을 통해 이를 달성한다: 3개의 YAML 설정 파일이 피쳐 그룹, 생성기 파라미터, 정규화 단계, 태스크 정의, 손실 가중치, 전문가 라우팅을 완전히 명시한다. 모든 학습 실행과 함께 config 스냅샷이 저장되며, 학습 평가 메트릭 파일이 전체 학습 출처 정보 (하이퍼파라미터, 데이터 분할, 최종 메트릭, 타임스탬프)를 기록한다. 고정된 랜덤 시드와 결합하여, 과거의 모든 실험은 아카이브된 config로부터 정확히 재현 가능하다.

6.5.3 로깅 및 추적 가능성 (제12조)

제12조는 위험 식별과 중대한 변경 사항에 대한 이벤트의 자동 기록을 요구한다. 학습 루프는 태스크별 손실 분해가 포함된 에포크별 로그를 생성하여, 감사인이 성능 변화가 정확히 언제 어디서 발생했는지 추적할 수 있다. NaN/Inf 탐지는 일반적인 학습 실패를 보고하는 대신 어떤 태스크에서 이상 그라디언트가 발생했는지를 식별한다. 그라디언트 노름 모니터링은 노름이 클리핑 임계값의 10배를 초과할 때 경고를 발생시켜 학습 안정성에 대한 감사 추적을 제공한다. 체크포인트는 대응하는 평가 메트릭과 함께 버전 관리되어, 데이터에서 배포 모델까지의 완전한 계보를 생성한다.

6.5.4 인간 감독 (제14조)

위에서 기술한 Human-in-the-Loop 메커니즘 외에도, 본 시스템은 인간 검토자를 위한 두 가지 추가 투명성 계층을 제공한다.

- 증류 후 LGBM 학생 모델은 태스크별 gain 기반 피쳐 중요도 순위를 노출하여 — 규제 준수 담당자가 딥러닝 전문지식 없이도 검토할 수 있는 인간 감독 감사를 제공한다.
- PLE 교사 모델의 CGC 게이트 가중치는 각 전문가의 모든 예측에 대한 기여를 정량화하여, 전문가 라우팅 메커니즘을 블랙박스 양상블이 아닌 투명한 구조로 만든다.

3-에이전트 LLM 파이프라인(4절)은 나아가 이러한 기술적 기여도를 규제 준수 담당자가 직접 평가할 수 있는 자연어 설명으로 변환한다.

6.5.5 정확성 및 견고성 (제15조)

제15조는 고위험 AI 시스템이 “적절한 수준의 정확성, 견고성, 사이버보안”을 달성할 것을 요구한다. 동반 논문의 어블레이

션 연구는 우아한 성능 저하를 입증한다: 어떤 단일 전문가를 제거하더라도 성능이 점진적으로 감소하며 치명적 실패를 유발하지 않아, 단일 구성요소가 핵심 장애점이 아님을 증명한다. 불확실성 가중치(Uncertainty weighting) [11]는 단일 태스크가 다중 태스크 목적 함수를 지배하는 것을 방지하여, 13개 전체 태스크에서 동시에 견고한 성능을 보장한다. 드리프트 모니터링(PSI 기반)은 배포 시 지속적인 견고성 검증을 제공하도록 설계되었다.

6.5.6 편향 모니터링 (제10조 2항 f호)

제10조 2항 f호는 건강, 안전, 기본권에 영향을 미칠 수 있는 편향에 대한 학습 데이터 검토를 요구한다. 학습 전 레이블 분포 검증(레이블 통계 파일을 통해)은 클래스 불균형이 문서화되고 처리됨을 보장한다. 학습 평가 메트릭의 태스크별 분해는 세그먼트별 성능 모니터링을 가능하게 한다: 감사인은 모델 정확도가 고객 인구통계 또는 상품 카테고리에 따라 체계적으로 변동하지 않는지 검증할 수 있다. 공정성 모니터 구성요소(불균등 영향, 통계적 동등성 차이, 균등 확률 차이)는 제10조 2항 f호가 요구하는 세분화 수준에서 자동화된 편향 탐지를 제공한다.

6.5.7 모델 리스크 관리 생애주기

본 시스템은 SR 11-7에 부합하는 5단계 MRM 생애주기를 구현한다: 개발(교사 모델 학습 + 학생 증류), 검증(보류 데이터에 대한 독립적 메트릭 평가), 승인(아래 기술하는 2단계 게이트), 모니터링(PSI 기반 연속 드리프트 탐지), 재학습(드리프트 임계값 초과 시 자동 재증류). 승인 단계는 2단계 게이트로 구성된다. **오프라인 게이트**(scripts/submit_pipeline.py::decide_promotion)는 증류 직후 실행되며, 모든 챌린저가 동일한 순서로 평가되고 감사 가능하도록 고정된 순서의 단락 평가(short-circuit) 의사결정 사다리를 적용한다: (1) --force-promote가 설정되어 있으면 챌린저는 운영자 오버라이드로 무조건 승격된다(trigger=manual); (2) 그렇지 않고 레지스트리에 기존 챔피언이 없으면, 챌린저는 부트스트랩 승격되고 비교는 수행되지 않는다; (3) 그렇지 않고 fidelity_summary.failed > 0 이면, 학습 메트릭이 챔피언보다 우수하더라도 안전 floor에 의해 즉시 거부되며 Competition은 생략된다 — 이는 teacher-student fidelity 보증을 유지하기 위함이다; (4) 그렇지 않으면 ModelCompetition.evaluate가 현 챔피언의 기록 메트릭과 비교하여, 주요 메트릭이 min_improvement(기본 0.5%) 이상 개선되고 보조 메트릭이 max_degradation(기본 2%) 이상 악화되지 않아야 하

지표	설명	결과
L1 템플릿 커버리지	템플릿 기반 추천사유 생성 태스크	100% (13/13)
템플릿 변형	고유 템플릿 수 (6개 범주 × 5개 변형)	30
PII 감지 패턴	정규식 기반 PII 검사 규칙	5
적용 규제 규칙	적합성, 동의, 거부권, 프로파일링, 고지	5

Table 11: 자동화된 추천사유 품질 지표. 인간 평가는 운영 배포 시 수행 예정 (Bedrock L2a 배포 이후).

며, 선택적으로 paired bootstrap 유의성 검정을 통과해야 promote, 그렇지 않으면 reject 판정을 반환한다. 모든 판정 — bootstrap, promote, reject, force_promote — 은 AuditLogger.log_model_promotion을 통해 HMAC 서명 + 해시 체인 연결된 S3 WORM 로그에 기록되어, 누가 무엇을 왜 승격/거부했는지 추적 가능한 부인 방지 감사 로그를 생성한다. 온라인 게이트 (ModelMonitor.evaluate_champion_challenger)는 (4) 단계가 챌린저를 승격한 이후 충분한 DynamoDB 예측 기록이 축적된 시점에만 호출되어 two-proportion z-test로 실트래픽 기반 재평가를 수행한다. 뼈대는 구축되어 있으나 아직 스케줄러에 연결되지 않아, 위 오프라인 사다리의 자동 의사결정에 **의도적으로** 포함되지 않으며, 실트래픽 규모가 비교를 정당화하는 시점에만 활성화된다. 드리프트 탐지기가 연속 모니터링 윈도우에서 발동하면 (설정 가능한 임계값, 기본 연속 3일), 재학습 단계가 자동 트리거되어 경쟁 사이클에 재진입하는 새로운 챌린저를 생성한다. 이 폐쇄 루프는 모델 리스크가 이산적 연간 검토 시점이 아닌 연속적으로 관리됨을 보장하여, SR 11-7 기대사항과 EU AI Act 제9조 리스크 관리 요구사항을 모두 충족한다.

7 실험

7.1 종류 실험

이진 태스크의 AUC 격차는 0.018–0.036 (평균 2.6 퍼센트 포인트)이며, 7개 태스크 전체에서 랭킹 상관관계는 0.96 이상이다. 이 수치는 v13 실행 기준이다; 논의 절에서 분석하는 두 가지 종류 교정 이후의 v14 재실행에서는 이진 평균 AUC 격차가 0.58 pp로 감소했으며, fidelity 게이트는 판정을 두 tier (Tier 1 차단 / 운영, Tier 2 정보 / 아키텍처 공유)로 분리해 보고한다. 주요 실패 양상은 보정 격차(0.08–0.10)였으며, 확률값이 중요한 이진 분류 태스크(churn_signal)에는 사후 Platt 스케일링으로 대응하였다. 2개 멀티클래스 태스크(nba_primary, segment_prediction)는 2× 무작위 교차 임계값 미달로 DIRECT(직접 하드 레이블 학습)로 라우팅

되었고, 3번째 태스크인 next_mcc(50-클래스)는 floor 미달로 SKIP(Layer 3 롤엔진)으로 라우팅되었다. 회귀 태스크 중 mcc_diversity_trend($R^2=0.031$)는 MAE 격차 0.025로 직접 학습(DIRECT)을 사용하였으며, product_stability와 cross_sell_count는 near-zero R^2 로 SKIP(Layer 3)으로 라우팅되었다.

7.2 추천사유 생성 품질

7.2.1 자동화된 추천사유 품질 지표

인간 평가는 실제 운영 배포 시 수행할 예정이며, 여기서는 자동화된 규제 준수 검증 결과를 보고한다. 평가는 L1 템플릿 커버리지, 템플릿 변형 다양성, PII 감지, 규제 규칙 적용을 포함한다.

7.2.2 AuditAgent 추천사유 품질 평가

AuditAgent는 L1 템플릿 엔진과 L2a Bedrock 재작성 파이프라인이 생성한 추천사유를 평가하여 4가지 자동화 품질 지표를 보고하였다.

7.2.3 L1 템플릿 추천사유 예시

Table 13는 운영 Lambda(ple-predict)에서 생성된 3개 태스크의 L1 템플릿 추천사유 실측 예시이다. L2a Bedrock 재작성 이전의 TemplateEngine 출력값 그대로이다.

7.2.4 L2a Bedrock 재작성 예시

L2a(Bedrock Sonnet)는 L1 템플릿을 고객 대면 자연어로 재작성한다. top_mcc_shift 태스크의 실측 전후 비교는 다음과 같다:

L1 (템플릿): 소비 패턴의 변화에 맞춘 혜택입니다. 다양한 소비 카테고리를 활용하시는 고객님께 맞춤 소비 혜택을(를) 추천드립니다.

L2a (Bedrock 재작성): 고객님의 다양한 소비 패턴에 맞춰 여러 카테고리에서 실질적인 혜택을 누리실 수 있도록 맞춤 소비 혜택 상품을 추천드립니다.

지표	정의	결과
근거 점수(Grounding)	추천사유 텍스트에서 한국어 키워드 매칭 태스크 비율	0.33 (3개 중 1개 매칭)
가독성(Readability)	유창성 점수 (템플릿 렌더링 오류 없음)	1.00
종합 품질(Overall quality)	$0.4 \times \text{근거} + 0.3 \times \text{가독성} + 0.3 \times \text{규제 준수}$ (모두 [0, 1]로 정규화)	0.74
편향 DI	보호 속성 전체에 대한 Disparate Impact	1.0 (편향 미검출)
국내 규제 준수	검사 규칙 (금소법 적합성, 동의, 거부권, 프로파일링, 고지)	5개 검사, 위반 0건

Table 12: AuditAgent 자동화 추천사유 품질 평가. 근거 점수 0.33은 표본 3개 태스크 중 1개에서만 기여 피처와의 한국어 키워드 매칭이 검증됨을 의미한다. 가독성 1.00은 템플릿 렌더링 실패 없음을 확인한다.

태스크	L1 템플릿 추천사유
top_mcc_shift	소비 패턴의 변화에 맞춘 혜택입니다. 다양한 소비 카테고리를 활용하시는 고객님의 맞춤 소비 혜택을(를) 추천드립니다.
will_acquire_investments	고객님의 재무 목표에 부합할 수 있습니다. 현재 금융 라이프사이클 단계에 적합한 투자 상품입니다.
churn_signal	고객님의 소중한 거래 관계를 유지하고자 합니다. 고객님의 이용 패턴을 분석하여 고객 유지 프로그램을(를) 추천드립니다.

Table 13: 운영 Lambda(ple-predict) L1 템플릿 추천사유 예시. 이 출력이 L2a Bedrock 재작성 파이프라인의 입력이 된다. 1행과 3행의 "(를)" 아티팩트가 L2a가 교정하는 결함의 전형적 예이다.

지표	설명	값
PII 패턴 수	정규식 기반 PII 감지 규칙	5
규제 검증 범주	환각, 규제, 적합성, 어조, 사실성 (Table 4 참조)	5
인간 검토 샘플 비율	L2a 출력 중 인간이 검토하는 비율	5%
L1 폴백 비율	게이트 실패 시 트리거; 임계값 설정 가능	설정 가능

Table 14: Safety Gate 자동화 지표. 정밀도/재현율 평가는 실서비스 배포 후 수행 예정; 검증 범주는 Table 4 에 정의됨.

구성요소	지연시간	비용/1K 요청	비고
L1 예측 + 13 태스크 (웜)	120ms	< \$0.02	Lambda; 실측값
L2a 첫 호출 (Bedrock Sonnet)	2.4s	\$0.01	온디맨드; 이후 캐시
L2a 캐시 적중	6ms	< \$0.001	DynamoDB; 실측값
콜드 스타트	6s	—	S3 모델 다운로드; 분산됨
LanceDB 사례 검색	< 100ms	< \$0.01	콜드스타트 그라운드; 과거 추천 사례

Table 15: 서빙 지연시간 분석 (Lambda 서버리스, GPU 미사용). 웜 Lambda 실측값. LanceDB는 축적된 추천 사례(LGBM 기여 피처 + 생성 사유)를 저장하며, 콜드스타트 고객은 유사 과거 사례를 검색하여 그라운딩에 활용.

L2a 재작성은 템플릿 아티팩트 "(를)"을 제거하고, 두 문장 구조를 단일 문장으로 통합하며, 핵심 근거 표현(소비 패턴, 카테고리, 혜택)을 보존한다. 첫 호출 지연시간은 2.4s(Bedrock Sonnet 온디맨드)이며, 동일한 (태스크, 피처 시그니처) 조합의 후속 호출은 DynamoDB 캐시에서 6ms에 결과를 반환한다.

7.3 Safety Gate 평가

Table 14 은 Safety Gate의 자동화 검증 지표를 보고하며, PII 탐지 커버리지, 규제 검사 범위, 인간 검토 샘플링 비율을

측정한다. 이 지표들은 게이트의 커버리지를 특성화하며; 정밀도/재현율 평가는 실서비스 트래픽 배포 후 수행 예정이다.

7.4 서빙 성능

운영 Lambda에서 서빙되는 13개 태스크 중: 10개 태스크는 Layer 2 LGBM으로 서빙되며 (종류 7개 + 직접 하드 레이블 학습 3개), 3개 태스크(next_mcc, product_stability, cross_sell_count)는 Layer 3 를 엔진으로 서빙된다. DynamoDB 감사 추적은 모든 예측 이벤트를 기록하며: 측정 기준일 현재 ple-prediction-log 테이블에 51건, ple-

audit-distillation 테이블에 18건이 기록되어 있으며, 규제 검사를 위한 서빙 의사결정의 검증 가능한 이력을 제공한다. 전체 교사 학습 및 증류 사이클은 SageMaker Spot 인스턴스에서 실행되며, 교사 학습에는 GPU(ml.g4dn.xlarge), LGBM 증류에는 CPU(ml.m5.4xlarge)를 사용한다; 증류 인스턴스는 13개 태스크 soft-label 작업량이 메모리를 초과하여 ml.m5.2xlarge에서 실행되었으며, 대표적인 spot 실행 1건은 62분, \$0.30에 완료되었다. Spot 가격 정책으로 온디맨드 대비 약 70%의 컴퓨팅 비용이 절감되며, 중단 위험은 자동 체크포인트링과 잡 재개로 관리된다.

7.5 규제 준수 감사

세 가지 차원에서 규제 적합성을 평가한다: 체크리스트 준수, 감사 추적 무결성, 공정성 지표.

체크리스트 준수. 금소법 제17-19조, EU AI Act 제13-14조, 금감원 AI 가이드라인에서 도출한 14개 규제 요건을 구현한다. 주요 항목: 추천 전 적합성 평가(금소법 제17조), AI 생성 콘텐츠 고지(AI기본법 제31조), 인간 감독 메커니즘(EU AI Act 제14조), 거부(opt-out) 기능.

감사 추적 무결성. 모든 추천 사유에 대해 다음을 기록한다: (1) 사유 생성에 사용된 LGBM gain 피쳐 중요도 벡터, (2) Safety Gate의 통과/실패 판정 및 실패 사유, (3) LLM 프롬프트-응답 쌍, (4) 추천을 원본 모델 버전에 연결하는 SHA-256 해시 체인. 감사 로그는 추가 전용(append-only)이며 변조 방지 구조로 저장되어 규제 검사에 적합하다. v1 대비 강화점으로, 해시 체인 검증기(verify_chain)는 이제 각 엔트리의 HMAC 서명을 상수 시간 비교로 재검증한다: 레코드를 고쳐 쓰고 하류 해시 링크를 재계산하는 변조-재연결(tamper-and-relink) 공격도 서명 키 없이는 엔트리별 서명 재검증을 통과하지 못한다.

서명의 신뢰는 키 관리에서 나온다. 그래서 v2 감사 스택은 키 관리를 배포 세부사항이 아닌 감사 설계의 일부로 다룬다. 로거는 prod / staging 환경에서 공개된 기본 키로는 기동을 거부하며 — 생성 시점에 AuditIntegrityError 를 발생시킨다 (core/monitoring/audit_logger.py) — 이는 가장 흔한 HMAC 배포 실패, 즉 공격자가 저장소에서 읽을 수 있는 키로 서명하는 상황을 제거한다. 프로덕션 키는 설정 파일이 아닌 SSM Parameter Store 에서 주입된다(setup_aws.sh 가 프로비저닝). AUDIT_FAIL_CLOSED 가 설정되면 감사 레코드의 S3 쓰기 실패는 swallow 되지 않고 예외로 전파되어, 감사가 조용히 깨진 채 운영되는 상황을 차단한다; 감사 버킷 자체

는 IaC 로 S3 Object Lock COMPLIANCE 모드로 프로비저닝되어 자격을 가진 관리자에게도 추가 전용이다. 온프레미스 참조 시스템도 동일한 posture(기본 키 거부, fail-closed 쓰기 옵션)를 강제하여 두 환경의 대칭을 유지한다.

공정성 지표. 보호 속성(연령대, 성별, 소득 분위, 지역 유형, 생애주기)별로 Disparate Impact(DI), Statistical Parity Difference(SPD), Equal Opportunity Difference(EOD)를 태스크별로 산출한다. 공정성 모니터가 배치 스케줄로 실행되며, 설정된 임계값을 초과하면 알람을 생성한다.

8 논의

8.1 주요 발견 요약

파이프라인 전체 평가에서 세 가지 발견이 도출된다.

발견 1: 트리 기반 증류에서 온도 스케일링이 불필요하다. 표준 Hinton 증류 공식($T = 3-20$)과 달리, 개발 과정에서 $T = 1$ 로 학습한 LGBM 학생이 $T = 5$ 대비 더 낮은 JSD와 보정 격차를 달성하는 것을 관찰하였다 (상세 T 비교는 하이퍼파라미터 선택 과정에서 수행되었으며 실험 절에는 별도 보고하지 않음; 설계 근거는 3.1절에 기술). 이는 Soft GBM 분석 [5]과 일치한다: 트리 모델은 소프트 레이블의 절대값과 순서에서 학습하며, 꼬리 확률의 경사 흐름이 아니다. 신경망 학생의 역전파를 위해 설계된 온도 하이퍼파라미터는 분할 기반 학습자에게 불필요하며 오히려 해롭다.

발견 2: LGBM gain 기반 피쳐 선택이 설명 품질을 보존한다. LGBM gain 기반 피쳐 중요도는 서빙 모델이 실제로 사용하는 피쳐를 반영하여, 추천사유가 실제 의사결정 근거와 일치하도록 보장한다. hmm_lifecycle_prob_growing이나 synth_monthly_spend 같은 피쳐는 gain이 높을 경우 선택되어 LLM 생성 설명을 고정하는 서사적 앵커("성장 단계", "소비 패턴")를 제공한다.

발견 3: Safety Gate는 선택이 아닌 필수이다. LLM 검증 없는 템플릿 기반 폴백은 구조적으로 근거가 있지만 때로 유창성이 떨어지는 사유를 생성한다 (예: Table 13 에 표시된 "(를)" 같은 한국어 조사 아티팩트, 또는 해당 고객에게 실제로 영향력이 없는 피쳐를 인용하는 경우). Safety Gate는 생성된 텍스트를 실제 LGBM gain 피쳐 중요도 벡터와 대조하여 환각 유사 오류를 감소시킨다.

발견 4: 적응형 증류 라우팅은 MRM 안전장치로 기능한다. 교사 임계값 게이트가 6개 태스크의 저품질 증류를 차단하였다: 2개 멀티클래스 태스크(nba_primary 7

클래스, segment_prediction 4클래스)와 1개 회귀 태스크(mcc_diversity_trend)는 DIRECT(직접 하드 레이블 학습)로 라우팅되었고; 1개 멀티클래스 태스크(next_mcc 50클래스)와 2개 회귀 태스크 (product_stability, cross_sell_count)는 floor 미달로 SKIP(Layer 3)으로 라우팅되었다. 이 자동 품질 분류는 SR 11-7 원칙에 부합한다: 모델 출력이 모니터링되고, 성능 저하된 구성요소는 서비스 중단 없이 격리된다. 모니터링 대시보드는 이러한 태스크를 다음 재학습 사이클에서 교사 개선이 필요한 항목으로 표시하여, 증류 품질과 교사 개발 우선순위 사이의 폐쇄 피드백 루프를 형성한다.

8.2 피처의 이중 역할

본 연구의 핵심 통찰: 금융 추천에서 피처는 이중 목적을 수행한다. 예측 기여가 미미한 피처라 할지라도(예: TDA 위상적 피처는 $\Delta AUC = 0.01$ 에 불과할 수 있음) 추천사유 추론에 대체 불가능한 맥락을 제공한다. 내부적으로 TDA 지속성(persistence)은 행동 형태 안정성을 포착하지만 — 고객은 “지속적 호몰로지”나 “베티 수”를 보지 않는다. 대신 피처 해석 레지스트리가 이를 비즈니스 언어로 역매핑하고 (예: “꾸준한 거래 패턴을 유지하고 계십니다”), LLM 에이전트가 이를 자연어 추천사유로 엮는다.

이는 피처 엔지니어링 평가를 재구성한다: 피처의 가치는 예측 기여도만이 아니라 추천사유 생성 파이프라인이 활용할 수 있는 추천 맥락에 대한 기여도이기도 하다. 동반 논문에서 주장했듯이, 무엇을 관측할 것인가가 어떻게 모델링할 것인가보다 중요하다 — 도메인 특화 질문에서 파생된 피처 (“소득이 항상적인가 일시적인가?”, “상품 채택이 전파처럼 확산되는가?”)는 내부 추론 맥락을 풍부하게 하여, 얇은 통계적 요약에 아무리 정교한 아키텍처를 적용하는 것보다 더 섬세한 비즈니스 언어 설명을 가능하게 한다.

8.3 이중 인과 경로: 설계된 것 vs. 발견된 것

본 아키텍처는 태스크 간 인과 관계를 인코딩하기 위한 두 가지 상호 보완적 메커니즘을 제공한다:

로짓 전이는 도메인 전문가가 명시적으로 설계한 알려진 인과 경로를 인코딩한다. 예를 들어, 이탈 신호 → 상품 안정성(이탈하는 고객은 상품 관여도가 감소), 다음 MCC 카테고리 → NBA 추천(소비 패턴이 상품 친화도를 예측) 등이다. 이는 코딩된 도메인 지식 — 실무자가 이미 이해하고 있는 관계를 시스템이 인코딩하는 것이다.

Causal Expert(NOTEARS DAG)는 데이터로부터 알려지지 않은 인과 경로를 발견한다. 피쳐 공간에 대한 방향성 비순환 그래프(DAG)를 학습함으로써, 실무자가 예상하지 못한 관계를 식별할 수 있다 — 예를 들어, 특정 채널 이용 패턴이 해외 결제 증가를 야기하고, 이것이 다시 여행 특화 체크카드에 대한 관심을 예측한다는 것.

이 이중 구조는 구체적인 규제 이점을 갖는다: 규제기관이 “왜 이 고객에게 이 상품을 추천했는가?”라고 질문할 때, 답변은 설계된 경로(로짓 전이: “이탈 위험과 상품 안정성 간의 알려진 관계를 인코딩했습니다”)와 발견된 경로(Causal Expert: “모델이 이 고객의 채널 행동과 투자 관심 사이의 데이터 기반 관계를 식별했습니다”)를 동시에 제시할 수 있다.

더 나아가, Causal Expert가 발견한 DAG는 향후 로짓 전이 설계에 근거를 제공한다 — DAG가 재학습 사이클에 걸쳐 일관되게 $A \rightarrow B$ 경로를 식별하면, 실무자가 다음 모델 버전에서 이를 명시적 로짓 전이로 승격시킬 수 있다. 이는 데이터 기반 발견이 점진적으로 설계된 인과 구조를 풍부하게 만드는 피드백 루프를 형성한다.

참고: 동반 논문의 합성 데이터 어블레이션에서 Causal Expert가 세그먼트 분류 태스크에서 negative transfer를 보였으나, 이는 인과 발견의 근본적 한계가 아닌 DeepFM과의 입력 라우팅 중복(둘 다 전체 피처 벡터를 수신)에 기인한 것으로 분석된다. 진정한 인과 구조가 존재하는 운영 데이터에서의 검증이 필요하다.

8.4 실무 배포 고려사항

- **LLM 선택:** 온프레미스 LLM vs. API(지연시간, 비용, 데이터 상주).
- **추천사유 품질 유지:** 주기적 인간 검토 + 자동화된 품질 점수.
- **규제 업데이트:** 아키텍처가 재설계 없이 새로운 규제 준수 검증 추가를 지원.

8.5 Cross-Architecture Distillation에서의

Fidelity 게이트 의미

v14 SageMaker 증류 재실행 (2026-05-08, m5.4xlarge, 3-layer fallback 활성화) 결과는 v13 phase0 의 낮은 teacher 집계 AUC 에 가려져 있던 fidelity 게이트의 두 가지 잠재 결함을 표면화하였다. 두 결함 모두 수정되었으며, 감사 트레일에서 게이트의 통과/실패 집계를 어떻게 읽어야 하는지를 결정하는 의미 이슈이므로 명시적으로 문서화한다.

결함 1: 게이트가 fallback 라우팅된 task 를 그 fallback 근거 자체로 평가하였다. 3-layer 서빙 fallback (CLAUDE.md §1.8) 은 teacher 의 판별 품질이 viability 임계값 이하이면 task 를 Layer 2 (direct hard-label LGBM) 로, floor 이하이면 Layer 3 (룰 엔진) 으로 라우팅한다. 그러나 기존 구현은 학습된 student 가 있는 모든 task 를 validate_fidelity 에 통과시켰으므로, teacher 가 신뢰 불가하다는 이유로 soft-label 종류에서 의도적으로 라우팅 이탈된 task 가 “student 가 teacher 와 얼마나 닮았는가” 로 점수가 매겨졌다 — 라우팅 자체가 도입하려고 한 바로 그 divergence 가 실패로 잡힌 셈이다. 수정안은 evaluate_teacher_thresholds 가 반환하는 distill_tasks 집합으로 게이트 적용 범위를 좁히고, fallback 라우팅된 task 에 대해 [SKIP-GATE] 로그 라인을 명시적으로 남겨 왜 제외됐는지 가 감사 로그에 기록되도록 한다 (silent omission 방지). 수정 후 fidelity_report.json 에는 새로운 gate_scope 필드 ("distilled_tasks_only" 또는 "all_tasks_with_students") 와 scoped_tasks 리스트가 추가되어, 규제기관이 소스 코드를 보지 않고도 어떤 task 가 어느 control 적용 대상이었는지 검증 가능하다.

결함 2: calibration_gap 이 teacher 와 student 의 calibration 을 혼동하였다. 기존 정의 $|ECE(teacher) - ECE(student)|$ 는 focal-loss 로 학습된 teacher 에 대해 완벽 Platt 스케일링된 student 를 실패로 판정한다: focal 은 calibration 이 아닌 ranking 을 최적화하므로 클래스 불균형 binary task 에서 teacher 의 ECE 는 구조적으로 높고 (예: 0.25), 이에 대해 student 의 ECE 가 0 에 가까워도 gap 은 0.25 로 평가되어 감사 임계값 0.05 를 크게 초과한다. 그러나 운영 관점의 핵심 질문은 “student 의 확률값이 결정 임계값에서 신뢰 가능한가” — 즉, ground truth 에 대한 student 자신의 ECE 다. 수정안은 _compute_calibration_gap 이 student ECE 만 반환하도록 재정의했으며, teacher 의 예측은 더 이상 참조하지 않는다. 동일한 0.05 임계값이 이제 teacher 결함이 배제한 유사도 요구가 아니라 프로덕션 스코어에 대한 절대 calibration 품질 요구로 해석된다.

잔여 신호: agreement 와 ranking-correlation 은 student 결함이 아닌 architecture 의 본질적 특성이다. 두 수정안 모두 적용 후에도 v14 binary 종류 집합은 min_agreement $\approx 0.75-0.82$ 와 min_ranking_corr $\approx 0.87-0.91$ 을 보고하며, 임계값 0.85 와 0.90 을 일부 하회한다. 이 지표들은 teacher 와 student 의 국소 결정 매칭 (top-1 argmax 일

치, score 의 스피어만 상관) 을 측정하며, 이들의 본질적 하한은 teacher-student architecture 쌍에 좌우된다. 동종 architecture 종류 (예: BERT $\rightarrow$ BERT, GPT $\rightarrow$ GPT) 는 student 가 teacher 의 귀납 편향을 그대로 상속받으므로 agreement > 0.92 가 일상적이다. 그러나 본 연구의 heterogeneous expert PLE $\rightarrow$ LGBM 은 cross-architecture 쌍이다: smooth multi-layer mixture-of-experts teacher 와 axis-aligned step 함수로 결정 경계를 표현하는 tree-ensemble student. Student 는 teacher 의 전역 ranking 을 일치시킬 수 있으나 (평균 AUC gap 0.0058 은 abstract 의 < 3.6 pp 주장 이내), 개별 point estimate 에서는 LGBM 이 매끄러운 결정 표면을 interpolate 할 수 없어 불일치가 발생한다.

결함 3: 단일 티어 게이트는 운영 결함과 architecture floor 를 동일하게 취급한다. Fix 1 + 2 적용 후 v14 v4 실행은 여전히 Tier 1 통과율 $\frac{0}{7}$ 을 보고했는데, 이는 student 가 운영 부적합이라서가 아니라 네 조건 (AUC gap, calibration ECE, agreement, ranking correlation) 이 모두 동시에 임계값을 통과해야 했기 때문이다. 운영상 핵심 신호 (AUC gap, student ECE) 는 7 개 task 모두에서 깔끔하게 통과했고, architecture 본질 지표 (agreement, ranking corr) 만 통과 못 했다. 항상 실패하는 게이트는 operator 가 skip_fidelity_gate=true 로 override 할 수밖에 없게 만들고 audit control 을 사실상 무력화한다 — 임계값 완화를 거절했을 때와 같은 결과로 귀결되는 셈이다. 해결은 두 control 중 하나를 완화 하는 것이 아니라 판정을 분리 하는 것이다. 이제 게이트는 메트릭의 측정 의도에 따라 두 티어로 publish 한다:

- **Tier 1 (blocking, 운영).** 프로덕션 스코어러의 작동 여부를 결정하는 지표: auc_gap 과 student ECE (binary), f_1 -macro gap (multiclass), MAE / RMSE gap (regression). 여기서의 실패는 배포 차단.
- **Tier 2 (informational, 진단).** Teacher-student 행동 유사도를 측정하는 지표: top-1 agreement, ranking correlation, Jensen-Shannon divergence (binary + multiclass), quartile agreement (regression). 위반은 fidelity_report.json 의 informational_failures 에 기록되고 tier2_violation_count 로 집계되지만, report 의 status 나 게이트의 pass/fail 집계에 영향을 주지 않는다.

이 분리 하에 v14 v4 실행의 증류 task 7 개는 Tier 1 = $\frac{6}{7}$ 통과, Tier 2 = $\frac{7}{7}$ 위반 (architecture floor) 으로 보고된다. Tier 1 의 잔여 실패 1 건은 cross_sell_count 의 rmse_gap 이며, 그 의미는 동반 손실 동역학 논문 (Paper 3) 의 Finding 14 에서 분석된다. 이 분리로 운영 판정이 명확해지고 cross-architecture 신호도 모니터링용으로 보존된다. 감사 로그를 보는 규제기관은 “이 student 가 망가졌나?” (Tier 1, 오늘의 답: 7 개 중 6 개는 아니오, 잔여 1 건은 cross_sell_count 회귀 gap) 와 “이 student 가 teacher 와 얼마나 비슷한가?” (Tier 2, 오늘의 답: PLE → LGBM 쌍의 예상 범위) 를 분리해서 판단할 수 있다. 향후 cross-architecture 실행은 자체 Tier 2 궤적을 보고하며, agreement 가 갑자기 0.5 이하로 무너지는 등의 사례는 tier2_violation_count 추세를 통해 여전히 이상치로 감지된다 — 차단 권한은 없지만 모니터링 권한은 유지. **Cross-architecture** 실행 전용으로 (Tier 2 의 **역사적 floor 대비 delta**) 별도 감사 지표를 도입하는 것은 자연스러운 후속 과제이나 본 연구에서는 채택하지 않는다.

8.6 한계

- LLM 의존성이 비용, 지연시간, 잔여 환각 위험을 발생시킨다.
- 인간 평가 규모가 전문가 가용성에 제한된다.
- 한국/EU 규제에 초점; 기타 관할권은 아직 분석되지 않았다.
- 템플릿 폴백 품질은 본질적으로 제한적이다.

8.7 향후 연구

- 추천사유 품질 → 전환율에 대한 실제 고객 A/B 테스트.
- 다국어 추천사유 생성(한국어, 영어, 중국어).
- 자동화된 규제 업데이트 파이프라인(규제 변경 → 규제 준수 검증 업데이트).
- 범용 API를 대체할 도메인 특화 미세조정 소형 LLM.

8.8 윤리 및 데이터 성명

본 버전의 모든 실험은 **합성 벤치마크 데이터**(Gaussian Copula + 잠재 변수 분산 예산, 고정 시드로 생성된 1M 고객)를 사용한다. 실제 고객 데이터는 포함되지 않았다. 실제 데이터 검증은 후속 개정판에서 계획되어 있다. 프로덕션 시스템 설계는 저위험 체크카드 상품만을 대상으로 하며, 투자 및 보험 상품 추천은 배포 범위에서 명시적으로 제외된다 (Section 6.3.1). 본 시스템은 한국 금감원 AI 가이드라인, EU AI Act, 한국 AI 기본법 준수를 염두에 두고 설계되었으며, 5개 보호 속성에 걸친 자동 공정성 모니터링을 포함한다.

9 결론

본 연구에서는 금융 상품 추천에서 모델 예측과 인간 설득 사이의 간극을 잇는 전체 체인 시스템을 제시하였다.

네 가지 핵심 기여가 본 연구를 정의한다.

- 적응적 3방향 임계값 게이팅(DISTILL/DIRECT/SKIP)과 3계층 폴백을 갖춘 지식 증류는 복잡한 PLE 교사 모델을 경량 LGBM 학생 모델로 압축할 때 서비스 연속성을 보장하며, LGBM gain 기반 피쳐 중요도가 설명 재료가 직접 활용된다.
- 3-에이전트 추천사유 생성 파이프라인(Feature Selector → Reason Generator → Safety Gate)은 비즈니스 매핑된 피쳐 기여도에 근거한 자연어 설명을 생성하며, 역할 분리를 통해 독립적 개선과 감사 로깅을 가능하게 한다.
- 2개의 운영 에이전트(OpsAgent, AuditAgent)가 모니터링 및 규제 준수 출력을 자연어로 해석하여 대시보드 피로를 해소하고, 전담 MLOps 인력 없이도 소규모 팀의 규제 준수 운영을 가능하게 한다 — 아키텍처를 5-에이전트 시스템(서빙 3 + 운영 2)으로 확장한다.
- 규제 준수가 설계 단계부터 내장된다 — 한국 금감원 가이드라인, EU AI Act, 한국 AI 기본법이 시스템 아키텍처 구성요소에 명시적으로 매핑되며, 자동화된 모니터링(드리프트, 공정성, 쏠림)과 핵심 의사결정 지점에서의 Human-in-the-Loop 감독을 갖춘다.

근본적인 통찰은 금융 AI에서 피쳐가 이중 역할을 수행한다는 것이다: 피쳐는 예측에 기여할 뿐만 아니라 궁극적으로 고객을 설득하고, 관계 관리자에게 힘을 부여하며, 규제기관을 만족시키는 설명 어휘에도 기여한다. 이는 전통적인 피쳐 엔지니어링 계산법을 재구성한다: AUC 기여가 미미하지만 비즈니스 해석 가능성이 풍부한 피쳐가 높은 AUC를 가지지만 의미 있는 설명을 생성하지 못하는 피쳐보다 더 가치 있을 수 있다.

본 시스템은 서버리스 인프라(AWS Lambda)에서의 배포를 위해 설계되어, 전용 GPU 서버 없이 120ms 원 지연시간(L1 예측 + 13 태스크)을 달성하며 — L2a 온디맨드 Bedrock 리라이트는 첫 호출 시 2.4s, 이후 캐시 적중 시 6ms, 콜드 스타트는 약 6s(S3 모델 다운로드)로, 제한된 ML 엔지니어링 리소스를 가진 금융기관의 운영 현실에 부합한다.

저자 기여

정선규 (PM/데이터 사이언티스트): 증류 전략, 추천사유 생성 파이프라인, 규제 준수 아키텍처 설계. 금융위험관리 도메인 전문성 기반 전체 시스템 설계 주도. 심은철, 김영찬: 증류 파

논문의 개념	구현 모듈
피쳐 해석 레지스트리	core/recommendation/reason/interpretation_registry.py
역매핑 레이어	core/recommendation/reason/reverse_mapper.py
팩트 추출 레이어	core/recommendation/reason/fact_extractor.py
3-에이전트 서빙 파이프라인	core/recommendation/reason/async_orchestrator.py
자체 검증 / Safety Gate	core/recommendation/reason/self_checker.py
템플릿 엔진	core/recommendation/reason/template_engine.py
운영 에이전트	core/agent/ops/
감사 에이전트	core/agent/audit/
합의 메커니즘	core/agent/consensus.py
진단 케이스 지식베이스	core/agent/case_store.py
시간적 팩트 스토어	core/agent/temporal_fact_store.py
대화 회상 메모리	core/agent/dialog_recall.py
도구 레지스트리	core/agent/tool_registry.py
설정 파일	configs/financial/*.yaml

Table 16: 논문 개념과 구현 모듈 매핑.

이프라인, 서빙 인프라, 모니터링 구성요소를 개발 서포터즈로서 구현.

연구비

본 연구는 외부 연구비, 보조금, 기관 인프라 지원을 일절 받지 않았다. AI 도구, 하드웨어, 모바일 통신비, AWS SageMaker 클라우드 학습(Spot 인스턴스), S3 스토리지, 운영 경비 등 모든 비용은 전적으로 제1저자의 개인 자금으로 충당하였으며, 자원이 극히 제한된 환경에서 데스크톱 GPU 1대로 개발을 수행하였다.

감사의 말

항상 업계 상황과 마케팅 관점에서 좋은 아이디어를 제공해주신 김연진에게 감사를 표한다.

불철주야 휴일도 저녁도 없이 개발에 헌신해주신 두 명의 엔지니어 심은철, 김영찬에게 깊은 감사를 표한다. 정식 고용이나 보상 없이도 프로젝트에 전력을 다해주신 이들의 헌신이 이 시스템의 완성을 가능하게 했다.

마지막으로, 이 연구를 가능하게 해준 AI 도구들에 감사를 표한다. 아이디어이션과 설계 브레인스토밍의 Gemini, 아키텍처 구축, 구현, 집필의 Claude Opus와 Sonnet, 그리고 원활한 개발 환경의 Cursor. 한 개인의 상상이 공상으로 끝날 수

있었던 것을, 소수의 인원과 이 도구들의 협업이 현실로 만들어주었다.

부록 A. 구현 참조

본 논문에서 기술한 개념들은 공개 코드 저장소에서 구체적인 Python 구현을 찾을 수 있다.² 주요 개념과 구현 모듈의 매핑은 다음과 같다:

상세한 구현 세부사항, 단위 테스트, 설정 파일은 공개 저장소에서 확인할 수 있다.

²https://github.com/bluethestyle/aws_ple_for_financial

DNA 그룹	태스크	룰	이론적 근거	트리거	활용 피처
Engagement	churn_signal	RFM 30/60/90일 감소 추세	관계 마케팅 (Berry '83)	R/F/M 동반 하락	HMM lifecycle, TDA persistence, Mamba temporal
Engagement	top_mcc_shift	MCC 엔트로피 변동 > 임계값	McKinsey CDJ 트리거	라이프스타일 변화 감지	TDA local, merchant_hierarchy, Mamba temporal
Lifecycle	nba_primary	상품 인접 행렬 +1단계	Kotler 5A 여정	상품 래더 갭	GMM cluster, LightGCN, economics PIH
Lifecycle	segment_prediction	잔액 x 빈도 x 상품수 3축	CLV 등급 모델 (파레토)	세그먼트 재분류	GMM cluster ID, HMM behavior, TDA global
Lifecycle	will_acquire_deposits	여유자금 비율 > 30% + 정기 예금 미보유	생애주기 저축 단계	유휴자금 감지	economics PIH, HMM journey, GMM cluster
Lifecycle	will_acquire_investments	적합성 등급 >= 상품 위험등급	적합성 원칙 (금소법 §17)	위험 매칭 기회	causal NOTEARS, HGCN hyperbolic, economics
Lifecycle	will_acquire_accounts	급여 입금 + 비주거래	SOW 확장 (PwC)	주거래 전환 가능	LightGCN, Mamba temporal, txn_behavior
Lifecycle	will_acquire_lending	신용 1-4등급 + DTI < 40%	신용 스코어링 + 적합성	대환 기회	causal NOTEARS, economics PIH, HMM lifecycle
Lifecycle	will_acquire_payments	주거래 MCC + 카드 1장	습관적 구매 (Kotler)	소비-카드 불일치	merchant_hierarchy, TDA local, Mamba temporal
Value	product_stability	30/60/90일 휴면 조기경고	고객 인게이지먼트 (Gallup)	활동 감소	Mamba temporal, HMM behavior, TDA persistence
Value	cross_sell_count	CLV 등급 목표 - 현재 보유수	지갑 점유율 (PwC)	상품 갭 > 0	LightGCN, GMM cluster, HGCN
Consumption	next_mcc	MCC 빈도 Top-K + 계절성	습관적 구매 행동	패턴 연속	Mamba temporal, merchant_hierarchy, TDA local
Consumption	mcc_diversity_trend	PIH 일시소득 시그널	Friedman 향상소득가설 (1957)	소득 충격 감지	economics PIH, TDA global, GMM

Table 17: 태스크별 3계층 룰 기반 폴백 규칙 (금융 DNA 그룹별). 모든 룰은 적합성 원칙(금소법 제17조) 하한선 적용.

10 부록

10.1 부록 A: 태스크별 3계층 룰 기반 폴백

교사 증류(1계층)와 직접 LGBM 학습(2계층)이 모두 불가능할 때 활성화되는 태스크별 룰이다. 각 룰은 검증된 마케팅 이론 또는 금융 도메인 실무에 근거하며, 금융 DNA 태스크 그룹별로 구조화하였다.

13개 룰 모두 공통 규제 하한선을 준수한다: 고객의 위험 감수 등급이 추천 상품의 위험 등급 이상이어야 한다(금융소비자보호법 제17조). 상세 룰 명세, 임계값, 추천 사유 템플릿은 설계 문서(docs/design/12_rule_based_fallback.md)에서 관리한다.

3계층 룰은 Phase 0에서 사전 계산된 피처(TDA, HGCN, Mamba, GMM 클러스터링, 인과 탐색, 경제학 등 11개 학문 분야)를 활용한다. 이러한 엔지니어링 피처를 통해 단순 RFM 휴리스틱보다 훨씬 정교한 룰 기반 추천이 가능하며, 추가 추론 비용은 없다.

Bibliography

- [1] Board of Governors of the Federal Reserve System. 2011. Supervisory Guidance on Model Risk Management. Retrieved from <https://www.federalreserve.gov/supervisionreg/srletters/sr1107.htm>

- [2] European Banking Authority. 2025. Report on Machine Learning in Internal Models.
- [3] European Parliament and Council. 2024. Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (AI Act).
- [4] Peter S. Fader, Bruce G.S. Hardie, and Ka Lok Lee. 2005. RFM and CLV: Using Iso-Value Curves for Customer Base Analysis. *Journal of Marketing Research* 42, 4 (2005), 415–430.
- [5] Jiawei Feng, Yang Yu, and Zhi-Hua Zhou. 2020. Soft Gradient Boosting Machine. In arXiv preprint arXiv:2006.04059, 2020.
- [6] Financial Services Commission (Korea). 2024. Financial Sector AI Guidelines.
- [7] Milton Friedman. 1957. *A Theory of the Consumption Function*. Princeton University Press.
- [8] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. 2015. Distilling the Knowledge in a Neural Network. In *NIPS Deep Learning and Representation Learning Workshop*, 2015.
- [9] Kalervo Järvelin and Jaana Kekäläinen. 2002. Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems* 20, 4 (2002), 422–446.
- [10] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. 2017. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [11] Alex Kendall, Yarin Gal, and Roberto Cipolla. 2018. Multi-Task Learning Using Uncertainty to Weigh Losses for Scene Geometry and Semantics. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.
- [12] Scott M Lundberg and Su-In Lee. 2017. A Unified Approach to Interpreting Model Predictions. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [13] National Assembly of Korea. 2024. Act on the Development of Artificial Intelligence and Establishment of Trust (AI Basic Act).
- [14] Judea Pearl. 2009. *Causality: Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press.
- [15] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. 2016. Why Should I Trust You?: Explaining the Predictions of Any Classifier. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016.
- [16] Amr Salih and others. 2023. Examining the Limitations of Post-hoc Explainability Methods in Finance. *Frontiers in Artificial Intelligence* (2023).